



UNIVERSIDAD ESAN
FACULTAD DE INGENIERÍA
INGENIERÍA DE TECNOLOGÍAS DE INFORMACIÓN Y SISTEMAS

**Predicción de Demanda mediante Modelos de Series Temporales y Machine Learning
para la Optimización del Reabastecimiento en la Empresa Donna S.A.C**

Trabajo de suficiencia profesional presentado en satisfacción parcial de los requerimientos
para obtener el título profesional de ingeniero de tecnologías de información y sistemas

Zacarías Kevin Paucar Tello
Jerson Walter Toledo Flores
Jean Pierre Castro Acuña
Asesor: Marks Calderón

Lima, 25 de mayo de 2026

Resumen

La presente investigación tuvo como objetivo implementar modelos de series temporales y Machine Learning para mejorar la toma de decisiones en el proceso de reabastecimiento de proveedores de la empresa Donna S.A.C. La problemática abordada se relaciona con la dificultad de estimar adecuadamente la demanda de productos, especialmente en contextos donde la variabilidad de las ventas, la estacionalidad y la corta vida útil de ciertos productos pueden generar sobrestock, quiebres de inventario, pérdidas económicas y decisiones de compra basadas principalmente en la experiencia del administrador.

La investigación se desarrolló bajo un enfoque aplicado y cuantitativo, utilizando datos históricos de ventas de la empresa como principal fuente de información. El proceso metodológico comprendió la adquisición y comprensión de los datos, el preprocesamiento de la información, la selección de variables relevantes, la construcción de variables temporales, el entrenamiento de modelos predictivos, la evaluación comparativa y el despliegue de la solución. Durante el preprocesamiento se realizaron actividades de limpieza, tratamiento de valores atípicos, agrupación de ventas por fecha, selección de columnas relevantes y generación de variables como día de la semana, mes, rezagos de ventas y medias móviles.

Para evaluar el desempeño de los modelos se utilizaron métricas como MAE, MSE, RMSE, MAPE y el coeficiente de determinación R^2 , con el propósito de comparar las predicciones generadas frente a los valores reales. Los resultados obtenidos permitieron identificar los modelos que presentaron el mejor desempeño general para cada categoría, al registrar menores niveles de error y un mejor ajuste respecto a los demás modelos evaluados. Asimismo, se desarrolló una solución de apoyo mediante un sistema que permite visualizar predicciones, comparar ventas reales y pronosticadas, y facilitar la planificación del reabastecimiento.

Finalmente, se concluye que la implementación de modelos predictivos contribuye a transformar los datos históricos de ventas en información útil para la toma de decisiones operativas. La solución propuesta permite reducir la incertidumbre en la compra de productos, optimizar el presupuesto de abastecimiento y disminuir riesgos asociados al exceso o falta de inventario, fortaleciendo así la eficiencia del proceso de pedido a proveedores en Donna S.A.C.

Palabras claves: Predicción, Ventas, Machine Learning, Regresión

Abstract

This research aimed to implement time series and Machine Learning models to improve decision-making in the supplier replenishment process of Donna S.A.C. The problem addressed is related to the difficulty of adequately estimating product demand, especially in contexts where sales variability, seasonality, and the short shelf life of certain products may lead to overstock, stockouts, economic losses, and purchasing decisions based mainly on the administrator's experience.

The research was developed under an applied and quantitative approach, using the company's historical sales data as the main source of information. The methodological process included data acquisition and understanding, information preprocessing, selection of relevant variables, construction of temporal features, training of predictive models, comparative evaluation, and deployment of the solution. During preprocessing, activities such as data cleaning, outlier treatment, sales aggregation by date, selection of relevant columns, and generation of variables such as day of the week, month, sales lags, and moving averages were carried out.

To evaluate model performance, metrics such as MAE, MSE, RMSE, MAPE, and the coefficient of determination R^2 were used, with the purpose of comparing the generated predictions against the actual values. The results obtained made it possible to identify the models that presented the best overall performance for each category, as they recorded lower error levels and a better fit compared to the other evaluated models. Likewise, a support solution was developed through a system that allows users to visualize predictions, compare actual and forecasted sales, and facilitate replenishment planning.

Finally, it is concluded that the implementation of predictive models contributes to transforming historical sales data into useful information for operational decision-making. The proposed solution helps reduce uncertainty in product purchasing, optimize the supply budget, and reduce risks associated with excess or insufficient inventory, thereby strengthening the efficiency of the supplier ordering process at Donna S.A.C.

Keywords: Forecasting, Sales, Machine Learning, Regression

Para mi familia y amigos

Índice general

Índice de Figuras	10
Índice de Tablas	13
1. PLANTEAMIENTO DEL PROBLEMA	15
1.1. Descripción de la Realidad Problemática	15
1.2. Formulación del Problema	17
1.2.1. Problema General	17
1.2.2. Problemas Específicos	17
1.3. Objetivos de la Investigación	18
1.3.1. Objetivo General	18
1.3.2. Objetivos Específicos	18
1.4. Justificación de la Investigación	18
1.4.1. Teórica	18
1.4.2. Práctica	19
1.4.3. Metodológica	19
1.5. Delimitación del Estudio	20
1.5.1. Espacial	20
1.5.2. Temporal	20
1.5.3. Conceptual	20

1.6. Hipótesis	21
1.6.1. Hipótesis General	21
1.6.2. Hipótesis Específicas	21
1.6.3. Matriz de Consistencia	21
2. MARCO TEÓRICO	22
2.1. Antecedentes de la investigación	22
2.1.1. Tesis relacionadas	22
2.1.2. Sales forecasting using long short term memory networks	22
2.1.3. Food Sales Prediction Strategy Using Machine Learning and Deep Learning Algorithms (Merdas & Hameed Mousa, 2023)	25
2.1.4. Modelo predictivo de ventas usando aprendizaje automático (Machine Learning) para pronosticar las ventas diarias de una empresa	31
2.1.5. Effects of data time lag in a decision-making system using machine learning for pork price prediction (Suaza-Medina et al., 2023)	34
2.1.6. Time-series analysis with smoothed Convolutional Neural Network	37
2.1.7. Construction of performance score dynamic prediction system for clinical departments using explainable machine learning (Wen et al., 2026)	40
2.1.8. Time Series Forecasting and Modelling of Food Demand Supply Chain based on Regressors Analysis	44
2.1.9. Advancing Retail Predictions: Integrating Diverse Machine Learning Models for Accurate Walmart Sales Forecasting (Wen et al., 2026)	47
2.1.10. Deep learning-enabled cherry price forecasting and real-time system deployment across multi-market supply chains in India (Shaheen et al., 2026)	50
2.1.11. Automated water demand forecasting for national-scale deployment: a prophet-based framework for Palestinian municipal water management (Salman & Shaka'a, 2026a)	53

2.1.12. Lightweight machine learning framework using temporal features for electric vehicle demand response forecasting on edge devices (Durrani et al., 2026b)	57
2.2. Bases Teóricas	61
2.2.1. Gestión de la cadena de suministro de productos perecibles	61
2.2.2. Machine Learning	62
2.2.3. Modelos predictivos de demanda	67
2.2.4. Series de tiempo	68
2.2.5. Tipos de series temporales	68
2.2.6. Elementos de la serie de tiempo	69
2.2.7. Aplicación de las series de tiempo	70
2.2.8. Computación en la nube	80
2.2.9. Streamlit	80
2.2.10. Gestión de inventarios	80
2.3. Marco Conceptual	82
2.3.1. Predicción de demanda	82
2.3.2. Demanda en empresas retail	83
2.3.3. Series temporales	83
2.3.4. Tendencia	84
2.3.5. Variación aleatoria o ruido	84
2.3.6. Machine Learning	84
2.3.7. Aprendizaje supervisado	85
2.3.8. Modelos de regresión	85
2.3.9. Modelos de series temporales	85
2.3.10. Algoritmos predictivos	86
2.3.11. Datos históricos	86

2.3.12. Preprocesamiento de datos	87
2.3.13. Entrenamiento del modelo	87
2.3.14. Validación del modelo	87
2.3.15. Métricas de evaluación	88
2.3.16. Precisión del modelo	88
2.3.17. Reabastecimiento	88
2.3.18. Inventario	89
2.3.19. Sobrestock	89
2.3.20. Optimización del reabastecimiento	89
3. ENTORNO EMPRESARIAL	91
3.1. Descripción de la empresa	91
3.1.1. Reseña histórica y actividad económica	91
3.1.2. Descripción de la organización	92
3.1.3. Datos generales estratégicos de la empresa	92
3.1.4. Modelo de negocio actual (CANVAS)	101
4. METODOLOGÍA DE LA INVESTIGACIÓN	102
4.1. Diseño de la investigación	102
4.1.1. Enfoque	102
4.1.2. Alcance	102
4.1.3. Tipo	103
4.1.4. Población y muestra	103
4.1.5. Unidad de análisis	103
4.2. Técnicas de recolección de datos	104
4.2.1. Selección de la Categoría de Estudio	104
4.2.2. Extracción de Datos desde SQL Server	104

4.2.3.	Construcción del Dataset Histórico	105
4.2.4.	Integración de Datos del Sistema POS	107
4.2.5.	Validación y Control de Calidad de los Datos	107
4.2.6.	Importancia de la Recolección de Datos en la Investigación	107
4.3.	Técnicas para el procesamiento y análisis de la información	108
4.3.1.	Metodología de la implementación de la solución	108
4.3.2.	Comprensión de los datos	110
4.3.3.	Pre-Procesamiento	112
4.3.4.	Modelamiento	113
4.3.5.	Evaluación	116
4.3.6.	Despliegue	118
4.4.	Metodología para la medición de resultados de la implementación	120
4.4.1.	Error Absoluto Medio	122
4.4.2.	Error Cuadrático Medio	122
4.4.3.	Raíz del Error Cuadrático Medio	123
4.4.4.	Error Porcentual Absoluto Medio	123
4.4.5.	Coeficiente de determinación	123
4.5.	Cronograma de actividades y presupuesto	125
5.	DESARROLLO DEL EXPERIMENTO	127
5.1.	Determinación y evaluación de alternativas de solución	127
5.2.	Propuesta solución	129
5.3.	Planeamiento y descripción de actividades	131
5.3.1.	Adquirir Base de Datos	131
5.3.2.	Preprocesamiento de datos	132
5.3.3.	Selección de algoritmos a utilizar	133

5.3.4. Definir parámetros	134
5.4. Desarrollo de actividades. Aplicación de herramientas de solución	135
5.4.1. Adquisición de datos	135
5.4.2. Partición de datos	136
5.4.3. Preprocesamiento de datos	136
5.4.4. Selección de Columnas relevantes	138
5.4.5. Seleccionamos los modelos a utilizar	139
5.4.6. Evaluación de los modelos	142
5.4.7. Simulación de la predicción	144
5.4.8. Despliegue de la solución	146
6. ANÁLISIS DE RESULTADOS	151
6.1. Resultados	151
6.2. Experiencia del usuario y uso operativo del sistema	153
7. CONCLUSIONES	155
Anexos	157
BIBLIOGRAFÍA	170

Índice de Figuras

2.1. Base de datos de los autores	26
2.2. Metodología empleada por los autores	28
2.3. Resultados obtenidos en el antecedente	30
2.4. Metodología antecedente	39
2.5. Resultado antecedente	40
2.6. Resultado antecedente	40
2.7. Árbol de decisión	63
2.8. Arquitectura LSTM	65
2.9. Series de tiempo	69
2.10. Componentes de la serie temporal	71
2.11. Aplicaciones de serie temporal	72
3.1. Organigrama Donna SAC	93
3.2. Matriz interna y externa	100
3.3. Business Model Canvas	101
4.1. Consulta SQL	105
4.2. Tablas de ventas	106
4.3. Metodología de implementación de la solución	109
4.4. Tablas de ventas	111
4.5. Análisis exploratorio de variables	112

4.6. Cronograma de actividades	125
5.1. Familia de productos	128
5.2. Predicción Vs. valores actuales	131
5.3. Datos históricos de ventas	132
5.4. Datos históricos de ventas con 3 columnas agregadas	132
5.5. Ventas de la familia verduras	133
5.6. Parametros de los modelos elegidos	134
5.7. Carga y lectura del dataset	135
5.8. preprocesamiento de la data	137
5.9. Gráfico de Outliers	137
5.10. Visualización preliminar del dataset procesado	138
5.11. Análisis de ventas por familia de productos	139
5.12. Evolución histórica de ventas por año	140
5.13. Ingeniería de características y construcción de variables temporales	141
5.14. Preparación de datos para el entrenamiento	142
5.15. Evaluación comparativa de modelos predictivos	143
5.16. Comparación entre ventas reales y predicciones	144
5.17. Proyección de ventas a 30 días	145
5.18. Tabla detallada del pronóstico	145
5.19. Base de datos en Supabase	147
5.20. Control de acceso y base de datos en Supabase	148
5.21. Dashboard de análisis	148
5.22. Log in de Dashboard	149
5.23. Key de API 12222para conexión entre Supabase y Python	149
6.1. Gráfico de ventas reales vs predicción	152

6.2. Gráfico de ventas reales vs predicción	153
1. Arquitectura de Software	160

Índice de Tablas

2.1. Tipos de suavizado de datos (data smoothing)	37
2.2. Resultados antecedente	47
2.3. Resultados de modelos predictivos	50
3.1. Oportunidades de Donna Sac	96
3.2. Amenazas de Donna Sac	97
3.3. Fortalezas de Donna Sac	98
3.4. Debilidades de Donna Sac	99
4.1. Instrumentos de medida para recolección de datos	109
4.2. Actividades de fase modelamiento	114
4.3. Actividades de fase evaluación	117
4.4. Actividades de fase Despliegue	119
4.5. Presupuesto	126
1. Matriz de consistencia	159
2. Fuente: Elaboración propia	161
3. Fuente: Elaboración propia	162
4. Fuente: Elaboración propia	163
5. Fuente: Elaboración propia	164
6. Fuente: Elaboración propia	165

7.	Fuente: Elaboración propia	166
8.	Fuente: Elaboración propia	167
9.	Fuente: Elaboración propia	167
10.	Fuente: Elaboración propia	168

Capítulo 1

PLANTEAMIENTO DEL PROBLEMA

1.1. Descripción de la Realidad Problemática

A nivel mundial, la predicción de la demanda de productos enfrenta desafíos significativos debido a la interacción de múltiples factores, entre ellos la variabilidad en los patrones de consumo, la influencia de variables externas, la disponibilidad limitada de datos completos y precisos, la corta vida útil de los productos y los costos derivados de errores en el abastecimiento. En este contexto, una estimación inexacta de la demanda puede traducirse en sobrestock, quiebre de inventario, deterioro de productos y pérdidas económicas, afectando directamente la rentabilidad y la eficiencia operativa de la cadena de suministro. Por ello, mejorar la precisión del pronóstico en productos se ha convertido en una necesidad estratégica para las empresas del sector retail, especialmente en aquellas que operan con productos frescos y de alta rotación («New Research Presents Policy Opportunities for China to Reduce Food Loss and Waste — The Global FoodBanking Network», 2023; Food and Agriculture Organization of the United Nations, 2011; El Madini, 2024).

Diversos estudios han evidenciado que, en el caso de productos, la demanda no depende únicamente del comportamiento histórico de ventas, sino también de factores como las condiciones climáticas, la estacionalidad, las promociones, los días festivos y las variaciones en los hábitos de consumo. Esta complejidad limita la utilidad de enfoques estáticos o tradicionales cuando se busca anticipar con precisión el comportamiento del mercado. En consecuencia, la incorporación de técnicas más sofisticadas de análisis de datos y modelos predictivos se vuelve fundamental para reducir el desperdicio, optimizar la reposición y sostener mejores niveles de servicio al cliente («New Research Presents Policy Opportunities for China to Reduce Food Loss and Waste — The Global FoodBanking Network», 2023; El Madini, 2024).

En este contexto, la aplicación de análisis de datos y modelos de pronóstico se presenta como una solución estratégica para fortalecer la planificación del abastecimiento. Bajo esta premisa, la utilización de pronósticos en productos permite planificar de mejor forma el proceso de abastecimiento a través de métodos cuantitativos, identificando patrones de comportamiento y estacionalidad en las series de tiempo. Sin embargo, otro desafío importante radica en la capacidad de las empresas para aprovechar al máximo los datos disponibles. Muchas empresas peruanas, especialmente las pequeñas y medianas, aún presentan limitaciones en infraestructura, capacidades digitales y experiencia analítica para implementar eficazmente soluciones de análisis de información. Aunque el país ha mostrado avances en materia de transformación digital, los esfuerzos para consolidar una adopción más amplia y efectiva de estas herramientas siguen siendo insuficientes (Heredia, 2020; Dini et al., 2021).

La decisión de incorporar Machine Learning se fundamenta en la necesidad de abordar problemas específicos en el manejo del stock y en la toma de decisiones empresariales. Como se ha señalado, los modelos de pronóstico constituyen procedimientos matemáticos orientados a anticipar eventos futuros a partir del análisis de patrones (Mintarya et al., 2023). En ese sentido, su aplicación permite mejorar la precisión de la proyección de ventas futuras, aspecto crítico para la estrategia empresarial y la gestión operativa. Además, la comparación de algoritmos como Random Forest, regresión lineal, ARIMA y redes neuronales ofrece la posibilidad de identificar qué enfoque resulta más adecuado en términos de precisión y aplicabilidad dentro de un contexto minorista caracterizado por productos, demanda variable y necesidad de respuesta rápida ante cambios del mercado.

En Perú, las empresas que han incrementado sus operaciones también han visto crecer el volumen de información que generan, lo cual exige una mayor capacidad para procesar, interpretar y convertir esos datos en decisiones oportunas. En el caso de Donna S.A.C., esta situación adquiere una importancia especial, ya que la empresa enfrenta dificultades en la gestión del stock y en la toma de decisiones vinculadas al pedido a proveedores. La falta de establecimiento de cantidades óptimas para satisfacer la demanda, así como la limitada identificación de productos más rentables, evidencian debilidades en la planificación y en el uso estratégico de la información disponible («Perú Panorama general», 2024).

Esta problemática resulta aún más crítica al tratarse de productos, donde un error de estimación no solo impacta el inventario, sino también la calidad del producto, la disponibilidad para el cliente y el nivel de merma. En el presente estudio, la categoría de verduras adquiere especial relevancia, ya que representa en promedio el 33 % de la demanda diaria en Market Donna S.A.C. y, debido a su corta vida útil, requiere decisiones de reposición más precisas y oportunas. El análisis de esta categoría permite observar con mayor claridad las variaciones diarias en la demanda, así como los efectos de factores como estacionalidad, días de la semana,

promociones y otros eventos externos, los cuales pueden influir en la precisión del modelo predictivo (El Madini, 2024).

A pesar de la importancia que tiene la predicción de la demanda en este entorno dinámico, aún se observa una marcada necesidad de fortalecer la implementación de modelos predictivos y técnicas de minería de datos en empresas de este tipo. En Donna S.A.C., la toma de decisiones basada en criterios subjetivos limita la capacidad de anticipar patrones de consumo y reduce la eficiencia del proceso de abastecimiento. Por ello, se evidencia la necesidad de implementar un modelo predictivo de la demanda de productos que permita mejorar la gestión de inventario y optimizar la toma de decisiones en el proceso de pedido a proveedores. De esta manera, no solo se busca incrementar la precisión del pronóstico, sino también contribuir a una planificación más eficiente, a la reducción de pérdidas y al fortalecimiento de la rentabilidad y competitividad de la empresa.

1.2. Formulación del Problema

1.2.1. Problema General

¿Como la implementación de modelos de series temporales y Machine Learning beneficiará la toma de decisiones en el proceso del pedido a los proveedores en la empresa Donna SAC?

1.2.2. Problemas Específicos

- ¿Cómo influye la consistencia de la base de datos histórica en la precisión de los modelos predictivos de demanda de productos?
- ¿Qué técnicas de preprocesamiento de datos permiten mejorar el rendimiento de los modelos de predicción de demanda en productos?
- ¿Qué variables influyen significativamente en el comportamiento de la demanda de productos en la empresa Donna S.A.C.?
- ¿Qué modelo de forecasting presenta mejores resultados en términos de precisión y aplicabilidad para optimizar la toma de decisiones en el pedido a proveedores?

1.3. Objetivos de la Investigación

1.3.1. Objetivo General

Implementar modelos de series temporales y Machine Learning que beneficien la toma de decisiones en el proceso del pedido a los proveedores en la empresa Donna SAC.

1.3.2. Objetivos Específicos

- Determinar cómo la consistencia de la base de datos histórica influye en la precisión de los modelos predictivos de demanda de productos.
- Identificar las técnicas de preprocesamiento de datos más efectivas para mejorar el rendimiento de los modelos de predicción de demanda en productos.
- Analizar las variables que influyen significativamente en el comportamiento de la demanda de productos en la empresa Donna S.A.C.
- Evaluar qué modelo de forecasting presenta mejores resultados en términos de precisión y aplicabilidad para optimizar la toma de decisiones en el pedido a proveedores.

1.4. Justificación de la Investigación

1.4.1. Teórica

Se justifica teóricamente primeramente porque las técnicas de aprendizaje automático pueden analizar conjuntos de datos más grandes con mayor eficiencia y precisión que los métodos convencionales, lo que posibilita proporcionar un entendimiento aún más profundo de los patrones y tendencias. Este estudio tiene como propósito contribuir al análisis predictivo mediante la implementación de técnicas avanzadas de forecasting aplicadas a series de tiempo. El resultado satisfactorio de este enfoque está destinado a ser utilizado en la gestión precisa de la demanda de productos en el sector minorista, contribuyendo así a la optimización de procesos y la toma de decisiones estratégicas. En conjunto, se busca la eficacia global de la gestión de inventario en el ámbito de la minería de datos.

1.4.2. Práctica

Esta investigación surge en respuesta a la imperante necesidad de optimizar el aprovechamiento de la valiosa base de datos de nuestra empresa. Nos proponemos no solo hacer uso de los datos históricos disponibles, sino también desarrollar e implementar un modelo predictivo eficiente. El propósito primordial es transformar estos pronósticos en herramientas esenciales para respaldar decisiones estratégicas informadas en la gestión de abastecimiento para nuestras tiendas minoristas. Resaltando esta justificación práctica, buscamos mejorar el desempeño y la eficacia de las operaciones mediante una gestión avanzada de la demanda, lo que a su vez impactará positivamente en la satisfacción del cliente, la optimización de inventarios y la rentabilidad general de la empresa.

1.4.3. Metodológica

. El principal problema que ayudará a resolver esta investigación es optimizar la precisión de la predicción de la demanda en las tiendas minoristas. Para ello, se implementará la técnica de forecasting aplicada a las series temporales, buscando obtener la mayor precisión posible en las predicciones de demanda. Este enfoque permitirá una gestión más eficaz del inventario y respaldará decisiones estratégicas basadas en datos predictivos más precisos y actualizados.

La metodología incluirá:

- Recopilación de datos históricos de ventas de productos.
- Identificación y recopilación de variables externas relevantes que puedan influir en la demanda (por ejemplo, eventos especiales, condiciones climáticas, tendencias de mercado).
- Selección y aplicación de técnicas de modelado predictivo, como regresión lineal, series temporales, o técnicas más avanzadas como modelos de redes neuronales o machine learning.
- Validación y Comparación de las predicciones con los datos reales de ventas.
- Implementación del modelo en un entorno empresarial y evaluación de su impacto en la rentabilidad.

1.5. Delimitación del Estudio

1.5.1. Espacial

La presente investigación se desarrolla en la empresa Market Donna S.A.C., ubicada en el distrito de Breña, provincia y departamento de Lima, cuya actividad principal es la comercialización de productos de supermercado. Dentro de este contexto empresarial, el estudio se delimita específicamente al análisis de la información de ventas correspondiente a la categoría de productos, con énfasis en la familia de productos, por ser una de las categorías de mayor relevancia operativa y comercial dentro de la empresa. Esta delimitación espacial permite contextualizar la propuesta en un entorno real de retail y enfocar el análisis en un segmento representativo del comportamiento de la demanda.

1.5.2. Temporal

La investigación se delimita temporalmente al análisis de los datos históricos de ventas registrados por la empresa Market Donna S.A.C. durante el período comprendido entre los años 2012 y 2026. Este horizonte temporal permite examinar el comportamiento de la demanda en distintos momentos del tiempo, identificar patrones, variaciones y tendencias, y disponer de una base de datos suficiente para el entrenamiento, validación y comparación de modelos predictivos. Asimismo, el estudio considera información transaccional y de demanda con una frecuencia de análisis principalmente diaria, en concordancia con la naturaleza operativa de los productos y con el objetivo de mejorar la toma de decisiones en el pedido a proveedores.

1.5.3. Conceptual

La presente, realizada en la empresa Donna S.A.C., se enfoca en la implementación de un modelo de Series de tiempo basado en algoritmos de aprendizaje automático. Este enfoque nos ayudará a realizar predicciones en la empresa, y la implementación se llevará a cabo utilizando herramientas básicas de producción. Se establecerán relaciones entre las diversas áreas presentes dentro de la empresa. Se evaluarán los beneficios que atraerá dicha implementación y se buscarán maneras de continuar mejorando el proceso.

1.6. Hipótesis

1.6.1. Hipótesis General

La implementación de modelos de series temporales y Machine Learning beneficiara en la toma de decisiones en el proceso de pedido a los proveedores en la empresa Donna SAC.

1.6.2. Hipótesis Específicas

- La consistencia de la base de datos histórica influye significativamente en la precisión de los modelos predictivos de demanda de productos.
- Las técnicas de preprocesamiento de datos, como la normalización, tratamiento de valores atípicos y selección de características, mejoran el rendimiento de los modelos de predicción de demanda.
- Variables como estacionalidad, promociones, días festivos y volumen de ventas influyen significativamente en el comportamiento de la demanda de productos.
- Los modelos avanzados de forecasting presentan mejores resultados de precisión y aplicabilidad en comparación con otros métodos de aprendizaje automático para optimizar la toma de decisiones en el pedido a proveedores.

1.6.3. Matriz de Consistencia

A continuación se presenta la matriz de consistencia elaborada para la presente investigación (véase Anexo 1).

Capítulo 2

MARCO TEÓRICO

2.1. Antecedentes de la investigación

En esta sección se presentarán diversos artículos de investigación o tesis las cuales abordarán diversas técnicas y enfoques que se emplearon para afrontar problemas similares al de esta tesis.

2.1.1. Tesis relacionadas

2.1.2. Sales forecasting using long short term memory networks

2.1.2.1. Planteamiento del Problema y objetivo

La tesis se enfoca en predecir las ventas de la empresa Annapolis Cider Company en Wolfville, Nova Scotia, con el objetivo de optimizar la asignación de recursos humanos. Se busca desarrollar un modelo de pronóstico que pueda predecir las ventas diarias y por hora con un margen de error del 10%. Se plantea que la precisión del 90% en las predicciones permitiría a la empresa gestionar sus recursos humanos de manera más eficiente. Para abordar este desafío, se utilizan técnicas de aprendizaje automático, específicamente redes neuronales LSTM, que son conocidas por su eficacia en problemas de series temporales. Además de los datos históricos de ventas, el modelo también considera información como la fecha y hora, datos meteorológicos, indicadores de apertura/cierre y eventos especiales. Se comparan varios modelos de pronóstico, incluido un modelo de línea base de persistencia, un modelo Avg6Week y un modelo ARIMA, con el modelo LSTM para evaluar su rendimiento en la predicción de ventas minoristas. Se reconoce que las ventas de cidra pueden presentar más variabilidad en

comparación con las ventas de restaurantes debido a la naturaleza menos predecible de las ventas por hora. Además, se menciona que condiciones climáticas extremas, como tormentas y huracanes, pueden aumentar la dificultad de predecir con precisión las ventas

2.1.2.2. Base de datos de los autores

En la tesis se utilizan varios conjuntos de datos para el análisis y la predicción de ventas de la empresa Annapolis Cider Company. Estos conjuntos de datos incluyen: Datos de ventas históricas almacenados en el sistema POS de la empresa para un período de hasta cuatro años. Datos meteorológicos observados y pronosticados obtenidos del sitio web Dark Sky a través de un sitio web de recopilación de datos meteorológicos desarrollado llamado Weather Archive. Datos de eventos especiales extraídos de varios calendarios en línea de la web, como Annapolis Valley Events, Office Holidays y Acadia Athletic. Estos conjuntos de datos se utilizan para entrenar y evaluar los modelos de pronóstico, incluidos los modelos LSTM, ARIMA, persistencia y Avg6Week, con el objetivo de predecir las ventas diarias y por hora de la empresa

2.1.2.3. Metodología empleada por los autores

En la metodología siguen diversos pasos para el análisis y pronóstico.

- **Data Collection:** En la fase de Recopilación de Datos, se adquirieron datos de ventas históricas de la empresa Annapolis Cider Company almacenados en su sistema POS, datos meteorológicos observados y pronosticados de Dark Sky a través de Weather Archive, y datos de eventos especiales de fuentes en línea. Estos conjuntos de datos se utilizaron para el análisis y la predicción de ventas.
- **Data Cleaning:** El proceso de Limpieza de Datos involucró la detección y eliminación de valores irrelevantes, outliers, valores faltantes y duplicados en los conjuntos de datos de ventas y clima. Se realizó una conversión de tipos de datos y se calcularon las ventas por hora y por día a partir de los datos de transacciones originales.
- **Descriptive Statistical Analysis:** El Análisis Estadístico Descriptivo se centró en crear resúmenes y medidas de los datos de ventas antes de desarrollar los modelos predictivos. Se utilizaron gráficos para analizar las ventas en diferentes escalas de tiempo y se identificaron patrones estacionales y tendencias en los datos.
- **Data Preparation:** En la etapa de Preparación de Datos, se realizaron acciones como la estacionalización de datos, la selección de características relevantes, la creación de un

indicador de eventos especiales, la normalización de datos y la división de datos en conjuntos de entrenamiento, validación y prueba. Además, se prepararon los datos de entrada para los modelos de pronóstico.

A continuación, se presenta un resumen detallado de los métodos de modelado de predicción utilizados:

- **Persistence Model:** En el modelo de persistencia, la predicción de ventas para el próximo día (o próxima hora) es exactamente igual a las ventas del día (o hora) actual. Este enfoque es un modelo de referencia estándar para series temporales y solo puede hacer predicciones a corto plazo.
- **Avg6Week Model:** En este enfoque común, se calcula el promedio de las ventas en el mismo día de la semana durante las últimas 6 semanas para predecir las ventas del próximo día. Este modelo proporciona predicciones para cualquier día de la semana en la próxima semana.
- **ARIMA Model:** Se desarrolló un modelo ARIMA (Autoregressive Integrated Moving Average) que utiliza las ventas de los últimos 7 días para predecir las ventas del día siguiente. Este enfoque se basa en la identificación de patrones en los datos de series temporales.
- **LSTM Neural Networks:** Se implementó una red neuronal LSTM (Long Short-Term Memory) recurrente que utiliza datos de ventas, variables de fecha y hora, condiciones meteorológicas observadas, indicadores de apertura/cierre e indicadores de eventos especiales de los últimos 7 días, junto con el pronóstico del clima para el día siguiente. Este modelo se desplaza en el tiempo para hacer predicciones a dos días en el futuro.

2.1.2.4. Resultados obtenidos

- **Daily Sales Prediction Results:** El modelo LSTM para predicción diaria de ventas mostró el menor error absoluto medio (MAE) en el conjunto de prueba, con un valor de \$597.93 y un error porcentual absoluto medio (MAPE) del 19.7 %. Esto representó una reducción del 22.6 % en el error de prueba en comparación con el modelo de persistencia diaria.
- **Hourly Sales Prediction Results:** Para la predicción por hora de las ventas, el modelo LSTM logró el menor MAE en el conjunto de prueba, con un valor de \$51.59 y un MAPE del 40.8 %. Esto representó una disminución del 17.2 % en el error de prueba en comparación con el modelo de persistencia por hora.

- **Comparative Analysis:** Se observó que el modelo LSTM superó significativamente a los modelos de persistencia, Avg6Week y ARIMA en términos de precisión de predicción tanto para las ventas diarias como por hora. La capacidad de la red neuronal LSTM para capturar patrones complejos en los datos de series temporales y su capacidad para aprender de secuencias largas contribuyeron a su rendimiento superior.
- **Impact of LSTM Features:** La inclusión de variables como datos de ventas históricas, fecha y hora, condiciones meteorológicas observadas, indicadores de apertura/cierre y eventos especiales en el modelo LSTM demostró ser crucial para mejorar la precisión de las predicciones de ventas. Estos factores externos y temporales permitieron al modelo LSTM capturar mejor la variabilidad en los datos de ventas.

2.1.3. Food Sales Prediction Strategy Using Machine Learning and Deep Learning Algorithms (Merdas & Hameed Mousa, 2023)

2.1.3.1. Planteamiento del Problema y objetivo

El estudio desarrollado por diversos autores abordó el problema de la predicción de ventas de productos alimenticios mediante técnicas de *forecasting*, *Machine Learning* y *Deep Learning*. Los investigadores señalan que las empresas dedicadas a la comercialización de alimentos enfrentan dificultades para estimar con precisión la demanda futura, lo cual puede ocasionar pérdidas económicas debido al desperdicio de productos perecibles, exceso de inventario o escasez de productos para los consumidores.

El objetivo principal de la investigación fue desarrollar una estrategia de predicción de ventas que permitiera identificar los algoritmos con mayor precisión y eficiencia para el pronóstico de demanda alimentaria. Para ello, se analizaron distintos modelos predictivos basados en técnicas de inteligencia artificial, con el propósito de optimizar la gestión de inventarios y mejorar la toma de decisiones empresariales.

Asimismo, el estudio buscó determinar el impacto de la correlación entre variables dentro de diferentes conjuntos de datos, evaluando cómo dichas relaciones afectan el desempeño de los modelos predictivos. Como aplicación final, los autores realizaron predicciones futuras sobre cantidades de productos alimenticios utilizando información histórica de ventas.

2.1.3.2. Base de datos de los autores

La investigación utilizó cuatro conjuntos de datos relacionados con ventas de alimentos y productos comerciales. Los tres primeros *datasets* fueron empleados para comparar el desempeño de diversos algoritmos de predicción, mientras que el cuarto *dataset* fue utilizado para realizar pruebas reales de *forecasting* sobre producción y ventas futuras.

El primer conjunto de datos provenía de la plataforma Alibaba Tianchi y contenía información de ventas de alimentos correspondientes al año 2019. Este *dataset* estaba conformado por aproximadamente 1000 registros y 15 variables relacionadas con categorías de productos, cantidades y precios.

El segundo *dataset* fue obtenido desde Kaggle y contenía información de ventas de alimentos de diez tiendas ubicadas en diferentes zonas geográficas. Este conjunto contaba con aproximadamente 8523 registros y 12 atributos asociados a precios, tipos de productos y establecimientos.

El tercer conjunto de datos también provenía de Kaggle y estaba relacionado con ventas de diferentes categorías y subcategorías de alimentos en distintas ciudades, incluyendo alrededor de 9995 registros y 10 atributos.

Finalmente, el cuarto *dataset* correspondía a ventas de dátiles en Iraq entre los años 2002 y 2020, incluyendo variables como cantidades producidas, precios, tipos de productos y número de árboles de palma. Este conjunto de datos fue utilizado para validar el modelo propuesto y realizar predicciones futuras de producción y ventas.

	Invoice ID	Branch	City	Customer	Gender	Product line	Unit price	Quantity	Tax %	Date	Time	Cost	gross income	Rating	Total
1	765-26-69	A	Yangon	Normal	Male	Candy	72.61	6	21.783	1/1/2019	10:39	435.66	21.783	6.9	457.443
2	530-90-98	A	Yangon	Member	Male	Drinks	47.59	8	19.036	1/1/2019	14:47	380.72	19.036	5.7	399.756
3	891-01-70	B	Mandalay	Normal	Female	Fruites	74.71	6	22.413	1/1/2019	19:07	448.26	22.413	6.7	470.673
4	493-65-62	C	Naypyitaw	Member	Female	Candy	36.98	10	18.49	1/1/2019	19:48	369.8	18.49	7	388.29
5	556-97-71	C	Naypyitaw	Normal	Female	Fruites	63.22	2	6.322	1/1/2019	15:51	126.44	6.322	8.5	132.762
6	133-14-72	C	Naypyitaw	Normal	Male	Dairy products	62.87	2	6.287	1/1/2019	11:43	125.74	6.287	5	132.027
7	651-88-73	A	Yangon	Normal	Female	Biscuit	65.74	9	29.583	1/1/2019	13:55	591.66	29.583	7.7	621.243
8	182-52-70	A	Yangon	Member	Female	Candy	27.04	4	5.408	1/1/2019	20:26	108.16	5.408	6.9	113.568
9	416-17-99	A	Yangon	Member	Female	Fruites	74.22	10	37.11	1/1/2019	14:42	742.2	37.11	4.3	779.31

Figura 2.1: Base de datos de los autores

2.1.3.3. Metodología empleada por los autores




Figura 2.2: Metodología empleada por los autores

■ Modelos utilizados:

La metodología incluyó la aplicación y comparación de múltiples algoritmos de *Machine Learning* y *Deep Learning* orientados a tareas de regresión y *forecasting*. Entre los modelos utilizados se encuentran *Linear Regression*, *Decision Tree*, *Random Forest*, *K-Nearest Neighbors*, *Gradient Boosting Regression*, *Bayesian Ridge Regression*, *Support Vector Regression* y modelos de *Deep Learning* como *LSTM*.

■ Etapas del proceso:

El proceso metodológico comenzó con la carga de múltiples *datasets* relacionados con ventas de alimentos. Posteriormente, se realizó la visualización de datos mediante gráficos y diagramas para comprender el comportamiento de las variables. Luego se efectuó el preprocesamiento de datos, incluyendo limpieza, normalización y análisis de correlación entre variables mediante mapas de calor (*Heatmaps*). Finalmente, los *datasets* fueron ingresados a trece algoritmos distintos para comparar su rendimiento predictivo utilizando métricas de evaluación.

■ Herramientas y tecnologías utilizadas:

Los autores utilizaron el lenguaje de programación Python junto con librerías especializadas en ciencia de datos y *Machine Learning*. Entre las herramientas empleadas destacan *pandas* y *NumPy* para el procesamiento de datos, *Seaborn* y *Matplotlib* para visualización gráfica, y bibliotecas de aprendizaje automático para entrenamiento y evaluación de modelos predictivos.

■ Procedimientos implementados:

Los procedimientos incluyeron análisis exploratorio de datos, evaluación de correlación entre variables, entrenamiento independiente de cada modelo y comparación de resultados mediante métricas de error. Los autores realizaron diferentes pruebas sobre *datasets* con distintos niveles de correlación para determinar qué algoritmos ofrecían mejores resultados bajo determinadas condiciones de los datos.

■ Evaluación de resultados:

Para medir el desempeño de los modelos predictivos, se utilizaron métricas de evaluación como RMSE (*Root Mean Square Error*), MAE (*Mean Absolute Error*), MSE (*Mean Squared Error*) y otros indicadores de precisión. Estas métricas permitieron comparar objetivamente la eficiencia de cada algoritmo en tareas de *forecasting* y predicción de ventas.

2.1.3.4. Resultados obtenidos

Los resultados demostraron que los modelos basados en técnicas de *Machine Learning* y *Deep Learning* obtuvieron una alta precisión en la predicción de ventas y demanda alimentaria. Los autores concluyeron que algoritmos *ensemble* como *Random Forest* y *Gradient Boosting Regression* presentaron un desempeño superior frente a modelos tradicionales en diversos escenarios.

Asimismo, los modelos de *Deep Learning* como *LSTM* mostraron una gran capacidad para capturar patrones temporales complejos y realizar predicciones de largo plazo con mayor precisión.

Finalmente, el estudio concluyó que la combinación de técnicas de *forecasting*, *Machine Learning* y análisis de variables permite mejorar significativamente la predicción de demanda, optimizando la gestión de inventarios y reduciendo pérdidas económicas en empresas del sector alimentario. Este antecedente guarda relación con la presente investigación debido a que ambos trabajos buscan desarrollar modelos predictivos basados en datos históricos para estimar la demanda futura mediante técnicas de aprendizaje automático.

Algorithm	MSE	MAE	Accuracy (R^2)
Multilayer Perceptron	3.2698	1.3527	58.97
SVR	1.4116	0.8377	82.29
Multiple Linear Regression	1.3652	0.8384	82.87
Decision Tree	0.315	0.2750	96.05
Random Forest Regressor	0.1082	0.2085	98.64
K- Nearest Neighbor (KNN)	3.9532	1.544	50.40
Bagging Regressor	0.1318	0.2254	98.35
Gaussian Processes Regressor	39.33	5.6	-393.48
RANSAC	1.3466	0.8240	83.10
Gradient Boosting	0.1079	0.2354	98.65
Elastic Net	1.3454	0.8252	83.12
Bayesian Ridge	1.3565	0.8316	82.98
Kernel Ridge	2.3668	1.1497	70.30

Figura 2.3: Resultados obtenidos en el antecedente

2.1.4. Modelo predictivo de ventas usando aprendizaje automático (Machine Learning) para pronosticar las ventas diarias de una empresa

2.1.4.1. Planteamiento del problema y objetivo

La tesis desarrollada por Baron Jaramillo (2024), en la Universidad Nacional Abierta y a Distancia – UNAD de Colombia, aborda el problema de la predicción de ventas diarias en una empresa comercial mediante el uso de técnicas de aprendizaje automático. El estudio parte de la necesidad de mejorar la capacidad de las organizaciones para anticipar el comportamiento futuro de sus ventas, considerando que una estimación imprecisa puede afectar la planificación de inventarios, la asignación de recursos, la gestión operativa y la toma de decisiones estratégicas.

El problema central identificado por el autor se relaciona con las limitaciones que presentan los métodos tradicionales de pronóstico cuando deben capturar patrones complejos de series temporales, especialmente aquellos asociados a estacionalidad, días festivos, vacaciones y variaciones propias del comportamiento comercial. Frente a ello, se plantea el uso de modelos de Machine Learning como una alternativa para mejorar la precisión de los pronósticos y generar información útil para la gestión empresarial.

El objetivo general de la investigación fue evaluar la efectividad de un modelo de Machine Learning implementado mediante el algoritmo Facebook Prophet para la predicción de ventas diarias en una empresa del sector comercial. Asimismo, el trabajo buscó comparar dicho modelo con métodos tradicionales de series temporales, como ARIMA y SARIMA, empleando métricas de evaluación que permitieran determinar el nivel de precisión y ajuste de cada modelo.

Este antecedente guarda relación con la presente investigación, debido a que ambos estudios emplean técnicas de predicción basadas en datos históricos de ventas para apoyar la toma de decisiones empresariales. Además, ambos trabajos consideran la comparación de modelos predictivos y el uso de métricas cuantitativas como parte fundamental para determinar qué enfoque ofrece mejores resultados en términos de precisión y aplicabilidad.

2.1.4.2. Base de datos de los autores

La investigación utilizó una base de datos histórica de ventas diarias de una empresa comercial. Según el autor, el conjunto de datos empleado permitió simular el rol de un científico de datos dentro del área de ventas, con el propósito de predecir ventas futuras a partir de información histórica. La base de datos consideró registros asociados a tiendas comerciales,

fechas y ventas, permitiendo estructurar una serie temporal orientada al análisis predictivo.

Dentro del proceso de análisis, el autor examinó la información disponible para identificar el número de registros, los tipos de datos, la presencia de valores nulos y las características generales del conjunto de datos. Posteriormente, se realizaron gráficos exploratorios para observar el comportamiento histórico de las ventas, así como patrones relacionados con el día, mes y año. Este procedimiento permitió identificar tendencias, variaciones y posibles comportamientos estacionales dentro de la serie de ventas.

La base de datos cumplió un papel fundamental en la investigación, ya que permitió entrenar y evaluar los modelos predictivos. Asimismo, la información histórica fue transformada y adaptada para cumplir con los requerimientos del algoritmo Facebook Prophet, el cual exige que las columnas de fecha y ventas sean renombradas como *ds* y *y*, respectivamente.

2.1.4.3. Metodología empleada por los autores

La metodología empleada por Baron Jaramillo (2024) se basó en el enfoque CRISP-DM, el cual proporciona una secuencia estructurada para el desarrollo de proyectos de minería de datos y Machine Learning. El proceso metodológico incluyó etapas de recolección, comprensión, preprocesamiento, modelamiento, evaluación y comparación de resultados.

En primer lugar, se realizó la recolección y carga del conjunto de datos históricos de ventas. Posteriormente, se efectuó una revisión de la estructura de la base de datos, identificando los campos disponibles, tipos de datos, número de registros y existencia de valores nulos. Esta fase permitió determinar si la información era adecuada para el análisis de series temporales y para el entrenamiento de modelos predictivos.

En segundo lugar, se desarrolló el análisis exploratorio de datos, mediante estadísticas descriptivas, mapas de calor, histogramas y gráficos de comportamiento histórico. A partir de este análisis, se identificaron patrones temporales en las ventas, tales como variaciones por día, mes y año. También se observó la existencia de comportamientos particulares en determinados periodos, como meses con mayores niveles de venta y tendencias decrecientes en ciertos tramos de la serie.

En tercer lugar, se implementó el modelo Facebook Prophet. Para ello, el autor preparó la base de datos renombrando las columnas principales de fecha y ventas, aplicó transformaciones sobre la serie temporal y entrenó el modelo mediante el método *fit()*. Luego, se generó un pronóstico a treinta días utilizando la función *make_future_dataframe*, con el fin de estimar el comportamiento futuro de las ventas.

Posteriormente, el autor incorporó días feriados y periodos de vacaciones dentro del modelo Prophet, con el objetivo de evaluar si estos factores mejoraban la precisión del pronóstico. Esta etapa permitió analizar la influencia de eventos especiales en la predicción de ventas y observar si su inclusión generaba cambios significativos en las métricas de evaluación.

Finalmente, se desarrollaron modelos tradicionales de comparación, específicamente ARIMA y SARIMA. Estos modelos fueron implementados para contrastar su rendimiento frente al modelo Facebook Prophet. La comparación se realizó utilizando métricas como el Error Cuadrático Medio (MSE), la Raíz del Error Cuadrático Medio (RMSE), el Error Absoluto Medio (MAE), el Error Porcentual Absoluto Medio (MAPE) y el coeficiente de determinación R^2 .

2.1.4.4. Resultados obtenidos

Los resultados obtenidos por Baron Jaramillo (2024) evidenciaron diferencias importantes entre los modelos evaluados. En la comparación general, el modelo ARIMA obtuvo los menores valores en MSE, RMSE y MAE, lo que indicó un mejor desempeño en términos de error absoluto y cuadrático. Por otro lado, los modelos Facebook Prophet, tanto con feriados como sin feriados, presentaron mejores resultados en MAPE y en el coeficiente de determinación R^2 .

En el caso de Facebook Prophet sin feriados ni vacaciones, el modelo obtuvo un MSE de 0.042068, RMSE de 0.205106, MAE de 0.159263, MAPE de 0.018904 y R^2 de 0.261623. Por su parte, Facebook Prophet con feriados y vacaciones obtuvo un MSE de 0.042112, RMSE de 0.205211, MAE de 0.159111, MAPE de 0.018881 y R^2 de 0.265667. Estos resultados mostraron que la inclusión de feriados y vacaciones produjo una mejora leve en algunas métricas, aunque no representó un cambio significativo en el rendimiento general del modelo.

El modelo ARIMA presentó un MSE de 0.026233, RMSE de 0.161967, MAE de 0.136773, MAPE de 1.595034 y R^2 de 0.006082. Estos valores indicaron que ARIMA tuvo un mejor desempeño en errores absolutos y cuadráticos, pero menor capacidad explicativa respecto a los modelos Prophet. En cambio, SARIMA presentó un desempeño inferior, con errores significativamente más altos, especialmente en MSE, RMSE, MAE y MAPE.

Como conclusión, el autor señala que la elección del modelo depende del criterio de evaluación priorizado. Si el objetivo principal es reducir el error absoluto y cuadrático, ARIMA resulta más conveniente. Sin embargo, si se prioriza la precisión relativa porcentual y el ajuste general del modelo, Facebook Prophet presenta mejores condiciones. Este antecedente resulta relevante para la presente investigación porque demuestra la importancia de comparar modelos

predictivos mediante diferentes métricas y de considerar no solo el menor error numérico, sino también la aplicabilidad del modelo dentro del contexto empresarial.

2.1.5. Effects of data time lag in a decision-making system using machine learning for pork price prediction (Suaza-Medina et al., 2023)

2.1.5.1. Planteamiento del Problema y Objetivo

El problema principal identificado en la investigación es la alta volatilidad de los precios en los mercados agrícolas, lo cual genera incertidumbre en los productores y demás agentes de la cadena de suministro. Esta volatilidad impacta directamente en la toma de decisiones económicas y en la estabilidad del mercado.

Asimismo, se evidencia una asimetría de información, ya que algunos actores del mercado poseen acceso a información más actualizada que otros, generando desventajas en la negociación de precios. Los sistemas tradicionales de fijación de precios, basados en consenso entre agentes, resultan limitados debido a su carácter subjetivo y dependiente de la información disponible.

En este contexto, el estudio plantea como problema central analizar el impacto del desfase temporal en la adquisición de datos (*time lag*) sobre la precisión de los modelos de predicción de precios.

El objetivo principal de la investigación es evaluar cómo el retraso en los datos afecta la calidad de las predicciones de precios utilizando modelos de aprendizaje automático. De manera específica, se busca comparar diferentes modelos predictivos, analizar el rendimiento con datos con y sin retraso, y desarrollar un sistema de apoyo a la toma de decisiones basado en el mejor modelo identificado.

2.1.5.2. Base de Datos

La investigación emplea datos provenientes de fuentes tanto públicas como privadas relacionadas con el mercado porcino europeo. Los datos públicos son obtenidos del Ministerio de Agricultura de España, los cuales presentan un retraso aproximado de dos semanas en su publicación. Por otro lado, los datos privados se obtienen mediante suscripción y permiten acceder a información sin retraso temporal.

Adicionalmente, se utilizan datos proporcionados por Eurostat, que incluyen precios

semanales de mercados porcinos de distintos países europeos, clasificados bajo el sistema S.E.U.R.O.P., el cual categoriza la calidad de la carne según el porcentaje de carne magra.

El estudio se centra en el mercado de Lleida, España, debido a su relevancia en la producción porcina. Se emplean un total de 322 semanas de datos históricos, comprendidos entre enero de 2016 y febrero de 2022.

Para la selección de variables, se realizó un análisis de correlación de Pearson, identificando mercados altamente correlacionados (mayores a 0.98) con el mercado de Lleida. Asimismo, se llevó a cabo un proceso de limpieza de datos, incluyendo la corrección de valores atípicos mediante interpolación.

2.1.5.3. Metodología Empleada por los Autores

La metodología utilizada se basa en la comparación de diferentes modelos de predicción de series temporales, incluyendo enfoques estadísticos, de aprendizaje automático y de aprendizaje profundo.

Entre los modelos estadísticos se utilizaron ARIMA y SARIMAX, los cuales son ampliamente aplicados en el análisis de series temporales. En cuanto a los modelos de aprendizaje automático, se incluyeron Random Forest, Support Vector Regression (SVR), XGBoost, LightGBM, CatBoost y Ridge Regression. Finalmente, en la categoría de aprendizaje profundo, se emplearon redes neuronales recurrentes (RNN) y modelos LSTM.

El proceso de entrenamiento de los modelos se realizó dividiendo los datos en un 80 % para entrenamiento y 20 % para prueba. Se utilizaron ventanas temporales de entre 2 y 12 semanas para analizar el impacto del tamaño de la ventana en la precisión del modelo.

Para la evaluación del rendimiento se emplearon las métricas RMSE (Root Mean Square Error) y el coeficiente de determinación R^2 . Además, se utilizó la herramienta Optuna para la optimización de hiperparámetros mediante técnicas de optimización bayesiana.

Se realizaron dos escenarios experimentales: uno utilizando datos públicos con retraso de dos semanas, y otro utilizando datos de suscripción sin retraso. Esto permitió comparar directamente el impacto del desfase temporal en la precisión de las predicciones.

Finalmente, el modelo con mejor desempeño fue integrado en un sistema de soporte a la toma de decisiones (DSS), el cual fue implementado en un entorno real dentro de una “Lonja” (mercado de referencia en España), permitiendo generar predicciones semanales de precios.

2.1.5.4. Resultados Obtenidos

■ a) Impacto del retraso en los datos

- Los modelos con datos sin retraso (suscripción) presentan mejor rendimiento.
- Existe una diferencia de aproximadamente 0.6 céntimos de euro en el error entre modelos con y sin retraso.

■ b) Mejor modelo

- El modelo con mejor desempeño fue **Ridge Regression**:
 - $RMSE \approx 0,01477$
 - $R^2 \approx 0,99342$
- Con datos públicos:
 - $RMSE \approx 0,02041$
- Esto demuestra que el acceso a datos actualizados mejora significativamente la precisión.

■ c) Importancia económica

- Aunque las diferencias parecen pequeñas, tienen un gran impacto.
- Variaciones de centavos por kilogramo pueden generar grandes pérdidas económicas en producción a gran escala.
- La precisión del modelo mejora la negociación en la cadena de suministro.

■ d) Hallazgos adicionales

- Los modelos no requieren grandes ventanas de datos: las mejores predicciones se logran con 2 a 4 semanas de información.
- No todos los modelos aprovechan bien múltiples variables: ARIMA funciona bien incluso con una sola serie.
- Los mercados presentan alta correlación regional, no global.

■ e) Validación en entorno real

- El sistema implementado logró un error máximo de:

$$0,02 \ (\approx 1,2 \%)$$

- Considerado adecuado para uso en mercados reales.

2.1.6. Time-series analysis with smoothed Convolutional Neural Network

2.1.6.1. Planteamiento del Problema y objetivo

La introducción del documento ‘Time-series analysis with Smoothed Convolutional Neural Network (SCNN)’ comienza destacando la importancia del análisis de series temporales en diversas áreas, como las finanzas, la meteorología y la medicina, donde la capacidad de predecir y comprender patrones en datos temporales es fundamental para la toma de decisiones efectivas. Se menciona que las técnicas tradicionales de suavizado de datos pueden mejorar la calidad de las series temporales al eliminar valores atípicos y ruido. Se introduce el concepto de Redes Neuronales Convolucionales (CNN), que son ampliamente utilizadas en el procesamiento de imágenes debido a su eficiencia en la extracción de características. El documento destaca que las CNN pueden ser aplicadas a problemas de series temporales al tratar los datos de entrada como arreglos unidimensionales, lo que las hace adecuadas para el análisis de datos temporales. La motivación principal del estudio es explorar cómo la combinación de técnicas de suavizado de datos con CNN puede mejorar la precisión en la predicción de series temporales. Se plantea la hipótesis de que, al optimizar el factor de suavizado en CNN, se puede lograr un rendimiento superior en la predicción de series temporales en comparación con otros métodos tradicionales.

Tabla 2.1: Tipos de suavizado de datos (data smoothing)

Método	Ventajas	Desventajas
Suavizado exponencial/Suavizado simple exponencial	Facilidad de cálculo, Flexibilidad, Buen rendimiento.	No es capaz de gestionar bien las tendencias.
Media móvil	Uso adecuado cuando hay ligera o nula variación estacional.	Puede no reflejar con exactitud las tendencias más recientes.
Recorrido aleatorio	Fácil de usar, Puede manejar flujos complicados.	No conserva con precisión la posición media de la vorticidad en el espacio libre, Soluciones ruidosas debido a errores estadísticos.

Fuente: Wibawa, A. P.(2022). Time-series analysis with smoothed Convolutional Neural Network. Journal of big Data, 9(1), 44.

2.1.6.2. Base de datos de los autores

Se presentan 4 conjuntos de datos diferentes, cada uno con características específicas:

1. Dataset 1: Se trata de una serie temporal de un año de visitantes diarios a un sitio web de la Universidad Negri Malang. Este conjunto de datos es multivariado y consta de 365 instancias con 4 atributos diferentes, como sesiones, visitas a páginas, visitantes y nuevos visitantes.
2. Dataset 2: Este conjunto de datos también es multivariado y consiste en datos diarios de visitantes a un sitio web, pero con diferentes atributos en comparación con el Dataset 1. Incluye información sobre cargas de página, visitas únicas, visitas por primera vez y visitas recurrentes.
3. Dataset 3: Se refiere a datos relacionados con el intercambio de divisas y la información de ventas. Es un conjunto de datos multivariado con 2 atributos y no presenta datos faltantes.
4. Dataset 4: Este conjunto de datos representa el consumo de energía eléctrica en 32 ciudades de la India. Es un conjunto multivariado con un atributo seleccionado para el estudio, que es la demanda de energía en Delhi.

Además, se menciona que se utilizan dos escenarios diferentes para evaluar el rendimiento del modelo en función de la composición de los datos de entrenamiento y prueba. En el primer escenario dividen en 70 % y 30 % en el entrenamiento y prueba respectivamente, en el segundo escenario dividen 80 % y 20 %.

2.1.6.3. Metodología empleada por los autores

1. Evaluación del método propuesto: Se inicia con la evaluación del método propuesto, que combina el suavizado exponencial con CNN (S-CNN). Se comparan los resultados obtenidos con S-CNN con los de otros métodos de pronóstico, como Multilayer Perceptron (MLP) y Long Short-Term Memory (LSTM). Se destaca que S-CNN supera a MLP y LSTM en términos de error cuadrático medio (MSE), con el mejor MSE logrado utilizando 76 capas ocultas.
2. Comparación de desempeño: Se presentan los resultados de pruebas de significancia utilizando el test t pareado basado en el número de capas ocultas de Lucas. Se comparan métricas como MSE, MAPE y tiempo de entrenamiento entre CNN y S-CNN. Se ob-

serva que S-CNN es más preciso que CNN en todos los escenarios y que el tiempo de procesamiento es menor con S-CNN.

3. Optimización del factor de suavizado: Se discute la importancia de encontrar el factor de suavizado óptimo (α) en el método propuesto. Se comparan diferentes valores de α y se concluye que el α óptimo produce los mejores resultados en términos de MSE y MAPE.
4. Impacto de las capas ocultas de Lucas: Se analiza el impacto de utilizar números de Lucas como capas ocultas en la CNN. Se muestra que las capas ocultas de Lucas tienen un efecto significativo en la precisión del modelo y en el tiempo de entrenamiento, mejorando el rendimiento del algoritmo de pronóstico.




Figura 2.4: Metodología antecedente

Fuente: Wibawa, A. P.(2022). Time-series analysis with smoothed Convolutional Neural Network. Journal of big Data, 9(1), 44.

2.1.6.4. Resultados obtenidos

Se resalta que los resultados obtenidos en el estudio sugieren que la implementación de S-CNN con capas ocultas de Lucas puede elevar el rendimiento del algoritmo de pronóstico en el análisis de series temporales, reduciendo el error cuadrático medio (MSE) y mejorando la precisión de las predicciones.




Figura 2.5: Resultado antecedente

Fuente: Wibawa, A. P.(2022). Time-series analysis with smoothed Convolutional Neural Network. *Journal of big Data*, 9(1), 44.




Figura 2.6: Resultado antecedente

Fuente: Wibawa, A. P.(2022). Time-series analysis with smoothed Convolutional Neural Network. *Journal of big Data*, 9(1), 44.

2.1.7. Construction of performance score dynamic prediction system for clinical departments using explainable machine learning (Wen et al., 2026)

2.1.7.1. Planteamiento del problema y objetivo

El sector salud enfrenta múltiples desafíos relacionados con la eficiencia operativa, el uso adecuado de recursos y la calidad del servicio. Diversos estudios han evidenciado que entre el 20 % y 40 % de los recursos sanitarios se desaprovechan debido a ineficiencias, lo cual impacta directamente en la gestión hospitalaria. En este contexto, los hospitales —que representan entre el 50 % y 80 % del gasto sanitario en muchos países— requieren herramientas más precisas para evaluar su desempeño.

Tradicionalmente, la evaluación del desempeño en hospitales se ha basado en indicadores estáticos y retrospectivos, generalmente calculados al final del año. Este enfoque presenta limitaciones importantes, como la falta de capacidad predictiva, baja cobertura de indicadores y escasa utilidad para la toma de decisiones en tiempo real. Además, los modelos convencionales carecen de interpretabilidad, lo que dificulta entender los factores que influyen en el desempeño.

Frente a esta problemática, el objetivo del estudio fue desarrollar un sistema dinámico de predicción del desempeño anual de los departamentos clínicos, utilizando técnicas de aprendizaje automático explicable. Este sistema busca no solo predecir resultados, sino también permitir una intervención temprana y mejorar la toma de decisiones gerenciales en hospitales.

2.1.7.2. Base de datos

La investigación utilizó datos reales obtenidos del sistema de información hospitalaria (HIS). Específicamente, se recopilieron datos correspondientes al periodo comprendido entre enero de 2023 y diciembre de 2024, abarcando un total de 648 registros provenientes de 27 departamentos clínicos.

El conjunto de datos incluyó:

- 10 variables independientes (indicadores de desempeño)
- 1 variable dependiente: puntaje anual de desempeño

Los indicadores estuvieron relacionados principalmente con:

- Estructura de ingresos
- Control de costos

Los departamentos fueron clasificados en:

- Departamentos médicos
- Departamentos de obstetricia y pediatría
- Departamentos quirúrgicos
- Otros departamentos clínicos

Para el entrenamiento del modelo, los datos se dividieron de manera cronológica:

- Conjunto de entrenamiento: datos del año 2023 (324 registros)

- Conjunto de prueba: datos del año 2024 (324 registros)

Asimismo, los datos fueron normalizados mediante el método *min-max scaling*, con el fin de estandarizar los valores antes del procesamiento.

2.1.7.3. Metodología empleada por los autores

La metodología propuesta se basa en el uso de modelos de aprendizaje automático explicable, combinados con un enfoque de predicción dinámica.

Modelos utilizados:

- | | |
|--------------------------|---------------------|
| ■ Regresión Lineal (LR) | ■ Gradient Boosting |
| ■ Árbol de decisión (DT) | ■ XGBoost |
| ■ Random Forest (RF) | ■ CatBoost |

Enfoque dinámico:

Se utilizaron ventanas temporales acumulativas para realizar predicciones progresivas durante el año:

- | | |
|-----------------|----------------------|
| ■ Enero – Marzo | ■ Enero – Septiembre |
| ■ Enero – Junio | |

Este enfoque permite monitorear el desempeño de forma continua y no únicamente al final del periodo.

Evaluación de modelos:

Los modelos fueron evaluados utilizando las siguientes métricas:

- | | |
|--|--------------------------------|
| ■ Coeficiente de determinación (R^2) | ■ Error absoluto medio (MAE) |
| ■ Error cuadrático medio (RMSE) | ■ Error cuadrático medio (MSE) |

Interpretabilidad:

Para mejorar la transparencia del modelo, se aplicó la técnica SHAP (*Shapley Additive Explanations*), la cual permitió identificar la contribución de cada variable en la predicción.

Implementación del sistema:

Finalmente, se desarrolló una herramienta web denominada *ClinDeptPredictor*, la cual permite:

- Ingresar datos mensuales
- Obtener predicciones en tiempo real
- Visualizar la importancia de las variables

2.1.7.4. Resultados obtenidos

Los resultados evidencian que el modelo de Regresión Lineal (LR) obtuvo el mejor desempeño en todas las ventanas temporales evaluadas.

Se obtuvieron los siguientes valores:

- R^2 : 0.8964, 0.9314 y 0.9640
- Menores valores de RMSE, MAE y MSE en comparación con otros modelos

Esto demuestra que el modelo presenta alta precisión y robustez para la predicción del desempeño hospitalario.

Asimismo, se identificaron los cinco indicadores más influyentes:

- Proporción de ingresos por servicios médicos
- Ingresos por seguro médico (consulta externa)
- Proporción de consumibles
- Ingresos por seguro médico (hospitalización)
- Gasto promedio por paciente hospitalizado

Estos factores se mantuvieron consistentes en todas las etapas, lo que evidencia la estabilidad del modelo.

Además, se observó que:

- El rendimiento del modelo mejora conforme se incrementa la cantidad de datos disponibles
- El sistema permite realizar predicciones anticipadas antes de finalizar el año
- Se logra una interpretación clara del modelo, superando el problema de “caja negra”

Finalmente, la herramienta desarrollada permitió aplicar el modelo en un entorno real, facilitando la toma de decisiones en la gestión hospitalaria.

2.1.8. Time Series Forecasting and Modelling of Food Demand Supply Chain based on Regressors Analysis

2.1.8.1. Planteamiento del Problema y objetivo

(Panda y Mohanty, 2023) El sector de entrega de alimentos enfrenta grandes desafíos en la gestión de inventarios, ya que la demanda de comidas puede ser altamente variable debido a factores como cambios estacionales, promociones y fluctuaciones en las preferencias de los clientes. Este comportamiento errático de la demanda complica la planificación de la producción y puede llevar a la empresa a sufrir pérdidas económicas. La sobreproducción de alimentos puede ocasionar desperdicio y costos innecesarios, mientras que la subproducción puede resultar en una escasez de productos, afectando la satisfacción del cliente y la lealtad hacia la marca. El objetivo principal de esta investigación es desarrollar un modelo de pronóstico de demanda que permita predecir con precisión el número de pedidos de comidas para las próximas 10 semanas. Con este modelo, la empresa puede optimizar la gestión de inventarios, minimizando el desperdicio de alimentos y los costos operativos, al mismo tiempo que mejora la disponibilidad de productos y la satisfacción del cliente. Al anticipar la demanda, la empresa podrá tomar decisiones más informadas sobre compras y producción, aumentando su eficiencia operativa y rentabilidad. Para llevar a cabo este estudio, se utilizó un conjunto de datos que abarca 145 semanas de pedidos semanales de 50 comidas diferentes, lo que proporciona un total de aproximadamente 450,000 entradas. Cada entrada incluye 15 características, entre ellas, el número de ventas, los precios, los descuentos aplicados, el centro de distribución, y otros atributos que influyen en la demanda. La importancia de este problema radica en que una predicción inexacta puede desencadenar una serie de problemas logísticos y financieros, afectando el rendimiento global de la empresa de entrega de alimentos.

2.1.8.2. Base de datos de los autores

El conjunto de datos, denominado “Food Demand Forecasting”, fue proporcionado por Genpact, una firma de servicios profesionales especializada en el análisis de datos empresariales. Este conjunto incluye registros históricos detallados de los pedidos realizados semanalmente para diferentes tipos de comidas. Los datos se distribuyen en tres archivos, los cuales contienen columnas como el ID del pedido, el número de semana, el ID de la comida, el ID del centro de cumplimiento, y el precio final. Los datos originales estaban en un formato heterogéneo y requirieron una preparación significativa para su uso en los modelos predictivos. Se aplicaron técnicas de limpieza y normalización para eliminar registros incompletos y valores atípicos que pudieran afectar la precisión del modelo. Además, se añadieron características adicionales, como medias móviles para capturar tendencias a corto plazo y características de rezago para incluir información histórica en el modelo. La construcción de estas nuevas características permitió enriquecer la información y mejorar la capacidad del modelo para detectar patrones en la demanda.

2.1.8.3. Metodología empleada por los autores

1. **Modelos Utilizados:** La metodología incluyó la utilización de varios modelos de machine learning y deep learning, con el objetivo de comparar su desempeño en la predicción de la demanda de comidas. Los modelos probados incluyeron Random Forest Regressor, Gradient Boosting Regressor, LightGBM, XGBoost, CatBoost Regressor, LSTM (Long Short-Term Memory) y BiLSTM (Bidirectional Long Short-Term Memory). La selección de estos modelos se basó en su capacidad para capturar relaciones no lineales y temporales en los datos.
2. **Etapas del Proceso:** El proceso se dividió en varias etapas. Inicialmente, se realizó la preparación de los datos, que incluyó la limpieza, normalización y creación de nuevas características. Posteriormente, se llevó a cabo el entrenamiento de los modelos utilizando un conjunto de datos que cubría 113 semanas. Para validar la precisión del modelo y ajustar los hiperparámetros, se utilizó un subconjunto de 10 semanas. Finalmente, se emplearon las últimas 10 semanas de datos para probar y evaluar el desempeño de los modelos.
3. **Herramientas y Tecnologías:** Para la implementación de los modelos, se utilizaron lenguajes de programación como Python y herramientas específicas de machine learning y deep learning. Entre los frameworks empleados destacan TensorFlow, Keras y scikit-learn, los cuales permitieron construir y entrenar redes neuronales complejas. Además, se

utilizaron pandas y NumPy para el manejo y preprocesamiento de los datos, y Matplotlib y Seaborn para la visualización de resultados.

4. **Procedimientos Implementados:** Se inició definiendo las estructuras de las redes neuronales, seleccionando el número de capas y neuronas adecuadas para captar las relaciones complejas entre las variables. Para los modelos de LSTM y BiLSTM, se prestó especial atención a la configuración de los hiperparámetros, como el número de épocas de entrenamiento, la tasa de aprendizaje y el tamaño de las secuencias de entrada. A lo largo del proceso, se llevaron a cabo múltiples iteraciones de entrenamiento para optimizar los modelos y mejorar la precisión en las predicciones.
5. **Optimización de Modelos:** Además de entrenar los modelos, se implementaron técnicas de optimización, como la búsqueda de hiperparámetros (Grid Search y Random Search) para encontrar la configuración más eficaz. También se aplicaron técnicas de regularización y “early stopping” para prevenir el sobreajuste del modelo durante el entrenamiento.
6. **Evaluación de Resultados:** Se evaluó el desempeño de los modelos utilizando métricas como RMSLE (Root Mean Squared Logarithmic Error), RMSE (Root Mean Squared Error), MAPE (Mean Absolute Percentage Error) y MAE (Mean Absolute Error). Estas métricas proporcionaron una visión detallada de la precisión y robustez de cada modelo al predecir la demanda.

2.1.8.4. Resultados obtenidos

Los resultados mostraron que los modelos de deep learning, en particular el modelo LSTM, superaron a los demás en términos de precisión al predecir la demanda de comidas. Las métricas de evaluación para el modelo LSTM incluyeron un RMSLE de 0.28, un RMSE de 18.83, un MAPE de 6.56 % y un MAE de 14.18. Estas cifras indicaron un alto nivel de precisión en las predicciones, lo que lo convierte en una herramienta eficaz para la planificación de inventarios.

Durante la evaluación, se realizó una comparación detallada entre los valores reales y los pronosticados por el modelo. Los resultados mostraron una fuerte correlación entre las predicciones y los valores reales, validando así la efectividad del modelo LSTM para capturar las tendencias y patrones de la demanda. Este análisis demostró que la implementación del modelo propuesto puede ayudar a las empresas de entrega de alimentos a gestionar sus inventarios de manera más eficiente, reduciendo los costos asociados al desperdicio de alimentos y mejorando la satisfacción del cliente.

Models/Metrics	RMSLE	RMSE	MAPE	MAE
Random Forest	0.35	228.92	10.822	115.90
Gradient Boost	0.31	226.46	10.03	123.48
Light Boost	0.31	194.68	10.08	104.49
XGB	0.30	205.31	9.97	106.17
CatBoost	0.29	186.68	9.76	99.40
LSTM	0.28	18.83	6.56	14.18
Bi-LSTM	0.37	31.88	12.8	28.33

Tabla 2.2: Resultados antecedente

Fuente: Kumar, P. (2023). Time Series Forecasting and Modeling of Food Demand Supply Chain Based on Regressors Analysis. IEEE Access

2.1.9. Advancing Retail Predictions: Integrating Diverse Machine Learning Models for Accurate Walmart Sales Forecasting (Wen et al., 2026)

2.1.9.1. Planteamiento del Problema y objetivo

(Neba Cyril et al., 2024) En el sector minorista, la previsión precisa de las ventas es un desafío constante. Los errores en las predicciones pueden tener un impacto significativo en la gestión de inventarios, llevando a problemas como el exceso de productos o su escasez. Estos problemas, a su vez, afectan negativamente la satisfacción del cliente, las operaciones y la rentabilidad de la empresa. Walmart, como líder en el sector retail, necesita un sistema robusto que le permita anticipar la demanda para optimizar sus estrategias de abastecimiento, compras y promociones.

El objetivo de esta investigación es desarrollar un sistema de pronóstico de ventas que utilice modelos de machine learning para mejorar la precisión de las predicciones de ventas en Walmart. Un sistema más preciso permitirá una mejor gestión del inventario, reducir costos asociados con el exceso o falta de stock, y optimizar la toma de decisiones estratégicas, especialmente durante períodos críticos como temporadas de vacaciones o cambios económicos. Para abordar este problema, se utilizaron datos históricos de ventas de Walmart que abarcan desde febrero de 2010 hasta octubre de 2012. Los datos incluyen una amplia variedad de variables como banderas de vacaciones, temperatura, precios de combustible, el Índice de Precios al Consumidor (CPI), tasas de desempleo y las ventas semanales. La inclusión de estas variables externas permitió al modelo captar patrones y relaciones más complejas en la variabilidad de la demanda.

2.1.9.2. Base de datos de los autores

El conjunto de datos fue obtenido de Kaggle, una plataforma que proporciona datasets para análisis y modelos predictivos. El dataset específico contiene información sobre las ventas de Walmart en diferentes tiendas y departamentos a lo largo de un período de casi tres años. Los datos están organizados en un formato tabular, con columnas que incluyen fechas, ventas semanales, identificadores de tienda y departamento, y variables externas como el clima y condiciones económicas.

Para asegurar la calidad de la información, se realizó un exhaustivo proceso de preparación de los datos. Esto incluyó la normalización de las variables, la eliminación de valores atípicos que pudieran distorsionar el modelo, y el manejo de valores faltantes. Durante esta etapa, se incorporaron características adicionales relevantes, como la extracción de información temporal (día de la semana, mes, año) y la identificación de períodos de alta demanda, como días festivos, para ayudar al modelo a captar mejor las tendencias y patrones estacionales.

2.1.9.3. Metodología empleada por los autores

1. **Modelos de Machine Learning Utilizados:** Se probaron varios modelos de machine learning para identificar cuál proporcionaba las predicciones más precisas. Entre los modelos evaluados se incluyeron la Regresión Lineal, Random Forest, Gradient Boosting Machines (GBM), eXtreme Gradient Boosting (XGBoost) y Light Gradient Boosting Machine (LightGBM). Estos modelos fueron seleccionados por su capacidad para manejar datos complejos y relaciones no lineales entre las variables.

2. Etapas del Proceso:

- **Preparación de Datos:** La primera etapa del proceso consistió en la recolección, limpieza y normalización de los datos. Los datos se dividieron en conjuntos de entrenamiento y validación para garantizar que el modelo fuera capaz de generalizar a nuevas situaciones. También se realizó una transformación de variables, como la creación de características temporales y la codificación de variables categóricas.
- **Entrenamiento del Modelo:** Se entrenaron los modelos seleccionados utilizando el conjunto de datos de entrenamiento. Durante esta etapa, se realizaron ajustes a los hiperparámetros de los modelos para optimizar su rendimiento, empleando técnicas como la búsqueda en cuadrícula (Grid Search) y la validación cruzada.
- **Validación:** Una vez entrenados los modelos, se validó su rendimiento utilizando el conjunto de datos de validación. Las métricas de evaluación incluyeron el Error Ab-

soluta Medio (MAE), la Raíz del Error Cuadrático Medio (RMSE) y el Coeficiente de Determinación (R-squared). Estas métricas proporcionaron una visión completa de la precisión y robustez de cada modelo al predecir las ventas.

3. **Herramientas y Tecnologías Utilizadas:** Para implementar y entrenar los modelos, se utilizaron lenguajes de programación como Python junto con bibliotecas y frameworks especializados en machine learning, tales como scikit-learn y XGBoost. El uso de estas herramientas permitió construir modelos complejos y eficientes en términos computacionales, además de facilitar el análisis y visualización de resultados.
4. **Procedimientos Implementados:** Durante el proceso de desarrollo del modelo, se definieron las estructuras de los algoritmos y se realizaron ajustes de hiperparámetros para optimizar su desempeño. Se implementaron técnicas de regularización y selección de características para mejorar la capacidad predictiva de los modelos y reducir el riesgo de sobreajuste. Además, se realizaron múltiples iteraciones de entrenamiento y prueba para garantizar que los modelos fueran capaces de adaptarse a las diferentes condiciones representadas en los datos históricos.

2.1.9.4. Resultados obtenidos

Los resultados del estudio mostraron que los modelos avanzados, especialmente XGBoost, proporcionaron un nivel de precisión superior en comparación con otros modelos más simples. El modelo XGBoost obtuvo un Error Absoluto Medio (MAE) de 1226.471, un RMSE de 1700.981, y un R-squared de 0.9999900, lo que indica una precisión casi perfecta en las predicciones. Este desempeño demuestra la capacidad del modelo para adaptarse a las complejas relaciones entre las variables y capturar las fluctuaciones en la demanda de ventas de Walmart. En contraste, los modelos más simples como la Regresión Lineal mostraron un rendimiento significativamente menor, con un MAE de 35632.510 y un RMSE de 80153.858. Esta diferencia destaca la importancia de utilizar algoritmos avanzados para abordar problemas de predicción complejos en el entorno minorista. Adicionalmente, se realizó un análisis de sesgo y equidad para evaluar el rendimiento de los modelos en diferentes segmentos temporales, como períodos de vacaciones y no vacaciones. Los resultados indicaron que los modelos avanzados, en particular XGBoost, lograron minimizar los errores de predicción y mantener un rendimiento equilibrado incluso en los períodos de alta variabilidad de la demanda.

Model	MAE	RMSE	R Squared
Linear Regression	35632.510	80153.858	0.9760562
Multiple Regression	35632.510	80153.858	0.9760562
GLM	35632.510	80153.858	0.9760562
Decision Tree	77388.082	93721.066	0.9696449
Ramdom Forest	12238.782	19814.965	0.9986431
GBM	10839.822	1700.981	0.9993119
XGBoost	1226.471	1700.981	0.9999900
LGB	1692.640	2297.930	0.9999818

Tabla 2.3: Resultados de modelos predictivos

Fuente: Cyril, N. (2024). Advancing Retail Predictions: Integrating Diverse Machine Learning Models for Accurate Walmart Sales Forecasting. Asian Journal of Probability and Statistics

2.1.10. Deep learning-enabled cherry price forecasting and real-time system deployment across multi-market supply chains in India (Shaheen et al., 2026)

2.1.10.1. Planteamiento del Problema y Objetivo

El estudio aborda la problemática de la alta volatilidad de precios en productos agrícolas perecederos, específicamente las cerezas. Este tipo de productos presenta fluctuaciones significativas debido a factores como la estacionalidad, cambios climáticos, oferta limitada y la ausencia de almacenamiento prolongado.

El problema central radica en que los métodos tradicionales de predicción, tales como ARIMA o SARIMA, presentan limitaciones para capturar comportamientos no lineales y dinámicos en los precios, lo que afecta negativamente la toma de decisiones de agricultores, comerciantes y formuladores de políticas públicas.

En este contexto, el objetivo principal del estudio es:

- Evaluar si los modelos de **Deep Learning (DL)** pueden superar a los métodos tradicionales y de Machine Learning en la predicción de precios.
- Desarrollar un sistema de **pronóstico en tiempo real** que permita generar predicciones diarias.

- Implementar una herramienta operativa que conecte la inteligencia artificial con el entorno real del mercado agrícola.

Asimismo, el estudio busca cerrar la brecha entre modelos teóricos y aplicaciones prácticas mediante la implementación de un sistema funcional durante una temporada real de comercialización.

2.1.10.2. Base de Datos

La investigación utiliza una base de datos compuesta por precios diarios de cereza en mercados mayoristas de la India, recolectados de registros oficiales de comités agrícolas.

Las principales características de la base de datos son:

- Cobertura temporal entre los años 2012 y 2024.
- Segmentación por variedad (Makhmali y Mishri).
- Frecuencia de registro diaria.
- Información proveniente de cinco mercados mayoristas.
- Clasificación por calidad (Super, Special y Fancy).

El proceso de recolección de datos incluyó la interacción directa con actores del mercado como comerciantes, agentes y funcionarios. Posteriormente, los datos fueron digitalizados y sometidos a procesos de validación para garantizar su precisión.

Asimismo, se aplicaron técnicas de preprocesamiento tales como:

- Imputación de valores faltantes.
- Pruebas de estacionariedad.
- Normalización de datos.

Esto permitió construir una base de datos robusta y adecuada para el entrenamiento de modelos predictivos.

2.1.10.3. Metodología empleada por los autores

El estudio implementa una metodología comparativa multienfoque, combinando modelos estadísticos, de Machine Learning y Deep Learning.

Modelos utilizados Se evaluaron los siguientes modelos:

- SARIMA
- Prophet
- Random Forest (RF)
- XGBoost
- LSTM (Long Short-Term Memory)
- Transformer

Proceso metodológico La metodología se desarrolló en las siguientes etapas:

- **Preprocesamiento:** limpieza de datos, imputación de valores faltantes, normalización y verificación de estacionariedad.
- **Entrenamiento y validación:** división cronológica de los datos en conjuntos de entrenamiento, validación y prueba, respetando la naturaleza temporal de la información.
- **Evaluación:** se utilizaron diversas métricas para medir el desempeño de los modelos:
 - MAE (Error absoluto medio)
 - RMSE (Raíz del error cuadrático medio)
 - sMAPE (Error porcentual simétrico)
 - DA (Exactitud direccional)
 - MFE (Error medio de pronóstico)
 - NMBE (Error normalizado)
- **Validación estadística:** se aplicó el test de Diebold-Mariano para determinar la significancia de las diferencias entre modelos.
- **Implementación en tiempo real:** desarrollo de un sistema web que integra modelos predictivos con datos en tiempo real mediante tecnologías como FastAPI y bases de datos.

2.1.10.4. Resultados Obtenidos

Los resultados del estudio evidencian que los modelos de Deep Learning superan significativamente a los métodos tradicionales.

Entre los principales hallazgos se destacan:

- Los modelos LSTM y Transformer obtuvieron el mejor rendimiento en todas las métricas evaluadas.
- Se alcanzó una precisión superior al 92 % en predicciones reales.
- Los errores fueron bajos, con valores de MAE entre 5 y 8, y RMSE entre 8 y 12.

- El sMAPE se mantuvo entre 5 % y 10 % en mercados principales.

El test de Diebold-Mariano confirmó que las mejoras de los modelos de Deep Learning son estadísticamente significativas.

En cuanto a la implementación en tiempo real, se obtuvieron los siguientes resultados:

- El sistema logró 82.3 % de disponibilidad operativa
- Se registraron 348 entradas de datos reales
- Tiempo de respuesta bajo (aproximadamente 250 ms).
- Alta adopción por parte de usuarios institucionales.

Estos resultados demuestran que los modelos no solo son precisos, sino también viables en entornos reales, consolidándose como herramientas eficaces para la toma de decisiones en mercados agrícolas.

Finalmente, el estudio concluye que el Deep Learning, especialmente los modelos LSTM, constituye una solución robusta para la predicción de precios en mercados volátiles, aportando significativamente al desarrollo de sistemas inteligentes de apoyo a la toma de decisiones.

2.1.11. Automated water demand forecasting for national-scale deployment: a prophet-based framework for Palestinian municipal water management (Salman & Shaka'a, 2026a)

2.1.11.1. Planteamiento del Problema y objetivo

En las últimas décadas, la gestión eficiente del agua se ha convertido en un problema crítico a nivel mundial debido a factores como el crecimiento poblacional, la urbanización acelerada, el cambio climático y restricciones políticas. Según el estudio analizado, más de 2 mil millones de personas sufren escasez de agua, siendo el Medio Oriente una de las regiones más afectadas, donde aproximadamente el 80 % de la población vive bajo condiciones de estrés hídrico severo Salman y Shaka'a, 2026b.

En este contexto, la predicción de la demanda de agua es fundamental para mejorar la planificación, distribución y asignación de recursos. Sin embargo, los métodos tradicionales de pronóstico presentan limitaciones importantes, como la necesidad de ajuste manual de parámetros y la dificultad para escalar los modelos a múltiples zonas con características heterogéneas.

Esto genera dependencia de especialistas y dificulta la implementación a gran escala Salman y Shaka'a, 2026b.

El problema central identificado en la investigación radica en la ausencia de sistemas automatizados capaces de realizar predicciones precisas en múltiples áreas sin intervención humana. Los enfoques existentes suelen centrarse en series de tiempo individuales, lo que limita su aplicabilidad en sistemas reales donde se manejan múltiples regiones con diferentes patrones de consumo.

Frente a esta problemática, el objetivo principal del estudio es desarrollar un sistema automatizado de predicción de demanda de agua basado en el modelo Prophet, capaz de:

- Eliminar la necesidad de ajuste manual de parámetros.
- Seleccionar automáticamente variables relevantes.
- Escalar el modelo a múltiples áreas de servicio.
- Mejorar la precisión en la predicción de la demanda.

Adicionalmente, el estudio busca validar este sistema en múltiples zonas reales, evaluar la influencia de variables externas (como clima y eventos culturales) y establecer lineamientos para su implementación a nivel nacional Salman y Shaka'a, 2026b.

2.1.11.2. Base de datos

La investigación utiliza una base de datos real correspondiente a la ciudad de Nablus, en Palestina, la cual presenta condiciones de alta escasez de agua y complejidad en los patrones de consumo.

El conjunto de datos incluye:

- Información de consumo mensual de agua.
- Datos correspondientes a 29 áreas urbanas.
- Un periodo de estudio de 60 meses (2019–2023).
- Variables externas como condiciones climáticas (temperatura, lluvia, humedad) y eventos culturales (Ramadán, festividades religiosas).

Las áreas analizadas presentan una alta heterogeneidad, incluyendo:

- Zonas urbanas.
- Centros comerciales.
- Áreas industriales.
- Campamentos de refugiados.

Los niveles de consumo varían significativamente entre áreas, desde aproximadamente 1,350 hasta 42,260 m³ por mes, lo que evidencia la complejidad del problema de predicción Salman y Shaka'a, 2026b.

Además, el estudio considera factores adicionales que afectan el consumo, como el uso de pozos de agua en temporada de lluvias, lo que introduce variaciones no lineales y dificulta la predicción. Esta diversidad convierte a la base de datos en un caso ideal para evaluar modelos de predicción en contextos reales y complejos.

2.1.11.3. Metodología empleada por los autores

La metodología propuesta se basa en el desarrollo de un sistema automatizado de predicción utilizando el modelo Prophet, complementado con técnicas de optimización y selección de variables.

■ Preprocesamiento de datos:

- Imputación de valores faltantes.
- Detección y tratamiento de valores atípicos.
- Validación de consistencia de datos.

■ Análisis exploratorio:

- Análisis de tendencia.
- Análisis de variabilidad residual.
- Evaluación de estacionalidad.
- Estudio de estacionariedad y autocorrelación.

■ Selección de variables (features): Se empleó un enfoque basado en ensamblaje que combina:

- Random Forest.
- Importancia por permutación.
- Información mutua.
- Correlación de Pearson.

■ Modelo de predicción: Se utilizó el modelo Prophet debido a sus ventajas:

- Manejo de datos no estacionarios.
 - Incorporación de estacionalidad y tendencias.
 - Inclusión de variables externas.
 - Interpretabilidad.
- **Optimización del modelo:** Se aplicó optimización bayesiana mediante Optuna para ajustar automáticamente los hiperparámetros.
 - **Evaluación del modelo:**
 - MAE (Error absoluto medio).
 - RMSE (Raíz del error cuadrático medio).
 - MAPE (Error porcentual absoluto medio).
 - MASE (Error absoluto escalado medio).

También se utilizó validación tipo *walk-forward*, simulando un entorno real de predicción.

2.1.11.4. Resultados obtenidos

Los resultados del estudio demuestran un alto nivel de precisión y eficiencia del modelo propuesto.

Entre los principales hallazgos destacan:

- El 93.1 % de las áreas alcanzaron un error menor al 10 % ($\text{MAPE} < 10\%$), considerado un nivel de precisión excelente.
- El error promedio fue de aproximadamente 7.3 %, con una mediana de 6.5 %.
- Se logró una mejora del 34.2 % respecto a modelos base tradicionales Salman y Shaka'a, 2026b.

Además:

- El modelo logró adaptarse a diferentes tipos de áreas (urbanas, industriales, residenciales).
- Se comprobó que variables como temperatura y tendencias temporales son altamente influyentes.

- El sistema mostró capacidad de escalabilidad para más de 550 regiones.

En términos computacionales:

- El tiempo promedio de ejecución fue de aproximadamente 22.7 segundos por área.
- El sistema completo procesó las 29 áreas en menos de 11 minutos.

Finalmente, el estudio concluye que el sistema desarrollado es viable para implementación a gran escala, permitiendo mejorar la planificación de recursos hídricos y facilitando la toma de decisiones en contextos de escasez de agua.

2.1.12. Lightweight machine learning framework using temporal features for electric vehicle demand response forecasting on edge devices (Durrani et al., 2026b)

2.1.12.1. Planteamiento del problema y objetivo

El rápido crecimiento del uso de vehículos eléctricos (EV) ha generado nuevos desafíos en la gestión de la demanda energética, especialmente en sistemas eléctricos con recursos limitados. La carga simultánea de múltiples vehículos puede provocar sobrecargas en la red, desequilibrios en la demanda y problemas operativos, particularmente en escenarios de alta penetración de EV Durrani et al., 2026a.

Diversos estudios han propuesto soluciones basadas en técnicas avanzadas de aprendizaje automático y aprendizaje profundo para predecir la demanda energética y optimizar estrategias de respuesta a la demanda (Demand Response, DR). Sin embargo, muchos de estos modelos presentan un alto costo computacional, lo que dificulta su implementación en dispositivos con recursos limitados, como sistemas embebidos o dispositivos de borde.

En este contexto, el problema principal abordado por los autores consiste en desarrollar modelos de predicción de demanda energética que sean **precisos, interpretables y computacionalmente eficientes**, capaces de ser implementados en entornos con restricciones de hardware.

El objetivo de la investigación es proponer un **framework de machine learning ligero** que permita predecir la carga de vehículos eléctricos y optimizar estrategias de respuesta a la demanda, manteniendo un equilibrio entre precisión predictiva y eficiencia computacional Durrani et al., 2026a.

2.1.12.2. Base de datos

La investigación utiliza un conjunto de datos público proveniente de Kaggle denominado *Electric Vehicle Charging Dataset*. Este dataset contiene información realista sobre el comportamiento de carga de vehículos eléctricos, incluyendo variables como:

- Tiempo de conexión
- Energía suministrada (kWh Delivered)
- Duración de la carga
- Variables temporales (hora, día, mes, día de la semana)

El dataset original contiene más de **2.1 millones de registros**, lo que representa un volumen significativo de datos para el análisis Durrani et al., 2026a.

Sin embargo, debido a la orientación del estudio hacia entornos de bajo consumo computacional, los autores realizaron un proceso de **downsampling**, seleccionando una muestra representativa de **50,000 registros**. Esto permitió reducir la carga computacional sin perder la representatividad estadística de los datos.

Además, se llevó a cabo un proceso de **ingeniería de características**, donde se generaron variables temporales adicionales como:

- | | |
|--------------------|-------|
| ■ Hora del día | ■ Mes |
| ■ Día de la semana | ■ Día |

Estas variables permitieron capturar patrones cíclicos en el comportamiento de carga de los vehículos eléctricos.

2.1.12.3. Metodología empleada por los autores

La metodología propuesta sigue un enfoque estructurado basado en un pipeline de machine learning optimizado para entornos con recursos limitados. Este proceso incluye las siguientes etapas:

1. Preprocesamiento de datos

Se realizó limpieza de datos, normalización y reducción del tamaño del dataset mediante muestreo aleatorio. No se encontraron valores faltantes significativos, lo que facilitó el proceso de modelado Durrani et al., 2026a.

2. Análisis exploratorio de datos (EDA)

El análisis reveló que la variable objetivo (kWh Delivered) presenta una distribución sesgada hacia la derecha, indicando que la mayoría de las sesiones de carga consumen poca energía, mientras que pocas sesiones presentan consumos altos.

Asimismo, se identificaron correlaciones moderadas entre variables temporales y la energía consumida, justificando su inclusión en el modelo.

3. Simulación de estrategias de Demand Response

Se incorporaron siete estrategias de respuesta a la demanda como variables categóricas:

- Peak Clipping
- Valley Filling
- Load Shifting
- Strategic Conservation
- Strategic Load Growth
- Flexible Load Shape
- None

Estas estrategias permiten modelar diferentes escenarios de gestión energética.

4. Modelos de Machine Learning

Se evaluaron cinco modelos de regresión:

- Regresión Lineal (LR)
- Support Vector Regression (SVR)
- K-Nearest Neighbors (KNN)
- Random Forest (RF)
- XGBoost

Estos modelos fueron seleccionados por su balance entre rendimiento y complejidad computacional.

5. Optimización de hiperparámetros

Se utilizó **Grid Search con validación cruzada (3-fold)** para optimizar parámetros como:

- Número de estimadores
- Profundidad máxima
- Tasa de aprendizaje
- Número de vecinos

6. Métricas de evaluación

Los modelos fueron evaluados mediante:

- MAE (Error absoluto medio)
- RMSE
- MSE (Error cuadrático medio)
- R^2

Estas métricas permitieron comparar el desempeño predictivo de cada modelo en diferentes estrategias DR.

2.1.12.4. Resultados obtenidos

Los resultados del estudio evidencian diferencias significativas en el desempeño de los modelos evaluados.

El modelo **XGBoost** obtuvo el mejor rendimiento en la mayoría de las estrategias de respuesta a la demanda, alcanzando valores de:

- $R^2 = 0,975$ en Strategic Conservation
- $R^2 = 0,943$ en Valley Filling

lo que indica una alta capacidad predictiva y ajuste del modelo a los datos Durrani et al., 2026a.

Por otro lado, el modelo **Random Forest** también mostró un buen desempeño, con valores de R^2 superiores a 0.7 en varias estrategias, posicionándose como una alternativa robusta.

En contraste:

- La **Regresión Lineal** presentó bajo desempeño, con valores de R^2 inferiores a 0.5
- El modelo **KNN** mostró alta sensibilidad al ruido y baja capacidad de generalización
- El modelo **SVR** logró resultados intermedios, pero con mayor costo computacional

Los resultados demuestran que los modelos basados en **ensamble (XGBoost y Random Forest)** son más efectivos para la predicción de demanda energética en sistemas de carga de vehículos eléctricos.

Finalmente, la investigación concluye que es posible implementar modelos de machine learning eficientes en entornos con recursos limitados, logrando un balance adecuado entre:

- Precisión
- Interpretabilidad
- Bajo costo computacional

Esto representa un avance importante para la implementación de sistemas inteligentes en redes eléctricas y estaciones de carga de vehículos eléctricos.

2.2. Bases Teóricas

2.2.1. Gestión de la cadena de suministro de productos perecibles

2.2.1.1. Logística de mercancías en descomposición

Se aborda una serie de consideraciones logísticas específicas para productos que tienen un tiempo de vida limitado. Por ejemplo, el manejo de la temperatura durante el transporte y almacenamiento es crucial para preservar la frescura y calidad de los productos. Esto puede involucrar el empleo de recipientes refrigerados, sistemas de vigilancia de temperatura en tiempo real y la selección de rutas que reduzcan al mínimo los tiempos de tránsito y los peligros de exposición a condiciones adversas.

2.2.1.2. Administración de existencias

En el ámbito de los productos perecibles, la gestión de existencias debe equilibrar la necesidad de mantener niveles adecuados de inventario para satisfacer la demanda con el riesgo de excesos y obsolescencia. Estrategias como el análisis predictivo de inventarios, la gestión colaborativa de la demanda y la optimización de la rotación de existencias son esenciales para aumentar la eficacia y reducir el desperdicio.

2.2.1.3. Control de calidad y seguridad alimentaria

La seguridad y calidad de los productos perecederos son elementos vitales de la cadena de suministro. Esto implica implementar prácticas de higiene y manipulación adecuadas en todas las fases del proceso, además de cumplir con regulaciones y estándares de seguridad alimentaria. La trazabilidad de los productos también resulta crucial para identificar y gestionar eficientemente cualquier problema relacionado con la calidad o seguridad que pueda surgir.

2.2.2. Machine Learning

El aprendizaje automático se basa en desarrollar algoritmos que permiten a los programas mejorar su rendimiento de manera autónoma a través de la experiencia. Estos algoritmos procesan grandes volúmenes de datos, identifican patrones y ajustan sus propios parámetros para realizar predicciones o tomar decisiones. A medida que el sistema se expone a más datos, afina su capacidad para realizar tareas específicas sin que sea necesario modificar su programación manualmente (Mitchell, 1997).

El proceso de aprendizaje automático implica etapas como la recopilación de datos, su procesamiento, el entrenamiento del modelo y la evaluación de su precisión. Durante el entrenamiento, el algoritmo ajusta sus parámetros para reducir el error y mejorar el desempeño. El objetivo es que el sistema sea capaz de generalizar a partir de ejemplos previos y realizar predicciones precisas cuando se le presenten nuevos datos.

2.2.2.1. Árboles de decisión

Un árbol de decisión es un método de aprendizaje utilizado para aproximar funciones que devuelven valores discretos. La estructura del modelo resultante se representa como un árbol de decisión, aunque también puede transformarse en un conjunto de reglas tipo "si-entonces" para facilitar su interpretación. Este enfoque es uno de los más populares en la inferencia inductiva y ha sido aplicado con éxito en diversas áreas, como el diagnóstico médico y la evaluación de riesgo crediticio.

El funcionamiento de un árbol de decisión consiste en clasificar instancias ordenándolas desde el nodo raíz hasta un nodo hoja. Cada nodo del árbol representa una prueba o condición sobre un atributo específico de la instancia, y cada rama corresponde a un posible valor de dicho atributo. Para clasificar una instancia, se empieza en el nodo raíz, se evalúa el atributo correspondiente y se sigue la rama que coincide con el valor de este atributo. Este proceso se repite de manera recursiva en los subárboles hasta llegar a un nodo hoja, que proporciona el resultado final de la clasificación. (Mitchell, 1997)

2.2.2.2. Regresión lineal

El modelo de regresión lineal simple describe la relación entre una variable predictora x y una respuesta y , donde dicha relación sigue una línea recta. En este modelo, el intercepto β_0 y la pendiente β_1 son parámetros desconocidos, y ε representa un término de error aleatorio. Se asume que los errores tienen una media cero y una varianza desconocida σ^2 . Además,




Figura 2.7: Árbol de decisión

Fuente: Mitchell, T. M. (1997). Machine learning (Vol. 1, No. 9). New York: McGraw-hill.

comúnmente se supone que los errores no están correlacionados, lo que significa que el valor de un error no depende del valor de otro.

En este contexto, es habitual considerar que el regresor x es controlado por el analista de datos y que se mide con un error despreciable, mientras que la respuesta y se trata como una variable aleatoria. Esto implica que existe una distribución de probabilidad para y en cada valor posible de x . (Montgomery et al., 2013)

$$y = \beta_0 + \beta_1 x + \varepsilon \quad (\text{Ecuación 2.1})$$

2.2.2.3. Support Vector Regression

Support Vector Regression (SVR) es una técnica de aprendizaje supervisado basada en máquinas de soporte vectorial (Support Vector Machines, SVM) utilizada para resolver problemas de regresión. A diferencia de la clasificación, donde el objetivo es encontrar una frontera de decisión que separe las clases, el objetivo de SVR es encontrar una función que prediga el valor de una variable continua. En lugar de clasificar, SVR busca una línea (o hiperplano en dimensiones superiores) que se ajuste a los datos dentro de un margen de error controlado.

El principio clave detrás de SVR es encontrar una función $f(x) = w \cdot x + b$ que se mantenga dentro de una tolerancia de error ε para todos los puntos de datos, minimizando al mismo tiempo la complejidad de la función (medida por la norma de w). Para aquellos puntos que no

pueden mantenerse dentro del margen ε , se introduce una variable de error que permite una penalización. (Wang, 2005)

Dado un conjunto de datos de entrenamiento $\{(x_i, y_i)\}_{i=1}^n$, donde x_i son las entradas y y_i son los valores de salida correspondientes, SVR minimiza la función de costo:

$$\frac{1}{2} \|w\|^2 + C \sum_{i=1}^n (\xi_i + \xi_i^*) \quad (\text{Ecuación 2.2})$$

sujeto a:

$$y_i - (w \cdot x_i + b) \leq \varepsilon + \xi_i \quad (\text{Ecuación 2.3})$$

$$(w \cdot x_i + b) - y_i \leq \varepsilon + \xi_i^* \quad (\text{Ecuación 2.4})$$

$$\xi_i, \xi_i^* \geq 0 \quad (\text{Ecuación 2.5})$$

Aquí: - w y b son los parámetros del modelo (el peso y el sesgo). - ε define un margen de tolerancia alrededor de la línea de predicción. - C es un parámetro de penalización que controla el equilibrio entre el margen de error ε y las desviaciones permitidas. - ξ_i y ξ_i^* son variables de error que permiten algunos puntos fuera del margen de tolerancia. (Wang, 2005)

2.2.2.4. Long Short-Term Memory Network (LSTM)

(Brownlee, 2017) La red LSTM se diferencia de una red MLP (Multi Layer Perceptron) clásica en varios aspectos fundamentales. Aunque, como en una MLP, la LSTM se organiza en capas de neuronas y los datos de entrada atraviesan la red para generar una predicción, comparte también la característica de conexiones recurrentes propias de las redes RNN. Esto significa que las activaciones de un paso anterior se usan como contexto en el siguiente paso temporal. Sin embargo, a diferencia de las RNN convencionales, las LSTM tienen una estructura particular que les permite sortear los obstáculos típicos de entrenamiento y escalado en las RNN. Esta capacidad para superar tales limitaciones y sus notables resultados hacen de las LSTM una técnica especialmente popular.

Uno de los problemas principales de las RNN tradicionales es la dificultad para entrenarlas de manera efectiva. Con frecuencia, el ajuste de pesos resultaba problemático, ya que las actualizaciones se volvían tan pequeñas que carecían de impacto (conocido como "gradientes que desaparecen") o tan grandes que llevaban a cambios abruptos e incluso errores (los llamados "gradientes que explotan"). Las LSTM, gracias a su diseño particular, logran evitar este problema, lo que amplía su capacidad para manejar información de contexto. En las RNN

estándar, la influencia de una entrada sobre la capa oculta y, en última instancia, sobre la salida, tiende a decaer o aumentar exponencialmente al pasar a través de múltiples conexiones recurrentes, limitando la capacidad de acceso a la información previa. Este problema, conocido como "gradiente evanescente", es uno de los desafíos que las LSTM solucionan.

La unidad básica en la red LSTM (Gupta et al., 2022), conocida como célula de memoria, se considera la unidad de procesamiento fundamental, similar a la neurona en redes MLP. Cada célula LSTM incluye pesos y tres puertas especializadas (entrada, salida y olvido), que operan de forma continua de manera similar a los procesos de lectura, escritura y reinicio en un sistema de memoria. Inspirada en el análisis del flujo de error en redes recurrentes previas, la arquitectura de memoria a largo plazo se diseñó para hacer accesibles los retrasos temporales largos, manteniendo el flujo de información estable. Una capa de LSTM está compuesta por bloques de memoria conectados de forma recurrente, lo que permite el aprendizaje eficiente de secuencias y dependencias prolongadas al evitar la rápida degradación o aumento de los gradientes en el tiempo.




Figura 2.8: Arquitectura LSTM

Fuente: D. Gupta et. al, Advanced Machine Intelligence and Signal Processing. (2022). Singapur: Springer Nature Singapore.

2.2.2.5. Prophet

Prophet es un modelo diseñado para realizar pronósticos de series temporales, destacándose por su robustez y flexibilidad para manejar patrones complejos, estacionalidades y datos con valores atípicos. Está pensado para ser intuitivo y fácil de ajustar, permitiendo su uso tanto por expertos como por no especialistas en análisis estadístico. (Hoarau, 2022)

Prophet descompone una serie temporal $y(t)$ en tres componentes principales, sumados

a un término de error aleatorio:

$$y(t) = T(t) + S(t) + H(t) + \varepsilon_t \quad (\text{Ecuación 2.6})$$

Donde: $T(t)$: Describe la tendencia o evolución a largo plazo de la serie. $S(t)$: Captura los patrones estacionales recurrentes. $H(t)$: Representa los efectos asociados a eventos específicos o festivos. ε_t : Corresponde al ruido aleatorio, que se modela como ruido gaussiano con media cero.

Componente de Tendencia ($T(t)$) El modelo permite dos enfoques para capturar tendencias:

1. Crecimiento Lineal: Modela la tendencia como una línea recta con puntos de cambio:

$$T(t) = (k + a(t)\delta)t + (m + a(t)\gamma) \quad (\text{Ecuación 2.7})$$

Donde: k es la tasa de crecimiento inicial. m es el intercepto inicial. $a(t)$ indica si hay puntos de cambio en t . δ y γ ajustan la pendiente e intercepto en dichos puntos.

2. Crecimiento Logístico: Se utiliza cuando el crecimiento está limitado por una capacidad máxima C :

$$T(t) = \frac{C}{1 + \exp(-k(t - m))} \quad (\text{Ecuación 2.8})$$

Aquí: C es el valor máximo alcanzable. k es la tasa de crecimiento. m es el tiempo en el que la serie alcanza la mitad de C .

Componente Estacional ($S(t)$) La estacionalidad se representa mediante una combinación de funciones seno y coseno, que permiten capturar patrones periódicos:

$$S(t) = \sum_{n=1}^N \left[a_n \cos\left(\frac{2\pi nt}{P}\right) + b_n \sin\left(\frac{2\pi nt}{P}\right) \right] \quad (\text{Ecuación 2.9})$$

Donde: P es el periodo del ciclo estacional (por ejemplo, 365 días para patrones anuales). a_n y b_n son coeficientes que determinan la amplitud y la forma del patrón.

Componente de Eventos y Festividades ($H(t)$). Este componente permite incluir efectos asociados a eventos específicos, modelados como variables indicadoras:

$$H(t) = \sum_{i=1}^L \text{indicador}(t \in \text{evento}_i) \cdot \beta_i \quad (\text{Ecuación 2.10})$$

Donde: evento_i representa un evento particular. β_i es la magnitud del impacto causado por dicho evento.

2.2.2.6. Autoregressive Integrated Moving Average (ARIMA)

ARIMA es un modelo estadístico ampliamente utilizado en series temporales para predecir valores futuros basándose en patrones observados en datos históricos. Es particularmente útil para datos que no son estacionarios, ya que incluye un componente de diferenciación para convertirlos en estacionarios.

El modelo ARIMA está compuesto por tres partes principales:

AR (Autoregressive): La parte autorregresiva indica que los valores pasados de la serie tienen un impacto directo en el valor actual. Está definido por un orden p , que representa el número de rezagos incluidos.

I (Integrated): La parte integrada implica la diferenciación de la serie para eliminar tendencias y hacerla estacionaria. El orden d especifica cuántas veces se diferencia la serie.

MA (Moving Average): La parte de promedio móvil indica que los errores pasados (residuos) afectan al valor actual. El orden q determina el número de términos de error pasados que se usan.

2.2.3. Modelos predictivos de demanda

2.2.3.1. Análisis de secuencias temporales

Las herramientas de modelado de secuencias temporales son esenciales para anticipar la demanda de productos que tienen una vida útil limitada. Estos modelos tienen la capacidad de detectar patrones estacionales, tendencias a largo plazo y efectos cíclicos en los datos históricos de ventas. Es crucial considerar factores como eventos estacionales, promociones de ventas y cambios en las preferencias del consumidor al desarrollar y ajustar estos modelos.

2.2.3.2. Inteligencia artificial y exploración de datos

Las técnicas de inteligencia artificial y exploración de datos ofrecen la capacidad de analizar grandes cantidades de datos de manera eficiente y descubrir patrones complejos que pueden no ser evidentes para los métodos tradicionales de análisis. Al emplear algoritmos de inteligencia artificial como regresión, agrupamiento o clasificación, es factible construir modelos predictivos más avanzados y adaptables que puedan identificar relaciones no lineales e interacciones entre variables.

2.2.3.3. Confirmación y optimización de modelos

La validación y optimización de modelos son procedimientos continuos e iterativos que aseguran la precisión y relevancia de los modelos predictivos de demanda. Esto implica comparar las proyecciones del modelo con datos reales y ajustar los parámetros del modelo según sea necesario para mejorar su rendimiento. La validación cruzada, la confirmación de hipótesis y el seguimiento constante de las métricas de rendimiento son prácticas convencionales en este proceso.

2.2.4. Series de tiempo

Las series temporales representan secuencias de datos dispuestos en orden cronológico, recolectados a lo largo de un periodo de tiempo. Estos datos pueden abarcar una amplia gama de fenómenos, tales como el valor de acciones, la temperatura diaria, las ventas mensuales, el tráfico diario, la demanda de productos, entre otros. El análisis de series temporales tiene como objetivo comprender y modelar la estructura, patrones y tendencias presentes en los datos a lo largo del tiempo. A diferencia de otros tipos de datos, como los datos de corte transversal, las series temporales poseen una dimensión temporal intrínseca y se emplean para realizar predicciones o inferir información sobre el futuro o el comportamiento de la serie. (Ocampo et al., 2004). Según Toro Ocampo, Mejía Giraldo y Salazar Isaza (2004), las series temporales comúnmente presentan ciertas características, tales como la tendencia (una dirección general de cambio a lo largo del tiempo), la estacionalidad (patrones recurrentes que se repiten en intervalos regulares) y la autocorrelación. El análisis de series temporales comprende el uso de técnicas y modelos específicos para descomponer y visualizar la serie, identificar patrones, modelar la tendencia y la estacionalidad, así como realizar pronósticos y predicciones.

2.2.5. Tipos de series temporales

Según Ocampo et al., 2004, hay varios tipos de series temporales que se clasifican según sus características y propiedades. A continuación, se describen algunos tipos comunes:

- **Tendencia:** Una serie temporal con tendencia muestra un cambio sistemático y sostenido en una dirección a lo largo del tiempo, ya sea ascendente (crecimiento) o descendente (decrecimiento).
- **Estacionalidad:** Las series temporales con estacionalidad exhiben patrones recurrentes que se repiten en intervalos regulares, como estacionalidad diaria, mensual o anual. Por




Figura 2.9: Series de tiempo

Fuente: P. Molina. et al., (2017). Modelación econométrica de la demanda de semilla de chile dulce Lamuyo y Blocky en Costa Rica mediante series de tiempo univariadas

ejemplo, la demanda de helados puede mostrar un patrón estacional con un aumento en los meses de verano.

- **Ciclos:** Los ciclos representan fluctuaciones recurrentes que no siguen un patrón de estacionalidad fijo. Estas fluctuaciones pueden tener una duración más larga que los patrones estacionales y no ocurren en intervalos regulares.
- **Ruido o componente aleatorio:** El ruido o componente aleatorio en una serie temporal representa la variabilidad aleatoria o irregular que no se puede atribuir a ninguna tendencia, estacionalidad o ciclo específico. Puede deberse a factores aleatorios, eventos imprevistos o errores de medición.
- **Serie temporal estacionaria:** No muestra una tendencia sistemática a lo largo del tiempo y tiene una varianza constante en diferentes períodos. Esto implica que la media y la autocorrelación no dependen del tiempo.
- **Serie temporal no estacionaria:** Muestra una tendencia, es decir, un cambio sistemático en la media o en la varianza a lo largo del tiempo (Ocampo et al., 2004).

2.2.6. Elementos de la serie de tiempo

Según Fierro Torres et al., 2022, tenemos las siguientes:

- **Tendencia secular:** La influencia en la tendencia a largo plazo de una serie de datos se deriva de diversos factores que operan a lo largo de períodos extensos. En términos simples, la tendencia de una serie temporal representa el gradual y constante patrón de sus fluctuaciones, originado por fuerzas duraderas asociadas con el crecimiento o declive, como cambios en la población, demografía, ingresos, salud, educación y tecnología. Dichas tendencias pueden manifestarse de distintas maneras: algunas incrementan de forma continua, otras decrecen, y algunas se mantienen estables durante períodos específicos.
- **Variación estacional:** El componente estacional en una serie de tiempo se refiere a las fluctuaciones en los datos causadas por influencias estacionales, las cuales se caracterizan por patrones repetitivos que se repiten. Por ejemplo, un fabricante de piscinas inflables espera una disminución en las ventas durante los meses de otoño e invierno, con picos de ventas durante la primavera y el verano.
- **Variación cíclica:** Las series temporales suelen mostrar patrones alternados de puntos ubicados tanto por encima como por debajo de la línea de tendencia, los cuales se extienden por más de un año, incluso después de haber eliminado los componentes estacionales e irregulares. Un ejemplo de esta variación son los ciclos económicos, que representan períodos recurrentes asociados con fases de prosperidad, recesión, depresión.
- **Variación irregular:** Se atribuye la existencia del componente irregular en una serie temporal a factores de corto plazo que son impredecibles y no se repiten en la serie. Este componente es responsable de la variabilidad aleatoria de la serie y su impacto no puede ser previsto.
 1. Variaciones generadas por eventos particulares claramente identificables, como elecciones, inundaciones, huelgas o terremotos.
 2. Variaciones aleatorias o casuales, razones no se pueden determinar de manera precisa, pero son propensas a igualarse a largo plazo.

2.2.7. Aplicación de las series de tiempo

Las series temporales cumplen dos objetivos principales: comprender las fuerzas que afectan a los datos e identificar la estructura que seguirán los datos observados. Este proceso implica ajustar modelos y emplearlos para efectuar pronósticos, llevar a cabo seguimientos, obtener retroalimentación y ejercer control en tiempo real o en el futuro. En resumen, permite tanto comprender las causas subyacentes de los datos como utilizar ese conocimiento para realizar predicciones y tomar decisiones informadas. (Brockwell y Davis, 2002)




Figura 2.10: Componentes de la serie temporal

Fuente: F, Torres. et al., (2022). Análisis comparativo de modelos tradicionales y modernos para pronóstico de la demanda: enfoques y características. RIDE. Revista Iberoamericana para la Investigación y el Desarrollo Educativo

2.2.7.1. Gradient Boosting

El Gradient Boosting es un algoritmo de aprendizaje supervisado perteneciente a la familia de los métodos de ensamble (ensemble methods), específicamente basado en el enfoque de boosting. Su objetivo principal es construir un modelo predictivo fuerte a partir de la combinación de múltiples modelos débiles, generalmente árboles de decisión de baja profundidad. El objetivo del Gradient Boosting es minimizar una función de pérdida $L(y, F(x))$, donde y representa el valor real y $F(x)$ la predicción del modelo. (Friedman, 2001)

El modelo se construye de manera aditiva como:

$$F_m(x) = F_{m-1}(x) + \gamma_m h_m(x) \quad (\text{Ecuación 2.11})$$

donde:

- $F_m(x)$ es el modelo en la iteración m
- $h_m(x)$ es el modelo débil en la iteración m
- γ_m es el coeficiente de ajuste (learning rate)




Figura 2.11: Aplicaciones de serie temporal

Fuente: Brockwell, P. et al., (2002). Introduction to time series and forecasting. New York, NY: Springer New York

En cada iteración, el modelo se ajusta a los pseudo-residuos, definidos como el gradiente negativo de la función de pérdida:

$$r_{im} = - \left[\frac{\partial L(y_i, F(x_i))}{\partial F(x_i)} \right]_{F(x)=F_{m-1}(x)} \quad (\text{Ecuación 2.12})$$

donde:

- r_{im} es el pseudo-residuo para la observación i en la iteración m

El valor óptimo de γ_m se obtiene resolviendo:

$$\gamma_m = \arg \min_{\gamma} \sum_{i=1}^n L(y_i, F_{m-1}(x_i) + \gamma h_m(x_i)) \quad (\text{Ecuación 2.13})$$

Finalmente, el modelo se actualiza iterativamente hasta alcanzar el número de iteraciones deseado o un criterio de convergencia.

2.2.7.2. XGBoost

XGBoost (Extreme Gradient Boosting) es un algoritmo de aprendizaje supervisado basado en árboles de decisión y técnicas de boosting. Fue desarrollado como una implementación optimizada del método Gradient Boosting, con mejoras orientadas al rendimiento computacional, regularización del modelo y escalabilidad para grandes volúmenes de datos. Este algoritmo

ha sido ampliamente utilizado en problemas de clasificación, regresión y ranking, debido a su capacidad para obtener alta precisión predictiva y manejar eficientemente datos de gran dimensión. Una de sus principales ventajas consiste en incorporar mecanismos de penalización de complejidad que permiten controlar el sobreajuste y mejorar la capacidad de generalización del modelo. (Chen y Guestrin, 2016)

XGBoost construye un modelo de manera secuencial, donde cada nuevo árbol se incorpora con el propósito de corregir los errores generados por los árboles previamente entrenados.

A diferencia del Gradient Boosting tradicional, XGBoost utiliza una expansión de segundo orden de la función de pérdida mediante gradiente y hessiano. Esto permite una optimización más precisa y estable durante el entrenamiento.

El modelo final se expresa como la suma de árboles de decisión:

$$\hat{y}_i = \sum_{k=1}^K f_k(x_i), \quad f_k \in \mathcal{F} \quad (\text{Ecuación 2.14})$$

donde:

- $\hat{y}_i$ es la predicción para la observación i
- $\mathcal{F}$ es el espacio de árboles de regresión
- f_k representa el árbol k
- K es el número total de árboles

El objetivo de XGBoost es minimizar una función objetivo compuesta por una función de pérdida y un término de regularización:

$$\mathcal{L}(\phi) = \sum_{i=1}^n l(y_i, \hat{y}_i) + \sum_{k=1}^K \Omega(f_k) \quad (\text{Ecuación 2.15})$$

donde:

- $l(y_i, \hat{y}_i)$ es la función de pérdida
- $\Omega(f_k)$ es el término de regularización del árbol

La función de regularización está definida como:

$$\Omega(f) = \gamma T + \frac{1}{2} \lambda \sum_{j=1}^T w_j^2 \quad (\text{Ecuación 2.16})$$

donde:

- T es el número de hojas del árbol
- γ penaliza el número de hojas
- w_j es el peso asociado a la hoja j
- λ controla la magnitud de los pesos

En la iteración t , el modelo se actualiza agregando un nuevo árbol:

$$\hat{y}_i^{(t)} = \hat{y}_i^{(t-1)} + f_t(x_i) \quad (\text{Ecuación 2.17})$$

Para facilitar la optimización, XGBoost utiliza una aproximación de segundo orden de la función objetivo:

$$\mathcal{L}^{(t)} \approx \sum_{i=1}^n \left[l(y_i, \hat{y}_i^{(t-1)}) + g_i f_t(x_i) + \frac{1}{2} h_i f_t^2(x_i) \right] + \Omega(f_t) \quad (\text{Ecuación 2.18})$$

donde:

$$g_i = \frac{\partial l(y_i, \hat{y}_i^{(t-1)})}{\partial \hat{y}_i^{(t-1)}} \quad (\text{Ecuación 2.19})$$

$$h_i = \frac{\partial^2 l(y_i, \hat{y}_i^{(t-1)})}{\partial (\hat{y}_i^{(t-1)})^2} \quad (\text{Ecuación 2.20})$$

Aquí, g_i representa el gradiente de primer orden y h_i el hessiano o derivada de segundo orden.

2.2.7.3. Random Forest

Random Forest es un algoritmo de aprendizaje supervisado basado en técnicas de ensamble, propuesto por Leo Breiman en 2001. Su principio fundamental consiste en construir múltiples árboles de decisión durante el entrenamiento y combinar sus predicciones para obtener un modelo más robusto y con mayor capacidad de generalización.

Este algoritmo es ampliamente utilizado en problemas de clasificación y regresión debido a su capacidad para reducir el sobreajuste que suele presentarse en árboles de decisión individuales. Además, Random Forest presenta buen desempeño frente a datos con alta dimensionalidad, ruido y relaciones no lineales entre variables. (Breiman, 2001)

Random Forest pertenece a la familia de métodos *bagging* (*bootstrap aggregating*). El procedimiento consiste en generar múltiples subconjuntos de entrenamiento mediante muestreo aleatorio con reemplazo a partir del conjunto de datos original.

Para cada subconjunto se entrena un árbol de decisión independiente. Durante la construcción de cada nodo, el algoritmo selecciona aleatoriamente un subconjunto de variables predictoras, lo cual introduce diversidad entre los árboles.

En problemas de clasificación, la predicción final se obtiene mediante votación mayoritaria entre los árboles. En problemas de regresión, la salida final corresponde al promedio de las predicciones individuales.

Sea un conjunto de entrenamiento:

$$D = \{(x_i, y_i)\}_{i=1}^n \quad (\text{Ecuación 2.21})$$

donde x_i representa el vector de variables de entrada y y_i la variable objetivo.

Se generan B muestras bootstrap del conjunto de entrenamiento, y para cada muestra se entrena un árbol de decisión $h_b(x)$.

En problemas de clasificación, la predicción final se define como:

$$\hat{y} = \text{mode}\{h_1(x), h_2(x), \dots, h_B(x)\} \quad (\text{Ecuación 2.22})$$

donde mode representa la clase más frecuentemente predicha por los árboles.

En problemas de regresión, la predicción final se obtiene mediante el promedio:

$$\hat{y} = \frac{1}{B} \sum_{b=1}^B h_b(x) \quad (\text{Ecuación 2.23})$$

Durante la construcción de cada árbol, en cada nodo se selecciona aleatoriamente un subconjunto de m variables entre las p variables disponibles, con la restricción:

$$m < p \quad (\text{Ecuación 2.24})$$

Este proceso reduce la correlación entre los árboles y mejora la capacidad de generalización del modelo.

2.2.7.4. K-Nearest Neighbors

K-Nearest Neighbors (KNN) es un algoritmo de aprendizaje supervisado utilizado en problemas de clasificación y regresión. Fue propuesto como un método no paramétrico basado en la similitud entre observaciones, donde la predicción de una nueva instancia se realiza

a partir de los ejemplos más cercanos presentes en el conjunto de entrenamiento. Una de las principales características de KNN es que no construye explícitamente un modelo durante la fase de entrenamiento. En lugar de ello, almacena los datos observados y realiza el proceso de inferencia cuando se presenta una nueva observación. Debido a su simplicidad conceptual y facilidad de implementación, es uno de los algoritmos fundamentales dentro del aprendizaje automático.

El principio de funcionamiento de KNN consiste en identificar las k observaciones del conjunto de entrenamiento más cercanas a una nueva observación, de acuerdo con una medida de distancia definida previamente. En problemas de clasificación, la clase asignada corresponde a la categoría mayoritaria entre los vecinos más próximos. En problemas de regresión, la predicción se obtiene como el promedio de los valores de dichos vecinos. El desempeño del algoritmo depende principalmente de tres factores: el valor de k , la métrica de distancia utilizada y la escala de las variables predictoras. (Hastie et al., 2009a)

Sea un conjunto de entrenamiento definido como:

$$D = \{(x_i, y_i)\}_{i=1}^n \quad (\text{Ecuación 2.25})$$

donde $x_i \in \mathbb{R}^p$ representa el vector de características y y_i la variable objetivo asociada.

Dada una nueva observación x , se calcula la distancia entre x y cada observación del conjunto de entrenamiento. Una de las métricas más utilizadas es la distancia euclidiana:

$$d(x, x_i) = \sqrt{\sum_{j=1}^p (x_j - x_{ij})^2} \quad (\text{Ecuación 2.26})$$

Posteriormente, se seleccionan los k vecinos más cercanos:

$$N_k(x) = \{x_{(1)}, x_{(2)}, \dots, x_{(k)}\} \quad (\text{Ecuación 2.27})$$

donde $x_{(j)}$ representa la observación correspondiente al j -ésimo vecino más próximo.

En problemas de clasificación, la predicción se obtiene mediante votación mayoritaria:

$$\hat{y} = \text{mode}\{y_i : x_i \in N_k(x)\} \quad (\text{Ecuación 2.28})$$

En problemas de regresión, la predicción se define como el promedio de las respuestas de los vecinos seleccionados:

$$\hat{y} = \frac{1}{k} \sum_{x_i \in N_k(x)} y_i \quad (\text{Ecuación 2.29})$$

El valor de k controla el grado de suavizado del modelo. Valores pequeños pueden generar alta sensibilidad al ruido, mientras que valores grandes tienden a producir fronteras de decisión más estables.

2.2.7.5. Holt-Winters

El método de Holt-Winters es una técnica de suavizamiento exponencial utilizada para el análisis y pronóstico de series temporales que presentan tendencia y estacionalidad. Fue desarrollado como una extensión del método de suavizamiento exponencial de Holt, incorporando un componente adicional que permite modelar patrones estacionales recurrentes.

Este método es ampliamente utilizado en problemas de pronóstico de demanda, ventas, consumo energético y otras aplicaciones donde los datos presentan comportamiento temporal estructurado. Su principal ventaja radica en su capacidad para capturar simultáneamente nivel, tendencia y estacionalidad dentro de una misma formulación. (Hyndman y Athanasopoulos, 2018a)

El método de Holt-Winters descompone una serie temporal en tres componentes fundamentales:

- nivel (l_t)
- tendencia (b_t)
- estacionalidad (s_t)

En cada instante de tiempo, estos componentes se actualizan utilizando ponderaciones exponenciales, otorgando mayor importancia a las observaciones recientes.

Existen dos variantes principales del método: aditiva y multiplicativa. La versión aditiva se utiliza cuando la magnitud de la estacionalidad permanece aproximadamente constante en el tiempo, mientras que la versión multiplicativa es apropiada cuando la amplitud estacional varía proporcionalmente con el nivel de la serie.

Sea y_t una serie temporal observada en el instante t , y sea m la longitud del período estacional.

En la versión aditiva, las ecuaciones de actualización son las siguientes.

Actualización del nivel:

$$l_t = \alpha(y_t - s_{t-m}) + (1 - \alpha)(l_{t-1} + b_{t-1}) \quad (\text{Ecuación 2.30})$$

Actualización de la tendencia:

$$b_t = \beta(l_t - l_{t-1}) + (1 - \beta)b_{t-1} \quad (\text{Ecuación 2.31})$$

Actualización de la estacionalidad:

$$s_t = \gamma(y_t - l_t) + (1 - \gamma)s_{t-m} \quad (\text{Ecuación 2.32})$$

donde:

- l_t representa el nivel de la serie en el instante t
- b_t representa la tendencia
- s_t representa el componente estacional
- α , β y γ son parámetros de suavizamiento tales que $0 < \alpha, \beta, \gamma < 1$

El pronóstico para h períodos hacia adelante se calcula mediante:

$$\hat{y}_{t+h} = l_t + hb_t + s_{t-m+h_m} \quad (\text{Ecuación 2.33})$$

donde:

$$h_m = ((h - 1) \text{ mód } m) + 1 \quad (\text{Ecuación 2.34})$$

En la variante multiplicativa, el componente estacional interviene de forma proporcional.

Actualización del nivel:

$$l_t = \alpha \left(\frac{y_t}{s_{t-m}} \right) + (1 - \alpha)(l_{t-1} + b_{t-1}) \quad (\text{Ecuación 2.35})$$

Actualización de la estacionalidad:

$$s_t = \gamma \left(\frac{y_t}{l_t} \right) + (1 - \gamma)s_{t-m} \quad (\text{Ecuación 2.36})$$

Pronóstico:

$$\hat{y}_{t+h} = (l_t + hb_t) s_{t-m+h_m} \quad (\text{Ecuación 2.37})$$

2.2.7.6. Naive

El método Naive es una técnica básica de pronóstico de series temporales utilizada como referencia en modelos de predicción. Su principio consiste en asumir que el valor futuro de una variable será igual al valor observado en el período inmediatamente anterior.

A pesar de su simplicidad, el método Naive posee gran importancia práctica, ya que suele emplearse como modelo base de comparación para evaluar el desempeño de métodos de pronóstico más complejos. En numerosas aplicaciones, especialmente cuando la serie presenta alta persistencia temporal, puede producir resultados competitivos. (Hyndman y Athanasopoulos, 2018b)

El enfoque del método Naive parte del supuesto de que la mejor estimación del siguiente valor observado es el último valor disponible de la serie.

Este procedimiento no requiere estimación de parámetros ni entrenamiento de modelos. La información histórica se resume únicamente en la observación más reciente.

En series temporales con estacionalidad también existe una variante denominada *Seasonal Naive*, en la cual el valor futuro se estima utilizando el valor correspondiente al mismo período estacional anterior.

Sea y_t una serie temporal observada en el instante t .

El pronóstico de un período hacia adelante se define como:

$$\hat{y}_{t+1} = y_t \quad (\text{Ecuación 2.38})$$

De forma general, el pronóstico para h períodos hacia adelante está dado por:

$$\hat{y}_{t+h} = y_t \quad (\text{Ecuación 2.39})$$

Esto implica que todas las predicciones futuras corresponden al último valor observado de la serie.

En el caso de series temporales estacionales, sea m la longitud del período estacional. El método Seasonal Naive se define como:

$$\hat{y}_{t+h} = y_{t+h-m} \quad (\text{Ecuación 2.40})$$

donde el pronóstico se obtiene utilizando el valor observado en el mismo período de la estación anterior.

Este método es especialmente útil como línea base de comparación, ya que permite determinar si modelos más sofisticados aportan mejoras reales en capacidad predictiva.

2.2.8. Computación en la nube

La computación en la nube (*cloud computing*) es un modelo de provisión de recursos informáticos bajo demanda a través de internet. Permite acceder a capacidad de procesamiento, almacenamiento, redes y servicios de software sin necesidad de que la organización mantenga infraestructura física propia.

De acuerdo con el National Institute of Standards and Technology (NIST), este paradigma se caracteriza por acceso ubicuo a recursos compartidos, aprovisionamiento rápido, elasticidad y escalabilidad. Estas propiedades permiten que los sistemas se adapten dinámicamente a variaciones en carga de trabajo, volumen de datos y número de usuarios.

En proyectos de analítica de datos y pronóstico, la computación en la nube facilita el despliegue de aplicaciones que integran procesamiento, visualización y acceso remoto a resultados. Además, favorece la reproducibilidad, la disponibilidad y la colaboración entre usuarios, lo cual resulta especialmente relevante en entornos de investigación aplicada.

2.2.9. Streamlit

Streamlit es un framework de código abierto orientado al desarrollo de aplicaciones web interactivas para ciencia de datos y aprendizaje automático utilizando el lenguaje Python.

Su principal característica consiste en permitir la construcción de interfaces de usuario de manera declarativa y con bajo nivel de complejidad técnica. A partir de scripts en Python, es posible integrar visualizaciones, tablas, métricas, formularios y componentes interactivos que facilitan la exploración de datos y la presentación de resultados analíticos.

En el contexto de una investigación orientada a pronóstico, Streamlit permite materializar los modelos desarrollados en una aplicación accesible mediante navegador web, facilitando la interacción con usuarios finales y la consulta de resultados en tiempo real.

2.2.10. Gestión de inventarios

La gestión de inventarios comprende el conjunto de actividades orientadas a planificar, controlar y administrar los niveles de existencias dentro de una organización. Su finalidad

consiste en asegurar la disponibilidad de productos para atender la demanda, minimizando simultáneamente costos asociados al almacenamiento, reposición, faltantes y pérdidas.(Chopra, 2019)

En empresas comerciales, una adecuada gestión de inventarios permite mantener equilibrio entre el nivel de servicio al cliente y la eficiencia operativa. Cuando los niveles de inventario son insuficientes pueden producirse quiebres de stock y pérdida de ventas; por el contrario, cuando los niveles son excesivos se incrementan los costos de almacenamiento, inmovilización de capital y riesgo de obsolescencia o deterioro.

2.2.10.1. Abastecimiento

El abastecimiento es el proceso mediante el cual una organización planifica, adquiere y repone los bienes necesarios para garantizar la continuidad de sus operaciones. Este proceso comprende actividades como la planificación de requerimientos, selección de proveedores, programación de pedidos y seguimiento de entregas.

En el contexto comercial, las decisiones de abastecimiento dependen en gran medida de la estimación de la demanda futura. Un proceso de abastecimiento basado en información predictiva permite reducir incertidumbre, mejorar la disponibilidad de productos y optimizar la asignación de recursos destinados a compras.

2.2.10.2. Productos perecibles

Los productos perecibles son bienes que presentan una vida útil limitada y cuya calidad se deteriora progresivamente con el transcurso del tiempo. Debido a esta característica, su almacenamiento prolongado incrementa la probabilidad de pérdidas económicas asociadas a vencimiento, deterioro físico o reducción de valor comercial.

La gestión de productos perecibles requiere especial atención en la planificación de inventarios, ya que las decisiones de reposición deben considerar simultáneamente la demanda esperada, la frecuencia de abastecimiento y el horizonte de conservación del producto.

En empresas dedicadas a la comercialización de productos perecibles, un pronóstico adecuado de la demanda permite reducir desperdicios, mejorar la disponibilidad y contribuir a una operación más eficiente.

2.2.10.3. Rotación de inventarios

La rotación de inventarios es un indicador que mide la frecuencia con que los productos son vendidos y repuestos durante un período determinado. Este indicador permite evaluar la velocidad de movimiento de los inventarios y el grado de eficiencia en la utilización de los recursos almacenados. Heizer et al., 2017

Matemáticamente, la rotación de inventarios puede expresarse como:

$$\text{Rotación de inventarios} = \frac{\text{Costo de ventas}}{\text{Inventario promedio}} \quad (\text{Ecuación 2.41})$$

Un valor alto de rotación generalmente indica que los productos tienen mayor dinamismo comercial y menor permanencia en almacén. En productos perecibles, una adecuada rotación contribuye a disminuir riesgos de vencimiento y deterioro.

2.3. Marco Conceptual

2.3.1. Predicción de demanda

La predicción de demanda se entiende como el proceso mediante el cual se estima el comportamiento futuro de las ventas o requerimientos de productos a partir del análisis de datos históricos, patrones temporales y variables que pueden influir en el consumo. En el contexto de una empresa retail, esta predicción permite anticipar cuántas unidades de un producto podrían venderse en un periodo determinado, lo cual resulta fundamental para planificar compras, gestionar inventarios y reducir decisiones basadas únicamente en la intuición.

En esta investigación, la predicción de demanda cumple un rol central, debido a que permite transformar los registros históricos de ventas en información útil para la toma de decisiones. A través de modelos de series temporales y machine learning, se busca identificar patrones de comportamiento en la demanda, tales como variaciones por días de la semana, estacionalidad, tendencias de crecimiento o disminución, y cambios asociados a factores externos. De esta manera, la predicción no solo permite estimar ventas futuras, sino también mejorar el proceso de reabastecimiento de productos en la empresa retail.

2.3.2. Demanda en empresas retail

La demanda en una empresa retail representa la cantidad de productos que los clientes están dispuestos a adquirir en un periodo determinado. Esta demanda puede variar de acuerdo con factores como el precio, la disponibilidad del producto, promociones, hábitos de consumo, días festivos, temporadas, ubicación del establecimiento y comportamiento del mercado.

En el caso de productos de consumo frecuente o perecibles, la demanda suele presentar alta variabilidad, ya que los clientes pueden modificar sus compras según la necesidad diaria, la frescura del producto o las condiciones del entorno. Por ello, en el sector retail resulta necesario analizar la demanda desde una perspectiva dinámica, considerando que no todos los productos se comportan de la misma manera. Algunos productos presentan ventas constantes, mientras que otros muestran picos de consumo en determinados días o temporadas.

Para la presente investigación, comprender la demanda permite establecer una base para seleccionar los datos adecuados, aplicar técnicas de análisis temporal y construir modelos predictivos que apoyen la planificación del reabastecimiento.

2.3.3. Series temporales

Una serie temporal es un conjunto de observaciones registradas de manera ordenada en el tiempo. En el contexto de ventas retail, una serie temporal puede estar formada por las ventas diarias, semanales o mensuales de un producto o familia de productos. Su principal característica es que cada dato se relaciona con un momento específico, lo que permite analizar la evolución de la demanda a lo largo del tiempo.

El análisis de series temporales permite identificar patrones como tendencia, estacionalidad, ciclos y variaciones aleatorias. Estos elementos son importantes porque ayudan a comprender si la demanda aumenta, disminuye, se repite en ciertos periodos o presenta comportamientos irregulares. En el caso de una empresa retail, este análisis permite anticipar comportamientos futuros y mejorar la planificación de inventarios.

En la presente investigación, las series temporales constituyen la base para el desarrollo de modelos predictivos, ya que permiten trabajar con datos históricos de ventas organizados cronológicamente.

2.3.4. Tendencia

La tendencia es el comportamiento general que sigue una serie temporal durante un periodo prolongado. Puede ser ascendente, descendente o estable. En el análisis de demanda, una tendencia ascendente indica que las ventas de un producto aumentan con el tiempo, mientras que una tendencia descendente muestra una disminución progresiva en el consumo.

En el contexto retail, identificar la tendencia es importante porque permite reconocer productos con crecimiento sostenido, productos en disminución o productos con comportamiento estable. Esta información ayuda a tomar decisiones de compra y reabastecimiento más adecuadas. Por ejemplo, si un producto presenta una tendencia creciente, la empresa puede aumentar progresivamente sus pedidos; si presenta una tendencia decreciente, puede reducir sus compras para evitar sobrestock.

2.3.5. Variación aleatoria o ruido

La variación aleatoria, también denominada ruido, corresponde a los cambios impredecibles que ocurren en una serie temporal y que no responden claramente a una tendencia o patrón estacional. En las ventas retail, estas variaciones pueden deberse a factores inesperados como cambios repentinos en el comportamiento del consumidor, problemas de abastecimiento, eventos externos, errores de registro o situaciones excepcionales del mercado.

Aunque el ruido no siempre puede eliminarse por completo, es importante identificarlo y controlarlo durante el procesamiento de datos, ya que puede afectar la precisión del modelo predictivo. Un modelo adecuado debe ser capaz de reconocer los patrones principales sin ajustarse excesivamente a variaciones aleatorias.

2.3.6. Machine Learning

El machine learning, o aprendizaje automático, es una rama de la inteligencia artificial que permite a los sistemas aprender a partir de datos y mejorar su desempeño en una tarea específica sin ser programados manualmente para cada situación. En lugar de depender únicamente de reglas fijas, los algoritmos de machine learning identifican patrones en los datos históricos y los utilizan para realizar predicciones o clasificaciones.

En el contexto de esta investigación, el machine learning se aplica a la predicción de demanda en una empresa retail. Su utilidad radica en que puede analizar grandes volúmenes de datos de ventas, detectar relaciones entre variables y generar pronósticos que apoyen la toma

de decisiones sobre reabastecimiento. A diferencia de métodos tradicionales, algunos modelos de machine learning pueden capturar relaciones no lineales y comportamientos complejos de la demanda.

Por ello, el machine learning representa una herramienta clave para mejorar la precisión del pronóstico, reducir errores de abastecimiento y fortalecer la gestión de inventarios.

2.3.7. Aprendizaje supervisado

El aprendizaje supervisado es un tipo de machine learning en el cual el modelo se entrena utilizando datos históricos que contienen variables de entrada y una variable objetivo conocida. En el caso de esta investigación, las variables de entrada pueden ser la fecha, día de la semana, mes, precio, cantidad vendida anteriormente o familia de producto, mientras que la variable objetivo corresponde a la demanda o cantidad vendida.

El objetivo del aprendizaje supervisado es que el modelo aprenda la relación entre las variables explicativas y la demanda, para luego realizar predicciones sobre datos nuevos. En una empresa retail, este enfoque permite construir modelos capaces de estimar ventas futuras a partir del comportamiento pasado.

2.3.8. Modelos de regresión

Los modelos de regresión son técnicas utilizadas para predecir valores numéricos continuos. En el caso de la predicción de demanda, estos modelos permiten estimar la cantidad de productos que podrían venderse en un periodo futuro. A diferencia de los modelos de clasificación, que asignan categorías, los modelos de regresión generan valores cuantitativos.

En esta investigación, los modelos de regresión son relevantes porque la demanda se expresa generalmente como una cantidad numérica de unidades vendidas. Por ello, algoritmos como regresión lineal, Random Forest Regressor, XGBoost Regressor, SVR o redes neuronales pueden utilizarse para estimar la demanda futura y comparar su desempeño mediante métricas de error.

2.3.9. Modelos de series temporales

Los modelos de series temporales son métodos diseñados para analizar datos ordenados cronológicamente y realizar pronósticos a partir de patrones históricos. Estos modelos consi-

deran la dependencia temporal entre observaciones, es decir, reconocen que las ventas actuales pueden estar relacionadas con ventas pasadas.

Entre los modelos de series temporales más utilizados se encuentran ARIMA, SARI-MA, Prophet y modelos basados en suavizamiento exponencial. Estos enfoques permiten capturar componentes como tendencia, estacionalidad y autocorrelación. En el contexto de una empresa retail, estos modelos son útiles para pronosticar ventas futuras y apoyar decisiones de reabastecimiento.

En esta investigación, los modelos de series temporales se emplean como una alternativa para analizar la evolución histórica de la demanda y compararla con modelos de machine learning.

2.3.10. Algoritmos predictivos

Los algoritmos predictivos son procedimientos computacionales que permiten analizar datos históricos y generar estimaciones sobre eventos futuros. En la predicción de demanda, estos algoritmos procesan información de ventas pasadas y variables relacionadas para identificar patrones que ayuden a estimar el comportamiento futuro del consumo.

Dentro de esta investigación, los algoritmos predictivos permiten comparar distintos enfoques de modelamiento, tales como modelos estadísticos de series temporales y modelos de machine learning. Esta comparación resulta importante porque no todos los algoritmos presentan el mismo rendimiento frente a los mismos datos. Algunos pueden funcionar mejor cuando existe estacionalidad clara, mientras que otros pueden ser más adecuados cuando existen múltiples variables explicativas o relaciones no lineales.

2.3.11. Datos históricos

Los datos históricos son registros acumulados de eventos pasados que sirven como base para el análisis y la predicción. En una empresa retail, estos datos pueden incluir ventas realizadas, cantidades vendidas, precios, fechas de transacción, productos, categorías, proveedores, inventario disponible y otros elementos asociados a la operación comercial.

En la presente investigación, los datos históricos de ventas son el insumo principal para construir los modelos predictivos. A partir de ellos, se identifican patrones de demanda, se entrena el modelo y se evalúa su capacidad para pronosticar ventas futuras. La calidad, cantidad y consistencia de estos datos son factores determinantes para obtener resultados confiables.

2.3.12. Preprocesamiento de datos

El preprocesamiento de datos es el conjunto de actividades orientadas a limpiar, transformar y preparar la información antes de utilizarla en un modelo predictivo. Esta etapa puede incluir la eliminación de duplicados, tratamiento de valores faltantes, corrección de errores, detección de valores atípicos, normalización de variables y organización temporal de los registros.

En la predicción de demanda, el preprocesamiento es indispensable porque los datos de ventas pueden contener inconsistencias que afecten el rendimiento del modelo. Por ejemplo, registros incompletos, fechas incorrectas o valores extremos pueden generar pronósticos poco confiables. Por ello, esta investigación considera el preprocesamiento como una fase clave para mejorar la precisión de los modelos de series temporales y machine learning.

2.3.13. Entrenamiento del modelo

El entrenamiento del modelo es el proceso mediante el cual un algoritmo aprende patrones a partir de un conjunto de datos históricos. Durante esta etapa, el modelo ajusta sus parámetros internos con el propósito de reducir el error entre los valores reales y los valores predichos.

En el contexto de esta investigación, el entrenamiento permite que el modelo aprenda el comportamiento de la demanda en la empresa retail. Para ello, se utilizan datos de ventas pasadas y variables asociadas al tiempo o al producto. Un entrenamiento adecuado permite que el modelo generalice mejor y sea capaz de realizar predicciones sobre periodos futuros.

2.3.14. Validación del modelo

La validación del modelo consiste en evaluar si el modelo predictivo es capaz de generar resultados confiables en datos que no fueron utilizados durante el entrenamiento. Esta etapa permite comprobar si el modelo realmente aprendió patrones útiles o si solo memorizó los datos históricos.

En predicción de demanda, la validación debe respetar el orden temporal de los datos, ya que no sería adecuado utilizar información futura para predecir periodos pasados. Por ello, se suele dividir la información en conjuntos de entrenamiento y prueba considerando la secuencia cronológica. En esta investigación, la validación permite comparar el desempeño de los modelos y seleccionar aquel que presente mejores resultados para apoyar el reabastecimiento.

2.3.15. Métricas de evaluación

Las métricas de evaluación son indicadores que permiten medir el nivel de error o precisión de un modelo predictivo. En la predicción de demanda, estas métricas ayudan a comparar los valores pronosticados con los valores reales de ventas.

Entre las métricas más utilizadas se encuentran el MAE, MSE, RMSE y MAPE. El MAE mide el error absoluto promedio; el MSE calcula el promedio de los errores elevados al cuadrado; el RMSE expresa el error en la misma unidad de la variable analizada; y el MAPE representa el error porcentual promedio. Estas métricas permiten determinar qué modelo ofrece un mejor desempeño y cuál resulta más útil para el proceso de reabastecimiento.

2.3.16. Precisión del modelo

La precisión del modelo hace referencia al grado de cercanía entre las predicciones generadas y los valores reales observados. En el contexto de predicción de demanda, un modelo más preciso permite estimar con mayor exactitud la cantidad de productos que se venderán en un periodo determinado.

Una mayor precisión contribuye a mejorar la planificación de compras, reducir faltantes, evitar exceso de inventario y optimizar los recursos destinados al abastecimiento. Sin embargo, la precisión debe analizarse junto con la aplicabilidad del modelo, ya que un modelo muy complejo puede no ser necesariamente el más adecuado si resulta difícil de interpretar o implementar dentro de la empresa.

2.3.17. Reabastecimiento

El reabastecimiento es el proceso mediante el cual una empresa repone sus productos para mantener niveles adecuados de inventario y satisfacer la demanda de los clientes. Este proceso implica decidir qué productos comprar, en qué cantidad y en qué momento realizar el pedido.

En una empresa retail, el reabastecimiento es una actividad crítica porque influye directamente en la disponibilidad de productos, la satisfacción del cliente, los costos operativos y la rentabilidad. Cuando el reabastecimiento se realiza sin información precisa, pueden generarse problemas como sobrestock, quiebre de stock, pérdidas por deterioro o compras innecesarias.

En esta investigación, la optimización del reabastecimiento se busca mediante el uso

de modelos predictivos que permitan anticipar la demanda y apoyar decisiones de compra más eficientes.

2.3.18. Inventario

El inventario representa el conjunto de productos almacenados por una empresa para su posterior venta o utilización. En el sector retail, el inventario permite garantizar la disponibilidad de productos para los clientes, pero también implica costos asociados al almacenamiento, control, manipulación y riesgo de deterioro.

Una gestión adecuada del inventario busca mantener un equilibrio entre disponibilidad y eficiencia. Tener demasiado inventario puede generar sobrecostos y pérdidas, mientras que tener poco inventario puede ocasionar quiebres de stock y pérdida de ventas. En esta investigación, el inventario se relaciona directamente con la predicción de demanda, ya que un pronóstico más preciso permite definir mejores cantidades de reabastecimiento.

2.3.19. Sobrestock

El sobrestock se produce cuando la empresa mantiene una cantidad de inventario superior a la demanda real. En productos perecibles o de alta rotación, este problema puede generar pérdidas económicas debido al deterioro, vencimiento, reducción de calidad, descuentos forzados o inmovilización de capital.

En el contexto de esta investigación, el sobrestock representa uno de los problemas que se busca reducir mediante la predicción de demanda. Al contar con estimaciones más precisas sobre las ventas futuras, la empresa puede evitar compras excesivas y ajustar mejor sus pedidos a proveedores.

2.3.20. Optimización del reabastecimiento

La optimización del reabastecimiento consiste en mejorar las decisiones relacionadas con la cantidad, frecuencia y momento de compra de productos, buscando equilibrar la disponibilidad de inventario con la reducción de costos y pérdidas. En una empresa retail, esta optimización permite mejorar el servicio al cliente, disminuir sobrestock, evitar quiebres de stock y reducir mermas.

En la presente investigación, la optimización del reabastecimiento se logra mediante el

uso de modelos de series temporales y machine learning aplicados a la predicción de demanda. El propósito es que la empresa pueda tomar decisiones basadas en datos y no únicamente en experiencia o criterios subjetivos.

Capítulo 3

ENTORNO EMPRESARIAL

3.1. Descripción de la empresa

3.1.1. Reseña histórica y actividad económica

Donna S.A.C, una exitosa empresa dedicada a los minimercados, se ha establecido como un destino de compras esencial para la comunidad. Con cuatro ubicaciones estratégicas, esta cadena se ha convertido en un punto de referencia para aquellos que buscan productos de calidad y atención personalizada. Su lema, "Donna S.A.C, donde cada compra es una experiencia", refleja su compromiso con la creación de un ambiente cálido y acogedor para sus clientes. Desde la entrada, los clientes son recibidos con un diseño moderno y limpio, facilitando una experiencia de compra placentera. La atención al cliente es primordial, con empleados capacitados siempre dispuestos a brindar ayuda, garantizando que cada visita sea positiva.

Las cuatro tiendas de Donna S.A.C están estratégicamente ubicadas para ofrecer fácil acceso a una amplia gama de productos, desde alimentos frescos hasta artículos para el hogar, satisfaciendo las cambiantes necesidades de sus clientes. Con un equipo de veinte empleados comprometidos, Donna S.A.C ha cultivado un ambiente laboral colaborativo y motivador mediante una capacitación continua que asegura un servicio informado y útil para los clientes. Esta dedicación al desarrollo del equipo no solo beneficia a los empleados, sino que también contribuye al ambiente positivo que caracteriza a cada tienda.

3.1.2. Descripción de la organización

Donna S.A.C, una cadena de minimarkets que va más allá de las expectativas convencionales, ha dejado una marca distintiva en el mundo de las compras minoristas. Con cuatro ubicaciones estratégicas, esta empresa se ha convertido en un pilar esencial para aquellos que buscan no solo productos de elevada calidad, así mismo una experiencia de compra inigualable.

Cada tienda Donna S.A.C ha sido diseñada con esmero para crear un ambiente acogedor y moderno. Desde la entrada, los clientes son recibidos con un diseño limpio y una disposición intuitiva de productos. La tienda no es solo un espacio de transacciones; es un destino donde la atención al cliente es una prioridad. Nuestro equipo de veinte empleados capacitados está siempre disponible para ayudar, proporcionando un servicio personalizado que transforma cada visita en una experiencia positiva. La diversidad de productos en Donna Sac es impresionante, desde alimentos frescos y productos del hogar hasta opciones de conveniencia para satisfacer las necesidades diarias. La cadena se enorgullece de mantener sus estantes abastecidos con productos de alta calidad, ofreciendo a los clientes la confianza de que encontrarán lo que necesitan, cuando lo necesiten.

Detrás de la exitosa operación de Donna Sac se encuentra un equipo de veinte trabajadores dedicados que personifican los valores de la empresa. La capacitación frecuente y el desarrollo profesional son fundamentales para nuestro enfoque en el servicio al cliente, asegurando que cada miembro del equipo esté bien informado y preparado para brindar asesoramiento útil.

3.1.2.1. Organigrama

Este organigrama es una representación simplificada de la estructura jerárquica de Donna Sac. Cada posición puede tener roles específicos y responsabilidades detalladas, y la organización está diseñada para fomentar la eficiencia operativa, la atención al cliente excepcional y la participación comunitaria.

3.1.3. Datos generales estratégicos de la empresa

Información Básica:

- Nombre completo de la empresa: Donna Sac.



Figura 3.1: Organigrama Donna SAC

- Fecha de fundación: 2000.
- Fundadores o actuales propietarios: Donaciano Paucar.
- Tiendas: 6 tiendas.
- Ubicación de cada tienda: 2 en Chorrillos, Surco, 2 en La Molina, Breña.
- Tamaño promedio de las tiendas en pies cuadrados: 120 ft²
- Número total de empleados: 40.
- Productos y Servicios: Consumo masivo.
- Segmentos de mercado objetivo: Personas proximas a las tiendas de Donna SAC.

3.1.3.1. Visión, misión y valores o principios

Visión: “Ser reconocidos como el referente líder en la experiencia de compra minorista, destacando por nuestra dedicación excepcional al cliente, la innovación en productos y servicios, y nuestro impacto positivo en las comunidades que servimos.”

Misión: “En Donna Sac, nos comprometemos a ofrecer a nuestros clientes una experiencia de compra única y satisfactoria, brindando productos de alta calidad, un servicio personalizado y contribuyendo activamente al bienestar de las comunidades locales. Nos esforzamos

por ser un destino esencial para aquellos que buscan más que una simple transacción, buscando una conexión significativa con sus necesidades diarias y valores compartidos.”

3.1.3.2. Objetivos estratégicos

Excelencia en la Experiencia del Cliente:

- Mejorar continuamente la atención al cliente para garantizar una experiencia de compra excepcional.
- Implementar programas de capacitación para el equipo humano que refuercen la significación del servicio al cliente.

Diversificación y Ampliación de Productos:

- Investigar y agregar nuevos productos que satisfagan las tendencias del mercado y las necesidades cambiantes de los clientes.
- Expandir las líneas de productos propios para aumentar la diferenciación en el mercado.

Innovación en Tecnología y Operaciones:

- Implementar tecnologías avanzadas para mejorar la eficiencia operativa, desde sistemas de gestión de inventario hasta soluciones de punto de venta.
- Explorar oportunidades para la implementación de plataformas digitales que mejoren la experiencia del cliente y faciliten la expansión en línea.

Desarrollo de la Cadena de Suministro Sostenible:

- Contribuir con proveedores implicados con prácticas sostenibles y éticas.
- Reducir la huella ambiental mediante prácticas de gestión de residuos y opciones de embalaje sostenibles.

Expansión Geográfica y Nuevas Tiendas:

- Identificar y evaluar nuevas ubicaciones estratégicas para la apertura de tiendas.
- Establecer alianzas con desarrolladores inmobiliarios para facilitar la expansión.

- Iniciativas de Responsabilidad Social Corporativa.
- Introducir iniciativas de responsabilidad social corporativa
- Establecer asociaciones con organizaciones benéficas y participar activamente en eventos comunitarios.

Optimización Financiera:

- Mejorar la eficiencia financiera mediante la implementación de herramientas de análisis y seguimiento.
- Buscar oportunidades para mejorar los márgenes de beneficio sin afectar la calidad de los recursos y servicios.

3.1.3.3. Evaluación interna y externa. FODA

Oportunidades	Ponderación	Clasificación	Puntuación
El crecimiento de la clase media peruana está generando una mayor demanda de productos y servicios de calidad. La tendencia de los peruanos se está centrando en la obtención de productos de manera más rápida y en menores tiempos de espera.	0.3	3	0.90
El cambio en los hábitos de consumo, los nuevos consumidores buscan cuidar su salud por lo que buscan frutas al momento de entrar a una tienda minorista.	0.05	3	0.15

Oportunidades	Ponderación	Clasificación	Puntuación
Cada vez salen nuevas marcas de productos de consumo masivo al mercado. Las alianzas estratégicas con otras empresas podrían ayudar a Donna a ampliar su oferta de productos.	0.1	2	0.20
La innovación tecnológica podría ayudar a Donna a mejorar la eficiencia y la experiencia de compra de los clientes. Implementación de IA en la capacitación o cajeros automáticos.	0.05	2	0.10
Las inversiones en marketing podrían ayudar a Donna el aumentar su reconocimiento de marca y atraer a nuevos clientes. Expansión de sus redes sociales y crear campañas que se alineen con las nuevas tendencias en su público objetivo.	0.15	1	0.15
	0.65		1.50

Tabla 3.1: Oportunidades de Donna Sac

Amenazas	Ponderación	Clasificación	Puntuación
El crecimiento del sector de las tiendas minoristas está generando una mayor competencia.	0.15	2	0.30

Amenazas	Ponderación	Clasificación	Puntuación
Los cambios en la inestabilidad económica y cambios de gobierno reducen el tiempo de compra de productos. Muchos consumidores obtan por las tiendas mayoristas en este tipo de situaciones.	0.05	2	0.10
Tambo posee una participación del 30 % en la categoria de tiendas minoristas.	0.05	2	0.10
Los cambios en los hábitos de consumo, hacia una mayor orientación hacia los productos orgánicos o saludables, podrían afectar la demanda de los productos de Donna y replantear un nuevo stock de productos.	0.05	3	0.15
Problemas de politica exterior de Perú con países a los que compramos productos internacionales podrian afectar el precio compra al que llegan a nuestro país.	0.05	2	0.10
	0.35		0.75

Tabla 3.2: Amenazas de Donna Sac

La empresa Donna se encuentra por debajo del promedio en cuestión de respuesta a los factores exteriores. Se recomienda darle más importancia a lo que esta pasando en su entorno macro para poder aprovechar las oportunidades del mercado.

Fortalezas	Ponderación	Clasificación	Puntuación
Experiencia de 20 años en el mercado minorista, conocimientos del entorno y adaptación a los diversos escenarios del proceso de compra del consumidor.	0.20	4	0.80
Ofrece productos mucho más variados que otras tiendas minoristas que estan top en la categoría, Donna ofrece productos que abarcan hasta frutas y verduras que son del día.	0.10	4	0.40
Donna se ubica en zonas de alto tráfico peatonal, lo que facilita el acceso a nuevos clientes	0.05	3	0.15
Se ofrece una pequeña capacitación de unos 3 días al personal para que se enfoque en crear relación con el cliente y que no solo se convierta en una transacción de bienes. Se le proporciona videos y un taller que se enfoca en ser empatico con el cliente al preguntar cosas de su vida diaria.	0.15	4	0.60
Empleados jóvenes, más ágiles y que recomiendan productos a los clientes con mayor rapidez de acuerdo a las tendencias del mercado.	0.10	3	0.30
	0.60		2.25

Tabla 3.3: Fortalezas de Donna Sac

Debilidades	Ponderación	Clasificación	Puntuación
La mayoría de las tiendas de Donna se encuentran en zonas urbanas, lo que limita su alcance al mercado rural.	0.15	1	0.15
Donna tiene una marca poco diferenciada, lo que puede dificultar su posicionamiento frente a la competencia que son en su mayoría tiendas de esquina o los mismos mercados.	0.05	1	0.05
Donna se concentra en la venta de productos básicos, lo que limita su oferta de productos a un público más especializado.	0.05	2	0.10
Donna no posee un horario de atención de 24 horas.	0.10	1	0.10
Alta rotación de personal, no se crea identidad de marca con el personal interno.	0.05	2	0.10
	0.40		0.50

Tabla 3.4: Debilidades de Donna Sac




Figura 3.2: Matriz interna y externa

Donna se encuentra en la Celda V, por lo tanto le conviene la estrategia de mantener y conservar. Lo que se plantea que haga Donna al no ser una opción la penetración de mercado por razones económicas es optar por la estrategia de desarrollo de producto. Lo que se plantea es introducir nuevos productos orgánicos y saludables, debido a la demanda de salud que está en crecimiento. Además, mejorar la calidad de productos y priorizar el bienestar del consumidor, darle un extra a cada compra para que pueda recordar nuestra marca.

3.1.4. Modelo de negocio actual (CANVAS)




Figura 3.3: Business Model Canvas

Capítulo 4

METODOLOGÍA DE LA INVESTIGACIÓN

4.1. Diseño de la investigación

En esta sección del documento se explicará cual es el diseño, el tipo y el enfoque del trabajo de investigación, así como también la población y la muestra del estudio.

4.1.1. Enfoque

Esta investigación adopta un enfoque cuantitativo, centrado principalmente en el análisis de datos históricos y la aplicación de modelos de series temporales para abordar la demanda de productos perecibles. La metodología se basa en la recopilación y análisis de datos cuantitativos diarios relacionados con la demanda, con el objetivo de ofrecer información y recomendaciones basadas en rigor estadístico y en la interpretación de patrones numéricos. Esto permitirá optimizar la gestión de la demanda de productos y mejorar la eficiencia operativa en la toma de decisiones de inversión en los pedidos a proveedores.

4.1.2. Alcance

Esta investigación es de tipo explicativa, ya que busca identificar los componentes y parámetros específicos que afectan la eficiencia de la cadena de suministro de la empresa Market Donna SAC. En particular, se centrará en el desarrollo e implementación de un sistema de pronóstico de demanda basado en modelos de Forecasting. El alcance se extiende a la evalua-

ción del impacto de este sistema en la gestión de las órdenes de productos perecibles, analizando los beneficios en términos de optimización de inversión, reducción de costos y mejora de la eficiencia operativa.

4.1.3. Tipo

La investigación es de tipo no experimental, dado que se trabajará con datos históricos comprendidos entre el año 2012 Y 2026. A partir de este análisis, se desarrollará un modelo predictivo para mejorar la precisión en la estimación de la demanda de productos en Market Donna SAC y, así, orientar decisiones más efectivas.

4.1.4. Población y muestra

La población de estudio incluye todas las categorías de productos que Market Donna SAC ofrece, entre las cuales se encuentran artículos de limpieza, frutas, verduras, lácteos, carnes, bebidas, abarrotos, tabaco, condimentos, embutidos, panes, entre otros. En total, la empresa cuenta con 16 categorías de productos que generan un promedio de 136,000 soles mensuales en ventas. La muestra seleccionada se concentra específicamente en la categoría de Verduras, que representa una de las familias de productos con mayor impacto en las ventas de la empresa. Al centrarnos en esta categoría de productos perecibles, el estudio busca realizar un análisis más preciso de la demanda diaria y proyectar las ventas en soles para la familia de verduras, dada su relevancia en las operaciones y en la rentabilidad de Market Donna SAC.

4.1.5. Unidad de análisis

La unidad de análisis de este estudio se centra en cada transacción individual de venta de productos dentro de la categoría seleccionada, que corresponde a las verduras. Cada transacción registrada en este segmento, desde el año 2012 hasta 2026, se considera como una unidad única de observación. Esto permite una comprensión granular y precisa de los patrones de compra, comportamientos de los clientes y tendencias de demanda asociadas específicamente a estos productos perecibles. Al examinar cada transacción de manera individual, el análisis busca capturar variaciones diarias en la demanda, observar los patrones de consumo recurrentes y detectar posibles picos o caídas en las ventas. Este enfoque detallado proporciona información valiosa para construir un modelo predictivo ajustado a las particularidades de la categoría de verduras, permitiendo identificar factores que podrían influir en la demanda, como la estacionalidad, días de la semana, campañas promocionales o eventos externos. Además, el análisis

de estas transacciones ofrece la oportunidad de estudiar la sensibilidad de la demanda a las variaciones en precios y promociones dentro de esta categoría. Estos datos permitirán una mejor previsión de la demanda en soles y servirán de base para la toma de decisiones estratégicas sobre los volúmenes de compra y la inversión diaria en reposición de inventario, asegurando así la disponibilidad de productos frescos y optimizando la eficiencia operativa de Market Donna SAC en esta categoría de productos perecibles.

4.2. Técnicas de recolección de datos

La etapa de recolección de datos constituyó uno de los componentes más críticos y fundamentales de la presente investigación, debido a que la calidad, consistencia y confiabilidad de la información histórica determinan directamente el desempeño y la precisión de los modelos de predicción de demanda. En investigaciones basadas en modelos de series temporales y algoritmos de Machine Learning, la disponibilidad de datos históricos estructurados y representativos resulta indispensable para identificar patrones de comportamiento, tendencias estacionales, variaciones cíclicas y fluctuaciones de consumo asociadas a la dinámica comercial de una empresa retail.

4.2.1. Selección de la Categoría de Estudio

La elección de los todos los productos respondió a criterios operacionales y analíticos orientados a maximizar la relevancia del estudio. Desde el punto de vista comercial, los productos presentan una alta rotación diaria, sensibilidad a factores externos y variabilidad significativa en los niveles de demanda. Estas características la convierten en un escenario adecuado para la aplicación de técnicas de pronóstico basadas en series temporales y aprendizaje automático.

Adicionalmente, debido a la naturaleza perecible de los productos, una estimación inadecuada de la demanda puede generar consecuencias importantes para la empresa, tales como sobrestock, pérdidas por vencimiento, desabastecimiento y reducción en los niveles de satisfacción del cliente. Por ello, el análisis permite evaluar el impacto real que pueden tener los modelos predictivos sobre la optimización del proceso de reabastecimiento.

4.2.2. Extracción de Datos desde SQL Server

Para implementar los modelos de predicción de demanda, se realizó una recopilación exhaustiva de información histórica utilizando el sistema de administración de bases de datos

SQL Server empleado por la empresa. Esta etapa implicó el diseño y ejecución de consultas SQL especializadas orientadas a la extracción, filtrado y consolidación de datos provenientes de múltiples tablas relacionales.

Inicialmente, se desarrollaron consultas SQL específicas 4.1 destinadas a identificar y extraer la información relevante asociada a productos, categorías, familias, códigos internos, precios de venta y registros transaccionales. Este procedimiento permitió depurar información redundante, eliminar inconsistencias y estructurar adecuadamente los datos requeridos para el análisis posterior.

Posteriormente, se diseñó una consulta SQL avanzada 4.2 que integró las diferentes tablas relacionales mediante operaciones de unión (*JOIN*), filtros condicionales y criterios de normalización de datos. Esta integración permitió consolidar un conjunto de datos centralizado, consistente y coherente, garantizando la integridad referencial necesaria para la construcción de modelos de pronóstico de demanda.



Figura 4.1: Consulta SQL

Fuente: Elaboración propia

4.2.3. Construcción del Dataset Histórico

Como parte del proceso de preparación de datos, se consolidó información histórica correspondiente a las transacciones de ventas de productos de la categoría de verduras, abarrotes, frutas, lácteos, artículos de limpieza, carnes, bebidas, condimentos, embutidos, entre otros desde el año 2012 hasta el año 2026. La amplitud temporal del conjunto de datos permitió disponer de una perspectiva histórica extensa, indispensable para identificar patrones de comportamiento de la demanda a corto, mediano y largo plazo.

El análisis temporal de esta información permitió detectar tendencias de crecimiento, patrones estacionales, variaciones semanales, fluctuaciones asociadas a campañas comerciales

y cambios en el comportamiento de consumo de los clientes. Estos elementos representan variables fundamentales para el entrenamiento y validación de modelos de series temporales y algoritmos predictivos.

Asimismo, la utilización de un horizonte histórico amplio permitió reducir el sesgo estadístico y mejorar la capacidad de generalización de los modelos de Machine Learning, facilitando la captura de relaciones complejas entre las variables analizadas.




Figura 4.2: Tablas de ventas

Fuente: Elaboración propia

4.2.4. Integración de Datos del Sistema POS

Complementariamente, se utilizaron registros provenientes del sistema de punto de venta (POS) de la empresa para capturar información transaccional en tiempo real relacionada con las ventas diarias. Esta integración permitió obtener datos detallados sobre frecuencia de compra, volumen de ventas, horarios de mayor demanda y comportamiento operativo de los productos analizados.

La incorporación de información del sistema POS fortaleció la precisión del conjunto de datos, debido a que proporcionó registros actualizados y directamente vinculados con las operaciones comerciales reales de la empresa. Además, permitió realizar un seguimiento continuo del comportamiento de la demanda y validar la consistencia de los datos históricos extraídos desde SQL Server.

4.2.5. Validación y Control de Calidad de los Datos

Con el objetivo de garantizar la confiabilidad de la información utilizada en la investigación, se ejecutaron procesos de validación y control de calidad de datos. Estas actividades incluyeron la identificación de registros duplicados, tratamiento de valores nulos, detección de inconsistencias temporales y verificación de integridad entre tablas relacionadas.

Aunque el enfoque principal de la investigación se centra en la predicción de la demanda y no en la gestión de inventarios, este análisis complementario permitió comprender indirectamente la relación existente entre la demanda diaria y las necesidades de reposición de productos perecibles.

Este seguimiento resultó especialmente relevante debido a que los productos de alta rotación requieren procesos de abastecimiento frecuentes y precisos para minimizar pérdidas operativas y garantizar disponibilidad constante para los clientes.

4.2.6. Importancia de la Recolección de Datos en la Investigación

La recolección y preparación de datos representó una fase estratégica dentro del desarrollo de la investigación, debido a que constituyó la base sobre la cual se construyeron los modelos de predicción de demanda. La precisión de los algoritmos de series temporales y Machine Learning depende directamente de la calidad y representatividad de los datos históricos utilizados durante el entrenamiento y validación de los modelos.

En consecuencia, la implementación de procedimientos rigurosos de extracción, integración, validación y consolidación de información permitió disponer de un dataset robusto y confiable, capaz de soportar el desarrollo de modelos predictivos orientados a optimizar el reabastecimiento de productos en Market Donna SAC.

Finalmente, las estrategias de recolección de datos desarrolladas en esta investigación proporcionaron una visión integral, cuantitativa y temporal del comportamiento de la demanda, permitiendo establecer una base sólida para la aplicación de técnicas avanzadas de análisis predictivo y toma de decisiones en entornos retail.

4.3. Técnicas para el procesamiento y análisis de la información

Para entrar con más detalles a la metodología se describen los pasos a seguir.

4.3.1. Metodología de la implementación de la solución

La metodología desarrollada en este proyecto se plantea como un proceso ordenado y progresivo, orientado a la construcción de un modelo predictivo de ventas. Este proceso permite pasar desde la obtención y preparación de los datos históricos hasta la evaluación de distintos modelos y el despliegue de una solución web funcional.

De esta manera, la metodología busca garantizar que el modelo propuesto no solo presente un adecuado desempeño predictivo, sino que también pueda ser utilizado como una herramienta de apoyo para la toma de decisiones dentro de la empresa.




Figura 4.3: Metodología de implementación de la solución

Tabla 4.1: Instrumentos de medida para recolección de datos

Técnica	Instrumento	Origen	Principales ventajas	Principales desventajas
Datos de ventas históricas	Registro de ventas(2012-2026)	Registro de la empresa	Obtiene datos cuantitativos sobre las ventas históricas de productos	No proporciona información cualitativa sobre los patrones de la demanda
Sistemas de punto de venta (POS)	Hardware POS	Registro en tiempo real de transacciones	Ofrece datos continuos y actualizados sobre las ventas	Dependencia de la confiabilidad del sistema
Datos de inventarios	Registro de inventarios	Registro de la empresa	Permite evaluar la relación entre la demanda y la gestión de inventarios Cuantitativamente	No proporciona información sobre factores externos

Fuente: Elaboración propia

Esta comprensión inicial es fundamental para orientar las etapas siguientes de la metodología KDD y garantizar que el análisis de los datos sea relevante y eficaz. La selección de la base de datos adecuada y de las variables para el modelo de aprendizaje automático se realizará utilizando la base de datos proporcionada por la entidad en este caso de estudio.

4.3.2. Comprensión de los datos

La investigación incluyó un proceso exhaustivo de exploración, análisis e interpretación de la información recopilada, con el objetivo de identificar patrones, tendencias y relaciones significativas. Este paso es fundamental para garantizar que los datos sean relevantes, precisos y útiles para responder a las preguntas de investigación y alcanzar los objetivos del estudio. El conjunto de datos utilizado abarca 7,340,659 registros de ventas, organizados por familia de productos, correspondientes a los años 2012 al 2026.




Figura 4.4: Tablas de ventas

Fuente: Elaboración propia

Se emplearon análisis univariado y bivariado para examinar y comprender los datos. El análisis univariado se centró en describir y resumir una sola variable a la vez, utilizando estadísticas como la media, mediana, moda y varianza, además de visualizaciones como histogramas para revelar la distribución y características específicas de esa variable. Por otro lado,


el análisis bivariado se enfocó en explorar la relación entre dos variables, empleando técnicas como tablas de correlación y regresión para identificar patrones, asociaciones y posibles causalidades entre las variables.

```
In [32]: 1 ##analisis variables continuas
         2 round(data_cleaned.describe(),2)


Out[32]:
```

	NUMERO	semana	año	TOTAL	cantidad	precio
count	615523.00	615523.00	615523.00	615523.00	615523.00	615523.00
mean	342483.96	24.41	2023.22	78.18	2.15	4.64
std	419716.21	15.11	0.66	242.82	8.72	5.71
min	1.00	1.00	2008.00	0.00	0.00	0.00
25%	79893.00	11.00	2023.00	8.00	0.84	1.40
50%	395298.00	22.00	2023.00	19.30	1.00	2.80
75%	480522.00	38.00	2023.00	42.60	1.15	5.80
max	14463708.00	53.00	2024.00	6763.50	2000.00	270.00


(a) Descripción cuantitativa



(b) Cuantificación de semanas



(c) Distribución de precio



(d) Correlación de variables

Figura 4.5: Análisis exploratorio de variables

Fuente: Elaboración propia

El mapa de calor muestra la correlación entre varias variables, como semana, año, total, producto, y precio. En general, las correlaciones son débiles, con solo una correlación negativa moderada entre semana y año (-0.38). Esto sugiere que no hay relaciones lineales fuertes entre las variables, lo cual indica que cada una aporta información única al conjunto de datos. Este análisis preliminar sugiere que no es necesario eliminar ninguna columna por redundancia, ya que las correlaciones no son suficientemente altas.

4.3.3. Pre-Procesamiento

En esta fase se efectuó, en primer lugar, la normalización de los nombres de las variables, con la finalidad de mantener una estructura homogénea dentro del conjunto de datos y evitar inconsistencias durante el procesamiento. Posteriormente, las variables de tipo temporal

fueron convertidas a un formato de fecha estándar, permitiendo ordenar cronológicamente los registros y facilitar el análisis de series temporales.

Asimismo, las variables numéricas relacionadas con las ventas fueron transformadas al tipo de dato correspondiente para asegurar su correcta interpretación por parte de los algoritmos de análisis. Durante este proceso también se identificaron y eliminaron registros incompletos, inconsistentes o con valores inválidos, especialmente aquellos asociados a fechas o montos de venta no reconocidos.

Después de la limpieza inicial, los datos fueron ordenados secuencialmente según la variable temporal. Este procedimiento resulta fundamental en problemas de predicción temporal, debido a que los modelos requieren preservar la relación cronológica entre observaciones históricas y futuras.

Posteriormente, se realizó la segmentación de la información según criterios específicos de análisis, tales como la sede y la familia de productos. Esta segmentación permitió trabajar con subconjuntos de datos más homogéneos y representativos, contribuyendo a mejorar la precisión y pertinencia de los modelos predictivos.

Finalmente, el preprocesamiento permitió obtener un conjunto de datos estructurado, consistente y preparado para las etapas posteriores de análisis exploratorio, entrenamiento y evaluación de modelos de predicción.

4.3.4. Modelamiento

Al concluir la etapa del preprocesamiento, las variables pudieron ser utilizadas para los modelos de cada modalidad, que fueron diseñados siguiendo las actividades de la [Tabla 4.2](#)

Tabla 4.2: Actividades de fase modelamiento

Actividades	Descripción	Tareas
Desarrollar modelos predictivos para data estructurada.	Implementación de un mínimo de 8 modelos de forecasting para entrenarlos y seleccionar el mejor para la data.	Escoger los modelos para entrenarlos y ver cual es el mejor modelo para realizar los pronósticos de ventas.
Seleccionar las métricas para la evaluación del modelo.	Implementación las métricas para poder evaluar a los modelos implementados.	Escoger las métricas que definirán cual modelo será mejor para realizar los pronósticos de venta (R2, MSE, RMSE y MAPE).

Fuente: Elaboración propia

Actividad 1: Desarrollar modelos predictivos para data estructurada.

En esta actividad, se diseñó la arquitectura que se utilizó para los datos estructurados. Para ello, se llevó a cabo un benchmarking sobre los modelos a utilizar:

- **ARIMA:** ARIMA es un modelo estadístico utilizado para analizar y predecir series temporales. Combina la parte autoregresiva (AR), que utiliza las observaciones pasadas para predecir valores futuros, con la parte de media móvil integrada (IMA), que maneja la variabilidad y tendencia de los datos.
- **LSTM:** LSTM es un tipo de red neuronal recurrente (RNN) diseñada para modelar secuencias temporales y dependencias a largo plazo. Es capaz de aprender dependencias temporales en los datos y es especialmente efectiva en problemas donde las relaciones entre eventos en el tiempo son importantes.
- **LINEAR REGRESSION:** La regresión lineal es un modelo estadístico que examina la relación lineal entre una variable dependiente y una o más variables independientes. El objetivo es encontrar la línea (o plano en casos de múltiples variables) que mejor se ajuste a los datos, minimizando la suma de los errores cuadráticos.
- **XGBOOST:** XGBoost es una implementación optimizada del algoritmo de gradient boosting, que se utiliza ampliamente en problemas de aprendizaje supervisado, tanto para clasificación como para regresión. Utiliza árboles de decisión como modelos base y se enfoca en mejorar el rendimiento a través de técnicas como la regularización y el manejo eficiente de conjuntos de datos grandes.

- **SVR:** SVR es una variante de las máquinas de vectores de soporte (SVM) adaptada para problemas de regresión. A diferencia de los métodos de regresión lineal, SVR utiliza vectores de soporte en un espacio de alta dimensión para predecir valores continuos, buscando la función que mejor se ajuste a los datos mientras mantiene un margen de error aceptable.
- **RANDOM FOREST:** Random Forest es un conjunto de árboles de decisión, donde cada árbol es construido de manera independiente y con muestras de datos aleatorias. La predicción final se obtiene por votación o promediando las predicciones individuales de los árboles, lo que mejora la precisión y reduce el sobreajuste.
- **DECISION TREE:** Un árbol de decisión es una estructura de modelo de aprendizaje automático que divide un conjunto de datos en subconjuntos más pequeños basados en características específicas de las variables predictoras. Cada nodo representa una característica y cada hoja representa un resultado o decisión.
- **GRADIENT BOOSTING:** Gradient Boosting es un algoritmo de aprendizaje supervisado que construye modelos de forma secuencial, donde cada nuevo modelo corrige los errores del anterior. Utiliza árboles de decisión como modelos base y optimiza una función de pérdida mediante el descenso de gradiente, logrando alta precisión en tareas de regresión y clasificación.
- **KNN (K-Nearest Neighbors):** KNN es un algoritmo de aprendizaje basado en instancias que realiza predicciones basándose en los datos más cercanos en el espacio de características. Para regresión, el valor predicho se obtiene como el promedio de los valores de sus vecinos más cercanos, lo que lo hace simple pero efectivo en ciertos contextos.
- **HOLT-WINTERS:** Holt-Winters es un método de suavizamiento exponencial utilizado para series temporales que presentan tendencia y estacionalidad. Este modelo combina componentes de nivel, tendencia y estacionalidad para realizar predicciones más precisas en datos con patrones periódicos.
- **NAIVE:** El modelo Naive es un enfoque simple de pronóstico en series temporales que asume que el valor futuro será igual al último valor observado. A pesar de su simplicidad, se utiliza como modelo base para comparar el rendimiento de modelos más complejos.
- **SARIMA:** SARIMA (Seasonal ARIMA) es una extensión del modelo ARIMA que incorpora componentes estacionales. Permite modelar tanto patrones no estacionales como estacionales en series temporales, siendo útil cuando los datos presentan ciclos repetitivos a lo largo del tiempo.

Actividad 2:

Seleccionar las métricas para la evaluación del modelo En esta actividad, se llevó a cabo una investigación basada en el estado del arte para identificar las métricas más utilizadas en investigaciones previas. Se encontró que las métricas más frecuentemente empleadas fueron las siguientes:

- **RMSE:** Calcula la raíz cuadrada de la media de los cuadrados de los errores entre las predicciones de un modelo y los valores reales. Es útil para medir el nivel de error promedio de las predicciones en la misma unidad que los datos originales.
- **MSE:** Calcula el promedio de los cuadrados de los errores entre las predicciones de un modelo y los valores reales. Proporciona una medida de la varianza de los errores, penalizando más fuertemente los errores grandes.
- **MAPE:** Calcula el promedio del porcentaje absoluto de los errores entre las predicciones de un modelo y los valores reales. Es útil para evaluar la precisión relativa de un modelo, especialmente en situaciones donde se desea conocer el error porcentual promedio.
- **R²:** Calcula el coeficiente de determinación, que mide la proporción de la variabilidad en los datos que es explicada por el modelo. Un valor de R² cercano a 1 indica un buen ajuste del modelo a los datos, mientras que un valor cercano a 0 indica un ajuste pobre.

4.3.5. Evaluación

Esta fase comprende la evaluación de los modelos desarrollados en la investigación a través de las métricas de regresión seleccionadas y explicadas en la sección 3.3.6. En la Tabla 4.3 se indican las actividades y tareas seguidas para esta etapa.

Tabla 4.3: Actividades de fase evaluación

Actividades	Descripción	Tareas
Evaluar el modelo predictivo	Evaluación del desempeño del modelo LSTM	Ejecutar experimentos para definir hiperparámetros.
Interpretar las métricas obtenidas	Observar los resultados de las métricas obtenidas permite inferir si el modelo puede ser un predictor confiable para los pronósticos.	Interpretar los resultados obtenidos de las métricas permite extraer conclusiones fundamentales sobre el rendimiento del modelo.

Fuente: Elaboración propia

Actividad 1: Evaluar el modelo predictivo.

En esta actividad, se procedió inicialmente con el entrenamiento de todos los modelos utilizando datos recopilados durante aproximadamente 3 años, que incluyen las ventas semanales de la familia con la que se cuenta con mayor cantidad de datos históricos. Este proceso de entrenamiento fue fundamental para ajustar los modelos y capturar patrones y tendencias significativas basadas en un conjunto de datos robusto y representativo. Para optimizar el rendimiento de los modelos, se llevaron a cabo entre 3 y 5 experimentos por cada diseño de modelo, explorando diversas combinaciones y ajustes de hiperparámetros en cada iteración. Esta estrategia sistemática permitió evaluar cómo diferentes configuraciones afectan el rendimiento del modelo en términos de métricas críticas como precisión, error y capacidad de generalización. Los experimentos no solo se centraron en la optimización de hiperparámetros, sino también en la selección de técnicas de preprocesamiento de datos y ajustes de arquitectura del modelo. Cada iteración fue diseñada para obtener insights valiosos sobre qué configuraciones maximizan la capacidad del modelo para realizar pronósticos precisos y confiables de las ventas semanales. Este enfoque riguroso y metódico no solo aseguró la mejora continua del rendimiento predictivo, sino que también proporcionó una base sólida para la toma de decisiones informadas sobre la implementación y refinamiento del modelo finalmente seleccionado.

Actividad 2: Interpretar las métricas obtenidas.

En esta actividad, se procedió inicialmente a realizar un análisis exhaustivo de las métricas obtenidas del modelo Regresión Lineal entrenado y ajustado. Estas métricas fueron meticulosamente calculadas para evaluar el desempeño del modelo en la predicción precisa de las ventas semanales, utilizando datos históricos recopilados durante aproximadamente 5 años.

Durante el análisis, se focalizó en métricas fundamentales como el RMSE (Root Mean Square Error), MSE (Mean Squared Error) y MAPE (Mean Absolute Percentage Error). Estas métricas proporcionaron una evaluación cuantitativa del nivel de precisión y error del modelo en comparación con las ventas reales observadas en el período de entrenamiento.

El estudio detallado de estas métricas permitió extraer conclusiones significativas sobre la capacidad del modelo para capturar variaciones y patrones en las ventas semanales. Además, facilitó la identificación de posibles áreas de mejora en términos de ajustes adicionales de hiperparámetros o refinamientos en la arquitectura del modelo Regresión Lineal. Este análisis crítico y sistemático es esencial para tomar decisiones informadas sobre la implementación y el desarrollo continuo del modelo Regresión Lineal en aplicaciones futuras de pronóstico de ventas. Asimismo, asegura un mejor rendimiento predictivo y una mayor precisión en la proyección de tendencias comerciales, beneficiando así la toma de decisiones estratégicas en el contexto empresarial.

4.3.6. Despliegue

En la última fase de la metodología seguida, se implementó el modelo propuesto después de completar su entrenamiento y evaluación correspondiente. Esta etapa final fue crucial para poner a prueba la capacidad predictiva del modelo en un entorno operativo real. Las actividades detalladas realizadas durante esta fase se describen en la Tabla 4.4, proporcionando una visión completa de los pasos ejecutados para asegurar la integración efectiva del modelo en la aplicación práctica.

Tabla 4.4: Actividades de fase Despliegue

Actividades	Descripción	Tareas
Diseñar prototipo de sistemas con modelo propuesto.	Diseño del prototipo del sistema que integrará la captura de datos con el modelo propuesto para predecir las ventas.	■ Diseñar una estructura de prototipo de sistema conformado por captura de datos y modelo propuesto. ■ Cargar complementos del modelo.
Ejecutar el prototipo y integrarlo con el modelo desarrollado.	Ejecución del sistema prototipo en tiempo real con proyectos de tecnología de campañas vigentes.	■ Ejecutar prototipo con dirección web de proyecto consultado. ■ Clasificar el estado de financiamiento a partir del resultado predicho.

Fuente: Elaboración propia

Después de analizar el rendimiento de cada modelo, tanto individualmente como el modelo final, se compararon los resultados con los antecedentes disponibles. Luego, se llevó a cabo una prueba piloto donde se ejecutó el modelo ensamblado entrenado, se obtuvieron sus características y se realizaron predicciones tanto del presupuesto para cada familia de productos como de la cantidad de productos necesarios para realizar un pedido.

Actividad 1: Diseñar prototipo de sistema con modelo propuesto

En esta actividad, se diseñó el prototipo del sistema que integra el modelo propuesto para optimizar la gestión de inventarios y mejorar la precisión en las proyecciones de demanda. El sistema fue concebido para utilizar datos históricos y variables clave, permitiendo una planificación más eficiente de las operaciones y una mejor adaptación a las fluctuaciones del mercado.

Entregable: Arquitectura del prototipo del sistema integrado.

Actividad 2: Ejecutar prototipo con proyectos tecnológicos vigentes. En esta actividad, se ejecuta el prototipo web diseñado para implementar el modelo, facilitando la visualización y la posibilidad de realizar un pedido automático de productos. Este sistema web fue desarrollado

con el fin de integrar de manera eficiente el modelo predictivo, permitiendo a los usuarios interactuar de forma intuitiva con las predicciones de demanda y facilitando la automatización del proceso de pedidos en tiempo real.

Entregable: Plataforma web con los resultados de los pronósticos obtenidos.

4.4. Metodología para la medición de resultados de la implementación

La medición de los resultados de la implementación se desarrolló mediante un procedimiento metodológico orientado a verificar si las preguntas específicas de la investigación fueron respondidas a partir del trabajo realizado durante la construcción, evaluación y despliegue del modelo predictivo. Para ello, se tomó como punto de partida la relación entre los problemas específicos, los objetivos específicos y las actividades ejecutadas en las fases de comprensión de datos, preprocesamiento, modelamiento, evaluación y despliegue de la solución. Bajo este enfoque, la medición no se limitó únicamente a calcular métricas de precisión, sino que buscó demostrar, de manera ordenada y sustentada, cómo cada etapa del proceso permitió obtener evidencia suficiente para responder las interrogantes planteadas en el estudio.

En primer lugar, para abordar la pregunta relacionada con la influencia de la consistencia de la base de datos histórica en la precisión de los modelos predictivos, se inició con la revisión estructural de la información disponible. Esta etapa consistió en analizar la calidad de los registros históricos de ventas, verificando la existencia de valores nulos, duplicados, inconsistencias en fechas, datos atípicos y continuidad temporal de la información. El límite metodológico de esta evaluación estuvo determinado por los datos disponibles en la empresa Donna S.A.C., por lo que el análisis se centró únicamente en la información registrada en la base de datos interna y no en fuentes externas. A partir de esta revisión, se estableció si la información histórica reunía condiciones mínimas de confiabilidad para ser utilizada en modelos de series temporales y Machine Learning. En consecuencia, la respuesta a esta pregunta se construyó observando cómo la depuración, organización y estructuración de los datos permitieron mejorar la estabilidad del conjunto de entrenamiento y reducir posibles distorsiones en los resultados predictivos.

Posteriormente, para responder la pregunta sobre qué técnicas de preprocesamiento permitieron mejorar el rendimiento de los modelos de predicción de demanda, se ejecutó una secuencia de actividades orientadas a transformar los datos originales en un conjunto apto para el entrenamiento de algoritmos predictivos. Este procedimiento incluyó la limpieza de registros, el tratamiento de valores faltantes, la corrección de inconsistencias, el manejo de valores atípi-

cos, la agregación de ventas por fecha, la selección de variables relevantes y la generación de variables temporales. El límite de esta fase estuvo dado por la naturaleza histórica y transaccional de la información, por lo que las transformaciones aplicadas se orientaron a conservar la estructura temporal de la demanda sin alterar el comportamiento real de los datos. Desde el punto de vista metodológico, estas técnicas fueron evaluadas según su aporte al rendimiento del modelo, comparando los resultados obtenidos luego del procesamiento de la información y verificando si las predicciones generadas se aproximaban de manera más consistente a los valores reales observados.

Asimismo, para tratar la pregunta referida a las variables que influyen significativamente en el comportamiento de la demanda de productos, se desarrolló un análisis exploratorio de datos y un proceso de ingeniería de características. Esta etapa permitió examinar el comportamiento histórico de las ventas e identificar patrones asociados al tiempo, tales como año, mes, día, día de la semana, fines de semana, rezagos de ventas y promedios móviles. El límite metodológico de esta identificación se estableció en función de las variables disponibles y derivables a partir de la base histórica de ventas, evitando incorporar factores externos que no estuvieran registrados de manera sistemática en la empresa. La respuesta a esta pregunta se construyó evaluando la utilidad de dichas variables dentro del proceso predictivo, es decir, observando si contribuían a capturar tendencias, estacionalidades o comportamientos recurrentes en la demanda. De esta manera, las variables seleccionadas fueron consideradas relevantes en la medida en que aportaron información útil para mejorar la capacidad explicativa y predictiva del modelo.

Finalmente, para responder la pregunta relacionada con qué modelo de *forecasting* presentó mejores resultados en términos de precisión y aplicabilidad para optimizar la toma de decisiones en el pedido a proveedores, se realizó una comparación metodológica entre los modelos implementados. Cada modelo fue entrenado y evaluado bajo condiciones equivalentes, utilizando el mismo conjunto de datos procesado, la misma variable objetivo y criterios de evaluación comparables. El límite de esta comparación estuvo definido por los algoritmos seleccionados para el estudio y por el horizonte de predicción establecido para el análisis de demanda. La medición se realizó mediante métricas cuantitativas como el Error Absoluto Medio, el Error Cuadrático Medio, la Raíz del Error Cuadrático Medio, el Error Porcentual Absoluto Medio y el coeficiente de determinación. Estas métricas permitieron comparar la diferencia entre los valores reales y los valores pronosticados, identificando el modelo con menor error y mejor ajuste. No obstante, la selección del modelo más adecuado no se basó únicamente en el resultado numérico, sino también en su aplicabilidad dentro del contexto operativo de Donna S.A.C., considerando su capacidad para apoyar decisiones vinculadas al reabastecimiento y al pedido a proveedores.

En conjunto, la metodología de medición permitió establecer una trazabilidad entre las preguntas específicas de investigación y las actividades desarrolladas durante la implementación. Primero, se evaluó la consistencia de los datos históricos; luego, se aplicaron técnicas de preprocesamiento para mejorar la calidad de la información; posteriormente, se identificaron variables relevantes para explicar el comportamiento de la demanda; y, finalmente, se compararon los modelos predictivos mediante métricas de evaluación. Este procedimiento permitió responder las preguntas específicas de forma gradual, objetiva y sustentada, demostrando que los resultados obtenidos no fueron producto de una evaluación aislada, sino de un proceso metodológico integral orientado a validar la utilidad del modelo predictivo en la toma de decisiones para el pedido a proveedores de Donna S.A.C.

4.4.1. Error Absoluto Medio

El Error Absoluto Medio mide la magnitud promedio del error entre los valores reales y los valores pronosticados. Esta métrica permite interpretar el error en las mismas unidades de la variable objetivo, por lo que resulta útil para conocer cuánto se desvía, en promedio, la predicción respecto a la demanda real.

En el contexto de esta investigación, el MAE permite estimar la diferencia promedio entre la cantidad real demandada y la cantidad pronosticada por el modelo. Por ello, esta métrica se relaciona directamente con la toma de decisiones en el pedido a proveedores, ya que un menor MAE indica que el modelo puede apoyar una planificación de compras más cercana a la demanda real.

$$MAE = \frac{1}{n} \sum_{i=1}^n |y_i - \hat{y}_i| \quad (\text{Ecuación 4.1})$$

Donde y_i representa el valor real de la demanda, $\hat{y}_i$ representa el valor pronosticado por el modelo y n corresponde al número total de observaciones evaluadas.

4.4.2. Error Cuadrático Medio

El Error Cuadrático Medio calcula el promedio de los errores elevados al cuadrado. Esta métrica penaliza con mayor intensidad los errores grandes, por lo que permite identificar modelos que presentan desviaciones significativas respecto a los valores reales.

Para la investigación, el MSE permite detectar si un modelo genera errores elevados en determinados periodos de demanda. Esto es importante porque, en productos perecibles, una

predicción muy alejada de la demanda real puede ocasionar exceso de inventario, merma o falta de productos disponibles para la venta.

$$MSE = \frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2 \quad (\text{Ecuación 4.2})$$

4.4.3. Raíz del Error Cuadrático Medio

La Raíz del Error Cuadrático Medio representa la raíz cuadrada del MSE. Su principal ventaja es que expresa el error en la misma unidad de la variable analizada, facilitando la interpretación del desempeño del modelo.

En esta investigación, el RMSE permite evaluar la magnitud del error considerando una mayor penalización para predicciones muy alejadas del valor real. Por esta razón, resulta útil para seleccionar modelos más estables y confiables en la planificación del reabastecimiento.

$$RMSE = \sqrt{\frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2} \quad (\text{Ecuación 4.3})$$

4.4.4. Error Porcentual Absoluto Medio

El Error Porcentual Absoluto Medio mide el error promedio en términos porcentuales. Esta métrica permite conocer qué tan alejada se encuentra la predicción respecto al valor real en términos relativos, lo cual facilita la comparación del desempeño entre modelos.

En el presente estudio, el MAPE permite interpretar el error de predicción de forma porcentual, lo cual resulta práctico para evaluar si el modelo mantiene un margen de error aceptable para la empresa. Un MAPE menor indica que el modelo tiene mayor precisión relativa y, por tanto, puede ser más útil para decidir cuánto pedir a los proveedores.

$$MAPE = \frac{1}{n} \sum_{i=1}^n \left| \frac{y_i - \hat{y}_i}{y_i} \right| \times 100 \quad (\text{Ecuación 4.4})$$

4.4.5. Coeficiente de determinación

El coeficiente de determinación permite medir la proporción de variabilidad de la demanda real que es explicada por el modelo. Un valor de R^2 más cercano a 1 indica una mayor capacidad explicativa del modelo sobre el comportamiento de la demanda.

En esta investigación, el R^2 permite evaluar qué tan bien el modelo logra representar los patrones históricos de la demanda. Esta métrica se relaciona con el objetivo de analizar las variables que influyen en el comportamiento de la demanda, ya que un mayor valor de R^2 indica que las variables utilizadas aportan información relevante para explicar las variaciones de las ventas.

$$R^2 = 1 - \frac{\sum_{i=1}^n (y_i - \hat{y}_i)^2}{\sum_{i=1}^n (y_i - \bar{y})^2} \quad (\text{Ecuación 4.5})$$

Donde $\bar{y}$ representa el promedio de los valores reales de la demanda.

En consecuencia, el modelo seleccionado fue aquel que presentó el mejor equilibrio entre bajo nivel de error, capacidad explicativa y aplicabilidad operativa para la planificación del reabastecimiento. De esta manera, la medición de resultados permitió verificar si la implementación del modelo predictivo contribuye a reducir la dependencia de decisiones empíricas y a fortalecer la planificación de pedidos a proveedores.

4.5. Cronograma de actividades y presupuesto

ACTIVIDADES O TAREAS	PERÍODO DE EJECUCIÓN / SEMANAS									
	1	2	3	4	5	6	7	8	9	10
Planteamiento del problema y objetivos										
Revisión bibliográfica										
Recopilación y preparación de datos										
Limpieza y transformación de datos										
Análisis exploratorio de datos										
Identificación de patrones y características de datos										
Selección de modelos										
Desarrollo e implementación del modelo seleccionado										
Estimación de parámetros del modelo										
Validación del modelo y comparación con datos reales										
Interpretación de resultados y análisis										
Redacción del informe final										

Figura 4.6: Cronograma de actividades

Fuente: Elaboración propia

Tabla 4.5: Presupuesto

Recurso	Categoría	Descripción	Costo (Soles)
Laptop	Equipo	Equipo de procesamiento del modelo de ML	3000
Internet	Servicio	Servicio básico para el uso del estudio	100
Electricidad	Servicio	Servicio básico para el uso del estudio	200
Python	Software	Lenguaje de programación de alto nivel	-
Servicio en la nube	Servicio	Alojar backend	100
Dominio web	Servicio	Dirección web personalizada	50
Mantenimiento Sistema	Servicio	Ajustes, pruebas y monitoreo del sistema	150
Almacenamiento nube	Servicio	Espacio virtual para respaldos del proyecto	50

Fuente: Elaboración propia

Capítulo 5

DESARROLLO DEL EXPERIMENTO

5.1. Determinación y evaluación de alternativas de solución

En primer lugar, se observó que la empresa cuenta con un amplio portafolio de productos, con más de 20 familias diferentes. Sin embargo, no todas estas familias tienen la misma relevancia en términos de ventas. Para abordar el desafío de predecir las ventas en este diverso conjunto de familias de productos, se llevó a cabo un proceso de selección cuidadoso. Se identificaron y seleccionaron las familias con mayor relevancia en las ventas, basándose en datos históricos y análisis de rendimiento comercial.




Figura 5.1: Familia de productos

Fuente: Elaboración propia

Las familias de productos seleccionadas para el análisis representan una parte significativa de las operaciones comerciales de la empresa. Se priorizaron según su contribución a los ingresos totales y su impacto en la rentabilidad general. Esta selección se basó en datos concretos, incluidos registros de ventas, análisis de tendencias del mercado y consultas con los departamentos de ventas y marketing. Con las familias de productos relevantes identificadas, se procedió a explorar diferentes enfoques para predecir las ventas futuras. Se reconocieron dos alternativas principales, diseñadas para maximizar la utilidad de los datos disponibles y adaptarse a las necesidades específicas de cada familia de productos:

1. Utilizar un Único Modelo de Predicción para las Familias Relevantes: En esta alternativa, se propone emplear un único modelo de predicción que abarque todas las familias de productos consideradas relevantes para las ventas. Este modelo se entrenaría utilizando datos históricos recopilados de estas familias y se utilizaría para realizar predicciones en tiempo real. Se considera que esta opción puede simplificar el proceso de predicción y ser más eficiente en términos de recursos y tiempo de implementación. No obstante, existe la preocupación de que este enfoque pueda subutilizar la información específica de cada familia, lo que podría resultar en predicciones menos precisas y adaptadas a las particularidades de cada una.
2. Probar múltiples modelos para cada familia relevante: Esta alternativa implica la eva-

luación de varios modelos de predicción para cada familia de productos relevante en las ventas. Dado que la empresa cuenta con un amplio conjunto de familias de productos, se seleccionaron las seis más relevantes en términos de ventas. Se considera probar modelos como regresión logística, LSTM y XGBoost, entre otros, para determinar cuál proporciona las mejores métricas de rendimiento para cada familia. Aunque esta opción puede ser más compleja y requerir más recursos computacionales y tiempo de implementación, ofrece la ventaja de una mayor personalización y optimización para cada familia, lo que podría resultar en predicciones más precisas y adaptadas a sus características específicas.

5.2. Propuesta solución

Esta propuesta, como se explicó anteriormente, implica un enfoque más granular y específico para cada familia de productos seleccionada. En lugar de aplicar un único modelo de predicción a todas las familias, se evalúa la idoneidad de múltiples modelos para cada una, considerando sus características individuales y su comportamiento histórico de ventas.

Para ello, se emplea un conjunto diverso de modelos de aprendizaje automático y de series temporales, entre los cuales se encuentran:

- **Linear Regression:** Modelo de regresión lineal que busca establecer una relación lineal entre las variables independientes y la variable dependiente.
- **Ridge y Lasso:** Variantes de la regresión lineal que incorporan regularización, permitiendo reducir el sobreajuste y mejorar la generalización del modelo.
- **Decision Tree:** Modelo basado en árboles de decisión que divide los datos en subconjuntos más homogéneos mediante reglas de decisión.
- **Random Forest:** Modelo de ensamble que combina múltiples árboles de decisión para mejorar la precisión y reducir la varianza.
- **Extra Trees:** Similar a Random Forest, pero introduce mayor aleatoriedad en la construcción de los árboles, lo que puede mejorar la robustez del modelo.
- **Gradient Boosting:** Modelo de ensamble que construye árboles de forma secuencial, corrigiendo los errores de los modelos anteriores.
- **K-Nearest Neighbors (KNN):** Modelo basado en la similitud entre datos, que realiza predicciones considerando los valores más cercanos en el espacio de características.

- **Support Vector Regression (SVR):** Modelo que utiliza máquinas de soporte vectorial para encontrar una función que se ajuste a los datos dentro de un margen de error tolerable.
- **XGBoost:** Algoritmo de *boosting* avanzado que optimiza iterativamente los errores, destacando por su alto rendimiento y eficiencia.
- **ARIMA:** Modelo de series temporales que captura relaciones autorregresivas y de medias móviles en los datos.
- **SARIMA:** Extensión de ARIMA que incorpora componentes estacionales, permitiendo modelar patrones repetitivos en el tiempo.
- **Prophet:** Modelo desarrollado por Facebook, diseñado para capturar tendencias, estacionalidades y efectos especiales en series temporales.

Todos estos modelos se entrenan con la misma finalidad: identificar cuál es el más adecuado para realizar predicciones de ventas para cada familia de productos. La selección del mejor modelo se basa en la comparación de métricas de rendimiento como el Error Cuadrático Medio (MSE), la Raíz del Error Cuadrático Medio (RMSE), el Coeficiente de Determinación (R^2) y el Error Porcentual Absoluto Medio (MAPE).

Asimismo, se evalúa la capacidad de cada modelo para capturar patrones relevantes en los datos, como tendencias a largo plazo, variaciones estacionales y comportamientos específicos de cada familia de productos.




Figura 5.2: Predicción Vs. valores actuales

Fuente: Elaboración propia

5.3. Planeamiento y descripción de actividades

5.3.1. Adquirir Base de Datos

Este paso involucra obtener acceso a la base de datos de la empresa que contiene los registros históricos de ventas de las diferentes familias de productos. Se establecerá comunicación con los departamentos pertinentes para obtener los datos necesarios de manera segura y ética. En la Figura observamos que se adquieren las ventas desde el año 2012 al 2026, sumando más de 7.340 millones de registros de ventas en este periodo.

```
df = pd.read_csv("data_with_added_columns.csv")
```

	SERIE	NUMERO	FECHA	TOTAL	producto	descripcion	unidad	igv	cantidad	precio	impuesto	subtotal	total	FAMILIA	dia_semana	dias_feriado	gasto_a_proveedores	numero_Transacciones
0	1	1082	2023-02-15	247,25	5601.0	NARANJA JUGO X KG	KG	0.0	107,5	2,3	0	247,25	247,25	FRUTA	2	0	1092	1084
1	1	1198	2024-08-04	184	5601.0	NARANJA JUGO X KG	KG	0.0	80	2,3	0	184	184	FRUTA	6	0	1118	1323
2	1	79238	2023-10-20	108	4843.0	BOLSAS T-SHIRT ASA PB 16X19	UND	18.0	10	4,3	6,559	36,441	43	DESCAR	4	0	902	960
3	1	79238	2023-10-20	108	4845.0	BOLSAS T-SHIRT ASA PB 21X24	PQT	18.0	5	10	7,627	42,373	50	DESCAR	4	0	1511	900
4	1	79238	2023-10-20	108	4849.0	BOLSAS WARA 10X15	UND	18.0	10	1,5	2,288	12,712	15	DESCAR	4	0	1011	877
...	...	...	...	...	...	...	...	...	...	...	...	...	...	...	...	...	...	...
620790	S001	59	2023-03-15	35,14	5763.0	PIMIENTO ROJO X KG	kg	18.0	0,73	6	0,66813	3,71186	4,38	VERDUR	2	0	927	1167
620791	S001	59	2023-03-15	35,14	5773.0	ROCOTO ENTERO X KG	KG	0.0	0,91	5	0	4,55	4,55	VERDUR	2	0	1131	1022
620792	S001	59	2023-03-15	35,14	5775.0	TOMATE ITALIANO X KG	KG	0.0	0,23	3	0	0,69	0,69	VERDUR	2	0	1536	1046
620793	S001	59	2023-03-15	35,14	5781.0	ZANAHORIA X KG	KG	0.0	0,52	2,2	0	1,144	1,144	VERDUR	2	0	1208	976
620794	S001	59	2023-03-15	35,14	5787.0	AJI VERDE X KG	KG	0.0	0,26	2,9	0	0,754	0,754	VERDUR	2	0	780	936

620795 rows x 18 columns

Figura 5.3: Datos históricos de ventas

Fuente: Elaboración propia

Posteriormente se decide agregar 3 nuevas columnas que serán relevantes para el pronostico de ventas. Siendo las columnas agregadas `dias_Feriado`, `gasto_a_proveedores` y `numero_Transacciones`

```
df = df[['FECHA', 'FAMILIA', 'cantidad', 'precio', 'dias_Feriado', 'gasto_a_proveedores', 'numero_Transacciones']].copy()
```

	FECHA	FAMILIA	cantidad	precio	dias_Feriado	gasto_a_proveedores	numero_Transacciones
0	2023-02-15	FRUTA	107,5	2,3	0	1092	1084
1	2024-08-04	FRUTA	80	2,3	0	1118	1323
2	2023-10-20	DESCAR	10	4,3	0	902	960
3	2023-10-20	DESCAR	5	10	0	1511	900
4	2023-10-20	DESCAR	10	1,5	0	1011	877
...	...	...	...	...	...	...	...
620790	2023-03-15	VERDUR	0,73	6	0	927	1167
620791	2023-03-15	VERDUR	0,91	5	0	1131	1022
620792	2023-03-15	VERDUR	0,23	3	0	1536	1046
620793	2023-03-15	VERDUR	0,52	2,2	0	1208	976
620794	2023-03-15	VERDUR	0,26	2,9	0	780	936

620795 rows x 7 columns

Figura 5.4: Datos históricos de ventas con 3 columnas agregadas

Fuente: Elaboración propia

5.3.2. Preprocesamiento de datos

Antes de utilizar los datos para el análisis y modelado, es fundamental realizar un preprocesamiento adecuado. Esto incluye la limpieza de datos para eliminar valores faltantes o erróneos, la normalización para asegurar que todas las variables estén en la misma escala y la codificación de variables categóricas si es necesario. Adicional a estos pasos para asegurar la calidad, se decidió trabajar con la familia de Verduras para este análisis de Forecasting




Figura 5.5: Ventas de la familia verduras

Fuente: Elaboración propia

5.3.3. Selección de algoritmos a utilizar

En este escenario, se han seleccionado los siguientes modelos para la predicción de ventas semanales de la familia de productos de verduras: Árbol de Decisión, Bosque Aleatorio, SVR, XGBoost, Regresión Lineal, ARIMA, LSTM y Prophet. Antes de proceder con el entrenamiento de estos modelos, se dividirán los datos en conjuntos de entrenamiento y prueba, asignando el 80 % de los datos para entrenamiento y el 20 % restante para pruebas.

5.3.3.1. Proceso de Entrenamiento y Evaluación de Modelos

1. **División de Datos:** Los datos se dividirán en dos conjuntos:

- **Entrenamiento (80 %):** Utilizado para entrenar los modelos.
- **Prueba (20 %):** Utilizado para evaluar el rendimiento de los modelos.

2. **Entrenamiento de Modelos:** Cada uno de los modelos seleccionados se entrenará utilizando el conjunto de datos de entrenamiento. Este proceso implicará ajustar los parámetros de cada modelo para optimizar su rendimiento.

5.3.4. Definir parámetros

Una vez seleccionados los modelos, se procederá a definir los parámetros iniciales de cada modelo y a realizar la optimización de hiperparámetros para mejorar su rendimiento predictivo. Esto se realizará utilizando técnicas como la búsqueda en cuadrícula o la optimización bayesiana. Una vez obteniendo estos parámetros se verá cual modelo es mejor para cada familia y se tomara la decisión de cual modelo trabajar con cada familia.

```
# Initialize models
models = {
    "Linear Regression": LinearRegression(),
    "Decision Tree": DecisionTreeRegressor(),
    "Random Forest": RandomForestRegressor(n_estimators=100),
    "SVR": SVR(),
    "XGBoost": XGBRegressor(),
    "ARIMA": None, # Placeholder for ARIMA model
    "LSTM": None, # Placeholder for LSTM model
    "Prophet": None # Placeholder for Prophet model
}

# Train and predict with each model
predictions = {}
for name, model in models.items():
    if name == "ARIMA":
        # Fit the ARIMA model on the training data (y_train)
        arima_model = auto_arima(y_train, seasonal=False, trace=True)
        arima_model.fit(y_train)
        # Make predictions for the test data (y_test)
        arima_forecast = arima_model.predict(n_periods=len(y_test))
        predictions[name] = arima_forecast.values
    elif name == "LSTM":
        # [samples, timesteps, features] -> 1 for predicting using the previous timestep
        X_train_lstm = X_train.values.reshape((X_train.shape[0], 1, X_train.shape[1]))
        X_test_lstm = X_test.values.reshape((X_test.shape[0], 1, X_test.shape[1]))

        # Define LSTM model
        lstm_model = Sequential()
        lstm_model.add(LSTM(50, activation='relu', input_shape=(X_train_lstm.shape[1], X_train_lstm.shape[2])))
        lstm_model.add(Dense(1))
        lstm_model.compile(optimizer='adam', loss='mse')

        # Fit the LSTM model
        lstm_model.fit(X_train_lstm, y_train, epochs=200, batch_size=32, verbose=0)

        # Make predictions
        lstm_predictions = lstm_model.predict(X_test_lstm)
        predictions[name] = lstm_predictions.flatten()
    elif name == "Prophet":
        # Define and fit the Prophet model
        prophet_model = Prophet()
        prophet_model.fit(train_df)

        # Make predictions
        prophet_forecast = prophet_model.predict(test_df[['ds']])
        predictions[name] = prophet_forecast['yhat'].values
    else:
        model.fit(X_train, y_train)
        predictions[name] = model.predict(X_test)
```

Figura 5.6: Parametros de los modelos elegidos

Fuente: Elaboración propia

5.4. Desarrollo de actividades. Aplicación de herramientas de solución

5.4.1. Adquisición de datos

La adquisición de datos consistió en recopilar la información histórica de ventas de la empresa, inicialmente almacenada en archivos externos como hojas de cálculo o archivos CSV. Para el análisis predictivo se utilizaron principalmente las variables **FECHA**, **Sede**, **FAMILIA** y **ventas_totales**, ya que estas permiten construir la serie temporal, segmentar la información por unidad operativa y definir la variable que será pronosticada.

Posteriormente, los datos fueron integrados en **Supabase**, una base de datos en la nube que permitió centralizar la información y mejorar su disponibilidad. Además, se organizaron tablas de usuarios y ventas, lo que permitió implementar un control de acceso por sede. Así, cada usuario puede visualizar únicamente los datos correspondientes a su sede, haciendo que el análisis y la predicción sean más específicos y seguros.

Finalmente, se verifica la correcta carga del dataset mostrando sus dimensiones y una vista preliminar de los primeros registros. Como resultado, se obtiene un conjunto de datos compuesto por aproximadamente 7.25 millones de registros y 102 columnas, evidenciando el manejo de una base de datos de gran escala para el desarrollo del sistema de proyección de ventas.

```
need, you may need to restart the kernel.  
[4]: import polars as pl  
  
df = pl.read_csv(  
    "tabla_detalle.csv",  
    separator=";",  
    infer_schema_length=20000,  
    ignore_errors=True,  
    try_parse_dates=False  
)  
  
print(df.shape)  
print(df.head())  
  
(7252669, 102)  
shape: (5, 102)
```

Figura 5.7: Carga y lectura del dataset

Fuente: Elaboración propia

5.4.2. Partición de datos

Después de ordenar los datos cronológicamente, se realizó la partición del conjunto de datos en entrenamiento y prueba. Esta división se hizo respetando el orden temporal, debido a que en los modelos de series de tiempo no es correcto mezclar los datos aleatoriamente, ya que el objetivo es predecir valores futuros a partir de información pasada.

El 80 % de los datos fue utilizado para entrenar los modelos, mientras que el 20 % restante fue destinado a la evaluación. Esta partición permitió simular un escenario real, donde el sistema aprende del historial de ventas y luego intenta predecir datos posteriores. De esta manera, se evaluó si el modelo podía anticipar correctamente el comportamiento futuro de la demanda.

5.4.3. Preprocesamiento de datos

Durante la etapa de preprocesamiento se aplicaron diversas técnicas orientadas a preparar, limpiar y optimizar la información antes del entrenamiento de los modelos predictivos. En primer lugar, se realizó la limpieza de datos, normalizando los nombres de las columnas, corrigiendo formatos e inconsistencias, eliminando registros duplicados e inválidos y tratando los valores nulos presentes en la base de datos histórica de ventas. Asimismo, la columna *FECHA* fue convertida a formato de fecha y la variable *ventas_totales* a formato numérico, permitiendo su correcto análisis en Python.

Posteriormente, los datos fueron ordenados cronológicamente y filtrados según la sede y la familia de productos seleccionada. Además, se efectuó el agrupamiento de productos por familias, especialmente en la categoría de verduras, con el propósito de consolidar la información comercial, facilitar el análisis del comportamiento de la demanda y reducir la complejidad de los datos.

De igual manera, se realizó la ingeniería y transformación de variables temporales mediante la extracción de atributos relevantes de la fecha, tales como año, mes, día y día de la semana, incluyendo también un indicador de fin de semana. Estas variables permitieron identificar patrones de estacionalidad y tendencias en las ventas.

Adicionalmente, se implementó la generación de variables derivadas o *lag features*, utilizando información de ventas de períodos anteriores mediante rezagos de 1, 7, 14 y 30 días, así como medias móviles de 7 y 30 días. Esto permitió que los modelos identificaran patrones diarios, semanales, quincenales y mensuales en la demanda, mejorando así su capacidad predictiva.

Finalmente, se efectuó el tratamiento de valores atípicos (*outliers*) para disminuir el impacto de registros anormales que pudieran afectar la precisión del modelo, y se aplicaron técnicas de normalización sobre las variables numéricas con el fin de estandarizar los datos y mejorar el desempeño de los algoritmos de aprendizaje automático utilizados en la investigación.

```
[24]: # Total general de nulos
df_modelo.null_count().sum_horizontal()

[24]: shape: (1,)
      sum
      ---
      u32
      ---
      1
```

Figura 5.8: preprocesamiento de la data

Fuente: Elaboración propia

En esa gráfica se observa claramente un outlier extremo alrededor del año 2018.

La mayoría de las ventas se mantienen dentro de un rango relativamente estable, mientras que existe un pico aislado que supera ampliamente el comportamiento normal de la serie. Ese valor anómalo rompe el patrón histórico de las ventas y podría estar asociado a:

- errores de digitación,
- carga incorrecta de información,
- duplicidad de registros,
- o un evento extraordinario no representativo del comportamiento real de la demanda.
- fallas en el sistema de captura,




Figura 5.9: Gráfico de Outliers

Fuente: Elaboración propia

5.4.4. Selección de Columnas relevantes

En esta etapa se presenta una vista preliminar del dataset procesado que será utilizado para el entrenamiento de los modelos predictivos. La Figura 5.10 muestra los primeros registros del conjunto de datos denominado `df_modelo`, el cual contiene información consolidada de ventas agrupadas por fecha y familia de productos.

El dataset está compuesto por variables fundamentales como la fecha de la transacción, la familia de productos, el total de ventas expresado en soles y el número de transacciones realizadas. Estas variables representan la base principal para el análisis temporal y la generación de proyecciones futuras.

Asimismo, esta validación preliminar permite confirmar que los datos fueron estructurados correctamente antes de iniciar el proceso de modelamiento predictivo.

```
i2]: df_modelo.head(1000)
```

```
i2]: shape: (1_000, 4)
```

FECHA	FAMILIA	ventas_totales	numero_transacciones
datetime[μs]	str	f64	u32
2010-12-06 00:00:00	"CONFIT"	48.9	16
2010-12-06 00:00:00	"ASEO P"	2.3	1
2010-12-06 00:00:00	"MENEST"	5.931	2
2010-12-06 00:00:00	"FARMAC"	1.5	1
2010-12-06 00:00:00	"POLLO"	24.81	5
...	...	...	...
2012-02-12 00:00:00	"COND"	1.0	3
2012-02-12 00:00:00	"MENEST"	31.37	11
2012-02-12 00:00:00	"PASAMA"	3.1	1
2012-02-12 00:00:00	"ESPE"	19.4	12
2012-02-12 00:00:00	"CARNE"	146.82	8

Figura 5.10: Visualización preliminar del dataset procesado

Fuente: Elaboración propia

En esta etapa se realiza una agregación de las ventas totales por familia de productos. Para ello, la información es agrupada utilizando la variable “FAMILIA”, permitiendo calcular la suma acumulada de ventas de cada categoría presente en el dataset.

Posteriormente, los resultados son ordenados de forma descendente con el objetivo de identificar cuáles son las familias con mayor volumen de ingresos dentro de la empresa. Este análisis exploratorio resulta importante porque permite reconocer qué categorías poseen mayor participación en las ventas totales y cuáles tienen mayor relevancia para el proceso predictivo.

Los resultados muestran que familias como “FRUTA”, “ABARRO”, “VERDUR” y “POLLO” concentran gran parte de las ventas históricas, evidenciando su importancia dentro del negocio.

```
[12]: ventas_familia = (
      df
      .group_by("FAMILIA")
      .agg(
        pl.col("TOTAL").sum().alias("ventas_totales")
      )
      .sort("ventas_totales", descending=True)
      )

ventas_familia.head(10)
```

[12]: shape: (10, 2)

FAMILIA	ventas_totales
str	f64
"FRUTA"	7.4690e6
"ABARRO"	6.6156e6
"VERDUR"	6.0950e6
"POLLO"	5.7845e6
"BEBIDA"	3.7570e6
"LACTEO"	3.5007e6
"CONFIT"	2.6707e6
"CARNE"	2.1799e6
"LICOR"	2.0530e6
"LIMPIE"	1.2343e6

Figura 5.11: Análisis de ventas por familia de productos

Fuente: Elaboración propia

5.4.5. Seleccionamos los modelos a utilizar

Para el desarrollo de la solución se evaluaron diferentes modelos de *machine learning* y series temporales, con el objetivo de identificar cuál ofrecía mejores resultados en la predicción de ventas. Entre los modelos utilizados se consideraron Regresión Lineal, Ridge, Lasso, *Decision Tree*, *Random Forest*, *Extra Trees*, *Gradient Boosting*, KNN y SVR.

Además, se incluyeron modelos orientados a series temporales como ARIMA, SARI-MA y Prophet, los cuales permiten capturar patrones históricos, tendencias y estacionalidades. Todos los modelos fueron entrenados usando las mismas variables predictoras y la misma variable objetivo, *ventas_totales*, para asegurar una comparación justa entre los algoritmos.




Figura 5.12: Evolución histórica de ventas por año

Fuente: Elaboración propia

En esta etapa se realiza el proceso de ingeniería de características sobre la serie temporal de ventas diarias. El objetivo consiste en generar variables adicionales que permitan al modelo identificar patrones históricos y mejorar la precisión de las proyecciones futuras.

Para ello, se construyen medias móviles de 7 y 30 días, las cuales permiten suavizar fluctuaciones diarias y detectar tendencias de corto y mediano plazo. Asimismo, se incorporan variables temporales derivadas de la fecha, como año, mes, día de la semana y un indicador de fin de semana.

De igual manera, se agregan variables rezagadas o *lags*, como *lag_1*, *lag_7*, *lag_14* y *lag_30*, las cuales almacenan información de ventas anteriores. Estas variables son fundamentales en modelos de *forecasting*, ya que permiten utilizar datos históricos para estimar el comportamiento futuro de la demanda.

Finalmente, se observa la presencia de valores nulos en los primeros registros de algunas columnas rezagadas y medias móviles. Esto ocurre porque al inicio de la serie temporal no existen suficientes observaciones previas para calcular dichas métricas, lo cual constituye un comportamiento normal dentro del proceso de construcción de variables temporales.

```
[30]: df_fruta_diario = df_fruta_diario.with_columns(
      pl.col("ventas_totales").rolling_mean(7).alias("media_7"),
      pl.col("ventas_totales").rolling_mean(30).alias("media_30")
    )

df_fruta_diario.head(15)

[30]: shape: (15, 12)
      FECHA  ventas_totales  year  month  day_of_week  fin_semana  lag_1  lag_7  lag_14  lag_30  media_7  media_30
      datetime[us]         f64    i32    i8        i8        i8      f64    f64    f64    f64    f64    f64
2012-01-05 00:00:00    439.73  2012     1         4          0    null    null    null    null    null    null
2012-01-06 00:00:00    275.54  2012     1         5          1    439.73    null    null    null    null    null
2012-01-07 00:00:00    362.77  2012     1         6          1    275.54    null    null    null    null    null
2012-01-08 00:00:00    418.98  2012     1         7          1    362.77    null    null    null    null    null
2012-01-09 00:00:00    398.81  2012     1         1          0    418.98    null    null    null    null    null
...
2012-01-15 00:00:00    513.09  2012     1         7          1    576.08    418.98    null    null    421.952857    null
2012-01-16 00:00:00    374.67  2012     1         1          0    513.09    398.81    null    null    418.504286    null
2012-01-17 00:00:00    431.75  2012     1         2          0    374.67    394.08    null    null    423.885714    null
2012-01-18 00:00:00    299.39  2012     1         3          0    431.75    397.62    null    null    409.852857    null
2012-01-19 00:00:00    352.93  2012     1         4          0    299.39    332.36    439.73    null    412.791429    null
```

Figura 5.13: Ingeniería de características y construcción de variables temporales

Fuente: Elaboración propia

En esta etapa se realiza la preparación de los datos para el entrenamiento de los modelos de aprendizaje automático. Inicialmente, el dataset es convertido desde el formato Polars a Pandas debido a la compatibilidad de las librerías de machine learning utilizadas posteriormente.

Posteriormente, se definen las variables predictoras que serán utilizadas por el modelo para aprender el comportamiento histórico de las ventas. Estas variables incluyen características temporales, rezagos históricos y medias móviles construidas previamente durante el preprocesamiento de datos.

Asimismo, se define la variable objetivo denominada `ventas_totales`, la cual representa el valor que el modelo deberá predecir. Finalmente, se separan las variables independientes (X) y la variable dependiente (y), obteniendo un total de 5,086 registros y 10 variables predictoras para el entrenamiento del sistema predictivo.

```
[32]: # convertir a pandas para usar sklearn después
df_pandas = df_modelo.to_pandas()

# variables predictoras
features = [
    "year",
    "month",
    "day_of_week",
    "fin_semana",
    "lag_1",
    "lag_7",
    "lag_14",
    "lag_30",
    "media_7",
    "media_30"
]

# target
target = "ventas_totales"

X = df_pandas[features]
y = df_pandas[target]

print(X.shape)
print(y.shape)

(5086, 10)
(5086,)
```

Figura 5.14: Preparación de datos para el entrenamiento

Fuente: Elaboración propia

5.4.6. Evaluación de los modelos

La evaluación de los modelos se realizó comparando las predicciones generadas con los valores reales del conjunto de prueba. Para medir el desempeño se utilizaron métricas como MAE, MSE, RMSE y R^2 . Estas métricas permitieron analizar el error promedio, penalizar errores grandes, interpretar el error en la misma unidad de ventas y conocer qué tan bien el modelo explica la variabilidad de los datos.

Con estos resultados se elaboró una comparación entre los modelos entrenados. El modelo ganador fue seleccionado considerando su desempeño general, es decir, buscando el menor nivel de error y una buena capacidad explicativa. Luego, el modelo con mejor rendimiento fue reentrenado con toda la información disponible para generar el pronóstico final.

Los resultados muestran que el modelo XGBoost obtuvo el mejor desempeño general, registrando los menores niveles de error y el mayor ajuste estadístico respecto a los demás modelos evaluados. Debido a ello, el sistema lo selecciona automáticamente como el modelo ganador para realizar las proyecciones futuras de ventas.




Figura 5.15: Evaluación comparativa de modelos predictivos

Fuente: Elaboración propia

En esta etapa se presenta la comparación entre las ventas reales y las predicciones generadas por el modelo seleccionado para la familia de productos “ABARRO”, una de las categorías con mayor participación dentro de las ventas totales de la empresa.

El gráfico muestra tres componentes principales: los datos históricos utilizados para el entrenamiento del modelo, los datos reales correspondientes al periodo de prueba y las predicciones generadas automáticamente por el algoritmo seleccionado.

El sistema implementado fue diseñado para realizar un proceso automático de selección de modelos predictivos. Para ello, el programa entrena múltiples algoritmos y posteriormente evalúa su desempeño mediante métricas estadísticas, seleccionando automáticamente el modelo con mejor rendimiento.

En este caso, el modelo ganador fue utilizado para generar las predicciones mostradas en el gráfico. Asimismo, puede observarse que las predicciones siguen de manera aproximada la tendencia general de las ventas reales, demostrando la capacidad del modelo para aprender patrones históricos y utilizarlos para estimar escenarios futuros.




Figura 5.16: Comparación entre ventas reales y predicciones

Fuente: Elaboración propia

5.4.7. Simulación de la predicción

En esta etapa se presenta la proyección de ventas para los próximos 30 días correspondiente a la familia de productos “ABARRO”, utilizando el modelo predictivo seleccionado automáticamente por el sistema.

El gráfico muestra tanto el comportamiento histórico reciente de las ventas como las predicciones futuras generadas por el modelo XGBoost. Las proyecciones se realizan considerando tendencias históricas, comportamiento reciente, variables temporales y patrones aprendidos durante el entrenamiento.

Asimismo, las predicciones mantienen una tendencia coherente respecto al histórico reciente, indicando que el modelo logra capturar adecuadamente el comportamiento promedio de la demanda para esta familia de productos.

Este tipo de proyección resulta útil para la toma de decisiones relacionadas con planificación de inventario, abastecimiento, compras y gestión comercial dentro de la empresa.



Figura 5.17: Proyección de ventas a 30 días

Fuente: Elaboración propia

Finalmente, se presenta la tabla de pronóstico generada por el sistema predictivo, la cual contiene las estimaciones de ventas diarias para los próximos 30 días correspondientes a la familia de productos analizada.

Cada registro incluye la fecha proyectada y el valor estimado de ventas en soles obtenido mediante el modelo XGBoost. Estas predicciones fueron generadas utilizando patrones históricos, tendencias recientes y variables temporales construidas durante el preprocesamiento de datos.

La tabla permite visualizar detalladamente las proyecciones día por día, facilitando el análisis operativo y la planificación estratégica de la empresa. Asimismo, el sistema incorpora la opción de descargar el pronóstico en formato CSV, permitiendo exportar los resultados para su utilización en reportes y análisis complementarios.

Tabla de pronóstico		
	FECHA	ventas_predichas
0	2026-03-09 00:00:00	1684.37
1	2026-03-10 00:00:00	1775.8199
2	2026-03-11 00:00:00	2644.8701
3	2026-03-12 00:00:00	1127.0601
4	2026-03-13 00:00:00	1414.37
5	2026-03-14 00:00:00	1766.54
6	2026-03-15 00:00:00	852.37
7	2026-03-16 00:00:00	1805.83
8	2026-03-17 00:00:00	1781.53
9	2026-03-18 00:00:00	2022.22

Descargar forecast en CSV


Figura 5.18: Tabla detallada del pronóstico

Fuente: Elaboración propia

5.4.8. Despliegue de la solución

Después de completar el proceso de adquisición, preparación, entrenamiento, evaluación y pronóstico, la solución fue desplegada mediante un dashboard interactivo desarrollado en *Streamlit*. Este dashboard permitió presentar los resultados del análisis y del modelo predictivo de forma visual, ordenada y accesible para el usuario final.

El despliegue integró tres elementos principales: la base de datos en *Supabase*, el procesamiento en Python y la interfaz web en *Streamlit*. *Supabase* fue utilizado como repositorio central de datos, almacenando la información de usuarios y ventas. Python fue utilizado para realizar la limpieza de datos, generación de variables, entrenamiento de modelos, evaluación y pronóstico. *Streamlit* fue utilizado para construir la interfaz visual mediante la cual el usuario puede interactuar con el sistema.



The image shows a database schema visualization with two tables: 'usuarios' and 'ventas'. The 'usuarios' table has columns: id_usuario (int4, primary key), usuario (varchar), password (varchar), and sede (varchar). The 'ventas' table has columns: id_venta (int4, primary key), FECHA (date), Sede (varchar), FAMILIA (text), and ventas_totales (numeric).

Table	Column	Type
usuarios	id_usuario	int4
	usuario	varchar
	password	varchar
	sede	varchar
ventas	id_venta	int4
	FECHA	date
	Sede	varchar
	FAMILIA	text
	ventas_totales	numeric

public.ventas

public.usuarios

+

Filter by id_venta, FECHA, Sede... or ask AI

id_venta	ventas_totales	FECHA	Sede	FAMILIA	
1	31.8	2010-12-06	Molina	ABARRO	
2	391.94	2012-01-05	Molina	ABARRO	
3	250.61	2012-01-06	Molina	ABARRO	
4	317.37	2012-01-07	Molina	ABARRO	
5	350.18	2012-01-08	Molina	ABARRO	
6	264.09	2012-01-09	Molina	ABARRO	
7	332.87	2012-01-10	Molina	ABARRO	
8	302.35	2012-01-11	Molina	ABARRO	
9	276.38	2012-01-12	Molina	ABARRO	
10	431.9	2012-01-13	Molina	ABARRO	
11	294.58	2012-01-14	Molina	ABARRO	
12	399.12	2012-01-15	Molina	ABARRO	
13	477.93	2012-01-16	Molina	ABARRO	
14	261.35	2012-01-17	Molina	ABARRO	
15	329.7	2012-01-18	Molina	ABARRO	
16	306.75	2012-01-19	Molina	ABARRO	
17	441.13	2012-01-20	Molina	ABARRO	
18	317.55	2012-01-21	Molina	ABARRO	
19	388.3	2012-01-22	Molina	ABARRO	

Figura 5.19: Base de datos en Supabase

Fuente: Elaboración propia

El sistema inicia con un formulario de acceso. El usuario ingresa sus credenciales y estas son validadas con la tabla de usuarios almacenada en *Supabase*. Si los datos son correctos, el sistema identifica la sede asociada al usuario y carga únicamente la información correspondiente a dicha sede. Esta lógica permite implementar un control de acceso por sede, evitando que un usuario visualice información de otras unidades operativas.




Figura 5.20: Control de acceso y base de datos en Supabase

Fuente: Elaboración propia

Una vez dentro del dashboard, el usuario puede seleccionar la familia de productos que desea analizar. A partir de esta selección, el sistema filtra la información, prepara los datos y muestra diferentes secciones de análisis. Entre las principales funcionalidades se encuentran el resumen ejecutivo de ventas, el análisis por día de la semana, la participación porcentual diaria, el promedio mensual, el crecimiento anual, la serie histórica, la evaluación del modelo predictivo, la comparación entre ventas reales y predichas, y el pronóstico de ventas a 30 días.




Figura 5.21: Dashboard de análisis

Fuente: Elaboración propia

El despliegue permite que el sistema funcione como una herramienta operativa para el

administrador de cada sede. En lugar de trabajar únicamente con archivos manuales o cálculos aislados, el usuario puede acceder a una plataforma web, revisar el comportamiento histórico de las ventas y obtener una estimación futura que apoye la planificación del pedido a proveedores.




Figura 5.22: Log in de Dashboard

Fuente: Elaboración propia

Además, la integración con *Supabase* permite que la información pueda actualizarse con nuevos registros de ventas. Conforme la empresa incorpore datos recientes, el sistema podrá procesarlos nuevamente y generar predicciones más actualizadas. Esto permite que el modelo mantenga una relación continua con la operación real de la empresa y no se limite a un análisis estático.




Figura 5.23: Key de API 12222 para conexión entre Supabase y Python

Fuente: Elaboración propia

En conjunto, el despliegue de la solución permite transformar el modelo predictivo en una herramienta funcional, accesible y útil para la toma de decisiones. De esta manera, el

proyecto no se limita a la construcción técnica de modelos, sino que culmina en una solución aplicada que permite mejorar la planificación de compras, reducir la incertidumbre en el reabastecimiento y apoyar una gestión más eficiente de productos perecibles.

Capítulo 6

ANÁLISIS DE RESULTADOS

6.1. Resultados

El presente capítulo tiene como finalidad analizar los resultados obtenidos a partir de la implementación de modelos predictivos aplicados a las ventas de la empresa **Market Dona**, enfocándose principalmente en la categoría de frutas. El propósito del estudio no solo fue obtener predicciones precisas de ventas, sino contribuir a la solución de uno de los principales problemas identificados en la empresa: el **sobrestock y la falta de stock de productos**.

Actualmente, Market Dona enfrenta dificultades relacionadas con la gestión de inventario debido a compras realizadas sin una estimación precisa de la demanda. Esta situación ocasiona dos escenarios negativos para la empresa. Por un lado, el exceso de productos genera sobrestock, incrementando pérdidas económicas por deterioro, especialmente en productos perecibles como las frutas. Por otro lado, una compra insuficiente provoca quiebres de stock, ocasionando pérdida de ventas y disminución de satisfacción en los clientes.

Frente a esta problemática, la investigación propone el uso de modelos predictivos como herramienta de apoyo para la toma de decisiones de compra. La finalidad es alcanzar un equilibrio adecuado entre la cantidad de productos adquiridos y la demanda real esperada. Para ello, se utilizó la predicción de ventas como base para elaborar un presupuesto de compra más preciso, permitiendo a Market Dona adquirir cantidades más cercanas a las necesidades reales del negocio.

De acuerdo con los resultados obtenidos, el modelo seleccionado como mejor alternativa fue **Linear Regression**, debido a que presentó los mejores indicadores de desempeño entre los modelos evaluados. Los resultados obtenidos fueron un **MAE de 399.57**, un **MSE de 279,381.62**, un **RMSE de 528.57** y un R^2 de **0.744**.




Figura 6.1: Gráfico de ventas reales vs predicción

El valor de $R^2 = 0,744$ indica que el modelo logra explicar aproximadamente el **74.4 % del comportamiento de las ventas**, lo que demuestra una capacidad adecuada para representar la tendencia de demanda en la categoría fruta. Esto es importante para Market Dona, ya que permite contar con estimaciones más confiables al momento de planificar las compras.

Asimismo, el **MAE de 399.57** refleja que el margen promedio de error del modelo es relativamente bajo en comparación con el volumen general de ventas. Esto significa que las predicciones obtenidas pueden utilizarse como referencia válida para definir presupuestos de abastecimiento y reducir decisiones basadas únicamente en experiencia empírica o intuición.

En el gráfico de ventas reales versus predicción se observa que las predicciones mantienen un comportamiento cercano a las ventas reales durante gran parte del periodo evaluado. Aunque existen algunas diferencias en momentos de alta variabilidad, el modelo logra seguir la tendencia general del mercado. Este comportamiento resulta favorable para la empresa, debido a que permite anticipar cambios en la demanda y ajustar las compras de manera más eficiente.

Los resultados también evidencian que los modelos de Machine Learning obtuvieron un mejor desempeño que los modelos tradicionales de series temporales, como ARIMA y SARIMA. Estos últimos presentaron errores más elevados y valores negativos de R^2 , lo cual indica una menor capacidad para representar el comportamiento real de las ventas. Esto sugiere que las ventas de Market Dona dependen no solo del tiempo, sino también de múltiples factores dinámicos que los modelos de aprendizaje automático pueden captar de mejor manera.

La implementación de este sistema predictivo representa una mejora significativa para la gestión comercial de Market Dona. Mediante el uso de presupuestos basados en predicción de ventas, la empresa puede planificar mejor sus compras y mantener un equilibrio más adecuado




Figura 6.2: Gráfico de ventas reales vs predicción

entre oferta y demanda. Esto permite:

- Reducir pérdidas ocasionadas por productos vencidos o deteriorados.
- Disminuir costos de almacenamiento innecesario.
- Evitar quiebres de stock y pérdida de clientes.
- Mejorar la disponibilidad de productos.
- Optimizar el uso del capital destinado a compras.
- Fortalecer la toma de decisiones basada en datos.

En términos prácticos, la predicción de ventas se convierte en una herramienta de apoyo para determinar cuánto comprar en cada periodo, evitando tanto compras excesivas como compras insuficientes. De esta manera, la empresa puede alcanzar un equilibrio de inventario que contribuya a mejorar su rentabilidad y eficiencia operativa.

Finalmente, los resultados demuestran que la aplicación de modelos predictivos en Market Dona puede contribuir significativamente a mejorar la gestión de inventario y el proceso de abastecimiento. El uso del modelo Linear Regression permitió obtener predicciones suficientemente precisas para apoyar la elaboración de presupuestos de compra, ayudando a reducir el sobrestock y minimizar la falta de productos, generando así un impacto positivo en las ventas y en la administración general de la empresa.

6.2. Experiencia del usuario y uso operativo del sistema

El sistema predictivo propuesto fue diseñado para que cada administrador de sede de Donna S.A.C. pueda tomar decisiones semanales más informadas en el pedido de productos

perecibles. Su principal objetivo es estimar la demanda futura y permitir un presupuesto de compra ajustado a las necesidades reales de la operación.

En cada ciclo semanal, el administrador ingresa al sistema para cargar o actualizar los datos de ventas recientes. Esta información se integra al histórico de ventas, asegurando que la base de datos refleje el comportamiento más reciente de la demanda. Con cada actualización, el sistema procesa los datos, construye variables relevantes como día de la semana, mes, rezagos de ventas y medias móviles, y genera nuevas predicciones que consideran patrones recientes y tendencias temporales.

A partir de estas proyecciones, el administrador puede determinar la cantidad de productos a solicitar a los proveedores. Si la predicción indica una mayor demanda, el presupuesto de compra puede incrementarse de manera controlada; si la demanda esperada es menor, se reduce el pedido para evitar exceso de inventario, deterioro de productos y pérdidas económicas.

Además, el sistema ofrece herramientas visuales como métricas, gráficos comparativos y tablas de predicción, lo que facilita la interpretación de los resultados y la comparación entre ventas reales y pronosticadas. La posibilidad de exportar los pronósticos permite utilizar la información en reportes internos o en la planificación de compras, fortaleciendo la gestión operativa.

Con el uso continuo, la base de datos se enriquece y el modelo se actualiza periódicamente, mejorando su precisión y adaptándose a cambios en el comportamiento de la demanda. De esta manera, el administrador no solo consulta una predicción, sino que participa en un ciclo constante de actualización, análisis y mejora del proceso de abastecimiento.

En resumen, el sistema proporciona un apoyo práctico y confiable en la gestión de productos perecibles, reduciendo la incertidumbre en la compra, optimizando el presupuesto semanal y minimizando riesgos asociados al sobrestock y quiebres de inventario. Su implementación contribuye a decisiones más precisas, ordenadas y basadas en datos, fortaleciendo la eficiencia y la rentabilidad de cada sede.

Capítulo 7

CONCLUSIONES

Se concluye que la implementación de un modelo predictivo de demanda contribuye a mejorar la toma de decisiones en el proceso de pedido a proveedores en Donna S.A.C., debido a que permite estimar la demanda futura de productos perecibles a partir de datos históricos de ventas y variables temporales relevantes. De esta manera, la empresa puede contar con una herramienta de apoyo para planificar el reabastecimiento con mayor precisión, reduciendo la dependencia de decisiones basadas únicamente en la experiencia o criterios subjetivos.

Respecto al primer objetivo específico, se determinó que la calidad de la base de datos histórica influye directamente en la precisión de los modelos predictivos. La disponibilidad de registros organizados, completos y consistentes permitió construir una serie temporal adecuada para el análisis de la demanda. Asimismo, la identificación de valores atípicos, datos duplicados o inconsistencias fue necesaria para evitar distorsiones en el entrenamiento del modelo y mejorar la confiabilidad de los resultados obtenidos.

En relación con el segundo objetivo específico, se concluye que las técnicas de preprocesamiento de datos fueron fundamentales para mejorar el rendimiento de los modelos de predicción. La limpieza de datos, la agrupación diaria de ventas, el tratamiento de valores atípicos, la selección de columnas relevantes y la construcción de variables temporales permitieron transformar los registros históricos en una base adecuada para el modelamiento predictivo. Estas actividades fortalecieron la capacidad del modelo para identificar patrones de comportamiento en la demanda de productos perecibles.

Con respecto al tercer objetivo específico, se identificó que las variables temporales e históricas tienen una influencia relevante en el comportamiento de la demanda. Factores como el día de la semana, el mes, las ventas históricas, los rezagos de demanda y los promedios móviles permitieron representar mejor las variaciones de consumo. Esto confirma que la de-

manda de productos perecibles no presenta un comportamiento uniforme, sino que responde a patrones temporales que deben ser considerados en el proceso de pronóstico.

En cuanto al cuarto objetivo específico, se evaluaron distintos modelos de forecasting y machine learning mediante métricas como MAE, MSE, RMSE, MAPE y R^2 . A partir de esta comparación, se seleccionó el modelo con mejor desempeño predictivo y mayor aplicabilidad para el contexto de la empresa. Según los resultados obtenidos, el modelo seleccionado presentó una capacidad adecuada para aproximarse a la demanda real, por lo que puede ser utilizado como apoyo para la planificación de compras y la optimización del reabastecimiento.

Finalmente, se concluye que la propuesta desarrollada representa una mejora metodológica y operativa para Donna S.A.C., ya que permite convertir los datos históricos de ventas en información útil para la toma de decisiones. La implementación del modelo predictivo no solo aporta a la estimación de la demanda futura, sino que también contribuye a reducir riesgos asociados al sobrestock, quiebres de stock y pérdidas por productos perecibles, fortaleciendo así la eficiencia del proceso de abastecimiento.

Anexos

Anexo I: Matriz de Consistencia

PROBLEMAS	OBJETIVOS	HIPÓTESIS
Problema General	Objetivo General	Hipótesis General
¿Como la implementación de modelos de series temporales y Machine Learning beneficiará la toma de decisiones en el proceso del pedido a los proveedores en la empresa Donna SAC?	Implementar modelos de series temporales y Machine Learning que beneficien la toma de decisiones en el proceso del pedido a los proveedores en la empresa Donna SAC.	La implementación de modelos de series temporales y Machine Learning beneficiara en la toma de decisiones en el proceso de pedido a los proveedores en la empresa Donna SAC.
Problemas Específicos	Objetivos Específicos	Hipótesis Específicas
¿Cómo influye la consistencia de la base de datos histórica en la precisión de los modelos predictivos de demanda de productos?	Determinar cómo la consistencia de la base de datos histórica influye en la precisión de los modelos predictivos de demanda de productos.	La consistencia de la base de datos histórica influye significativamente en la precisión de los modelos predictivos de demanda de productos.
¿Qué técnicas de preprocesamiento de datos permiten mejorar el rendimiento de los modelos de predicción de demanda en productos?	Identificar las técnicas de preprocesamiento de datos más efectivas para mejorar el rendimiento de los modelos de predicción de demanda en productos.	Las técnicas de preprocesamiento de datos, como la normalización, tratamiento de valores atípicos y selección de características, mejoran el rendimiento de los modelos de predicción de demanda.
¿Qué variables influyen significativamente en el comportamiento de la demanda de productos en la empresa Donna S.A.C.?	Analizar las variables que influyen significativamente en el comportamiento de la demanda de productos en la empresa Donna S.A.C.	Variables como estacionalidad, promociones, días festivos y volumen de ventas influyen significativamente en el comportamiento de la demanda de productos.
¿Qué modelo de forecasting presenta mejores resultados en términos de precisión y aplicabilidad para optimizar la toma de decisiones en el pedido a proveedores?	Evaluar qué modelo de forecasting presenta mejores resultados en términos de precisión y aplicabilidad para optimizar la toma de decisiones en el pedido a proveedores.	Los modelos avanzados de forecasting presentan mejores resultados de precisión y aplicabilidad en comparación con otros métodos de aprendizaje automático para optimizar la toma de decisiones en el pedido a proveedores.

Tabla 1: Matriz de consistencia

Anexo II: Arquitectura de Software




Figura 1: Arquitectura de Software

Anexo III: Estados Financieros

ESTADO DE GANANCIAS Y PÉRDIDAS (ENERO 2026)

LOCAL:	SAMOA
PERIODO:	Ene-26
VENTAS ORION	273,126.10
COSTO DE MERCAD VENDIDA	198,915.12
MARGEN COMERCIAL	74,210.98
MERMAS	641.27
PERDIDAS	753.80
MARGEN BRUTO	72,815.91
RRHH TIENDA	23,886.95
RRHH CENTRAL	2,183.75
GASTO DE COMPRA	1,219.90
GASTOS DE VENTAS	3,225.93
COMISION POS	5,192.28
GASTO DE MKT	152.00
PAGO DE SERVICIOS	3,309.20
COSTOS DE LOCACION	4,504.88
GASTOS FINANCIEROS	142.21
EBITDA	29,283.23
PAGO DEUDAS	-
INVERSIONES	33,000.00
EBIT	(3,716.77)
IMPUESTOS	2,993.40
BENEFICIOS NETOS	(6,710.17)

Tabla 2: Fuente: Elaboración propia

FLUJO DE CAJA (ENERO 2026)

LOCAL:	SAMOA
PERIODO:	Ene-26
SALDO INI y/o ANT	
APALANCAMIENTO / PRESTAMOS	
VENTAS ORION	273,126.10
PAGO POR MERCADERIAS	191,255.72
RRHH TIENDA	23,886.95
RRHH CENTRAL	2,183.75
GASTO DE COMPRA	1,219.90
GASTOS DE VENTAS	3,225.93
COMISION POS	5,192.28
GASTO DE MKT	152.00
PAGO DE SERVICIOS	3,309.20
COSTOS DE LOCACION	4,504.88
GASTOS FINANCIEROS	142.21
PAGO DE DEUDAS	-
INVERSIONES	33,000.00
IMPUESTOS	2,993.40
EGRESOS TOTAL	271,066.22
FLUJO DE CAJA	2,059.88

Tabla 3: Fuente: Elaboración propia

Descripción:

En enero 2026, la tienda **Samoa** tuvo ventas de **S/ 273,126.10** con un margen bruto de **S/ 72,815.91**. El **EBITDA** fue de **S/ 29,283.23**, aunque tras inversiones de **S/ 33,000** y otros gastos, el **EBIT** quedó negativo en **(S/ 3,716.77)**, resultando en una pérdida neta de **(S/ 6,710.17)**. El flujo de caja fue positivo en **S/ 2,059.88**, indicando que a pesar de los resultados contables negativos, las operaciones generaron liquidez suficiente para cubrir los compromisos inmediatos.

ESTADO DE GANANCIAS Y PÉRDIDAS (FEBRERO 2026)

LOCAL:	SAMOA
PERIODO:	Feb-24
VENTAS ORION	255,282.10
COSTO DE MERCAD VENDIDA	180,542.02
MARGEN COMERCIAL	74,740.08
MERMAS	1,693.47
PERDIDAS	178.30
MARGEN BRUTO	72,868.31
RRHH TIENDA	22,124.69
RRHH CENTRAL	2,783.75
GASTO DE COMPRA	1,342.50
GASTOS DE VENTAS	3,488.70
COMISION POS	4,886.10
GASTO DE MKT	-
PAGO DE SERVICIOS	3,724.80
COSTOS DE LOCACION	-
GASTOS FINANCIEROS	28.50
EBITDA	34,546.27
PAGO DEUDAS	-
INVERSIONES	15,263.49
EBIT	19,282.78
IMPUESTOS	2,812.20
BENEFICIOS NETOS	16,470.58

Tabla 4: Fuente: Elaboración propia

FLUJO DE CAJA (FEBRERO 2026)

LOCAL:	SAMOA
PERIODO:	Feb-24
SALDO INI y/o ANT	
APALANCAMIENTO / PRESTAMOS	
VENTAS ORION	255,282.10
PAGO POR MERCADERIAS	184,699.99
RRHH TIENDA	22,124.69
RRHH CENTRAL	2,783.75
GASTO DE COMPRA	1,342.50
GASTOS DE VENTAS	3,488.70
COMISION POS	4,886.10
GASTO DE MKT	-
PAGO DE SERVICIOS	3,724.80
COSTOS DE LOCACION	-
GASTOS FINANCIEROS	28.50
PAGO DE DEUDAS	-
INVERSIONES	15,263.49
IMPUESTOS	2,812.20
EGRESOS TOTAL	241,154.72
FLUJO DE CAJA	14,127.38

Tabla 5: Fuente: Elaboración propia

Descripcion:

En febrero 2026, las ventas descendieron a **S/ 255,282.10**, pero el margen bruto se mantuvo estable en **S/ 72,868.31**. El **EBITDA** subió a **S/ 34,546.27** y el **EBIT** fue de **S/ 19,282.78**, generando beneficios netos de **S/ 16,470.58**. El flujo de caja mejoró significativamente a **S/ 14,127.38**, reflejando un manejo más eficiente de los costos y una recuperación de liquidez, lo que indica un mejor control en la planificación de compras y mermas.

ESTADO DE GANANCIAS Y PÉRDIDAS (MARZO 2026)

LOCAL:	SAMOA
PERIODO:	Mar-24
VENTAS ORION	276,817.65
COSTO DE MERCAD VENDIDA	198,176.69
MARGEN COMERCIAL	78,640.96
MERMAS	-
PERDIDAS	468.30
MARGEN BRUTO	78,172.66
RRHH TIENDA	27,444.76
RRHH CENTRAL	4,527.01
GASTO DE COMPRA	1,182.00
GASTOS DE VENTAS	3,945.50
COMISION POS	5,497.56
GASTO DE MKT	400.00
PAGO DE SERVICIOS	3,392.80
COSTOS DE LOCACION	-
GASTOS FINANCIEROS	28.50
EBITDA	31,811.53
PAGO DEUDAS	-
INVERSIONES	14,480.33
EBIT	17,331.20
IMPUESTOS	1,578.25
BENEFICIOS NETOS	15,752.95

Tabla 6: Fuente: Elaboración propia

FLUJO DE CAJA (MARZO 2026)

LOCAL:	SAMOA
PERIODO:	Mar-24
SALDO INI y/o ANT	
APALANCAMIENTO / PRESTAMOS	
VENTAS ORION	276,817.65
PAGO POR MERCADERIAS	-
RRHH TIENDA	27,444.76
RRHH CENTRAL	4,527.01
GASTO DE COMPRA	1,182.00
GASTOS DE VENTAS	3,945.50
COMISION POS	5,497.56
GASTO DE MKT	400.00
PAGO DE SERVICIOS	3,392.80
COSTOS DE LOCACION	-
GASTOS FINANCIEROS	28.50
PAGO DE DEUDAS	-
INVERSIONES	14,480.33
IMPUESTOS	1,578.25
EGRESOS TOTAL	62,476.71
FLUJO DE CAJA	214,340.94

Tabla 7: Fuente: Elaboración propia

Descripcion: En marzo 2026, las ventas alcanzaron **S/ 276,817.65** con un margen bruto de **S/ 78,172.66**. El **EBITDA** se situó en **S/ 31,811.53** y el **EBIT** en **S/ 17,331.20**, con beneficios netos de **S/ 15,752.95**. El flujo de caja se elevó a **S/ 214,340.94**, mostrando que la empresa mantuvo un fuerte control sobre los egresos y logró una sólida generación de liquidez, consolidando la eficiencia operativa.

Balance General (Abril 2026)

Activos		Pasivos	
Caja y bancos	S/ 98,451.00	Pasivos corrientes	S/ 70,000.00
Cuentas por cobrar	S/ 35,000.00	Pasivos no corrientes	S/ 53,000.00
Inventario optimizado	S/ 115,000.00	Total Pasivos	S/ 123,000.00
Anticipos	S/ 8,000.00	Patrimonio	
Activos fijos netos	S/ 80,000.00	Capital	S/ 202,840.00
		Utilidad abril	S/ 33,611.00
		Reserva (Contingencias)	-S/ 23,000.00
		Total Patrimonio	S/ 213,451.00
Total Activos	S/ 336,451.00	PASIVOS + PATRIMONIO	S/ 336,451.00

Tabla 8: Fuente: Elaboración propia

Estado de Resultados (Abril 2026)

Ingresos	S/ 304,800.00
Egreso	S/ 248,349.00
Flujo Operativo	S/ 56,451.00
Sistema de control	S/ 6,000.00
Pago de deuda neto	S/ 2,000.00
Caja neta	S/ 48,451.00

Tabla 9: Fuente: Elaboración propia

Estado de Resultados Detallado (Abril 2026)

Ventas	S/ 289,800.00
Costo de Ventas	S/ 201,200.00
Margen Comercial	S/ 88,600.00
Mermas	290.00
Perdidas	150.00
Margen Bruto real	88,160.00
RRHH TIENDA	27,800.00
RRHH CENTRAL	4,800.00
GASTO DE COMPRA	1,200.00
GASTOS DE VENTAS	3,700.00
COMISIÓN POS	5,600.00
GASTO DE MKT	-450.00
SERVICIOS	3,500.00
LOCACIÓN	4,500.00
GASTOS FINANCIEROS	30.00
EBITDA	37,480.00
Depreciacion	1,200.00
EBIT	36,280.00
Impuestos	1,769.00
UTILIDAD NETA	34,511.00

Tabla 10: Fuente: Elaboración propia

Descripción:

En abril 2026, tras aplicar el modelo predictivo desarrollado en la tesis para optimizar los pedidos de proveedores y reducir costos, las ventas crecieron a **S/ 289,800.00**, con un margen bruto real de **S/ 88,160.00**, evidenciando una mejora en la rentabilidad operativa. El **EBITDA** fue de **S/ 37,480.00** y el **EBIT** se ubicó en **S/ 36,280.00**, generando una utilidad neta de **S/ 34,511.00**. La caja neta disponible fue de **S/ 48,451.00** y el flujo operativo alcanzó **S/ 56,451.00**, demostrando que la aplicación del modelo permitió reducir mermas, optimizar inventarios y mejorar la liquidez, cumpliendo con el objetivo de la tesis de optimizar la toma de decisiones en los pedidos a proveedores y controlar los gastos.

En conclusión, al comparar los primeros cuatro meses del año, se observa que la implementación del modelo predictivo en abril permitió un **incremento en ventas, reducción de**

pérdidas y mermas, y un **flujo de caja más saludable**, lo que confirma que el modelo está funcionando según lo previsto y aporta valor tangible a la gestión financiera y operativa de Market Donna.

BIBLIOGRAFÍA

- Benites Sernaqué, J. M. (2021). *Implementación de un sistema de pronóstico de ventas utilizando redes neuronales artificiales para la empresa Cerámicos Lambayeque SAC* [Tesis de grado]. Universidad Señor de Sipán.
- Breiman, L. (2001). Random Forests. *Machine Learning*, 45(1), 5-32. <https://doi.org/10.1023/A:1010933404324>
- Brockwell, P. J., & Davis, R. A. (2002). *Introduction to time series and forecasting*. Springer.
- Brownlee, J. (2017). *Long Short-Term Memory Networks With Python: Develop Sequence Prediction Models with Deep Learning*. Machine Learning Mastery. <https://books.google.com.pe/books?id=m7SoDwAAQBAJ>
- Chen, T., & Guestrin, C. (2016). XGBoost: A Scalable Tree Boosting System. *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*, 785-794. <https://doi.org/10.1145/2939672.2939785>
- Chopra, S. (2019). *Supply Chain Management: Strategy, Planning, and Operation* (7.^a ed.). Pearson.
- Dini, M., Gligo, N., & Patiño, A. (2021). *Transformación digital de las mipymes: elementos para el diseño de políticas*. CEPAL.
- Durrani, A. M., et al. (2026a). Lightweight machine learning framework using temporal features for electric vehicle demand response forecasting on edge devices. *Scientific Reports*, 16, 947.
- Durrani, A. M., UlAsar, A., Aziz, A., Khan, W., Yousaf, M. Z., Anjam, F., Farooq, U., Abdullah, M., & Shabaz, M. (2026b). Lightweight machine learning framework using temporal features for electric vehicle demand response forecasting on edge devices. *Scientific Reports*, 16, 947. <https://doi.org/10.1038/s41598-025-30465-9>
- El Madini, F. E. (2024). *Enhancing Fresh-Food Retail Forecasting with Machine Learning and External Factors* [Tesis de maestría, Stockholm University].
- Fayyad, U., Piatetsky-Shapiro, G., & Smyth, P. (1996). The KDD process for extracting useful knowledge from volumes of data. *Communications of the ACM*, 39(11), 27-34.

- Feng, M., Zheng, J., Ren, J., Hussain, A., Li, X., Xi, Y., & Liu, Q. (2019). Big data analytics and mining for effective visualization and trends forecasting of crime data. *IEEE Access*, 7, 106111-106123.
- Fierro Torres, C. Á., Castillo Pérez, V. H., & Torres Saucedo, C. I. (2022). Análisis comparativo de modelos tradicionales y modernos para pronóstico de la demanda: enfoques y características. *Revista Iberoamericana para la Investigación y el Desarrollo Educativo*, 24. <https://doi.org/https://doi.org/10.23913/ride.v12i24.1203>
- Food and Agriculture Organization of the United Nations. (2011). *Global Food Losses and Food Waste: Extent, Causes and Prevention*. FAO.
- Friedman, J. H. (2001). Greedy Function Approximation: A Gradient Boosting Machine. *The Annals of Statistics*, 29(5), 1189-1232.
- Gupta, D., Sambyo, K., Prasad, M., & Agarwal, S. (2022). *Advanced Machine Intelligence and Signal Processing*. Springer Nature Singapore. <https://books.google.com.pe/books?id=Sup3EAAQBAJ>
- Hastie, T., Tibshirani, R., & Friedman, J. (2009a). *The Elements of Statistical Learning* (2.^a ed.). Springer.
- Hastie, T., Tibshirani, R., & Friedman, J. (2009b). *The Elements of Statistical Learning* (2.^a ed.). Springer.
- Heizer, J., Render, B., & Munson, C. (2017). *Operations Management: Sustainability and Supply Chain Management* (12.^a ed.). Pearson.
- Heredia, A. (2020). *Políticas de fomento para la incorporación de las tecnologías digitales en las micro, pequeñas y medianas empresas de América Latina: revisión de experiencias y oportunidades* [Accessed: 2024-10-24].
- Higa Shimabukuro, H. (2021). Análisis de pronóstico de demanda para poder gestionar el inventario aplicado al sector salud.
- Hoarau, M. (2022). *Time Series Analysis on AWS: Learn how to build forecasting models and detect anomalies in your time series data*. Packt Publishing. <https://books.google.com.pe/books?id=4ohbEAAQBAJ>
- Hyndman, R. J., & Athanasopoulos, G. (2018a). *Forecasting: Principles and Practice* (2.^a ed.). OTexts.
- Hyndman, R. J., & Athanasopoulos, G. (2018b). *Forecasting: Principles and Practice* (2.^a ed.). OTexts.
- Jamali, S., & Rangwala, H. (2009). Digging Digg: Comment Mining, Popularity Prediction, and Social Network Analysis. *2009 International Conference on Web Information Systems and Mining*. <https://doi.org/10.1109/WISM.2009.15>

- Laura Huaita, R. M. (2020). *Modelo predictivo de demanda basado en redes neuronales para aprovisionamiento en empresas textiles* [Tesis doctoral]. Universidad Mayor de San Andres.
- Mell, P., & Grance, T. (2011). The NIST Definition of Cloud Computing. *National Institute of Standards and Technology*, (800-145).
- Merdas, H., & Hameed Mousa, A. (2023). Food sales prediction model using machine learning techniques. *International Journal of Electrical and Computer Engineering (IJECE)*, 13, 6578. <https://doi.org/10.11591/ijece.v13i6.pp6578-6585>
- Mintarya, L. N., Halim, J. N., Angie, C., Achmad, S., & Kurniawan, A. (2023). Machine learning approaches in stock market prediction: A systematic literature review [7th International Conference on Computer Science and Computational Intelligence 2022]. *Procedia Computer Science*, 216, 96-102. <https://doi.org/https://doi.org/10.1016/j.procs.2022.12.115>
- Mitchell, T. (1997). *Machine Learning*. McGraw-Hill. <https://books.google.com.pe/books?id=EoYBngEACAAJ>
- Molina, J. P. (2017). Modelación econométrica de la demanda de semilla de chile dulce Lamuyo y Blocky en Costa Rica mediante series de tiempo univariadas. *e-Agronegocios*, 3(2).
- Montgomery, D., Peck, E., & Vining, G. (2013). *Introduction to Linear Regression Analysis*. Wiley. <https://books.google.com.pe/books?id=ISyiRZh09oEC>
- Neba Cyril, C., Shu Fuhnwi, G., Nsuh, G., Agbara, P., Neba, A., Webnda, F., & Ikpe, V. (2024). Advancing Retail Predictions: Integrating Diverse Machine Learning Models for Accurate Walmart Sales Forecasting. *Asian Journal of Probability and Statistics*, 26, 1-23. <https://doi.org/10.9734/ajpas/2024/v26i7626>
- New Research Presents Policy Opportunities for China to Reduce Food Loss and Waste — The Global FoodBanking Network* [Accessed: 2024-11-04]. (2023). <https://www.foodbanking.org/es/news/new-research-presents-policy-opportunities-for-china-to-reduce-food-loss-and-waste/>
- Ocampo, E. M. T., GIRALDO, D. A. M., & Isaza, H. S. (2004). Pronóstico de ventas usando redes neuronales. *Scientia et technica*, 10(26), 25-30.
- Panda, S. K., & Mohanty, S. N. (2023). Time Series Forecasting and Modeling of Food Demand Supply Chain Based on Regressors Analysis. *IEEE Access*, 11, 42679-42700. <https://doi.org/10.1109/ACCESS.2023.3266275>
- Parra Ortega, M. W., et al. (2017). Gestión de la cadena de suministro Supply Chain Management y logística en Colombia.
- Paul, L. C., Suman, A. A., & Sultan, N. (2013). Methodological analysis of principal component analysis (PCA) method. *International Journal of Computational Engineering & Management*, 16(2), 32-38.

- Perú Panorama general* [Accessed: 2023-01-15]. (2024). <https://www.bancomundial.org/es/country/peru/overview>
- Robles Rakov, M. A., & Valverde Campos, M. Y. (2021). *Sistema de predicción para incrementar las ventas de accesorios y repuestos automotrices en la empresa GGP Automotriz* [Tesis de grado]. Universidad San Martín de Porres.
- Rodríguez-León, J., & Pachón-Rincón, M. (2021). Estudio de pronóstico para la planeación, caso de estudio empresa distribuidora del sector farmacéutico. *Revista UIS ingenierías*, 20(4), 59-78.
- Salman, A., & Shaka'a, Y. (2026a). Automated water demand forecasting for national-scale deployment: a prophet-based framework for Palestinian municipal water management. *Scientific Reports*, 16, 3295. <https://doi.org/10.1038/s41598-025-33060-0>
- Salman, A., & Shaka'a, Y. (2026b). Automated water demand forecasting for national-scale deployment: a prophet-based framework for Palestinian municipal water management. *Scientific Reports*, 16, 3295. <https://doi.org/10.1038/s41598-025-33060-0>
- Shaheen, F. A., Gul, A., Ganai, N., Majid, M., Rashid, M., & Sultan, A. (2026). Deep learning-enabled cherry price forecasting and real-time system deployment across multi-market supply chains in India. *Scientific Reports*, 16, 1582. <https://doi.org/10.1038/s41598-025-30980-9>
- Streamlit Inc. (2024). Streamlit Documentation.
- Suaza-Medina, M. E., Zarazaga-Soria, F. J., Pinilla-Lopez, J., Lopez-Pellicer, F. J., & Lacasta, J. (2023). Effects of data time lag in a decision-making system using machine learning for pork price prediction. *Neural Computing and Applications*. <https://doi.org/10.1007/s00521-023-08730-7>
- Villarreal, F. (2016). Introducción a los Modelos de Pronósticos. *Univ. Nac. del Sur*, 1-121.
- Villarreal Buenaventura, D. E., & Prada Gómez, Y. (2016). Una versión homotópica del teorema de cauchy y su aplicación a los gráficos alfa.
- Wadalkar, Y., Sai Tarun, Y. V. H., Singhal, J., & Sonkusare, R. (2021a). A Comparative Analysis based approach for Bitcoin Price Forecasting. *International Journal of Engineering Research & Technology (IJERT)*, 10(4), 650-654.
- Wadalkar, Y., Sai Tarun, Y. V. H., Singhal, J., & Sonkusare, R. (2021b). A comparative analysis based approach for Bitcoin price forecasting. *International Journal of Engineering Research and Technology (IJERT)*, 10(4).
- Wang, L. (2005). *Support Vector Machines: Theory and Applications*. Springer Berlin Heidelberg. <https://books.google.com.pe/books?id=uTzMPJjVjsMC>
- Wen, H., Li, X., Zhang, H., Wen, B., Ren, Y., & Zhao, X. (2026). Construction of performance score dynamic prediction system for clinical departments using explainable machine

- learning. *Health Information Science and Systems*, 14, 8. <https://doi.org/10.1007/s13755-025-00394-y>
- Zhou, Z.-H. (2021). *Machine Learning*. Springer Singapore. <https://doi.org/https://doi.org/10.1007/978-981-15-1967-3>