



UNIVERSIDAD ESAN
FACULTAD DE INGENIERÍA
INGENIERÍA DE TECNOLOGÍAS DE INFORMACIÓN Y SISTEMAS

Desarrollo de modelo predictivo de la demanda de productos perecibles para la optimización de la toma de decisiones en el pedido de Proveedores en la empresa Market Donna utilizando técnicas de Forecasting

Trabajo de investigación para el curso de Trabajo de Tesis II

Zacarías Kevin Paucar Tello
Jerson Walter Toledo Flores
Asesor: Marks Calderón

Lima, 15 de abril de 2026

Resumen

Para optimizar la toma de decisiones en la compra de productos de la empresa, es fundamental desarrollar un modelo predictivo de demanda que integre datos históricos de ventas con información relevante, como precios, cantidades, días festivos, número de transacciones y otros factores. Este proceso comienza con una recopilación exhaustiva de datos, seguida de un análisis exploratorio para identificar patrones y tendencias significativas.

La selección de características permite determinar las variables que tienen mayor impacto en la demanda. Posteriormente, se emplean técnicas de modelado predictivo, como regresión lineal, redes neuronales, máquinas de soporte vectorial (SVM), Random Forest, ARIMA, Prophet, entre otros modelos de forecasting y aprendizaje automático, para predecir el volumen futuro de ventas. Una vez entrenado, el modelo se valida rigurosamente para garantizar su precisión. Tras su implementación, es crucial realizar un seguimiento continuo del modelo para ajustarlo y optimizar las predicciones frente a cambios en el mercado y otros factores relevantes. Esto permite mejorar la gestión de decisiones estratégicas y diseñar políticas de precios más efectivas. La investigación se centra en el uso de modelos de series de tiempo para identificar las áreas con mayor volumen de ventas, maximizando así los ingresos potenciales. Los modelos de series temporales son herramientas analíticas que permiten analizar y predecir patrones en datos secuenciales a lo largo del tiempo.

Para llevar a cabo este enfoque, es esencial recopilar datos detallados de ventas por familia de productos, incluyendo información como volúmenes de ventas diarios, semanales o mensuales, ingresos generados y factores externos, como promociones, eventos especiales, fines de semana o días festivos. Mediante el análisis de estos datos, es posible identificar patrones y tendencias que faciliten pronósticos precisos para la empresa Donna S.A.C.

El análisis de series de tiempo implica estudiar la estructura temporal de los datos, considerando factores como tendencia, estacionalidad y variaciones aleatorias. Con esta comprensión, se aplican modelos estadísticos y técnicas de pronóstico para estimar el comportamiento futuro de las ventas. Utilizando este enfoque, la empresa puede obtener estimaciones confiables y precisas que impulsen una mejor toma de decisiones estratégicas y operativas.

Palabras claves: Predicción, Ventas, Machine Learning, Regresión

Abstract

To optimize decision-making in the company's product purchasing process, it is essential to develop a demand predictive model that integrates historical sales data with relevant information such as prices, quantities, holidays, number of transactions, and other factors. This process begins with comprehensive data collection, followed by exploratory analysis to identify significant patterns and trends.

Feature selection helps determine the variables that have the greatest impact on demand. Subsequently, predictive modeling techniques, such as linear regression, neural networks, support vector machines (SVM), Random Forest, ARIMA, Prophet, and other forecasting and machine learning models, are employed to predict future sales volumes. Once trained, the model undergoes rigorous validation to ensure its accuracy. After implementation, continuous monitoring of the model is crucial to adjust and optimize predictions in response to market changes and other relevant factors. This enables improved strategic decision-making and the development of more effective pricing policies. The research focuses on using time series models to identify areas with the highest sales volumes, thereby maximizing potential revenue. Time series models are analytical tools that allow the analysis and forecasting of patterns in sequential data over time.

To carry out this approach, it is essential to collect detailed sales data by product category, including information such as daily, weekly, or monthly sales volumes, generated revenue, and external factors like promotions, special events, weekends, or holidays. By analyzing this data, it is possible to identify patterns and trends that facilitate accurate forecasts for the company Donna S.A.C. Time series analysis involves studying the temporal structure of the data, considering factors such as trends, seasonality, and random variations. With this understanding, statistical models and forecasting techniques are applied to estimate future sales behavior. Using this approach, the company can obtain reliable and accurate estimates that drive better strategic and operational decision-making.

Keywords: Forecasting, Sales, Machine Learning, Regression

Para mi familia y amigos

Índice general

Índice de Figuras	10
Índice de Tablas	12
1. PLANTEAMIENTO DEL PROBLEMA	13
1.1. Descripción de la Realidad Problemática	13
1.2. Formulación del Problema	15
1.2.1. Problema General	15
1.2.2. Problemas Específicos	15
1.3. Objetivos de la Investigación	15
1.3.1. Objetivo General	15
1.3.2. Objetivos Específicos	16
1.4. Justificación de la Investigación	16
1.4.1. Teórica	16
1.4.2. Práctica	16
1.4.3. Metodológica	17
1.5. Delimitación del Estudio	17
1.5.1. Espacial	17
1.5.2. Temporal	18
1.5.3. Conceptual	18

1.6. Hipótesis	18
1.6.1. Hipótesis General	18
1.6.2. Hipótesis Específicas	18
1.6.3. Matriz de Consistencia	19
2. MARCO TEÓRICO	20
2.1. Antecedentes de la investigación	20
2.1.1. Tesis relacionadas	20
2.1.2. Sales forecasting using long short term memory networks	20
2.1.3. Investigación sobre Implementación de un Sistema de Pronóstico de Ventas utilizando Redes Neuronales Artificiales para la Empresa Cerámicos Lambayeque SAC	23
2.1.4. Aplicativo Web de Series Temporales para el Pronóstico de Ventas en la Empresa SERMIMIN	25
2.1.5. Análisis de Pronóstico de Demanda para la Gestión del Inventario en el Sector Salud	27
2.1.6. Artículos relacionados	29
2.1.7. Time-series analysis with smoothed Convolutional Neural Network	29
2.1.8. Approaching sales forecasting using recurrent neural networks and transformers	33
2.1.9. Prediction Analysis Sales for Corporate Services Telecommunications Company using Gradient Boost Algorithm	36
2.1.10. Predicting Future Sales of Retail Products using Machine Learning	37
2.1.11. Time Series Forecasting and Modelling of Food Demand Supply Chain based on Regressors Analysis	40
2.1.12. Advancing Retail Predictions: Integrating Diverse Machine Learning Models for Accurate Walmart Sales Forecasting	43
2.1.13. Demand Forecasting for Online Market Stock: Case study Cleanroom Apparel	46

2.2. Bases Teóricas	50
2.2.1. Gestión de la cadena de suministro de productos perecibles	50
2.2.2. Machine Learning	51
2.2.3. Modelos predictivos de demanda	57
2.2.4. Series de tiempo	57
2.2.5. Tipos de series temporales	58
2.2.6. Elementos de la serie de tiempo	59
2.2.7. Aplicación de las series de tiempo	61
2.2.8. Métodos de suavizamiento de la serie	61
2.2.9. Técnica de suavizamiento exponencial	62
2.2.10. Método de suavización exponencial simple	62
2.2.11. ¿Qué valor de alfa usar?	62
2.2.12. Tipos de suavizado exponencial	63
2.2.13. Ventajas del método de suavización exponencial simple	64
2.3. Marco Conceptual	65
2.3.1. Predicción	65
2.3.2. Modelos de regresión	65
2.3.3. Modelos de clasificación	65
2.3.4. Abastecimiento	65
2.3.5. Precisión del modelo	66
2.3.6. Aprovisionamiento	66
2.3.7. Eficiencia	66
2.3.8. Gestión logística	66
2.3.9. Eficacia	66
2.3.10. Series temporales	66
2.3.11. Especificidad	67

2.3.12. Automatización	67
2.3.13. Validación cruzada	67
2.3.14. Algoritmo de pronóstico	67
2.3.15. Red neuronal artificial	67
2.3.16. Datos históricos	67
3. METODOLOGÍA DE LA INVESTIGACIÓN	68
3.1. Diseño de la investigación	68
3.1.1. Enfoque	68
3.1.2. Alcance	68
3.1.3. Tipo	69
3.1.4. Población y muestra	69
3.1.5. Unidad de análisis	69
3.2. Técnicas de recolección de datos	70
3.3. Técnicas para el procesamiento y análisis de la información	72
3.3.1. Metodología de la implementación de la solución	73
3.3.2. Comprensión del negocio	74
3.3.3. Comprensión de los datos	76
3.3.4. Procesamiento	82
3.3.5. Transformación	82
3.3.6. Modelamiento	82
3.3.7. Evaluación	87
3.3.8. Despliegue	89
3.4. Metodología para la medición de resultados de la implementación	90
3.4.1. Raíz del error cuadrático medio (RMSE)	90
3.4.2. Error cuadrático medio (MSE)	90

3.4.3. Error Porcentual Absoluto Medio (MAPE)	91
3.4.4. Coeficiente de determinación	91
3.5. Cronograma de actividades y presupuesto	92
4. ENTORNO EMPRESARIAL	93
4.1. Descripción de la empresa	93
4.1.1. Reseña histórica y actividad económica	93
4.1.2. Descripción de la organización	94
4.1.3. Datos generales estratégicos de la empresa	95
5. DESARROLLO DEL EXPERIMENTO	103
5.1. Determinación y evaluación de alternativas de solución	103
5.2. Propuesta solución	105
5.3. Planeamiento y descripción de actividades	106
5.3.1. Adquirir Base de Datos	106
5.3.2. Preprocesamiento de datos	107
5.3.3. Selección de algoritmos a utilizar	108
5.3.4. Definir parámetros	109
5.4. Desarrollo de actividades. Aplicación de herramientas de solución	110
5.4.1. Preprocesamiento de datos	110
5.4.2. Selección de Columnas relevantes	110
5.4.3. Seleccionamos los modelos a utilizar	112
5.5. Medición de la solución	114
5.5.1. Simulación de la predicción	115
6. ANÁLISIS DE RESULTADOS	117
6.1. Resultados	117

7. CONCLUSIONES	120
Anexos	121
A. Anexo I: Matriz de Consistencia	122
BIBLIOGRAFÍA	124

Índice de Figuras

2.1. Metodología antecedente	32
2.2. Resultado antecedente	32
2.3. Resultado antecedente	33
2.4. Resultado antecedente	35
2.5. Árbol de decisión	52
2.6. Arquitectura LSTM	55
2.7. Series de tiempo	58
2.8. Componentes de la serie temporal	60
2.9. Aplicaciones de serie temporal	61
2.10. Posibles valores alfa	63
3.1. Consulta SQL	71
3.2. Tablas de ventas	72
3.3. Metodología KDD	73
3.4. Selección de tablas SQL	78
3.5. Tablas de ventas	79
3.6. Descripción cuantitativa	80
3.7. Cuantificación de semanas	80
3.8. Distribución de precion	81
3.9. Correlación de variables	81

3.10. Cronograma de actividades	92
4.1. Organigrama Donna SAC	95
4.2. Matriz interna y externa	102
5.1. Familia de productos	104
5.2. Predicción Vs. valores actuales	106
5.3. Datos históricos de ventas	107
5.4. Datos históricos de ventas con 3 columnas agregadas	107
5.5. Ventas de la familia verduras	108
5.6. Parametros de los modelos elegidos	109
5.7. Identificando las columnas con datos faltantes	110
5.8. Columnas de datos	111
5.9. Datos históricos de ventas	111
5.10. División de prueba y entrenamiento	112
5.11. Modelos elegidos	112
5.12. Definicion de modelos y métricas	113
5.13. Comparación de resultados	113
5.14. Resultados de modelos	114
5.15. Predicción numerica del mejor modelo	116
5.16. Predicción con el mejor modelo	116

Índice de Tablas

2.1. Resultados de Ventas pronosticadas	25
2.2. Tipos de suavizado de datos (data smoothing)	30
2.3. Resultados antecedente	40
2.4. Resultados antecedente	43
2.5. Resultados de modelos predictivos	46
3.1. Instrumentos de medida para recolección de datos	74
3.2. Actividades de la comprensión de negocio	75
3.3. Actividades de la Comprensión de los datos	77
3.4. Actividades de fase modelamiento	83
3.5. Actividades de fase evaluación	87
3.6. Actividades de fase Despliegue	89
3.7. Presupuesto	92
4.1. Oportunidades de Donna Sac	98
4.2. Amenazas de Donna Sac	99
4.3. Fortalezas de Donna Sac	101
4.4. Debilidades de Donna Sac	101
6.1. Comparación de metricas	119
A.1. Matriz de consistencia	123

Capítulo 1

PLANTEAMIENTO DEL PROBLEMA

1.1. Descripción de la Realidad Problemática

A nivel mundial, la predicción de la demanda de productos perecibles enfrenta desafíos significativos debido a la complejidad de los factores externos, la disponibilidad limitada de datos completos y precisos, la variabilidad en la vida útil de los productos, la naturaleza estática de muchos modelos predictivos, los desafíos logísticos y de distribución, así como los costos asociados con errores en las predicciones. Mejorar la rentabilidad en este contexto requiere el desarrollo de modelos más sofisticados que consideren estos desafíos y una gestión efectiva de la cadena de suministro para minimizar los riesgos financieros asociados con la incertidumbre en la demanda. Por ejemplo, un estudio realizado en China examinó la importancia de la precisión en las predicciones para evitar pérdidas en la industria de alimentos perecibles en el contexto de la rentabilidad empresarial («New Research Presents Policy Opportunities for China to Reduce Food Loss and Waste — The Global FoodBanking Network», 2023). Además, en un trabajo llevado a cabo en Estados Unidos, se destacó la influencia de factores externos como las condiciones climáticas y los cambios en los hábitos de consumo en la demanda de productos perecibles, lo cual impacta directamente en la rentabilidad de las empresas. Estas investigaciones reflejan la preocupación global por mejorar la capacidad predictiva en el ámbito de los productos perecibles para optimizar la rentabilidad en un contexto empresarial cada vez más competitivo.

En este contexto, la aplicación de minería de datos y modelos de pronóstico se presenta como una solución estratégica. “Bajo esta premisa, la utilización de pronósticos en estos productos ayudará a planificar de mejor forma el proceso de abastecimiento, a través de métodos cuantitativos. Para llevar a cabo este estudio se aplica un análisis de autocorrelación a todas las series de tiempo, con el fin de verificar la estacionalidad o aleatoriedad de los productos”. Otro

desafío importante es la capacidad de las empresas para aprovechar al máximo los datos disponibles. Muchas empresas peruanas, especialmente las pequeñas y medianas, pueden carecer de la infraestructura y la experiencia necesarias para implementar eficazmente soluciones de análisis de información. Aunque Perú ya cuenta con dos ediciones de la Agenda Digital y ha manifestado un notable interés político en promover el uso de las TIC y el crecimiento de la Sociedad de la Información, los esfuerzos por establecer un marco institucional y una política completa que impulse la transformación digital del país aún no han sido suficientes (Heredia, 2020). Esto puede deberse a limitaciones presupuestarias, falta de talento especializado o simplemente falta de conocimiento sobre las ventajas que pueden ofrecer estas tecnologías. Además, el aspecto regulatorio y de privacidad también es un factor crucial. A medida que las empresas recopilan y analizan grandes cantidades de datos, es fundamental garantizar que lo hagan de manera ética y cumpliendo con las leyes de protección de datos. En Perú, como en muchos otros lugares, la regulación en torno a la privacidad de los datos está en constante evolución, lo que puede plantear desafíos adicionales para las empresas que buscan aprovechar el potencial del análisis.

La decisión de incorporar Machine learning se fundamenta en la necesidad de abordar problemas específicos en el manejo del stock y la toma de decisiones. “Es por ello que se ha creído conveniente hacer uso de IA, ya que en la empresa existen problemas respecto al stock de productos y esencialmente en la toma de decisiones. Los modelos de pronóstico son un procedimiento matemático que se utiliza para prevenir eventos o desenlaces futuros a través del análisis de patrones” Mintarya et al., 2023. El objetivo es mejorar la precisión de la proyección de ventas futuras, un aspecto crítico en la estrategia empresarial y la toma de decisiones. “Se han seleccionado diversos algoritmos de aprendizaje automático, como Random Forest, Regresión lineal, ARIMA y Redes Neuronales entre otras implementadas en Keras, para su aplicación en datos de ventas del año 2023 al 2024. Estos modelos se compararán en términos de precisión y eficacia en la proyección de ventas”.

En Perú, en el actual escenario de crecimiento económico del 2.3 % entre 2014 y 2023 («Perú Panorama general», 2024). Las empresas, incluida Donna S.A.C., han experimentado una expansión significativa en sus operaciones. Este aumento ha llevado consigo la gestión de una cantidad considerable de información, planteando desafíos cruciales en cuanto al procesamiento y análisis preciso de datos en tiempo real. Esta complejidad ha generado una toma de decisiones basada en datos subjetivos, afectando negativamente la planificación estratégica. Específicamente para Donna S.A.C., la gestión del stock de productos y la toma de decisiones relacionadas presentan obstáculos sustanciales. La falta de establecimiento de cantidades óptimas de productos para satisfacer la demanda, así como la identificación de productos más rentables, son problemas evidentes. A pesar de la importancia de la predicción en este entorno

dinámico, se observa una marcada escasez de investigaciones dedicadas a la implementación de modelos predictivos y técnicas de minería de datos en este contexto.

Esta aplicación específica de técnicas avanzadas de pronóstico en el ámbito minorista destaca la falta de investigaciones centradas en la predicción en empresas de este sector, evidenciando la urgencia de adoptar enfoques innovadores para mejorar la eficacia de la gestión de inventario y la toma de decisiones estratégicas en Donna S.A.C.

1.2. Formulación del Problema

1.2.1. Problema General

¿Como la implementación de un modelo predictivo de la demanda de productos perecibles beneficiará la toma de decisiones en el proceso del pedido a los proveedores en la empresa Donna SAC?

1.2.2. Problemas Específicos

- ¿Cómo pueden los modelos de predicción de demanda contribuir a una planificación de existencias de productos?
- ¿Qué técnicas de preprocesamiento de datos son más efectivas para mejorar la precisión de los modelos de predicción de demanda en productos perecibles?
- ¿Cuál es la influencia de las variables de la demanda para predecir productos perecibles y como pueden ajustarse en función al modelo?
- ¿Cuál es la función de los modelos avanzados de Forecasting de la demanda y cómo se comparan con otros métodos de aprendizaje automático en cuanto a precisión y aplicabilidad?

1.3. Objetivos de la Investigación

1.3.1. Objetivo General

Implementar un modelo predictivo de la demanda de productos perecibles que beneficie la toma de decisiones en el proceso del pedido a los proveedores en la empresa Donna SAC.

1.3.2. Objetivos Específicos

- Determinar cómo los modelos de predicción de demanda pueden contribuir a optimizar la planificación de existencias de productos.
- Determinar las técnicas de preprocesamiento de datos más efectivas para mejorar la precisión de los modelos de predicción de demanda en productos perecibles.
- Determinar que variables de la demanda influyen en predecir productos perecibles.
- Evaluar la eficacia de los modelos avanzados de Forecasting en la predicción de la demanda en una tienda, comparándolos con otros métodos de aprendizaje automático en términos de precisión y aplicabilidad

1.4. Justificación de la Investigación

1.4.1. Teórica

Se justifica teóricamente primeramente porque las técnicas de aprendizaje automático pueden analizar conjuntos de datos más grandes con mayor eficiencia y precisión que los métodos convencionales, lo que posibilita proporcionar un entendimiento aún más profundo de los patrones y tendencias. Este estudio tiene como propósito aportar nuevos conocimientos en el big data de datos mediante la implementación de técnicas avanzadas de forecasting de series de tiempo. El resultado satisfactorio de este enfoque está destinado a ser utilizado en la gestión precisa de la demanda de productos en el sector minorista, contribuyendo así a la optimización de procesos y la toma de decisiones estratégicas. En conjunto, se busca la eficacia global de la gestión de inventario en el ámbito de la minería de datos.

1.4.2. Práctica

Esta investigación surge en respuesta a la imperante necesidad de optimizar el aprovechamiento de la valiosa base de datos de nuestra empresa. Nos proponemos no solo hacer uso de los datos históricos disponibles, sino también desarrollar e implementar un modelo predictivo eficiente. El propósito primordial es transformar estos pronósticos en herramientas esenciales para respaldar decisiones estratégicas informadas en la gestión de abastecimiento para nuestras tiendas minoristas. Resaltando esta justificación práctica, buscamos mejorar el desempeño y la eficacia de las operaciones mediante una gestión avanzada de la demanda, lo que a su

vez impactará positivamente en la satisfacción del cliente, la optimización de inventarios y la rentabilidad general de la empresa.

1.4.3. Metodológica

. El principal problema que ayudará a resolver esta investigación es optimizar la precisión de la predicción de la demanda en las tiendas minoristas. Para ello, se implementará la técnica de forecasting aplicada a las series temporales, buscando obtener la mayor precisión posible en las predicciones de demanda. Este enfoque permitirá una gestión más eficaz del inventario y respaldará decisiones estratégicas basadas en datos predictivos más precisos y actualizados.

La metodología incluirá:

- Recopilación de datos históricos de ventas de productos perecibles.
- Identificación y recopilación de variables externas relevantes que puedan influir en la demanda (por ejemplo, eventos especiales, condiciones climáticas, tendencias de mercado).
- Selección y aplicación de técnicas de modelado predictivo, como regresión lineal, series temporales, o técnicas más avanzadas como modelos de redes neuronales o machine learning.
- Validación del modelo utilizando técnicas como la validación cruzada y la comparación de los resultados predichos con los datos reales de ventas.
- Implementación del modelo en un entorno empresarial y evaluación de su impacto en la rentabilidad.

1.5. Delimitación del Estudio

1.5.1. Espacial

Se realizará en la empresa Donna S.A.C. ubicada en el distrito de Breña, Provincia y Departamento de Lima. Teniendo como giro principal la venta de productos de supermercado.

1.5.2. Temporal

Se llevará a cabo en la empresa Donna S.A.C. mediante el análisis de los datos mensuales obtenidos desde el año 2023 al 2024, los cuales se obtendrán a partir de la data registrada por la empresa y proporcionados por el personal encargado del manejo de datos.

1.5.3. Conceptual

La presente, realizada en la empresa Donna S.A.C., se enfoca en la implementación de un modelo de Series de tiempo basado en algoritmos de aprendizaje automático. Este enfoque nos ayudará a realizar predicciones en la empresa, y la implementación se llevará a cabo utilizando herramientas básicas de producción. Se establecerán relaciones entre las diversas áreas presentes dentro de la empresa. Se evaluarán los beneficios que atraerá dicha implementación y se buscarán maneras de continuar mejorando el proceso.

1.6. Hipótesis

1.6.1. Hipótesis General

La implementación de un modelo predictivo de la demanda de productos perecibles beneficiara en la toma de decisiones en el proceso de pedido a los proveedores en la empresa Donna SAC.

1.6.2. Hipótesis Específicas

- El uso de modelos de predicción de demanda mejora la planificación de existencias de productos asegurando la disponibilidad adecuada.
- Las técnicas de procesamiento de datos como la normalización de datos, el tratamiento de valores atípicos y la selección de características relevantes, serán más efectivas para mejorar la precisión de los modelos de predicción de demanda en productos perecibles
- Las variables escogidas de la demanda tienen influencia significativa en el modelo.
- Los modelos avanzados de Forecasting proporcionan una mayor precisión y aplicabilidad en la predicción de la demanda en un entorno de tienda, en comparación con otros métodos de aprendizaje automático

1.6.3. Matriz de Consistencia

A continuación se presenta la matriz de consistencia elaborada para la presente investigación (véase Anexo [A.1](#)).

Capítulo 2

MARCO TEÓRICO

2.1. Antecedentes de la investigación

En esta sección se presentarán diversos artículos de investigación o tesis las cuales abordarán diversas técnicas y enfoques que se emplearon para afrontar problemas similares al de esta tesis.

2.1.1. Tesis relacionadas

2.1.2. Sales forecasting using long short term memory networks

2.1.2.1. Planteamiento del Problema y objetivo

La tesis se enfoca en predecir las ventas de la empresa Annapolis Cider Company en Wolfville, Nova Scotia, con el objetivo de optimizar la asignación de recursos humanos. Se busca desarrollar un modelo de pronóstico que pueda predecir las ventas diarias y por hora con un margen de error del 10%. Para abordar este desafío, se utilizan técnicas de aprendizaje automático, específicamente redes neuronales LSTM, que son conocidas por su eficacia en problemas de series temporales. Además de los datos históricos de ventas, el modelo también considera información como la fecha y hora, datos meteorológicos, indicadores de apertura/cierre y eventos especiales. Se comparan varios modelos de pronóstico, incluido un modelo de línea base de persistencia, un modelo Avg6Week y un modelo ARIMA, con el modelo LSTM para evaluar su rendimiento en la predicción de ventas minoristas. Se reconoce que las ventas de cidra pueden presentar más variabilidad en comparación con las ventas de restaurantes debido a la naturaleza menos predecible de las ventas por hora. Además, se menciona que condiciones

climáticas extremas, como tormentas y huracanes, pueden aumentar la dificultad de predecir con precisión las ventas

2.1.2.2. Base de datos de los autores

En la tesis se utilizan varios conjuntos de datos para el análisis y la predicción de ventas de la empresa Annapolis Cider Company. Estos conjuntos de datos incluyen: Datos de ventas históricas almacenados en el sistema POS de la empresa para un período de hasta cuatro años. Datos meteorológicos observados y pronosticados obtenidos del sitio web Dark Sky a través de un sitio web de recopilación de datos meteorológicos desarrollado llamado Weather Archive. Datos de eventos especiales extraídos de varios calendarios en línea de la web, como Annapolis Valley Events, Office Holidays y Acadia Athletic. Estos conjuntos de datos se utilizan para entrenar y evaluar los modelos de pronóstico, incluidos los modelos LSTM, ARIMA, persistencia y Avg6Week, con el objetivo de predecir las ventas diarias y por hora de la empresa

2.1.2.3. Metodología empleada por los autores

En la metodología siguen diversos pasos para el análisis y pronóstico.

- **Data Collection:** En la fase de Recopilación de Datos, se adquirieron datos de ventas históricas de la empresa Annapolis Cider Company almacenados en su sistema POS, datos meteorológicos observados y pronosticados de Dark Sky a través de Weather Archive, y datos de eventos especiales de fuentes en línea. Estos conjuntos de datos se utilizaron para el análisis y la predicción de ventas.
- **Data Cleaning:** El proceso de Limpieza de Datos involucró la detección y eliminación de valores irrelevantes, outliers, valores faltantes y duplicados en los conjuntos de datos de ventas y clima. Se realizó una conversión de tipos de datos y se calcularon las ventas por hora y por día a partir de los datos de transacciones originales.
- **Descriptive Statistical Analysis:** El Análisis Estadístico Descriptivo se centró en crear resúmenes y medidas de los datos de ventas antes de desarrollar los modelos predictivos. Se utilizaron gráficos para analizar las ventas en diferentes escalas de tiempo y se identificaron patrones estacionales y tendencias en los datos.
- **Data Preparation:** En la etapa de Preparación de Datos, se realizaron acciones como la estacionalización de datos, la selección de características relevantes, la creación de un indicador de eventos especiales, la normalización de datos y la división de datos en conjuntos de entrenamiento, validación y prueba. Además, se prepararon los datos de entrada

para los modelos de pronóstico.

A continuación, se presenta un resumen detallado de los métodos de modelado de predicción utilizados:

- **Persistence Model:** En el modelo de persistencia, la predicción de ventas para el próximo día (o próxima hora) es exactamente igual a las ventas del día (o hora) actual. Este enfoque es un modelo de referencia estándar para series temporales y solo puede hacer predicciones a corto plazo.
- **Avg6Week Model:** En este enfoque común, se calcula el promedio de las ventas en el mismo día de la semana durante las últimas 6 semanas para predecir las ventas del próximo día. Este modelo proporciona predicciones para cualquier día de la semana en la próxima semana.
- **ARIMA Model:** Se desarrolló un modelo ARIMA (Autoregressive Integrated Moving Average) que utiliza las ventas de los últimos 7 días para predecir las ventas del día siguiente. Este enfoque se basa en la identificación de patrones en los datos de series temporales.
- **LSTM Neural Networks:** Se implementó una red neuronal LSTM (Long Short-Term Memory) recurrente que utiliza datos de ventas, variables de fecha y hora, condiciones meteorológicas observadas, indicadores de apertura/cierre e indicadores de eventos especiales de los últimos 7 días, junto con el pronóstico del clima para el día siguiente. Este modelo se desplaza en el tiempo para hacer predicciones a dos días en el futuro.

2.1.2.4. Resultados obtenidos

- **Daily Sales Prediction Results:** El modelo LSTM para predicción diaria de ventas mostró el menor error absoluto medio (MAE) en el conjunto de prueba, con un valor de \$597.93 y un error porcentual absoluto medio (MAPE) del 19.7 %. Esto representó una reducción del 22.6 % en el error de prueba en comparación con el modelo de persistencia diaria.
- **Hourly Sales Prediction Results:** Para la predicción por hora de las ventas, el modelo LSTM logró el menor MAE en el conjunto de prueba, con un valor de \$51.59 y un MAPE del 40.8 %. Esto representó una disminución del 17.2 % en el error de prueba en comparación con el modelo de persistencia por hora.
- **Comparative Analysis:** Se observó que el modelo LSTM superó significativamente a los modelos de persistencia, Avg6Week y ARIMA en términos de precisión de predicción

tanto para las ventas diarias como por hora. La capacidad de la red neuronal LSTM para capturar patrones complejos en los datos de series temporales y su capacidad para aprender de secuencias largas contribuyeron a su rendimiento superior.

- **Impact of LSTM Features:** La inclusión de variables como datos de ventas históricas, fecha y hora, condiciones meteorológicas observadas, indicadores de apertura/cierre y eventos especiales en el modelo LSTM demostró ser crucial para mejorar la precisión de las predicciones de ventas. Estos factores externos y temporales permitieron al modelo LSTM capturar mejor la variabilidad en los datos de ventas.

2.1.3. Investigación sobre Implementación de un Sistema de Pronóstico de Ventas utilizando Redes Neuronales Artificiales para la Empresa Cerámicos Lambayeque SAC

2.1.3.1. Planteamiento del Problema y objetivo

La investigación presenta la implementación de un sistema basado en redes neuronales artificiales (RNA) para pronosticar las ventas en la empresa “Cerámicos Lambayeque SAC”. Para esto, se emplean datos históricos de ventas diarias y mensuales correspondientes a los años 2016 y 2017. Estos datos, obtenidos de los sistemas transaccionales de la empresa, a menudo se encuentran en desorden, incompletos o manipulados. Sin embargo, las RNA son capaces de filtrar el ruido y manejar estos datos de manera efectiva.

Los datos de ventas se almacenan en un arreglo bidimensional estático de 200 filas por 5 columnas, donde las ventas de 2016 se guardan en las posiciones de 0 a 71, las de 2017 en las posiciones de 72 a 143, y las ventas pronosticadas para 2018 se almacenan desde la posición 144 hasta la 199. Cada venta diaria se normaliza dividiéndola entre 1000.

Durante el entrenamiento de la RNA, se visualizan las ventas pronosticadas y se ajustan los pesos sinápticos iniciales. La estructura de la red neuronal consiste en cuatro neuronas de entrada, doce neuronas ocultas y una neurona de salida. Los atributos de la red se definen y se asignan valores a través de matrices para los pesos sinápticos. El entrenamiento de la RNA incluye la asignación de datos de ventas y un número determinado de iteraciones, así como la definición del ratio de aprendizaje. Durante cada iteración, se obtienen y visualizan los errores de predicción. El software permite al usuario comparar las ventas históricas y pronosticar las ventas diarias desde enero hasta julio de 2018.

2.1.3.2. Base de datos de los autores

Las ventas realizadas por la empresa durante los años 2016 y 2017. Esta información, que se encuentra en la base de datos de la empresa, será utilizada para realizar el pronóstico. Las ventas diarias y mensuales de los años 2016 y 2017 se almacenan en un arreglo bidimensional estático de 200 filas por 5 columnas. Las ventas de 2016 se ubican desde el ítem 0 hasta el ítem 71, mientras que las ventas de 2017 se colocan desde la posición 72 hasta la posición 143. Finalmente, las posiciones desde la 144 hasta la 199 se reservan para las ventas diarias y mensuales pronosticadas para el año 2018.

2.1.3.3. Metodología empleada por los autores

1. Definición del Almacén de Ventas: Se estableció una estructura bidimensional para registrar las ventas diarias mensuales, organizadas en filas, con el fin de utilizarlas en el entrenamiento y predicción mediante la red neuronal.
2. Creación de la Solución y Proyectos: Se empleó Microsoft Visual C# 2013 para desarrollar la aplicación, configurando una solución inicial en blanco y proyectos específicos para la red neuronal y la aplicación de consola.
3. Codificación del Sistema: Se detallaron los pasos necesarios para la programación del sistema de pronóstico de ventas, abarcando la definición de pesos y la visualización de datos de ventas durante el entrenamiento de la red neuronal.
4. Entrenamiento de la Red Neuronal: Se realizó el entrenamiento de la red neuronal, estableciendo parámetros como el número máximo de épocas y creando arreglos para manejar los gradientes de salida e entrada, así como las señales de los nodos ocultos y de salida.
5. Barajado de Datos: Se implementó un proceso para mezclar aleatoriamente los datos de ventas, visitando cada dato en un orden aleatorio para optimizar el entrenamiento de la red neuronal.
6. Fijar Pesos: En esta etapa, se asignan los pesos previamente generados para la red neuronal, asegurando que los valores correctos se apliquen a los nodos de la red.
7. Implementación de la Red: Se desarrolló una clase específica para la red neuronal, que incluye todas las funciones y métodos necesarios para predecir las ventas diarias mensuales.

8. Definición de Atributos de la Clase: Se establecieron las variables que representan el número de nodos de entrada, nodos ocultos y nodos de salida de la red, además de matrices para almacenar las entradas y los pesos sinápticos.
9. Inicialización de Pesos: Se generaron los pesos iniciales necesarios para el funcionamiento de la red neuronal, que se utilizan durante el entrenamiento y la predicción de ventas.
10. Cálculo de Salidas Deseadas: Se llevaron a cabo cálculos específicos para determinar las salidas deseadas de la red neuronal, mejorando así la precisión de las predicciones de ventas.

2.1.3.4. Resultados obtenidos

Tabla 2.1: Resultados de Ventas pronosticadas

Mes	Venta diaria S/.	Venta pronosticada con la red S/.	Grado de confiabilidad %
Enero	670675	668705	99,71
Febrero	678351	645902	95,22
Marzo	708787	663617	93,63
Abril	701295	659217	94,00
Mayo	701760	646789	92,17
Junio	692871	650631	93,90
Julio	704171	650239	92,34

Fuente: Benites Sernaqué, J. M. (2021). Implementación de un sistema de pronóstico de ventas utilizando redes neuronales artificiales para la empresa Cerámicos Lambayeque SAC.

2.1.4. Aplicativo Web de Series Temporales para el Pronóstico de Ventas en la Empresa SERMIMIN

2.1.4.1. Planteamiento del Problema y objetivo

La tesis trata sobre la imprecisión en los pronósticos de ventas en varias empresas, incluida SERMIMIN, una consultora registrada en OSINERGMIN y OEFA. De acuerdo con varios estudios, muchos ejecutivos no valoran lo suficiente la importancia de predecir ventas,

considerándolo impreciso y poco fiable para nuevos productos. No obstante, un pronóstico preciso es fundamental, ya que influye en la planificación de producción, compras, inventarios y ventas.

El uso insuficiente de herramientas de pronóstico, especialmente de software especializado, es un problema recurrente. Las empresas que carecen de software adecuado para predecir ventas experimentan deficiencias importantes. La inteligencia artificial (IA) y el aprendizaje automático proporcionan soluciones avanzadas para mejorar la precisión de los pronósticos. La IA permite a las computadoras imitar el pensamiento humano, comprender el lenguaje natural y realizar tareas complejas de manera eficiente. La implementación de modelos matemáticos y algoritmos de IA puede disminuir significativamente los errores de pronóstico.

En el caso de SERMIMIN, la empresa realiza sus pronósticos de manera empírica, lo que ha provocado errores y costos adicionales. La ausencia de un sistema de información adecuado para registrar y evaluar sus parámetros de servicio agrava estos problemas. Se desarrolla un aplicativo web utilizando redes neuronales para mejorar la precisión del pronóstico de ventas en SERMIMIN.

2.1.4.2. Metodología empleada por los autores

En esta investigación sobre el pronóstico de ventas, se registrarán las ventas realizadas por la empresa Sermimin, ingresando estos datos en el sistema para entrenar redes neuronales con información histórica de ventas. Posteriormente, se realiza el pronóstico según los servicios de la empresa. El sistema pasará por una fase de entrenamiento para identificar un modelo de pronóstico óptimo, utilizando indicadores de precisión para generar información confiable en los pronósticos de ventas de la empresa. En cuanto al método de análisis de datos en esta investigación utilizó un enfoque cuantitativo con un diseño pre-experimental. Además, se emplearon métodos estadísticos para validar o refutar las hipótesis planteadas en capítulos anteriores.

2.1.4.3. Resultados obtenidos

Como resultados se concluye que hubo una mejora significativa en el indicador de desviación media absoluta, que pasó de un valor de 625.83 antes de la incorporación del aplicativo de redes neuronales a 104.58 después de su implementación, reduciéndose en 521.83 puntos. Además, se concluye que el indicador de error porcentual medio absoluto también mejoró considerablemente, pasando de un valor de 1568.0 antes de la implementación del sistema de redes

neuronales a 2.9167 después, representando una mejora de 1348 puntos. Como resultado final, el aplicativo web basado en redes neuronales mejora notablemente ambos indicadores, tanto la desviación media absoluta como el error porcentual medio absoluto, demostrando su efectividad en el pronóstico de ventas para la empresa Sermimin.

2.1.5. Análisis de Pronóstico de Demanda para la Gestión del Inventario en el Sector Salud

2.1.5.1. Planteamiento del Problema y objetivo

En esta investigación optaron por diseñar preliminarmente un aplicativo web destinado a realizar pronósticos de la demanda futura de todos sus productos, utilizando conceptos de Machine Learning. Este enfoque permitiría prever con mayor precisión la demanda futura y serviría como soporte tecnológico para agilizar la toma de decisiones.

Como primer paso, la plataforma web se conectaría con la base de datos proporcionada por Amazon Web Services (AWS), donde se registraría toda la información de los usuarios y los algoritmos, incluidos los resultados de los pronósticos de demanda. Los algoritmos se implementarían utilizando el lenguaje de programación Python, conocido por su uso amplio y versatilidad en diversas industrias debido a su licencia de código abierto. Además, se emplearía Anaconda, una distribución de Python especializada en aplicaciones de ciencia de datos y Machine Learning, capaz de manejar grandes volúmenes de datos.

Para el desarrollo del modelo, se implementarían varios tipos de algoritmos y se seleccionaría el que ofreciera mayor precisión y aplicabilidad en el sector de la empresa. Los resultados se visualizarían mediante el servicio de Power BI, presentando diversos gráficos y tablas, como el plan de compras a futuro, accesibles desde una PC en cualquier momento.

2.1.5.2. Metodología empleada por los autores

- **Etapas 01: Empatizar.** Se centró en comprender el comportamiento del usuario en la gestión de sus inventarios. Se llevaron a cabo diversas encuestas virtuales utilizando Google Forms, dirigidas a importadores y vendedores de materiales del sector salud. Estas encuestas recogieron opiniones sobre la gestión de inventarios, las herramientas utilizadas y la planificación de compras futuras. En total, se realizaron 60 encuestas, de las cuales el 36.6% de los encuestados reportó contar con un sistema digital de inventarios en sus empresas.

- **Etapa 02: Definir.** En esta segunda fase, se identificaron las necesidades del cliente mediante encuestas y entrevistas, seleccionando los principales insights y necesidades clave que agregarían valor al proyecto. Descubrieron que el costo mensual o anual de las soluciones de gestión de inventarios era una preocupación importante para los usuarios, ya que a menudo resultaban inviables. Además, los usuarios preferían herramientas con un número reducido de módulos, ya que una complejidad excesiva podría desanimarlos a seguir utilizándolas debido al tiempo requerido para la capacitación.
- **Etapa 03: Prototipar.** Después de identificar y definir las necesidades de los usuarios, se diseñaron el storyboard y el prototipo, incluyendo capturas de la aplicación web. Estas actividades ayudaron a materializar las ideas seleccionadas mediante sesiones de brainstorming con los usuarios.
- **Etapa 04: Esquema del Prototipo Inicial.** La arquitectura del prototipo consistió en un aplicativo web que permitía a los usuarios acceder y conectarse al servicio web en la nube a través de Amazon Web Services (AWS) mediante un servicio API. Esto incluía bases de datos de usuarios, algoritmos y resultados. Para la validación de los clientes, se utilizó un servicio web llamado "Validar", donde los usuarios ingresaban su ID y contraseña para acceder al sistema. Una vez autenticados, los usuarios ingresaban datos iniciales a la base de datos de algoritmos a través del servicio web "Pronóstico" para encontrar el algoritmo más adecuado según los datos históricos proporcionados. Los algoritmos fueron desarrollados en Python, y los resultados se almacenaban en la base de datos de resultados, sirviendo de base para cálculos de pronósticos y mostrando diversos dashboards mediante Power BI.
- **Etapa 05: Evaluar.** Las evaluaciones del prototipo realizadas por los usuarios finales permitieron mejorar constantemente su diseño basado en sus observaciones y sugerencias. Se desarrollaron varias versiones del prototipo, destacando su simplicidad, la disposición de tablas y gráficos, y la importancia de los datos de entrada y salida para un pronóstico adecuado de la demanda futura. Estas mejoras aseguraron que la interacción con la plataforma web fuera ágil y fácil de manejar.

2.1.5.3. Resultados obtenidos

La solución se orienta específicamente hacia pequeñas y medianas empresas dedicadas a la importación y venta de productos de salud, así como a cadenas de farmacias y clínicas en las zonas 6, 7 y 8 de Lima Metropolitana, atendiendo a los Niveles Socioeconómicos (NSE) A, B, y C. La propuesta implica la instauración de una plataforma web que utiliza la infraestructura

Cloud de almacenamiento de datos y la página web de Amazon Web Services (AWS), junto con un motor generador de información en tiempo real basado en Python, un modelo de aprendizaje supervisado y diversos paneles de control en Power BI para proyectar la demanda futura. El proyecto fue desarrollado en 63 días con una inversión de S/ 65,700 soles. Conclusión: La herramienta ha permitido a los usuarios realizar pronósticos precisos de la demanda futura, lo que ha llevado a una optimización de los niveles de inventario y una reducción de los costos operativos en un 30 %. Esto ha resultado en un aumento del 94 % en las utilidades y en la mejora del nivel de servicio.

2.1.6. Artículos relacionados

2.1.7. Time-series analysis with smoothed Convolutional Neural Network

2.1.7.1. Planteamiento del Problema y objetivo

La introducción del documento ‘Time-series analysis with Smoothed Convolutional Neural Network (SCNN)’ comienza destacando la importancia del análisis de series temporales en diversas áreas, como las finanzas, la meteorología y la medicina, donde la capacidad de predecir y comprender patrones en datos temporales es fundamental para la toma de decisiones efectivas. Se menciona que las técnicas tradicionales de suavizado de datos pueden mejorar la calidad de las series temporales al eliminar valores atípicos y ruido. Se introduce el concepto de Redes Neuronales Convolucionales (CNN), que son ampliamente utilizadas en el procesamiento de imágenes debido a su eficiencia en la extracción de características. El documento destaca que las CNN pueden ser aplicadas a problemas de series temporales al tratar los datos de entrada como arreglos unidimensionales, lo que las hace adecuadas para el análisis de datos temporales. La motivación principal del estudio es explorar cómo la combinación de técnicas de suavizado de datos con CNN puede mejorar la precisión en la predicción de series temporales. Se plantea la hipótesis de que, al optimizar el factor de suavizado en CNN, se puede lograr un rendimiento superior en la predicción de series temporales en comparación con otros métodos tradicionales.

Tabla 2.2: Tipos de suavizado de datos (data smoothing)

Método	Ventajas	Desventajas
Suavizado exponencial/Suavizado simple exponencial	Facilidad de cálculo, Flexibilidad, Buen rendimiento.	No es capaz de gestionar bien las tendencias.
Media móvil	Uso adecuado cuando hay ligera o nula variación estacional.	Puede no reflejar con exactitud las tendencias más recientes.
Recorrido aleatorio	Fácil de usar, Puede manejar flujos complicados.	No conserva con precisión la posición media de la vorticidad en el espacio libre, Soluciones ruidosas debido a errores estadísticos.

Fuente: Wibawa, A. P.(2022). Time-series analysis with smoothed Convolutional Neural Network. Journal of big Data, 9(1), 44.

2.1.7.2. Base de datos de los autores

Se presentan 4 conjuntos de datos diferentes, cada uno con características específicas:

1. Dataset 1: Se trata de una serie temporal de un año de visitantes diarios a un sitio web de la Universidad Negri Malang. Este conjunto de datos es multivariado y consta de 365 instancias con 4 atributos diferentes, como sesiones, visitas a páginas, visitantes y nuevos visitantes.
2. Dataset 2: Este conjunto de datos también es multivariado y consiste en datos diarios de visitantes a un sitio web, pero con diferentes atributos en comparación con el Dataset 1. Incluye información sobre cargas de página, visitas únicas, visitas por primera vez y visitas recurrentes.
3. Dataset 3: Se refiere a datos relacionados con el intercambio de divisas y la información de ventas. Es un conjunto de datos multivariado con 2 atributos y no presenta datos faltantes.
4. Dataset 4: Este conjunto de datos representa el consumo de energía eléctrica en 32 ciudades de la India. Es un conjunto multivariado con un atributo seleccionado para el estudio, que es la demanda de energía en Delhi.

Además, se menciona que se utilizan dos escenarios diferentes para evaluar el rendimiento del modelo en función de la composición de los datos de entrenamiento y prueba. En el primer escenario dividen en 70 % y 30 % en el entrenamiento y prueba respectivamente, en el segundo escenario dividen 80 % y 20 %.

2.1.7.3. Metodología empleada por los autores

1. Evaluación del método propuesto: Se inicia con la evaluación del método propuesto, que combina el suavizado exponencial con CNN (S-CNN). Se comparan los resultados obtenidos con S-CNN con los de otros métodos de pronóstico, como Multilayer Perceptron (MLP) y Long Short-Term Memory (LSTM). Se destaca que S-CNN supera a MLP y LSTM en términos de error cuadrático medio (MSE), con el mejor MSE logrado utilizando 76 capas ocultas.
2. Comparación de desempeño: Se presentan los resultados de pruebas de significancia utilizando el test t pareado basado en el número de capas ocultas de Lucas. Se comparan métricas como MSE, MAPE y tiempo de entrenamiento entre CNN y S-CNN. Se observa que S-CNN es más preciso que CNN en todos los escenarios y que el tiempo de procesamiento es menor con S-CNN.
3. Optimización del factor de suavizado: Se discute la importancia de encontrar el factor de suavizado óptimo (α) en el método propuesto. Se comparan diferentes valores de α y se concluye que el α óptimo produce los mejores resultados en términos de MSE y MAPE.
4. Impacto de las capas ocultas de Lucas: Se analiza el impacto de utilizar números de Lucas como capas ocultas en la CNN. Se muestra que las capas ocultas de Lucas tienen un efecto significativo en la precisión del modelo y en el tiempo de entrenamiento, mejorando el rendimiento del algoritmo de pronóstico.




Figura 2.1: Metodología antecedente

Fuente: Wibawa, A. P.(2022). Time-series analysis with smoothed Convolutional Neural Network. Journal of big Data, 9(1), 44.

2.1.7.4. Resultados obtenidos

Se resalta que los resultados obtenidos en el estudio sugieren que la implementación de S-CNN con capas ocultas de Lucas puede elevar el rendimiento del algoritmo de pronóstico en el análisis de series temporales, reduciendo el error cuadrático medio (MSE) y mejorando la precisión de las predicciones.




Figura 2.2: Resultado antecedente

Fuente: Wibawa, A. P.(2022). Time-series analysis with smoothed Convolutional Neural Network. Journal of big Data, 9(1), 44.




Figura 2.3: Resultado antecedente

Fuente: Wibawa, A. P.(2022). Time-series analysis with smoothed Convolutional Neural Network. Journal of big Data, 9(1), 44.

2.1.8. Approaching sales forecasting using recurrent neural networks and transformers

2.1.8.1. Planteamiento del Problema y objetivo

Se destaca el crecimiento del comercio electrónico y la importancia de mejorar los sistemas de cadena de suministro para satisfacer la creciente demanda en la industria minorista en línea. Se menciona que la precisión en la predicción de la demanda del cliente es fundamental para optimizar aspectos como la ubicación de inventarios, la expansión de la red y la planificación de entrada y salida. El artículo destaca la importancia de un pronóstico preciso y rápido de la demanda en la cadena de suministro para mejorar la ejecución de los procesos descendentes correspondientes, como la planificación de entrada y salida, la ubicación de inventarios y la planificación de la red. Los autores presentan tres alternativas basadas en técnicas de aprendizaje profundo para predecir las ventas de clientes a nivel de día, tienda y producto. Con esto propone el uso de técnicas de aprendizaje profundo, como redes neuronales recurrentes y transformers, para abordar el problema de pronóstico de la demanda de manera generalizada, permitiendo predecir las ventas para diferentes productos, ubicaciones y momentos con un solo modelo. Esto contrasta con otros enfoques, como los modelos de la familia ARIMA, que solo pueden manejar una serie temporal de producto-ubicación a la vez.

2.1.8.2. Base de datos de los autores

El conjunto de datos utilizado en este estudio es el conjunto de datos de ventas de supermercados de Corporación Favorita. Este conjunto de datos fue publicado como parte de

una competencia de Kaggle y contiene registros de ventas diarias para 4400 artículos únicos en 54 tiendas ecuatorianas diferentes. Los datos abarcan desde el 1 de enero de 2013 hasta el 15 de agosto de 2017. Además de la información de ventas diarias, se proporcionan datos adicionales que incluyen detalles sobre la cantidad de ventas, las ubicaciones de las tiendas, la fecha, familia del artículo, precio del aceite y días festivos.

2.1.8.3. Metodología empleada por los autores

Se llevó a cabo una metodología experimental detallada que incluye los siguientes pasos: Selección del conjunto de datos: Se utilizó el conjunto de datos proporcionado por la Corporación Favorita, que consta de una gran cantidad de muestras (alrededor de 400 Millones) que permiten el uso de modelos de aprendizaje profundo. Diseño de arquitecturas: Se diseñaron dos arquitecturas neuronales diferentes para abordar el problema de pronóstico de ventas: un modelo seq2seq y un modelo transformer. Estas arquitecturas fueron adaptadas y modificadas para ajustarse específicamente al problema de pronóstico de ventas en el contexto de la Corporación Favorita. Implementación de la arquitectura seq2seq: La arquitectura Seq2seq (sequence-to-sequence) es un modelo diseñado para mapear una secuencia de entrada a una secuencia de salida, sin restricciones en las longitudes de ambas secuencias. En el contexto del pronóstico de ventas, el modelo Seq2seq se utiliza para predecir las ventas diarias de productos en tiendas específicas. La arquitectura Seq2seq consta de dos componentes principales: el codificador y el decodificador. El codificador procesa la secuencia de entrada, que en este caso incluiría datos históricos de ventas y otras características relevantes, y condensa esta información en un vector de contexto de longitud fija. Este vector de contexto captura la información clave de la secuencia de entrada y se utiliza para guiar la generación de la secuencia de salida. En el contexto del estudio, se ha modificado la arquitectura Seq2seq original para incluir un módulo de condicionamiento de contexto. Este módulo permite que el modelo se adapte a características estáticas adicionales, como incrustaciones de productos y tiendas, lo que ayuda a mejorar la precisión de las predicciones. Además, se ha utilizado un truco de entrenamiento llamado "random max time step trick" que permite al modelo adaptarse a diferentes pasos de tiempo sin necesidad de volver a entrenar el modelo cada vez que se requiere una predicción. Implementación de la arquitectura transformer: La arquitectura Transformer es un modelo de aprendizaje profundo que se introdujo en 2017 y ha demostrado ser altamente efectivo en una variedad de tareas de procesamiento del lenguaje natural y pronóstico de series temporales. En el contexto del pronóstico de ventas, el modelo Transformer se utiliza para predecir las ventas diarias de productos en tiendas específicas sin depender de redes neuronales recurrentes. El Transformer consta de dos componentes principales: el codificador y el decodificador. A diferencia de las arquitecturas basadas en redes neuronales recurrentes, el Transformer utiliza mecanismos de

atención y autoatención para capturar las relaciones a largo plazo en las secuencias de entrada y salida. Estos mecanismos permiten al modelo aprender dependencias a diferentes distancias en la secuencia, lo que lo hace especialmente efectivo para pronósticos de series temporales. En el contexto del estudio, se implementa la arquitectura Transformer adaptada para el pronóstico de ventas. El modelo Transformer elimina la necesidad de utilizar redes neuronales recurrentes al implementar mecanismos de atención y autoatención. Estos mecanismos permiten al modelo mapear una secuencia de entrada a una secuencia de salida, adaptándose a diferentes longitudes de secuencia y capturando relaciones complejas entre los datos. Además, el modelo Transformer se basa en una función de similitud escalada de producto punto que facilita la comparación de secuencias de diferentes longitudes. Esta función de similitud escalada ayuda al modelo a comparar y relacionar diferentes partes de la secuencia de entrada y salida de manera eficiente, lo que contribuye a su capacidad para realizar pronósticos precisos y generalizables.

2.1.8.4. Resultados obtenidos

Muestran cómo se puede lograr un buen rendimiento utilizando una arquitectura simple de secuencia a secuencia con un esfuerzo mínimo de preprocesamiento de datos. Además, describimos un truco de entrenamiento para hacer que el modelo sea más independiente del tiempo y, por lo tanto, mejorar la generalización a lo largo del tiempo. La solución propuesta logra un RMSLE de alrededor de 0.54.

Period	Model	RMSLE	RMSWLE	MALE
1	Seq2seq	0.5380 ± 0.0016	0.5376 ± 0.0016	0.3450 ± 0.0024
	Seq2seq trimmed	0.5381 ± 0.0008	0.5377 ± 0.0008	0.3442 ± 0.0008
	Transformer	0.5439 ± 0.0024	0.5436 ± 0.0023	0.3386 ± 0.001
	Baseline: random	1.474 ± 0.0003	1.4795 ± 0.0003	1.0691 ± 0.0002
	Baseline: average	1.0422	1.05	0.8744
2	Seq2seq	0.5431 ± 0.0014	0.5421 ± 0.0013	0.3475 ± 0.0012
	Seq2seq trimmed	0.5413 ± 0.0019	0.5403 ± 0.0018	0.3444 ± 0.0012
	Transformer	0.5495 ± 0.0021	0.5486 ± 0.0021	0.3415 ± 0.0012
	Baseline: random	1.4649 ± 0.0002	1.4702 ± 0.0002	1.0577 ± 0.0003
	Baseline: average	1.0358	1.0433	0.8655
3	Seq2seq	0.544 ± 0.0021	0.5431 ± 0.0021	0.3502 ± 0.0028
	Seq2seq trimmed	0.5423 ± 0.0015	0.5414 ± 0.0016	0.3481 ± 0.0017
	Transformer	0.5414 ± 0.0015	0.5407 ± 0.0014	0.3366 ± 0.0012
	Baseline: random	1.4555 ± 0.0002	1.4606 ± 0.0002	1.0517 ± 0.0002
	Baseline: average	1.029	1.0363	0.8616
Benchmark	Kechyn et al. (2018)	–	0.578	–
Benchmark	Calero and Caro (2018)	–	0.555	–

Figura 2.4: Resultado antecedente

Fuente: Vallés-Pérez, I.(2022). Approaching sales forecasting using recurrent neural networks and transformers. Expert Systems with Applications, 201, 116993.

2.1.9. Prediction Analysis Sales for Corporate Services Telecommunications Company using Gradient Boost Algorithm

2.1.9.1. Planteamiento del Problema y objetivo

El documento se centra en la importancia de analizar y predecir las ventas en el ámbito empresarial, específicamente en una empresa de telecomunicaciones. Se destaca la relevancia de contar con estimaciones precisas para que la compañía pueda sobrevivir en un mercado competitivo y aumentar su crecimiento. Se menciona que el uso de técnicas de aprendizaje automático es fundamental para mejorar las predicciones futuras de ventas, ya que los sistemas de pronóstico tradicionales enfrentan dificultades al tratar con grandes volúmenes de datos y al intentar mejorar la precisión de las predicciones de ventas. Se hace referencia a la necesidad de analizar la confiabilidad de las ventas de empresa a empresa (B2B) utilizando técnicas de aprendizaje automático. Se menciona que a lo largo de los años han surgido varios estudios que buscan predecir y pronosticar las ventas, y se destaca un sistema de análisis desarrollado utilizando métodos predictivos de aprendizaje automático. Se identificaron tres diferencias clave en los métodos alternativos para estimar las ventas de oportunidad, lo que llevó a una mejora significativa en la precisión de las predicciones. Además, se menciona que el objetivo de la investigación es evaluar y analizar el uso de técnicas de aprendizaje automático para predecir las ventas, centrándose en las ventas B2B. Se describe el proceso de recopilación y preparación de datos, donde se utilizó información de ventas de tres años consecutivos (2016, 2017 y 2018) para predecir los ingresos B2B. Se destaca la importancia de seleccionar y procesar los datos relevantes para mejorar la precisión de las predicciones de ventas.

2.1.9.2. Base de datos de los autores

Utilizan un conjunto de datos de ventas anuales por producto para llevar a cabo el análisis de predicción de ventas en el contexto de ventas B2B para una empresa de telecomunicaciones. El conjunto de datos proporciona información detallada sobre las ventas de los productos MIDI y NO-MIDI durante los años 2016, 2017 y 2018, desglosadas por trimestre. El conjunto de datos incluye información sobre las ventas en millones para cada trimestre de los años mencionados, tanto para los productos MIDI como para los productos NO-MIDI. Los datos incluían información detallada como categoría, región, tipo de artículo, ID de oportunidad, trimestre, nombre del producto, subcomponente del producto, producto de servicio (MIDI) e ingresos por ventas.

2.1.9.3. Metodología empleada por los autores

1. Recopilación y Preparación de Datos: Se recopilaron datos de ventas de tres años consecutivos (2016, 2017 y 2018) para realizar el análisis de predicción de ingresos B2B. Se eliminaron datos no utilizables, redundantes e irrelevantes para obtener un conjunto de datos seleccionado que incluía trimestre, año, y elementos de servicio y cantidad.
2. Preprocesamiento de Datos: Después de la preparación de datos, se llevó a cabo un estudio exploratorio para comprender la esencia de los resultados obtenidos. Se realizaron seis medidas esenciales de minería de datos, que incluyen conciencia de datos, planificación, simulación, evaluación e implementación.
3. Se llevó a cabo la detección de valores atípicos como parte del proceso de optimización del modelo. La identificación de valores atípicos puede ser útil para mejorar el modelo o como punto de partida para futuras optimizaciones. Se hizo hincapié en la importancia de la calidad de los datos y se sugirió la eliminación de atributos de datos menos críticos.
4. Eliminación de Atributos Menos Críticos: Se sugiere la eliminación de atributos de datos menos críticos que pueden no contribuir significativamente a la precisión de las predicciones. Esto ayuda a simplificar el modelo y mejorar su eficacia en la predicción de ventas B2B.
5. Se presentan los resultados de la predicción en forma de tablas y gráficos que muestran las proyecciones de ventas para productos MIDI y NO-MIDI durante un período de cinco años. Estos resultados ayudan a visualizar las tendencias futuras y a tomar decisiones informadas sobre estrategias de ventas y presupuestos.

2.1.10. Predicting Future Sales of Retail Products using Machine Learning

2.1.10.1. Planteamiento del Problema y objetivo

Sobre la predicción de ventas futuras de productos minoristas, se destaca la importancia de la precisión en la predicción de ventas para cualquier organización, ya sea una pequeña empresa o una empresa Fortune 500. Se menciona que esta precisión proporciona una estimación precisa del crecimiento de los ingresos de la empresa y puede utilizarse para planificar acciones de demanda y suministro a corto plazo. Además, sirve como guía para diseñar planes que se alineen con los objetivos organizacionales generales para la prudencia financiera. Se menciona que el objetivo del proyecto es predecir las ventas totales de cada producto y tienda

para el próximo mes utilizando datos pasados. Se destaca que se trabajó con un conjunto de datos desafiante de series temporales que consiste en datos de ventas diarias proporcionados por una de las mayores empresas de software de Rusia, la empresa 1C. Para realizar las predicciones del próximo mes, se implementaron el algoritmo eXtreme Gradient Boosting (XGBoost) y una arquitectura de red basada en Long Short Term Memory (LSTM) para realizar la tarea de aprendizaje. Se menciona que la métrica utilizada para evaluar el rendimiento de los modelos y comparar los algoritmos implementados fue el error cuadrático medio de la raíz (RMSE). Además se destaca que XGBoost tuvo un mejor desempeño que LSTM en este conjunto de datos, lo que se atribuye a su relativa mayor dispersión.

2.1.10.2. Base de datos de los autores

El conjunto de datos es una combinación de datos de series temporales y datos estáticos. Los datos estáticos incluyen columnas como el nombre del artículo, la categoría del artículo, el ID de la tienda, etc., que no cambian con el tiempo, mientras que la cantidad de artículos y el precio del artículo varían con el tiempo. Se menciona que se siguió un proceso convencional de ingeniería de datos que incluyó limpieza de datos, análisis exploratorio de datos y creación de características.

2.1.10.3. Metodología empleada por los autores

La predicción de ventas futuras de productos minoristas fue un proceso fundamental para crear variables predictivas significativas a partir de los datos disponibles. A continuación, se presenta un resumen detallado de las acciones de ingeniería de características llevadas a cabo:

1. Creación de un Conjunto de Datos Combinado: Se inició el proceso de ingeniería de características combinando todos los conjuntos de datos proporcionados, como los datos de tiendas, artículos y categorías de artículos, en un conjunto de datos maestro. Esta integración permitió tener una visión holística de la información disponible para el modelado predictivo.
2. Generación de Características Basadas en Análisis Exploratorio: Se tomaron como base las observaciones del Análisis Exploratorio de Datos (EDA) para crear nuevas características relevantes. Por ejemplo, se crearon características relacionadas con el recuento de cada día de la semana en el bloque de fechas, el recuento de fines de semana y características estacionales basadas en el mes o la temporada.

3. Incorporación de Información Temporal: Se extrajeron características temporales como retrasos temporales para capturar patrones de series temporales en los datos de ventas. Estas características incluyeron información sobre las ventas pasadas para cada producto y tienda, lo que permitió al modelo aprender de las tendencias históricas.
4. Consideración de Variables Categóricas: Se realizaron transformaciones en variables categóricas, como la codificación one-hot encoding, para representarlas de manera adecuada en los modelos de aprendizaje automático. Esto incluyó la codificación de variables como la categoría del artículo o el ID de la tienda para que fueran interpretables por los algoritmos de predicción.

Modelos utilizados

5. XGBoost: Se seleccionó XGBoost como uno de los algoritmos iniciales debido a su amplia utilización en competiciones de ciencia de datos. XGBoost ofrece ventajas en términos de optimización del sistema a través de la paralelización y la optimización del hardware, así como la capacidad de manejar eficientemente diferentes patrones de esparsidad en los datos.
6. ARIMA: Se incluyó el modelo ARIMA, ampliamente utilizado en series temporales, para comparar su rendimiento con otros modelos.
7. LSTM: Se implementó una arquitectura basada en LSTM (Long Short-Term Memory) para modelar eficientemente características estáticas y dinámicas, inspirados en trabajos previos que demostraron la eficacia de combinar LSTM con redes neuronales totalmente conectadas.
8. División de Datos: Se dividió el conjunto de datos en un conjunto de entrenamiento y un conjunto de validación, utilizando los primeros 32 meses para entrenar los modelos y el mes 33 para validar las predicciones.
9. Ajuste de Hiperparámetros: Se realizó una búsqueda de hiperparámetros sobre un espacio de búsqueda utilizando muestreo aleatorio uniforme en el conjunto de validación para optimizar los modelos.
10. Evaluación de Modelos: Se evaluaron los modelos en función de su capacidad para predecir las ventas futuras de productos y tiendas, considerando métricas de rendimiento como el error cuadrático medio (MSE) o el error absoluto medio (MAE).

2.1.10.4. Resultados obtenidos

Se encontró que XGBoost superó a los otros modelos, incluyendo ARIMA y LSTM, en la predicción de las ventas futuras de productos y tiendas. Se atribuyó el mejor rendimiento de XGBoost a la buena ingeniería de características y a la capacidad de ajustar una amplia gama de hiperparámetros durante la optimización.

Modelo	RMSE de Entrenamiento	RMSE de Validación	RMSE de Prueba
XGBoost	0.76467	0.807264	0.87815
LSTM	0.804657	0.898786	0.92417
ARIMA	0.963426	0.9823224	1.09266

Tabla 2.3: Resultados antecedente

Fuente: Swami, D.(2020). Predicting future sales of retail products using machine learning. arXiv preprint arXiv:2008.07779.

2.1.11. Time Series Forecasting and Modelling of Food Demand Supply Chain based on Regressors Analysis

2.1.11.1. Planteamiento del Problema y objetivo

(Panda y Mohanty, 2023) El sector de entrega de alimentos enfrenta grandes desafíos en la gestión de inventarios, ya que la demanda de comidas puede ser altamente variable debido a factores como cambios estacionales, promociones y fluctuaciones en las preferencias de los clientes. Este comportamiento errático de la demanda complica la planificación de la producción y puede llevar a la empresa a sufrir pérdidas económicas. La sobreproducción de alimentos puede ocasionar desperdicio y costos innecesarios, mientras que la subproducción puede resultar en una escasez de productos, afectando la satisfacción del cliente y la lealtad hacia la marca. El objetivo principal de esta investigación es desarrollar un modelo de pronóstico de demanda que permita predecir con precisión el número de pedidos de comidas para las próximas 10 semanas. Con este modelo, la empresa puede optimizar la gestión de inventarios, minimizando el desperdicio de alimentos y los costos operativos, al mismo tiempo que mejora la disponibilidad de productos y la satisfacción del cliente. Al anticipar la demanda, la empresa podrá tomar decisiones más informadas sobre compras y producción, aumentando su eficiencia operativa y rentabilidad. Para llevar a cabo este estudio, se utilizó un conjunto de datos que abarca 145 semanas de pedidos semanales de 50 comidas diferentes, lo que proporciona un total de aproximadamente 450,000 entradas. Cada entrada incluye 15 características, entre ellas,

el número de ventas, los precios, los descuentos aplicados, el centro de distribución, y otros atributos que influyen en la demanda. La importancia de este problema radica en que una predicción inexacta puede desencadenar una serie de problemas logísticos y financieros, afectando el rendimiento global de la empresa de entrega de alimentos.

2.1.11.2. Base de datos de los autores

El conjunto de datos, denominado “Food Demand Forecasting”, fue proporcionado por Genpact, una firma de servicios profesionales especializada en el análisis de datos empresariales. Este conjunto incluye registros históricos detallados de los pedidos realizados semanalmente para diferentes tipos de comidas. Los datos se distribuyen en tres archivos, los cuales contienen columnas como el ID del pedido, el número de semana, el ID de la comida, el ID del centro de cumplimiento, y el precio final. Los datos originales estaban en un formato heterogéneo y requirieron una preparación significativa para su uso en los modelos predictivos. Se aplicaron técnicas de limpieza y normalización para eliminar registros incompletos y valores atípicos que pudieran afectar la precisión del modelo. Además, se añadieron características adicionales, como medias móviles para capturar tendencias a corto plazo y características de rezago para incluir información histórica en el modelo. La construcción de estas nuevas características permitió enriquecer la información y mejorar la capacidad del modelo para detectar patrones en la demanda.

2.1.11.3. Metodología empleada por los autores

1. **Modelos Utilizados:** La metodología incluyó la utilización de varios modelos de machine learning y deep learning, con el objetivo de comparar su desempeño en la predicción de la demanda de comidas. Los modelos probados incluyeron Random Forest Regressor, Gradient Boosting Regressor, LightGBM, XGBoost, CatBoost Regressor, LSTM (Long Short-Term Memory) y BiLSTM (Bidirectional Long Short-Term Memory). La selección de estos modelos se basó en su capacidad para capturar relaciones no lineales y temporales en los datos.
2. **Etapas del Proceso:** El proceso se dividió en varias etapas. Inicialmente, se realizó la preparación de los datos, que incluyó la limpieza, normalización y creación de nuevas características. Posteriormente, se llevó a cabo el entrenamiento de los modelos utilizando un conjunto de datos que cubría 113 semanas. Para validar la precisión del modelo y ajustar los hiperparámetros, se utilizó un subconjunto de 10 semanas. Finalmente, se emplearon las últimas 10 semanas de datos para probar y evaluar el desempeño de los

modelos.

3. **Herramientas y Tecnologías:** Para la implementación de los modelos, se utilizaron lenguajes de programación como Python y herramientas específicas de machine learning y deep learning. Entre los frameworks empleados destacan TensorFlow, Keras y scikit-learn, los cuales permitieron construir y entrenar redes neuronales complejas. Además, se utilizaron pandas y NumPy para el manejo y preprocesamiento de los datos, y Matplotlib y Seaborn para la visualización de resultados.
4. **Procedimientos Implementados:** Se inició definiendo las estructuras de las redes neuronales, seleccionando el número de capas y neuronas adecuadas para captar las relaciones complejas entre las variables. Para los modelos de LSTM y BiLSTM, se prestó especial atención a la configuración de los hiperparámetros, como el número de épocas de entrenamiento, la tasa de aprendizaje y el tamaño de las secuencias de entrada. A lo largo del proceso, se llevaron a cabo múltiples iteraciones de entrenamiento para optimizar los modelos y mejorar la precisión en las predicciones.
5. **Optimización de Modelos:** Además de entrenar los modelos, se implementaron técnicas de optimización, como la búsqueda de hiperparámetros (Grid Search y Random Search) para encontrar la configuración más eficaz. También se aplicaron técnicas de regularización y “early stopping” para prevenir el sobreajuste del modelo durante el entrenamiento.
6. **Evaluación de Resultados:** Se evaluó el desempeño de los modelos utilizando métricas como RMSLE (Root Mean Squared Logarithmic Error), RMSE (Root Mean Squared Error), MAPE (Mean Absolute Percentage Error) y MAE (Mean Absolute Error). Estas métricas proporcionaron una visión detallada de la precisión y robustez de cada modelo al predecir la demanda.

2.1.11.4. Resultados obtenidos

Los resultados mostraron que los modelos de deep learning, en particular el modelo LSTM, superaron a los demás en términos de precisión al predecir la demanda de comidas. Las métricas de evaluación para el modelo LSTM incluyeron un RMSLE de 0.28, un RMSE de 18.83, un MAPE de 6.56% y un MAE de 14.18. Estas cifras indicaron un alto nivel de precisión en las predicciones, lo que lo convierte en una herramienta eficaz para la planificación de inventarios. Durante la evaluación, se realizó una comparación detallada entre los valores reales y los pronosticados por el modelo. Los resultados mostraron una fuerte correlación entre las predicciones y los valores reales, validando así la efectividad del modelo LSTM para capturar las tendencias y patrones de la demanda. Este análisis demostró que la implementación del

modelo propuesto puede ayudar a las empresas de entrega de alimentos a gestionar sus inventarios de manera más eficiente, reduciendo los costos asociados al desperdicio de alimentos y mejorando la satisfacción del cliente.

Models/Metrics	RMSLE	RMSE	MAPE	MAE
Random Forest	0.35	228.92	10.822	115.90
Gradient Boost	0.31	226.46	10.03	123.48
Light Boost	0.31	194.68	10.08	104.49
XGB	0.30	205.31	9.97	106.17
CatBoost	0.29	186.68	9.76	99.40
LSTM	0.28	18.83	6.56	14.18
Bi-LSTM	0.37	31.88	12.8	28.33

Tabla 2.4: Resultados antecedente

Fuente: Kumar, P. (2023). Time Series Forecasting and Modeling of Food Demand Supply Chain Based on Regressors Analysis. IEEE Access

2.1.12. Advancing Retail Predictions: Integrating Diverse Machine Learning Models for Accurate Walmart Sales Forecasting

2.1.12.1. Planteamiento del Problema y objetivo

(Neba Cyril et al., 2024) En el sector minorista, la previsión precisa de las ventas es un desafío constante. Los errores en las predicciones pueden tener un impacto significativo en la gestión de inventarios, llevando a problemas como el exceso de productos o su escasez. Estos problemas, a su vez, afectan negativamente la satisfacción del cliente, las operaciones y la rentabilidad de la empresa. Walmart, como líder en el sector retail, necesita un sistema robusto que le permita anticipar la demanda para optimizar sus estrategias de abastecimiento, compras y promociones.

El objetivo de esta investigación es desarrollar un sistema de pronóstico de ventas que utilice modelos de machine learning para mejorar la precisión de las predicciones de ventas en Walmart. Un sistema más preciso permitirá una mejor gestión del inventario, reducir costos asociados con el exceso o falta de stock, y optimizar la toma de decisiones estratégicas, especialmente durante períodos críticos como temporadas de vacaciones o cambios económicos. Para abordar este problema, se utilizaron datos históricos de ventas de Walmart que abarcan desde febrero de 2010 hasta octubre de 2012. Los datos incluyen una amplia variedad de variables como banderas de vacaciones, temperatura, precios de combustible, el Índice de Precios al

Consumidor (CPI), tasas de desempleo y las ventas semanales. La inclusión de estas variables externas permitió al modelo captar patrones y relaciones más complejas en la variabilidad de la demanda.

2.1.12.2. Base de datos de los autores

El conjunto de datos fue obtenido de Kaggle, una plataforma que proporciona datasets para análisis y modelos predictivos. El dataset específico contiene información sobre las ventas de Walmart en diferentes tiendas y departamentos a lo largo de un período de casi tres años. Los datos están organizados en un formato tabular, con columnas que incluyen fechas, ventas semanales, identificadores de tienda y departamento, y variables externas como el clima y condiciones económicas.

Para asegurar la calidad de la información, se realizó un exhaustivo proceso de preparación de los datos. Esto incluyó la normalización de las variables, la eliminación de valores atípicos que pudieran distorsionar el modelo, y el manejo de valores faltantes. Durante esta etapa, se incorporaron características adicionales relevantes, como la extracción de información temporal (día de la semana, mes, año) y la identificación de períodos de alta demanda, como días festivos, para ayudar al modelo a captar mejor las tendencias y patrones estacionales.

2.1.12.3. Metodología empleada por los autores

1. **Modelos de Machine Learning Utilizados:** Se probaron varios modelos de machine learning para identificar cuál proporcionaba las predicciones más precisas. Entre los modelos evaluados se incluyeron la Regresión Lineal, Random Forest, Gradient Boosting Machines (GBM), eXtreme Gradient Boosting (XGBoost) y Light Gradient Boosting Machine (LightGBM). Estos modelos fueron seleccionados por su capacidad para manejar datos complejos y relaciones no lineales entre las variables.
2. **Etapas del Proceso:**
 - **Preparación de Datos:** La primera etapa del proceso consistió en la recolección, limpieza y normalización de los datos. Los datos se dividieron en conjuntos de entrenamiento y validación para garantizar que el modelo fuera capaz de generalizar a nuevas situaciones. También se realizó una transformación de variables, como la creación de características temporales y la codificación de variables categóricas.
 - **Entrenamiento del Modelo:** Se entrenaron los modelos seleccionados utilizando el conjunto de datos de entrenamiento. Durante esta etapa, se realizaron ajustes a los

hiperparámetros de los modelos para optimizar su rendimiento, empleando técnicas como la búsqueda en cuadrícula (Grid Search) y la validación cruzada.

- **Validación:** Una vez entrenados los modelos, se validó su rendimiento utilizando el conjunto de datos de validación. Las métricas de evaluación incluyeron el Error Absoluto Medio (MAE), la Raíz del Error Cuadrático Medio (RMSE) y el Coeficiente de Determinación (R-squared). Estas métricas proporcionaron una visión completa de la precisión y robustez de cada modelo al predecir las ventas.

3. **Herramientas y Tecnologías Utilizadas:** Para implementar y entrenar los modelos, se utilizaron lenguajes de programación como Python junto con bibliotecas y frameworks especializados en machine learning, tales como scikit-learn y XGBoost. El uso de estas herramientas permitió construir modelos complejos y eficientes en términos computacionales, además de facilitar el análisis y visualización de resultados.
4. **Procedimientos Implementados:** Durante el proceso de desarrollo del modelo, se definieron las estructuras de los algoritmos y se realizaron ajustes de hiperparámetros para optimizar su desempeño. Se implementaron técnicas de regularización y selección de características para mejorar la capacidad predictiva de los modelos y reducir el riesgo de sobreajuste. Además, se realizaron múltiples iteraciones de entrenamiento y prueba para garantizar que los modelos fueran capaces de adaptarse a las diferentes condiciones representadas en los datos históricos.

2.1.12.4. Resultados obtenidos

Los resultados del estudio mostraron que los modelos avanzados, especialmente XGBoost, proporcionaron un nivel de precisión superior en comparación con otros modelos más simples. El modelo XGBoost obtuvo un Error Absoluto Medio (MAE) de 1226.471, un RMSE de 1700.981, y un R-squared de 0.9999900, lo que indica una precisión casi perfecta en las predicciones. Este desempeño demuestra la capacidad del modelo para adaptarse a las complejas relaciones entre las variables y capturar las fluctuaciones en la demanda de ventas de Walmart. En contraste, los modelos más simples como la Regresión Lineal mostraron un rendimiento significativamente menor, con un MAE de 35632.510 y un RMSE de 80153.858. Esta diferencia destaca la importancia de utilizar algoritmos avanzados para abordar problemas de predicción complejos en el entorno minorista. Adicionalmente, se realizó un análisis de sesgo y equidad para evaluar el rendimiento de los modelos en diferentes segmentos temporales, como períodos de vacaciones y no vacaciones. Los resultados indicaron que los modelos avanzados, en particular XGBoost, lograron minimizar los errores de predicción y mantener un rendimiento equilibrado incluso en los períodos de alta variabilidad de la demanda.

Model	MAE	RMSE	R Squared
Linear Regression	35632.510	80153.858	0.9760562
Multiple Regression	35632.510	80153.858	0.9760562
GLM	35632.510	80153.858	0.9760562
Decision Tree	77388.082	93721.066	0.9696449
Ramdom Forest	12238.782	19814.965	0.9986431
GBM	10839.822	1700.981	0.9993119
XGBoost	1226.471	1700.981	0.9999900
LGB	1692.640	2297.930	0.9999818

Tabla 2.5: Resultados de modelos predictivos

Fuente: Cyril, N. (2024). Advancing Retail Predictions: Integrating Diverse Machine Learning Models for Accurate Walmart Sales Forecasting. Asian Journal of Probability and Statistics

2.1.13. Demand Forecasting for Online Market Stock: Case study Clean-room Apparel

2.1.13.1. Planteamiento del Problema y objetivo

El problema del estudio se centra en la necesidad de crear un marco de pronóstico apropiado para la planificación de la demanda de producción de las pequeñas y medianas empresas (PYMES). Estas empresas a menudo enfrentan desafíos debido a la variabilidad en las ventas de productos y la falta de técnicas de pronóstico efectivas, lo que puede resultar en exceso de inventario o escasez de productos. Esto se debe a que las decisiones de producción a menudo se basan en la experiencia de los empleados, lo que no siempre responde a la demanda del cliente.

El objetivo del estudio es analizar y desarrollar un marco de pronóstico que permita prever la demanda de productos, particularmente para los cinco productos más vendidos por la empresa. Para lograr esto, se utilizan una variedad de técnicas de predicción, como el promedio móvil, el suavizado exponencial y el análisis de regresión, para determinar el método más efectivo para reducir el error de predicción y optimizar la cantidad económica de pedido además de los costos totales asociados con la producción y el inventario.

2.1.13.2. Base de datos de los autores

El estudio utilizó una base de datos de ventas de productos de una empresa de 2015 a 2017.

Estos son los elementos clave de esta base de datos:

1. **Productos Analizados:** Se seleccionaron los cinco productos más vendidos, que se denominaron A, B, C, E y L.
2. **Recopilación de información:** La base de datos contiene datos sobre:
 - La cantidad de unidades vendidas de cada producto durante el período mencionado se conoce como demanda.
 - El precio de cada producto es el precio unitario.
 - El valor total de ventas de cada producto se puede calcular multiplicando la demanda por el precio.
3. **Formato de Presentación:** Una tabla con columnas para el nombre del producto, la demanda total, el precio por unidad y el valor total de ventas contiene los datos. Por ejemplo, la tabla muestra que el Producto A tuvo una demanda de 14,110 unidades al precio de 530 Baht, lo que resultó en un valor total de ventas de 7,478,300 Baht.
4. **Objetivo de los datos:** Estos datos se utilizan para aplicar una variedad de técnicas de pronóstico y determinar cuál es la más efectiva para prever la demanda futura. También se utilizan para determinar la cantidad económica de pedido (EOQ) y los costos totales relacionados con la gestión del inventario.

2.1.13.3. Metodología empleada por los autores

1. **Recolección de Datos**
 - **Origen de los Datos:** Se obtuvieron datos de ventas de productos de una empresa durante los años 2015 a 2017.
 - **Selección de Productos:** Se identificaron los cinco productos más vendidos, denominados Producto A, B, C, E y L.
2. **Análisis de la Información**
 - **Características de los Datos:** Se examinaron aspectos clave de los datos de ventas, tales como la demanda total, el precio unitario y el valor total de ventas para cada producto.
 - **Organización de los Datos:** Los datos fueron presentados en tablas que detallan la demanda, el precio y el valor total de cada producto.

3. Selección de Técnicas de Pronóstico

- **Métodos Comparados:** Se seleccionaron cuatro métodos de pronóstico para evaluar su precisión:
 - a) Promedio Móvil
 - b) Suavizado Exponencial Simple
 - c) Suavizado Exponencial Doble
 - d) Análisis de Regresión

4. Aplicación de Técnicas de Pronóstico

- **Implementación:** Se aplicaron los métodos seleccionados a los datos de ventas de los cinco productos para estimar la demanda futura.
- **Cálculo de Errores:** Se midió la precisión de cada pronóstico utilizando el Error Absoluto Porcentual Medio (MAPE).

5. Identificación del Método Más Eficiente

- **Comparación de Resultados:** Se contrastaron los valores de MAPE para determinar cuál método proporcionó el pronóstico más exacto para cada producto.
- **Selección del Método:** Se eligió el método con el menor MAPE como el más adecuado para cada producto.

6. Cálculo de la Cantidad Económica de Pedido

- **Cálculo de EOQ:** Después de seleccionar el método de pronóstico más preciso, se determinó la cantidad económica de pedido para cada producto, optimizando la gestión de inventario.
- **Evaluación de Costos:** Se calcularon los costos totales asociados a la administración del inventario, utilizando los pronósticos y la EOQ obtenidos.

7. Interpretación de Resultados

- **Visualización:** Los resultados fueron representados mediante gráficos que muestran la demanda de cada producto a lo largo del tiempo.
- **Conclusiones:** Se discutieron las repercusiones de los resultados en la gestión de inventario y la satisfacción del cliente, así como recomendaciones para investigaciones futuras.

2.1.13.4. Resultados obtenidos

Producto A

- Método de Pronóstico Utilizado: Análisis de Regresión
- MAPE: 22.03
- Cantidad Económica de Pedido (EOQ): 172 unidades
- Costo Total: 27,345.51 Baht

Producto B

- Método de Pronóstico Utilizado: Suavizado Exponencial Simple
- Valor de α : 0.056
- MAPE: 72.20
- Cantidad Económica de Pedido (EOQ): 150 unidades
- Costo Total: 23,280.66 Baht

Producto C

- Método de Pronóstico Utilizado: Análisis de Regresión
- MAPE: 28.10
- Cantidad Económica de Pedido (EOQ): 193 unidades
- Costo Total: 24,953.52 Baht

Producto E

- Método de Pronóstico Utilizado: Promedio Móvil ($n = 3$)
- MAPE: 31.50
- Cantidad Económica de Pedido (EOQ): 336 unidades
- Costo Total: 14,109.57 Baht

Producto L

- Método de Pronóstico Utilizado: Análisis de Regresión
- MAPE: 47.00
- Cantidad Económica de Pedido (EOQ): 1844 unidades
- Costo Total: 6,639.97 Baht

Análisis de Resultados

- **Efectividad de los Métodos:** El análisis de regresión demostró ser el método más efectivo para los Productos A y C, mientras que el suavizado exponencial simple fue el más adecuado para el Producto B. El promedio móvil fue el mejor para el Producto E.
- **Variación en EOQ:** Las cantidades económicas de pedido (EOQ) varían significativamente entre los productos, con el Producto L requiriendo la mayor cantidad de 1844 unidades, lo que indica una alta demanda o un costo de mantenimiento bajo en comparación con otros productos.
- **Costos Totales:** Los costos totales asociados a la gestión del inventario también varían, reflejando las diferencias en la demanda y la cantidad de pedido óptima.

2.2. Bases Teóricas

2.2.1. Gestión de la cadena de suministro de productos perecibles

2.2.1.1. Logística de mercancías en descomposición

Se aborda una serie de consideraciones logísticas específicas para productos que tienen un tiempo de vida limitado. Por ejemplo, el manejo de la temperatura durante el transporte y almacenamiento es crucial para preservar la frescura y calidad de los productos. Esto puede involucrar el empleo de recipientes refrigerados, sistemas de vigilancia de temperatura en tiempo real y la selección de rutas que reduzcan al mínimo los tiempos de tránsito y los peligros de exposición a condiciones adversas.

2.2.1.2. Administración de existencias

En el ámbito de los productos perecibles, la gestión de existencias debe equilibrar la necesidad de mantener niveles adecuados de inventario para satisfacer la demanda con el riesgo de excesos y obsolescencia. Estrategias como el análisis predictivo de inventarios, la gestión colaborativa de la demanda y la optimización de la rotación de existencias son esenciales para aumentar la eficacia y reducir el desperdicio.

2.2.1.3. Control de calidad y seguridad alimentaria

La seguridad y calidad de los productos perecederos son elementos vitales de la cadena de suministro. Esto implica implementar prácticas de higiene y manipulación adecuadas en todas las fases del proceso, además de cumplir con regulaciones y estándares de seguridad alimentaria. La trazabilidad de los productos también resulta crucial para identificar y gestionar eficientemente cualquier problema relacionado con la calidad o seguridad que pueda surgir.

2.2.2. Machine Learning

El aprendizaje automático se basa en desarrollar algoritmos que permiten a los programas mejorar su rendimiento de manera autónoma a través de la experiencia. Estos algoritmos procesan grandes volúmenes de datos, identifican patrones y ajustan sus propios parámetros para realizar predicciones o tomar decisiones. A medida que el sistema se expone a más datos, afina su capacidad para realizar tareas específicas sin que sea necesario modificar su programación manualmente (Mitchell, 1997).

El proceso de aprendizaje automático implica etapas como la recopilación de datos, su procesamiento, el entrenamiento del modelo y la evaluación de su precisión. Durante el entrenamiento, el algoritmo ajusta sus parámetros para reducir el error y mejorar el desempeño. El objetivo es que el sistema sea capaz de generalizar a partir de ejemplos previos y realizar predicciones precisas cuando se le presenten nuevos datos.

2.2.2.1. Árboles de decisión

Un árbol de decisión es un método de aprendizaje utilizado para aproximar funciones que devuelven valores discretos. La estructura del modelo resultante se representa como un árbol de decisión, aunque también puede transformarse en un conjunto de reglas tipo "si-entonces" para facilitar su interpretación. Este enfoque es uno de los más populares en la infe-

rencia inductiva y ha sido aplicado con éxito en diversas áreas, como el diagnóstico médico y la evaluación de riesgo crediticio.

El funcionamiento de un árbol de decisión consiste en clasificar instancias ordenándolas desde el nodo raíz hasta un nodo hoja. Cada nodo del árbol representa una prueba o condición sobre un atributo específico de la instancia, y cada rama corresponde a un posible valor de dicho atributo. Para clasificar una instancia, se empieza en el nodo raíz, se evalúa el atributo correspondiente y se sigue la rama que coincide con el valor de este atributo. Este proceso se repite de manera recursiva en los subárboles hasta llegar a un nodo hoja, que proporciona el resultado final de la clasificación. (Mitchell, 1997)




Figura 2.5: Árbol de decisión

Fuente: Mitchell, T. M. (1997). Machine learning (Vol. 1, No. 9). New York: McGraw-hill.

2.2.2.2. Regresión lineal

El modelo de regresión lineal simple describe la relación entre una variable predictora x y una respuesta y , donde dicha relación sigue una línea recta. En este modelo, el intercepto β_0 y la pendiente β_1 son parámetros desconocidos, y ε representa un término de error aleatorio. Se asume que los errores tienen una media cero y una varianza desconocida σ^2 . Además, comúnmente se supone que los errores no están correlacionados, lo que significa que el valor de un error no depende del valor de otro.

En este contexto, es habitual considerar que el regresor x es controlado por el analista de datos y que se mide con un error despreciable, mientras que la respuesta y se trata como una

variable aleatoria. Esto implica que existe una distribución de probabilidad para y en cada valor posible de x . (Montgomery et al., 2013)

$$y = \beta_0 + \beta_1 x + \varepsilon \quad (\text{Ecuación 2.1})$$

2.2.2.3. Support Vector Regression

Support Vector Regression (SVR) es una técnica de aprendizaje supervisado basada en máquinas de soporte vectorial (Support Vector Machines, SVM) utilizada para resolver problemas de regresión. A diferencia de la clasificación, donde el objetivo es encontrar una frontera de decisión que separe las clases, el objetivo de SVR es encontrar una función que prediga el valor de una variable continua. En lugar de clasificar, SVR busca una línea (o hiperplano en dimensiones superiores) que se ajuste a los datos dentro de un margen de error controlado.

El principio clave detrás de SVR es encontrar una función $f(x) = w \cdot x + b$ que se mantenga dentro de una tolerancia de error ε para todos los puntos de datos, minimizando al mismo tiempo la complejidad de la función (medida por la norma de w). Para aquellos puntos que no pueden mantenerse dentro del margen ε , se introduce una variable de error que permite una penalización. (Wang, 2005)

Dado un conjunto de datos de entrenamiento $\{(x_i, y_i)\}_{i=1}^n$, donde x_i son las entradas y y_i son los valores de salida correspondientes, SVR minimiza la función de costo:

$$\frac{1}{2} \|w\|^2 + C \sum_{i=1}^n (\xi_i + \xi_i^*) \quad (\text{Ecuación 2.2})$$

sujeto a:

$$y_i - (w \cdot x_i + b) \leq \varepsilon + \xi_i \quad (\text{Ecuación 2.3})$$

$$(w \cdot x_i + b) - y_i \leq \varepsilon + \xi_i^* \quad (\text{Ecuación 2.4})$$

$$\xi_i, \xi_i^* \geq 0 \quad (\text{Ecuación 2.5})$$

Aquí: - w y b son los parámetros del modelo (el peso y el sesgo). - ε define un margen de tolerancia alrededor de la línea de predicción. - C es un parámetro de penalización que controla el equilibrio entre el margen de error ε y las desviaciones permitidas. - ξ_i y ξ_i^* son variables de error que permiten algunos puntos fuera del margen de tolerancia. (Wang, 2005)

2.2.2.4. Long Short-Term Memory Network (LSTM)

(Brownlee, 2017) La red LSTM se diferencia de una red MLP (Multi Layer Perceptron) clásica en varios aspectos fundamentales. Aunque, como en una MLP, la LSTM se organiza en capas de neuronas y los datos de entrada atraviesan la red para generar una predicción, comparte también la característica de conexiones recurrentes propias de las redes RNN. Esto significa que las activaciones de un paso anterior se usan como contexto en el siguiente paso temporal. Sin embargo, a diferencia de las RNN convencionales, las LSTM tienen una estructura particular que les permite sortear los obstáculos típicos de entrenamiento y escalado en las RNN. Esta capacidad para superar tales limitaciones y sus notables resultados hacen de las LSTM una técnica especialmente popular.

Uno de los problemas principales de las RNN tradicionales es la dificultad para entrenarlas de manera efectiva. Con frecuencia, el ajuste de pesos resultaba problemático, ya que las actualizaciones se volvían tan pequeñas que carecían de impacto (conocido como "gradientes que desaparecen") o tan grandes que llevaban a cambios abruptos e incluso errores (los llamados "gradientes que explotan"). Las LSTM, gracias a su diseño particular, logran evitar este problema, lo que amplía su capacidad para manejar información de contexto. En las RNN estándar, la influencia de una entrada sobre la capa oculta y, en última instancia, sobre la salida, tiende a decaer o aumentar exponencialmente al pasar a través de múltiples conexiones recurrentes, limitando la capacidad de acceso a la información previa. Este problema, conocido como "gradiente evanescente", es uno de los desafíos que las LSTM solucionan.

La unidad básica en la red LSTM (Gupta et al., 2022), conocida como célula de memoria, se considera la unidad de procesamiento fundamental, similar a la neurona en redes MLP. Cada célula LSTM incluye pesos y tres puertas especializadas (entrada, salida y olvido), que operan de forma continua de manera similar a los procesos de lectura, escritura y reinicio en un sistema de memoria. Inspirada en el análisis del flujo de error en redes recurrentes previas, la arquitectura de memoria a largo plazo se diseñó para hacer accesibles los retrasos temporales largos, manteniendo el flujo de información estable. Una capa de LSTM está compuesta por bloques de memoria conectados de forma recurrente, lo que permite el aprendizaje eficiente de secuencias y dependencias prolongadas al evitar la rápida degradación o aumento de los gradientes en el tiempo.




Figura 2.6: Arquitectura LSTM

Fuente: D. Gupta et. al, Advanced Machine Intelligence and Signal Processing. (2022). Singapur: Springer Nature Singapore.

2.2.2.5. Prophet

Prophet es un modelo diseñado para realizar pronósticos de series temporales, destacándose por su robustez y flexibilidad para manejar patrones complejos, estacionalidades y datos con valores atípicos. Está pensado para ser intuitivo y fácil de ajustar, permitiendo su uso tanto por expertos como por no especialistas en análisis estadístico. (Hoarau, 2022)

Prophet descompone una serie temporal $y(t)$ en tres componentes principales, sumados a un término de error aleatorio:

$$y(t) = T(t) + S(t) + H(t) + \varepsilon_t \quad (\text{Ecuación 2.6})$$

Donde: $T(t)$: Describe la tendencia o evolución a largo plazo de la serie. $S(t)$: Captura los patrones estacionales recurrentes. $H(t)$: Representa los efectos asociados a eventos específicos o festivos. ε_t : Corresponde al ruido aleatorio, que se modela como ruido gaussiano con media cero.

Componente de Tendencia ($T(t)$) El modelo permite dos enfoques para capturar tendencias:

1. Crecimiento Lineal: Modela la tendencia como una línea recta con puntos de cambio:

$$T(t) = (k + a(t)\delta)t + (m + a(t)\gamma) \quad (\text{Ecuación 2.7})$$

Donde: k es la tasa de crecimiento inicial. m es el intercepto inicial. $a(t)$ indica si hay puntos de cambio en t . δ y γ ajustan la pendiente e intercepto en dichos puntos.

2. Crecimiento Logístico: Se utiliza cuando el crecimiento está limitado por una capacidad máxima C :

$$T(t) = \frac{C}{1 + \exp(-k(t - m))} \quad (\text{Ecuación 2.8})$$

Aquí: C es el valor máximo alcanzable. k es la tasa de crecimiento. m es el tiempo en el que la serie alcanza la mitad de C .

Componente Estacional ($S(t)$) La estacionalidad se representa mediante una combinación de funciones seno y coseno, que permiten capturar patrones periódicos:

$$S(t) = \sum_{n=1}^N \left[a_n \cos\left(\frac{2\pi nt}{P}\right) + b_n \sin\left(\frac{2\pi nt}{P}\right) \right] \quad (\text{Ecuación 2.9})$$

Donde: P es el periodo del ciclo estacional (por ejemplo, 365 días para patrones anuales). a_n y b_n son coeficientes que determinan la amplitud y la forma del patrón.

Componente de Eventos y Festividades ($H(t)$). Este componente permite incluir efectos asociados a eventos específicos, modelados como variables indicadoras:

$$H(t) = \sum_{i=1}^L \text{indicador}(t \in \text{evento}_i) \cdot \beta_i \quad (\text{Ecuación 2.10})$$

Donde: evento_i representa un evento particular. β_i es la magnitud del impacto causado por dicho evento.

2.2.2.6. Autoregressive Integrated Moving Average (ARIMA)

ARIMA es un modelo estadístico ampliamente utilizado en series temporales para predecir valores futuros basándose en patrones observados en datos históricos. Es particularmente útil para datos que no son estacionarios, ya que incluye un componente de diferenciación para convertirlos en estacionarios.

El modelo ARIMA está compuesto por tres partes principales:

AR (Autoregressive): La parte autorregresiva indica que los valores pasados de la serie tienen un impacto directo en el valor actual. Está definido por un orden p , que representa el número de rezagos incluidos.

I (Integrated): La parte integrada implica la diferenciación de la serie para eliminar tendencias y hacerla estacionaria. El orden d especifica cuántas veces se diferencia la serie.

MA (Moving Average): La parte de promedio móvil indica que los errores pasados (residuos) afectan al valor actual. El orden q determina el número de términos de error pasados que se usan.

2.2.3. Modelos predictivos de demanda

2.2.3.1. Análisis de secuencias temporales

Las herramientas de modelado de secuencias temporales son esenciales para anticipar la demanda de productos que tienen una vida útil limitada. Estos modelos tienen la capacidad de detectar patrones estacionales, tendencias a largo plazo y efectos cíclicos en los datos históricos de ventas. Es crucial considerar factores como eventos estacionales, promociones de ventas y cambios en las preferencias del consumidor al desarrollar y ajustar estos modelos.

2.2.3.2. Inteligencia artificial y exploración de datos

Las técnicas de inteligencia artificial y exploración de datos ofrecen la capacidad de analizar grandes cantidades de datos de manera eficiente y descubrir patrones complejos que pueden no ser evidentes para los métodos tradicionales de análisis. Al emplear algoritmos de inteligencia artificial como regresión, agrupamiento o clasificación, es factible construir modelos predictivos más avanzados y adaptables que puedan identificar relaciones no lineales e interacciones entre variables.

2.2.3.3. Confirmación y optimización de modelos

La validación y optimización de modelos son procedimientos continuos e iterativos que aseguran la precisión y relevancia de los modelos predictivos de demanda. Esto implica comparar las proyecciones del modelo con datos reales y ajustar los parámetros del modelo según sea necesario para mejorar su rendimiento. La validación cruzada, la confirmación de hipótesis y el seguimiento constante de las métricas de rendimiento son prácticas convencionales en este proceso.

2.2.4. Series de tiempo

Las series temporales representan secuencias de datos dispuestos en orden cronológico, recolectados a lo largo de un periodo de tiempo. Estos datos pueden abarcar una amplia gama

de fenómenos, tales como el valor de acciones, la temperatura diaria, las ventas mensuales, el tráfico diario, la demanda de productos, entre otros. El análisis de series temporales tiene como objetivo comprender y modelar la estructura, patrones y tendencias presentes en los datos a lo largo del tiempo. A diferencia de otros tipos de datos, como los datos de corte transversal, las series temporales poseen una dimensión temporal intrínseca y se emplean para realizar predicciones o inferir información sobre el futuro o el comportamiento de la serie. (Ocampo et al., 2004). Según Toro Ocampo, Mejía Giraldo y Salazar Isaza (2004), las series temporales comúnmente presentan ciertas características, tales como la tendencia (una dirección general de cambio a lo largo del tiempo), la estacionalidad (patrones recurrentes que se repiten en intervalos regulares) y la autocorrelación. El análisis de series temporales comprende el uso de técnicas y modelos específicos para descomponer y visualizar la serie, identificar patrones, modelar la tendencia y la estacionalidad, así como realizar pronósticos y predicciones.




Figura 2.7: Series de tiempo

Fuente: P. Molina. et al., (2017). Modelación econométrica de la demanda de semilla de chile dulce Lamuyo y Blocky en Costa Rica mediante series de tiempo univariadas

2.2.5. Tipos de series temporales

Según Ocampo et al., 2004, hay varios tipos de series temporales que se clasifican según sus características y propiedades. A continuación, se describen algunos tipos comunes:

- **Tendencia:** Una serie temporal con tendencia muestra un cambio sistemático y sostenido en una dirección a lo largo del tiempo, ya sea ascendente (crecimiento) o descendente (decrecimiento).

- **Estacionalidad:** Las series temporales con estacionalidad exhiben patrones recurrentes que se repiten en intervalos regulares, como estacionalidad diaria, mensual o anual. Por ejemplo, la demanda de helados puede mostrar un patrón estacional con un aumento en los meses de verano.
- **Ciclos:** Los ciclos representan fluctuaciones recurrentes que no siguen un patrón de estacionalidad fijo. Estas fluctuaciones pueden tener una duración más larga que los patrones estacionales y no ocurren en intervalos regulares.
- **Ruido o componente aleatorio:** El ruido o componente aleatorio en una serie temporal representa la variabilidad aleatoria o irregular que no se puede atribuir a ninguna tendencia, estacionalidad o ciclo específico. Puede deberse a factores aleatorios, eventos imprevistos o errores de medición.
- **Serie temporal estacionaria:** No muestra una tendencia sistemática a lo largo del tiempo y tiene una varianza constante en diferentes períodos. Esto implica que la media y la autocorrelación no dependen del tiempo.
- **Serie temporal no estacionaria:** Muestra una tendencia, es decir, un cambio sistemático en la media o en la varianza a lo largo del tiempo (Ocampo et al., 2004).

2.2.6. Elementos de la serie de tiempo

Según Fierro Torres et al., 2022, tenemos las siguientes:

- **Tendencia secular:** La influencia en la tendencia a largo plazo de una serie de datos se deriva de diversos factores que operan a lo largo de períodos extensos. En términos simples, la tendencia de una serie temporal representa el gradual y constante patrón de sus fluctuaciones, originado por fuerzas duraderas asociadas con el crecimiento o declive, como cambios en la población, demografía, ingresos, salud, educación y tecnología. Dichas tendencias pueden manifestarse de distintas maneras: algunas incrementan de forma continua, otras decrecen, y algunas se mantienen estables durante períodos específicos.
- **Variación estacional:** El componente estacional en una serie de tiempo se refiere a las fluctuaciones en los datos causadas por influencias estacionales, las cuales se caracterizan por patrones repetitivos que se repiten. Por ejemplo, un fabricante de piscinas inflables espera una disminución en las ventas durante los meses de otoño e invierno, con picos de ventas durante la primavera y el verano.

- **Variación cíclica:** Las series temporales suelen mostrar patrones alternados de puntos ubicados tanto por encima como por debajo de la línea de tendencia, los cuales se extienden por más de un año, incluso después de haber eliminado los componentes estacionales e irregulares. Un ejemplo de esta variación son los ciclos económicos, que representan períodos recurrentes asociados con fases de prosperidad, recesión, depresión.
- **Variación irregular:** Se atribuye la existencia del componente irregular en una serie temporal a factores de corto plazo que son impredecibles y no se repiten en la serie. Este componente es responsable de la variabilidad aleatoria de la serie y su impacto no puede ser previsto.
 1. Variaciones generadas por eventos particulares claramente identificables, como elecciones, inundaciones, huelgas o terremotos.
 2. Variaciones aleatorias o casuales, razones no se pueden determinar de manera precisa, pero son propensas a igualarse a largo plazo.




Figura 2.8: Componentes de la serie temporal

Fuente: F, Torres. et al., (2022). Análisis comparativo de modelos tradicionales y modernos para pronóstico de la demanda: enfoques y características. RIDE. Revista Iberoamericana para la Investigación y el Desarrollo Educativo

2.2.7. Aplicación de las series de tiempo

Las series temporales cumplen dos objetivos principales: comprender las fuerzas que afectan a los datos e identificar la estructura que seguirán los datos observados. Este proceso implica ajustar modelos y emplearlos para efectuar pronósticos, llevar a cabo seguimientos, obtener retroalimentación y ejercer control en tiempo real o en el futuro. En resumen, permite tanto comprender las causas subyacentes de los datos como utilizar ese conocimiento para realizar predicciones y tomar decisiones informadas. (Brockwell y Davis, 2002)




Figura 2.9: Aplicaciones de serie temporal

Fuente: Brockwell, P. et al., (2002). Introduction to time series and forecasting. New York, NY: Springer New York

2.2.8. Métodos de suavizamiento de la serie

Según Villarreal, 2016 tenemos a los siguientes:

1. Promedio móvil: Se obtiene un promedio móvil al sustituir cada valor de una serie con la media calculada a partir de esa observación y algunos de los valores anteriores y posteriores.
2. Promedio móvil ponderado: Para ejemplificar la aplicación de esta técnica, se fortalecerá la primera sección del caso anterior acerca de las ventas de gasolina. Este método consiste en asignar un factor de ponderación distinto a cada dato, con frecuencia asignando un peso más significativo a la observación más reciente desde la cual se busca hacer el pronóstico, y este peso disminuye a medida que nos alejamos en el tiempo.

2.2.9. Técnica de suavizamiento exponencial

La simplicidad y el bajo costo de los métodos de suavización exponencial los definidos en una opción atractiva para las empresas grandes y pequeñas, así como para los técnicos que los apoyan. Estos métodos pueden servir como una alternativa de pronóstico accesible. La suavización exponencial es una técnica que emplea un promedio ponderado de valores previos en una serie temporal como pronósticos. La fórmula indica que los pronósticos para el período $t+1$ se obtienen mediante una combinación ponderada del valor real en el período t y los pronósticos para el período t . Este enfoque constituye una variante particular del método de promedios móviles ponderados, en el cual se asigna un único peso a la observación más reciente.

$$F_{t+1} = \alpha Y_t(1 - \alpha)F_t \quad \text{donde} \quad 0 \leq \alpha \leq 1 \quad (\text{Ecuación 2.11})$$

2.2.10. Método de suavización exponencial simple

Según Villarreal Buenaventura y Prada Gómez, 2016, se tiene las siguientes características:

1. Facilidad de uso, aplicable a corto plazo.
2. La serie carece de tendencias o estacionalidad.
3. Modela la serie temporal como una fracción del valor inmediatamente anterior y su complemento estimado.
4. Alfa (α) = constante de atenuación de la serie, se sugiere que esté en el rango de 0 a 1.

$$\hat{y}_t = \alpha y_{t-1} + (1 - \alpha)\hat{y}_{t-1} \quad (\text{Ecuación 2.12})$$

2.2.11. ¿Qué valor de alfa usar?

Cuando la serie de tiempo tiene una opción aleatoria considerable, es recomendable utilizar una constante de suavización pequeña. Se opta por esta elección debido a que gran parte del error en el pronóstico se atribuye a la variabilidad aleatoria. Por consiguiente, se busca evitar una reacción exagerada y ajustar los pronósticos de manera demasiado rápida. En contraposición, cuando la serie temporal presenta una variabilidad limitada, la elección de valores más altos para la constante de suavización ofrece la ventaja de adaptar rápidamente los pronósticos en caso de errores, permitiendo así una respuesta más ágil a condiciones cambiantes. La

elección del valor se realiza con el objetivo de minimizar el error de pronóstico (Villarreal Buenaventura y Prada Gómez, 2016).




Figura 2.10: Posibles valores alfa

Fuente: Molina, J. (2017). Modelación econométrica de la demanda de semilla de chile dulce Lamuyo y Blocky en Costa Rica mediante series de tiempo univariadas. e-Agronegocios

2.2.12. Tipos de suavizado exponencial

1. Suavizado exponencial simple (aplicable a series sin tendencia ni estacionalidad). Diversos enfoques de suavizado exponencial actualizan el resultado del valor previo mediante la inclusión del último dato de la serie original. Este proceso combina la información previamente disponible con la contribución proporcionada por el nuevo dato mediante un parámetro, donde $0 < \alpha < 1$.

$$S_i = \alpha x_i + (1 - \alpha)S_{i-1} \quad (\text{Ecuación 2.13})$$

2. Suavizado exponencial doble (aplicable a series con tendencia, pero sin estacionalidad). El suavizado exponencial doble conserva información acerca de la tendencia mediante la retención de dos señales suavizadas: si para la señal suavizada y ti para la tendencia suavizada. El parámetro β se emplea para aplicar suavizado exponencial a la tendencia.

$$S_i = \alpha x_i + (1 - \alpha)(S_{i-1} + t_{i-1}) \quad (\text{Ecuación 2.14})$$

$$t_i = \beta(x_i - \hat{S}_{i-1}) + (1 - \beta)t_{i-1} \quad (\text{Ecuación 2.15})$$

3. Suavizado triple exponencial (indicado para series con tendencia y estacionalidad). En este método, se incorpora un tercer componente para representar la estacionalidad, pudiendo esta ser aditiva o multiplicativa, según la necesidad.

$$S_i = \alpha(x_i - P_{i-k}) + (1 - \alpha)(S_{i-1} + t_{i-1}) \quad (\text{Ecuación 2.16})$$

$$t_i = \beta(S_i - \hat{S}_{i-1}) + (1 - \beta)t_{i-1} \quad (\text{Ecuación 2.17})$$

$$t_i = \beta(S_i - \hat{S}_{i-1}) + (1 - \beta)t_{i-1} \quad (\text{Ecuación 2.18})$$

$$P_i = \gamma(X_i - \hat{S}_i) + (1 - \gamma)p_{i-k} \quad (\text{Ecuación 2.19})$$

$$X_{i+h} = S_i + \hat{h}t_i + p_{i-k+h} \quad (\text{Ecuación 2.20})$$

2.2.13. Ventajas del método de suavización exponencial simple

El enfoque de suavización exponencial es extensamente empleado como técnica de pronósticos debido a su sencillez, siendo adoptado tanto por empresas pequeñas como por aquellas de mayor envergadura. Su implementación resulta fácil, ya sea a través de una hoja de cálculo en Excel o mediante software especializado como Forecast Pro. A continuación, se detallan sus beneficios:

1. Formulación simple: Únicamente se requiere el pronóstico anterior, la demanda real del período pronosticado y la constante de suavización. Esto facilita su aplicación y comprensión.
2. Requiere pocos datos históricos: A diferencia de otros métodos de pronóstico que pueden necesitar una gran cantidad de datos históricos, la suavización exponencial puede proporcionar pronósticos precisos incluso con un volumen limitado de datos.
3. Precisión: Al ser un modelo exponencial, la suavización exponencial tiende a ser más precisa en la predicción de la demanda futura en comparación con otros métodos de pronóstico.
4. Flexibilidad: Permite ajustar la importancia relativa de la demanda actual y la demanda antigua al asignar un peso adecuado a cada valor en el cálculo del pronóstico. Esto proporciona flexibilidad para adaptarse a diferentes patrones de demanda.

Sin embargo, al igual que los métodos de promedio móvil, la suavización exponencial tiene una desventaja en su respuesta a las tendencias. Aunque un valor de constante de suavización (alfa) puede responder a cambios en el promedio, los cambios sistemáticos en la tendencia pueden generar un error de pronóstico significativo. En estos casos, cuando se obtienen buenos resultados con un valor de alfa mayor a 0.5, puede ser más apropiado considerar el uso del alisado exponencial doble para obtener una mejor precisión en el pronóstico.

2.3. Marco Conceptual

2.3.1. Predicción

“Es una herramienta de planificación que respalda a la gestión en sus esfuerzos por abordar la incertidumbre del futuro, muy principalmente en datos del pasado y presente, así como en el análisis de tendencias” (Rios Herrera, 2020)

2.3.2. Modelos de regresión

“Modelo matemático que se utiliza para predecir una variable continua (como el precio de un producto o la demanda de un servicio) a partir de una o varias variables de entrada” (Roldán, 2020)

2.3.3. Modelos de clasificación

“Modelo matemático que se utiliza para predecir la pertenencia de una observación a una o varias categorías” (Martinez Heras, 2020)

2.3.4. Abastecimiento

“La función logística tiene la responsabilidad de proporcionar todos los recursos necesarios para asegurar el funcionamiento adecuado de una empresa, a incluir la supervisión de los procesos relacionados con la obtención de materias primas, la producción.” (Laura Huaita, 2020)

2.3.5. Precisión del modelo

“Medida de qué tan bien se ajusta el modelo a los datos históricos y qué tan buena es su capacidad para predecir la demanda futura.” (Robles Rakov & Valverde Campos, 2021)

2.3.6. Aprovisionamiento

“Es la función logística de una empresa que implica la gestión integral del suministro de materiales útiles para su operación, tal como la supervisión de los procesos involucrados en La adquisición de materias primas, la elaboración de productos, la fabricación, la distribución, el transporte y la entrega.” (Laura Huaita, 2020)

2.3.7. Eficiencia

“Está vinculado a la optimización de recursos con el objetivo de lograr un fin específico” (Robles Rakov & Valverde Campos, 2021)

2.3.8. Gestión logística

“Se trata del conjunto de prácticas y métodos empleados para planificar, organizar, llevar a cabo y supervisar la administración de recursos (materiales, humanos, financieros) necesarios en cualquier proceso de producción o prestación de servicios. Esto abarca la gestión de inventarios, el transporte, la distribución, la administración de almacenes y la coordinación de los flujos de información y bienes” (Fierro Torres et al., 2022)

2.3.9. Eficacia

“La efectividad de la cadena de suministro se basa en la garantía de que la calidad, la cantidad y la puntualidad en la entrega sean netamente impecables.” (Robles Rakov & Valverde Campos, 2021)

2.3.10. Series temporales

“Una red neuronal se conforma por un grupo de neuronas conectadas entre sí a través de enlaces. Cada neurona recibe como entradas las salidas de las neuronas de las capas previas,

multiplicando cada una de estas entradas por un peso. Luego, se suman los resultados parciales y se calcula la salida mediante una función de activación.” (Benites Sernaqué, 2021)

2.3.11. Especificidad

“Medida de la capacidad de un modelo para identificar correctamente valores negativos” (Higa Shimabukuro, 2021)

2.3.12. Automatización

“Aplicación de tecnología para realizar procesos o tareas de manera autónoma, sin intervención humana” (Fierro Torres et al., 2022)

2.3.13. Validación cruzada

“Método empleado para evaluar la capacidad predictiva de un modelo al dividir los datos en conjuntos de entrenamiento y prueba” (Rios Herrera, 2020)

2.3.14. Algoritmo de pronóstico

“Modelo matemático que utiliza técnicas estadísticas y de aprendizaje automático para predecir valores futuros” (Rodríguez-León y Pachón-Rincón, 2021)

2.3.15. Red neuronal artificial

“Modelo matemático inspirado en la estructura y función del cerebro humano, que se utiliza para procesar información y resolver problemas complejos” (Benites Sernaqué, 2021)

2.3.16. Datos históricos

“Conjunto de datos previos que se utilizan para entrenar un modelo predictivo” (Robles Rakov y Valverde Campos, 2021)

Capítulo 3

METODOLOGÍA DE LA INVESTIGACIÓN

3.1. Diseño de la investigación

En esta sección del documento se explicará cual es el diseño, el tipo y el enfoque del trabajo de investigación, así como también la población y la muestra del estudio.

3.1.1. Enfoque

Esta investigación adopta un enfoque cuantitativo, centrado principalmente en el análisis de datos históricos y la aplicación de modelos de series temporales para abordar la demanda de productos perecibles. La metodología se basa en la recopilación y análisis de datos cuantitativos diarios relacionados con la demanda, con el objetivo de ofrecer información y recomendaciones basadas en rigor estadístico y en la interpretación de patrones numéricos. Esto permitirá optimizar la gestión de la demanda de productos y mejorar la eficiencia operativa en la toma de decisiones de inversión en los pedidos a proveedores.

3.1.2. Alcance

Esta investigación es de tipo explicativa, ya que busca identificar los componentes y parámetros específicos que afectan la eficiencia de la cadena de suministro de la empresa Market Donna SAC. En particular, se centrará en el desarrollo e implementación de un sistema de pronóstico de demanda basado en modelos de Forecasting. El alcance se extiende a la evalua-

ción del impacto de este sistema en la gestión de las órdenes de productos perecibles, analizando los beneficios en términos de optimización de inversión, reducción de costos y mejora de la eficiencia operativa.

3.1.3. Tipo

La investigación es de tipo no experimental, dado que se trabajará con datos históricos comprendidos entre el año 2023 Y 2024. A partir de este análisis, se desarrollará un modelo predictivo para mejorar la precisión en la estimación de la demanda de productos perecibles en Market Donna SAC y, así, orientar decisiones más efectivas.

3.1.4. Población y muestra

La población de estudio incluye todas las categorías de productos que Market Donna SAC ofrece, entre las cuales se encuentran artículos de limpieza, frutas, verduras, lácteos, carnes, bebidas, abarrotos, tabaco, condimentos, embutidos, panes, entre otros. En total, la empresa cuenta con 16 categorías de productos que generan un promedio de 136,000 soles mensuales en ventas. La muestra seleccionada se concentra específicamente en la categoría de Verduras, que representa una de las familias de productos con mayor impacto en las ventas de la empresa. Al centrarnos en esta categoría de productos perecibles, el estudio busca realizar un análisis más preciso de la demanda diaria y proyectar las ventas en soles para la familia de verduras, dada su relevancia en las operaciones y en la rentabilidad de Market Donna SAC.

3.1.5. Unidad de análisis

La unidad de análisis de este estudio se centra en cada transacción individual de venta de productos dentro de la categoría seleccionada, que corresponde a las verduras. Cada transacción registrada en este segmento, desde el año 2023 hasta 2024, se considera como una unidad única de observación. Esto permite una comprensión granular y precisa de los patrones de compra, comportamientos de los clientes y tendencias de demanda asociadas específicamente a estos productos perecibles. Al examinar cada transacción de manera individual, el análisis busca capturar variaciones diarias en la demanda, observar los patrones de consumo recurrentes y detectar posibles picos o caídas en las ventas. Este enfoque detallado proporciona información valiosa para construir un modelo predictivo ajustado a las particularidades de la categoría de verduras, permitiendo identificar factores que podrían influir en la demanda, como la estacionalidad, días de la semana, campañas promocionales o eventos externos. Además, el análisis

de estas transacciones ofrece la oportunidad de estudiar la sensibilidad de la demanda a las variaciones en precios y promociones dentro de esta categoría. Estos datos permitirán una mejor previsión de la demanda en soles y servirán de base para la toma de decisiones estratégicas sobre los volúmenes de compra y la inversión diaria en reposición de inventario, asegurando así la disponibilidad de productos frescos y optimizando la eficiencia operativa de Market Donna SAC en esta categoría de productos perecibles.

3.2. Técnicas de recolección de datos

La recolección de datos para esta investigación se focalizó en la obtención de información sobre la categoría de verduras, la cual representa en promedio el 33 % de la demanda diaria en Market Donna SAC. Esta categoría fue seleccionada estratégicamente debido a su relevancia en la demanda diaria y su corta vida útil, lo que la convierte en un componente esencial para el análisis de productos perecibles en la empresa. Para implementar el modelo de series de tiempo y realizar pronósticos de demanda diarios que contribuyan a maximizar los ingresos, se llevó a cabo una recopilación exhaustiva de datos históricos a través de un sistema de administración de bases de datos en SQL Server. Inicialmente, se desarrollaron consultas SQL específicas 3.1 para filtrar y extraer las tablas relevantes, tales como las de productos, precios, familias y códigos. Este proceso permitió estructurar y organizar la información de manera adecuada para su posterior análisis. Posteriormente, se diseñó una consulta SQL 3.2 avanzada que integró y combinó las tablas requeridas, garantizando la coherencia e integridad de los datos necesarios para construir los modelos de pronóstico de demanda. Esta metodología proporcionó un conjunto de datos preciso y completo, indispensable para la aplicación de técnicas avanzadas de series de tiempo. El análisis incluyó el examen detallado de transacciones de productos de la categoría de verduras desde el año 2023 hasta 2024, brindando una perspectiva temporal amplia para identificar patrones y tendencias de demanda diaria a lo largo del tiempo. Además, se utilizó el sistema de punto de venta (POS) de la empresa para capturar datos en tiempo real sobre las transacciones, lo que permitió un seguimiento constante y detallado de la demanda en esta categoría. Para mejorar la precisión de los datos, se revisaron registros continuos de los niveles de inventario de la categoría de verduras. Aunque la investigación se centra en la demanda y no en la gestión de inventarios, este seguimiento indirecto permitió observar cómo la demanda afecta la reposición de productos perecibles, lo cual es crucial para la planificación diaria en productos de alta rotación. Estas estrategias de recolección de datos se diseñaron para ofrecer una visión integral y cuantitativa de la demanda de la categoría de verduras en Market Donna SAC, focalizándose en este grupo de productos perecibles que tiene un impacto significativo en las ventas diarias y en la eficiencia operativa general de la empresa.

```

SELECT
  t.name AS ID,
  (SUM(p.rows) AS RowCounts)
FROM
  SYS.TABLES t
INNER JOIN
  SYS.INDEXES i ON t.object_id = i.object_id
INNER JOIN
  SYS.OBJECTS o ON i.object_id = o.object_id AND i.index_id IN (0, 1)
WHERE
  t.is_ms_shipped = 0
GROUP BY
  t.name
ORDER BY
  (SUM(p.rows) DESC);

--
SELECT * FROM factura ORDER BY FECHA DESC ;
SELECT * FROM detalle ORDER BY FECHA DESC ;
SELECT * FROM detalle ORDER BY FECHA DESC ;
SELECT * FROM detalle ORDER BY FECHA DESC ;

---CABECERA---
SELECT SERIE, NUMERO, INDIC, FECHA, TOTAL, NETO FROM factura ORDER BY FECHA DESC ;
SELECT SERIE, NUMERO, INDIC, FECHA, TOTAL, NETO FROM detalle ORDER BY FECHA DESC ;

--- DETALLE ---
SELECT SERIE, NUMERO, producto, descripcion, unidad, tipo, igu, cantidad, precio, impuesto, subtotal, total FROM detalle ORDER BY FECHA DESC ;
SELECT SERIE, NUMERO, producto, descripcion, unidad, igu, cantidad, precio, impuesto, subtotal, total FROM detalle ORDER BY FECHA DESC ;

---
SELECT b.* FROM FINANCIO b
WHERE (b.SERIE, b.NUMERO) NOT IN (SELECT c.SERIE, c.NUMERO FROM factura c);
ORDER BY b.FECHA DESC ;

---
SELECT c.SERIE, NUMERO, INDIC, FECHA, TOTAL, NETO FROM factura ORDER BY FECHA DESC ;
SELECT c.SERIE, NUMERO, producto, descripcion, unidad, igu, cantidad, precio, impuesto, subtotal, total FROM detalle ;

```

Figura 3.1: Consulta SQL
Fuente: Elaboración propia




Figura 3.2: Tablas de ventas

Fuente: Elaboración propia

3.3. Técnicas para el procesamiento y análisis de la información

Para entrar con más detalles a la metodología se describen los pasos a seguir.

3.3.1. Metodología de la implementación de la solución

El primer paso en el proceso KDD (Knowledge Discovery in Databases) consiste en la comprensión y selección de los datos disponibles, así como en la definición clara de los objetivos de la investigación desde la perspectiva del investigador. Este proceso se fundamenta en el conocimiento previo y adquirido durante el estudio. En el contexto del análisis de tendencias de ventas a lo largo del tiempo, este paso implica examinar minuciosamente aspectos como el monto de la transacción, la fecha y hora de compra, la cantidad adquirida, la categoría de producto (familia) y el producto específico. Además, resulta esencial definir con precisión los objetivos específicos de la investigación, tales como la identificación de patrones de comportamiento en las series temporales de ventas. Estos objetivos guían el análisis detallado y permiten enfocar la metodología hacia la detección de patrones útiles que faciliten la toma de decisiones y la optimización de la gestión de demanda en productos perecibles.




Figura 3.3: Metodología KDD

Fuente: Fayyad, U., Piatetsky-Shapiro, G., Smyth, P. (1996). The KDD process for extracting useful knowledge from volumes of data. Communications of the ACM, 39(11), 27-34.

Tabla 3.1: Instrumentos de medida para recolección de datos

Técnica	Instrumento	Origen	Principales ventajas	Principales desventajas
Datos de ventas históricas	Registro de ventas(2023-2024)	Registro de la empresa	Obtiene datos cuantitativos sobre las ventas históricas de productos perecibles	No proporciona información cualitativa sobre los patrones de la demanda
Sistemas de punto de venta (POS)	Hardware POS	Registro en tiempo real de transacciones	Ofrece datos continuos y actualizados sobre las ventas	Dependencia de la confiabilidad del sistema
Datos de inventarios	Registro de inventarios	Registro de la empresa	Permite evaluar la relación entre la demanda y la gestión de inventarios Cuantitativamente	No proporciona información sobre factores externos

Fuente: Elaboración propia

Esta comprensión inicial es fundamental para orientar las etapas siguientes de la metodología KDD y garantizar que el análisis de los datos sea relevante y eficaz. La selección de la base de datos adecuada y de las variables para el modelo de aprendizaje automático se realizará utilizando la base de datos proporcionada por la entidad en este caso de estudio.

3.3.2. Comprensión del negocio

En la fase inicial, se identificó el problema mediante la comprensión del contexto de la investigación. A partir de esta comprensión, se establecieron los objetivos y requisitos esperados para el proyecto. La siguiente tabla muestra la lista de actividades y tareas planificadas.

Tabla 3.2: Actividades de la comprensión de negocio

Actividades	Descripción	Tareas
Definir problemas, objetivos e hipótesis.	Se definieron los problemas, objetivos, e hipótesis tanto generales como específicos de la investigación.	■ Identificar la problemática del contexto. ■ Establecer los objetivos de la investigación. ■ Formular las hipótesis del estudio.
Desarrollar la literatura de la investigación.	Se realizó una selección de antecedentes y estudios previos relacionados con la investigación.	■ Buscar estudios relacionados al tema, la metodología y solución.
Definir metodología de la investigación.	Se definió la metodología a implementarse en el estudio.	■ Seleccionar la metodología a implementar en base a la investigación de antecedentes.

Fuente: Elaboración propia

Actividad 1: Definir problemas, objetivos e hipótesis.

Esta actividad describe cómo se identificaron los problemas y se establecieron los objetivos e hipótesis, tanto generales como específicos, de la investigación, basándose en el análisis de la situación problemática actual.

Entregable: Problemas, objetivos e hipótesis.

Actividad 2: Desarrollar la literatura de la investigación.

Una vez definidos los objetivos, se llevó a cabo la búsqueda de fuentes, publicaciones, libros, artículos y material académico relacionado con el contexto, sus características y los métodos empleados para resolver problemas en ese entorno. Además, se desarrolló el marco teórico del

estudio.

Entregable: Antecedentes académicos en la forma de objetivo, base de datos, metodología y resultados en el contexto de la investigación

Actividad 3: Definir la metodología de la investigación.

Después de obtener suficientes recursos intelectuales y revisar los trabajos previos necesarios para el desarrollo de la investigación, se analizaron detalladamente cada uno de los antecedentes y se compararon las metodologías implementadas por distintos autores. Al finalizar esta tarea, y con base en la literatura y los procesos más alineados con el presente estudio, se seleccionó la metodología KDD como la opción más adecuada.

Entregable: Metodología a implementar.

3.3.3. Comprensión de los datos

La investigación incluyó un proceso exhaustivo de exploración, análisis e interpretación de la información recopilada, con el objetivo de identificar patrones, tendencias y relaciones significativas. Este paso es fundamental para garantizar que los datos sean relevantes, precisos y útiles para responder a las preguntas de investigación y alcanzar los objetivos del estudio. El conjunto de datos utilizado abarca 525 mil registros de ventas, organizados por familia de productos, correspondientes a los años 2023 al 2024. Para mayor claridad, se elaboró una tabla que presenta las actividades y tareas realizadas. [3.3](#)

Tabla 3.3: Actividades de la Comprensión de los datos

Actividades	Descripción	Tareas
Selección de la base de datos	Base de datos que contenga variables que aporten al modelo y representen significancia al pronóstico	■ Construir los query en SQL para seleccionar las variables representativas para la investigación. ■ Agrupar las variables por familias para preparar el análisis.
Análisis bivariado y univariado	Análisis del comportamiento de las variables y en la descripción y resumen de una sola variable a la vez para entender y representar las características básicas	■ Construir los scripts en python para analizar variables y pares de variables. ■ Entender las características de cada variable.

Fuente: Elaboración propia

Actividad 1: Selección de la base de datos.

La selección de los datos en SQL implicó escoger una base de datos con variables específicas del negocio dentro de un sistema de gestión de bases de datos (DBMS).

```
1  SELECT
2      t.name AS TableName,
3      SUM(p.rows) AS RowCounts
4  FROM
5      sys.tables t
6  INNER JOIN
7      sys.indexes i ON t.object_id = i.object_id
8  INNER JOIN
9      sys.partitions p ON i.object_id = p.object_id
10 WHERE
11     t.is_ms_shipped = 0
12 GROUP BY
13     t.name
14 ORDER BY
15     SUM(p.rows) DESC;
16
17 SELECT * FROM factura ORDER BY FECHA DESC ;
18 select * from detalle ORDER BY FECHA DESC ;
19 select * from jelchead ORDER BY FECHA DESC ;
20 select * from recibo ORDER BY FECHA DESC ;
```

Figura 3.4: Selección de tablas SQL

Fuente: Elaboración propia




Figura 3.5: Tablas de ventas

Fuente: Elaboración propia

Entregable: Tablas de ventas

Actividad 2: Análisis bivariado y univariado.

Se emplearon análisis univariado y bivariado para examinar y comprender los datos. El análisis univariado se centró en describir y resumir una sola variable a la vez, utilizando estadísticas

como la media, mediana, moda y varianza, además de visualizaciones como histogramas para revelar la distribución y características específicas de esa variable. Por otro lado, el análisis bivariado se enfocó en explorar la relación entre dos variables, empleando técnicas como tablas de correlación y regresión para identificar patrones, asociaciones y posibles causalidades entre las variables.

```
In [32]: 1 ##analisis variables continuas
          2 round(data_cleaned.describe(),2)
```

Out[32]:

	NUMERO	semana	anio	TOTAL	cantidad	precio
count	615523.00	615523.00	615523.00	615523.00	615523.00	615523.00
mean	342483.96	24.41	2023.22	78.18	2.15	4.64
std	419716.21	15.11	0.66	242.82	8.72	5.71
min	1.00	1.00	2008.00	0.00	0.00	0.00
25%	79893.00	11.00	2023.00	8.00	0.84	1.40
50%	395298.00	22.00	2023.00	19.30	1.00	2.80
75%	480522.00	38.00	2023.00	42.60	1.15	5.80
max	14463708.00	53.00	2024.00	6763.50	2000.00	270.00

Figura 3.6: Descripción cuantitativa

Fuente: Elaboración propia




Figura 3.7: Cuantificación de semanas

Fuente: Elaboración propia




Figura 3.8: Distribución de precion

Fuente: Elaboración propia




Figura 3.9: Correlación de variables

Fuente: Elaboración propia

El mapa de calor muestra la correlación entre varias variables, como semana, año, total, producto, y precio. En general, las correlaciones son débiles, con solo una correlación negativa moderada entre semana y año (-0.38). Esto sugiere que no hay relaciones lineales fuertes entre las variables, lo cual indica que cada una aporta información única al conjunto de datos. Este análisis preliminar sugiere que no es necesario eliminar ninguna columna por redundancia, ya que las correlaciones no son suficientemente altas.

Entregable: Análisis estadístico de variables

3.3.4. Procesamiento

El segundo paso en la metodología KDD se centra en la preparación de los datos de transacciones de ventas de manera diaria. Este proceso implica realizar operaciones básicas de limpieza y depuración, eliminando ruido y valores atípicos que puedan afectar la calidad y precisión de los resultados. Además, se recopila información relevante para entender y modelar el ruido presente en los datos, lo que facilita una interpretación más clara de los patrones y tendencias. Se implementan también estrategias para gestionar campos de datos que carecen de información cronológica, asegurando así la coherencia y cohesión de los datos para un análisis efectivo.

3.3.5. Transformación

En el tercer paso de la metodología KDD, se realiza la transformación de datos para adecuarlos al análisis, centrándose en agrupar los productos por familias. Esta fase implica identificar características que representen eficazmente los datos y que se ajusten a los objetivos específicos de la tarea de análisis. Según estos objetivos, se seleccionan las características más relevantes para proporcionar información significativa sobre las ventas. Además, se aplican técnicas para reducir la complejidad de los datos o encontrar representaciones más concisas y manejables. Este proceso es fundamental para simplificar la estructura de los datos y facilitar un análisis más eficiente y efectivo.

3.3.6. Modelamiento

Al concluir la etapa del preprocesamiento, las variables pudieron ser utilizadas para los modelos de cada modalidad, que fueron diseñados siguiendo las actividades de la Tabla [3.4](#)

Tabla 3.4: Actividades de fase modelamiento

Actividades	Descripción	Tareas
Desarrollar modelos predictivos para data estructurada.	Implementación de un mínimo de 8 modelos de forecasting para entrenarlos y seleccionar el mejor para la data.	Escoger los modelos para entrenarlos y ver cual es el mejor modelo para realizar los pronósticos de ventas.
Seleccionar las métricas para la evaluación del modelo.	Implementación las métricas para poder evaluar a los modelos implementados.	Escoger las métricas que definirán cual modelo será mejor para realizar los pronósticos de venta (R2, MSE, RMSE y MAPE).

Fuente: Elaboración propia

Actividad 1: Desarrollar modelos predictivos para data estructurada.

En esta actividad, se diseñó la arquitectura que se utilizó para los datos estructurados. Para ello, se llevó a cabo un benchmarking sobre los modelos a utilizar:

- **ARIMA:** ARIMA es un modelo estadístico utilizado para analizar y predecir series temporales. Combina la parte autoregresiva (AR), que utiliza las observaciones pasadas para predecir valores futuros, con la parte de media móvil integrada (IMA), que maneja la variabilidad y tendencia de los datos.
- **LSTM:** LSTM es un tipo de red neuronal recurrente (RNN) diseñada para modelar secuencias temporales y dependencias a largo plazo. Es capaz de aprender dependencias temporales en los datos y es especialmente efectiva en problemas donde las relaciones entre eventos en el tiempo son importantes.
- **LINEAR REGRESSION:** La regresión lineal es un modelo estadístico que examina la relación lineal entre una variable dependiente y una o más variables independientes. El objetivo es encontrar la línea (o plano en casos de múltiples variables) que mejor se ajuste a los datos, minimizando la suma de los errores cuadráticos.
- **XGBOOST:** XGBoost es una implementación optimizada del algoritmo de gradient boosting, que se utiliza ampliamente en problemas de aprendizaje supervisado, tanto para clasificación como para regresión. Utiliza árboles de decisión como modelos base y se enfoca en mejorar el rendimiento a través de técnicas como la regularización y el manejo eficiente de conjuntos de datos grandes.

- **SVR:** SVR es una variante de las máquinas de vectores de soporte (SVM) adaptada para problemas de regresión. A diferencia de los métodos de regresión lineal, SVR utiliza vectores de soporte en un espacio de alta dimensión para predecir valores continuos, buscando la función que mejor se ajuste a los datos mientras mantiene un margen de error aceptable.
- **RANDOM FOREST:** Random Forest es un conjunto de árboles de decisión, donde cada árbol es construido de manera independiente y con muestras de datos aleatorias. La predicción final se obtiene por votación o promediando las predicciones individuales de los árboles, lo que mejora la precisión y reduce el sobreajuste.
- **DECISION TREE:** Un árbol de decisión es una estructura de modelo de aprendizaje automático que divide un conjunto de datos en subconjuntos más pequeños basados en características específicas de las variables predictoras. Cada nodo representa una característica y cada hoja representa un resultado o decisión.
- **PROPHET:** Prophet es un modelo desarrollado por Facebook para realizar pronósticos de series temporales. Es especialmente útil cuando se cuenta con datos estacionales, festivos o fluctuaciones regulares, y permite manejar datos con puntos faltantes o valores atípicos. Es fácil de usar y flexible para ajustar tendencias y patrones estacionales.

Con base en la revisión de estudios previos, se observó que los modelos LSTM, Regresión Lineal y Árbol de Decisión ofrecieron los mejores resultados en experimentos similares. Dado que el objetivo de la investigación era implementar un modelo de regresión, se decidió utilizar Regresión Lineal para el análisis de los datos estructurados.

Diseño de la Arquitectura Regresión Lineal Múltiple

La ecuación general de la regresión lineal múltiple se define como:

$$Y = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \dots + \beta_n X_n + \varepsilon \quad (\text{Ecuación 3.1})$$

Donde:

- Y : Variable dependiente o respuesta.
- $X_1, X_2, \dots, X_n$: Variables independientes o explicativas.
- β_0 : Intercepto o término constante.
- $\beta_1, \beta_2, \dots, \beta_n$: Coeficientes de las variables independientes, que representan su contribución al valor de Y .

- ε : Error residual, que captura las desviaciones no explicadas por el modelo.

El objetivo es estimar los coeficientes $\beta_0, \beta_1, \dots, \beta_n$ que minimicen la suma de los errores al cuadrado (Método de Mínimos Cuadrados Ordinarios):

$$\text{Minimizar: } \sum_{i=1}^m (Y_i - \hat{Y}_i)^2 \quad (\text{Ecuación 3.2})$$

Donde $\hat{Y}_i$ es el valor predicho para la i -ésima observación.

Entregable: Modelo Regresión Lineal para el pronóstico de ventas.

Actividad 2: Seleccionar las métricas para la evaluación del modelo. En esta actividad, se llevó a cabo una investigación basada en el estado del arte para identificar las métricas más utilizadas en investigaciones previas. Se encontró que las métricas más frecuentemente empleadas fueron las siguientes:

- **RMSE:** Calcula la raíz cuadrada de la media de los cuadrados de los errores entre las predicciones de un modelo y los valores reales. Es útil para medir el nivel de error promedio de las predicciones en la misma unidad que los datos originales.
- **MSE:** Calcula el promedio de los cuadrados de los errores entre las predicciones de un modelo y los valores reales. Proporciona una medida de la varianza de los errores, penalizando más fuertemente los errores grandes.
- **MAPE:** Calcula el promedio del porcentaje absoluto de los errores entre las predicciones de un modelo y los valores reales. Es útil para evaluar la precisión relativa de un modelo, especialmente en situaciones donde se desea conocer el error porcentual promedio.

De acuerdo a la anterior lista, estas métricas ayudarán a:

- Evaluar la precisión y el rendimiento de modelos predictivos en comparación con los valores reales.
- Cuantificar el nivel de error y la discrepancia entre las predicciones del modelo y los datos observados.
- Optimizar y ajustar los parámetros del modelo para minimizar el error y mejorar la precisión de las predicciones.

Estas métricas proporcionan una base sólida para la evaluación rigurosa de modelos predictivos en diversas aplicaciones, facilitando la toma de decisiones informadas y la mejora continua del rendimiento del modelo.

Las métricas señaladas se calculan de la siguiente manera:

RMSE (Root Mean Square Error)

Calcular los errores individuales: Para cada predicción $\hat{y}_i$ y su valor real y_i , calcula el error cuadrático.

$$\text{Error}_i = (\hat{y}_i - y_i)^2 \quad (\text{Ecuación 3.3})$$

Calcular el promedio de los errores cuadráticos: Luego, calcula el promedio de estos errores cuadráticos sobre todos los puntos de datos.

$$\text{MSE} = \frac{1}{n} \sum_{i=1}^n (\hat{y}_i - y_i)^2 \quad (\text{Ecuación 3.4})$$

Calcular la raíz cuadrada del MSE: Finalmente, obtén el RMSE tomando la raíz cuadrada del MSE.

$$\text{RMSE} = \sqrt{\text{MSE}} \quad (\text{Ecuación 3.5})$$

MSE (Mean Squared Error)

Calcular los errores individuales: Para cada predicción $\hat{y}_i$ y su valor real y_i , calcula el error cuadrático como en el paso 1 del RMSE:

$$\text{Error}_i = (\hat{y}_i - y_i)^2 \quad (\text{Ecuación 3.6})$$

Calcular el promedio de los errores cuadráticos: Luego, calcula el promedio de estos errores cuadráticos sobre todos los puntos de datos.

$$\text{MSE} = \frac{1}{n} \sum_{i=1}^n (\hat{y}_i - y_i)^2 \quad (\text{Ecuación 3.7})$$

MAPE (Mean Absolute Percentage Error)

Calcular los errores porcentuales individuales: Para cada predicción $\hat{y}_i$ y su valor real y_i , calcula el error porcentual absoluto.

$$Error_i = \left(\frac{y_i - \hat{y}_i}{y_i} \right) \times 100 \quad (\text{Ecuación 3.8})$$

Calcular el promedio de los errores porcentuales: Luego, calcula el promedio de estos errores porcentuales sobre todos los puntos de datos.

$$MAPE = \frac{1}{n} \sum_{i=1}^n \left(\frac{|y_i - \hat{y}_i|}{y_i} \right) \times 100 \quad (\text{Ecuación 3.9})$$

Entregable: Modelo LSTM entrenado con sus respectivas métricas.

3.3.7. Evaluación

Esta fase comprende la evaluación de los modelos desarrollados en la investigación a través de las métricas de regresión seleccionadas y explicadas en la sección 3.3.6. En la Tabla 3.5 se indican las actividades y tareas seguidas para esta etapa.

Tabla 3.5: Actividades de fase evaluación

Actividades	Descripción	Tareas
Evaluar el modelo predictivo	Evaluación del desempeño del modelo LSTM	Ejecutar experimentos para definir hiperparámetros.
Interpretar las métricas obtenidas	Observar los resultados de las métricas obtenidas permite inferir si el modelo puede ser un predictor confiable para los pronósticos.	Interpretar los resultados obtenidos de las métricas permite extraer conclusiones fundamentales sobre el rendimiento del modelo.

Fuente: Elaboración propia

Actividad 1: Evaluar el modelo predictivo.

En esta actividad, se procedió inicialmente con el entrenamiento de todos los modelos utilizando datos recopilados durante aproximadamente 3 años, que incluyen las ventas semanales de la familia con la que se cuenta con mayor cantidad de datos históricos. Este proceso de entrenamiento fue fundamental para ajustar los modelos y capturar patrones y tendencias significativas basadas en un conjunto de datos robusto y representativo. Para optimizar el rendimiento de los modelos, se llevaron a cabo entre 3 y 5 experimentos por cada diseño de modelo, explorando diversas combinaciones y ajustes de hiperparámetros en cada iteración. Esta estrategia

sistemática permitió evaluar cómo diferentes configuraciones afectan el rendimiento del modelo en términos de métricas críticas como precisión, error y capacidad de generalización. Los experimentos no solo se centraron en la optimización de hiperparámetros, sino también en la selección de técnicas de preprocesamiento de datos y ajustes de arquitectura del modelo. Cada iteración fue diseñada para obtener insights valiosos sobre qué configuraciones maximizan la capacidad del modelo para realizar pronósticos precisos y confiables de las ventas semanales. Este enfoque riguroso y metódico no solo aseguró la mejora continua del rendimiento predictivo, sino que también proporcionó una base sólida para la toma de decisiones informadas sobre la implementación y refinamiento del modelo finalmente seleccionado.

Entregable: Modelo Regresión Lineal Entrenado y Ajustado.

Actividad 2: Interpretar las métricas obtenidas.

En esta actividad, se procedió inicialmente a realizar un análisis exhaustivo de las métricas obtenidas del modelo Regresión Lineal entrenado y ajustado. Estas métricas fueron meticulosamente calculadas para evaluar el desempeño del modelo en la predicción precisa de las ventas semanales, utilizando datos históricos recopilados durante aproximadamente 5 años.

Durante el análisis, se focalizó en métricas fundamentales como el RMSE (Root Mean Square Error), MSE (Mean Squared Error) y MAPE (Mean Absolute Percentage Error). Estas métricas proporcionaron una evaluación cuantitativa del nivel de precisión y error del modelo en comparación con las ventas reales observadas en el período de entrenamiento.

El estudio detallado de estas métricas permitió extraer conclusiones significativas sobre la capacidad del modelo para capturar variaciones y patrones en las ventas semanales. Además, facilitó la identificación de posibles áreas de mejora en términos de ajustes adicionales de hiperparámetros o refinamientos en la arquitectura del modelo Regresión Lineal. Este análisis crítico y sistemático es esencial para tomar decisiones informadas sobre la implementación y el desarrollo continuo del modelo Regresión Lineal en aplicaciones futuras de pronóstico de ventas. Asimismo, asegura un mejor rendimiento predictivo y una mayor precisión en la proyección de tendencias comerciales, beneficiando así la toma de decisiones estratégicas en el contexto empresarial.

Entregable: Resultados de las métricas MSE, RMSE, MAPE.

3.3.8. Despliegue

En la última fase de la metodología seguida, se implementó el modelo propuesto después de completar su entrenamiento y evaluación correspondiente. Esta etapa final fue crucial para poner a prueba la capacidad predictiva del modelo en un entorno operativo real. Las actividades detalladas realizadas durante esta fase se describen en la Tabla 3.6, proporcionando una visión completa de los pasos ejecutados para asegurar la integración efectiva del modelo en la aplicación práctica.

Tabla 3.6: Actividades de fase Despliegue

Actividades	Descripción	Tareas
Diseñar prototipo de sistemas con modelo propuesto.	Diseño del prototipo del sistema que integrará la captura de datos con el modelo propuesto para predecir las ventas.	■ Diseñar una estructura de prototipo de sistema conformado por captura de datos y modelo propuesto. ■ Cargar complementos del modelo.
Ejecutar el prototipo y integrarlo con el modelo desarrollado.	Ejecución del sistema prototipo en tiempo real con proyectos de tecnología de campañas vigentes.	■ Ejecutar prototipo con dirección web de proyecto consultado. ■ Clasificar el estado de financiamiento a partir del resultado predicho.

Fuente: Elaboración propia

Después de analizar el rendimiento de cada modelo, tanto individualmente como el modelo final, se compararon los resultados con los antecedentes disponibles. Luego, se llevó a cabo una prueba piloto donde se ejecutó el modelo ensamblado entrenado, se obtuvieron sus características y se realizaron predicciones tanto del presupuesto para cada familia de productos como de la cantidad de productos necesarios para realizar un pedido.

Actividad 1: Diseñar prototipo de sistema con modelo propuesto

En esta actividad, se diseñó el prototipo del sistema que integra el modelo propuesto para optimizar la gestión de inventarios y mejorar la precisión en las proyecciones de demanda. El sistema fue concebido para utilizar datos históricos y variables clave, permitiendo una planificación más eficiente de las operaciones y una mejor adaptación a las fluctuaciones del mercado.

Entregable: Arquitectura del prototipo del sistema integrado.

Actividad 2: Ejecutar prototipo con proyectos tecnológicos vigentes. En esta actividad, se ejecuta el prototipo web diseñado para implementar el modelo, facilitando la visualización y la posibilidad de realizar un pedido automático de productos. Este sistema web fue desarrollado con el fin de integrar de manera eficiente el modelo predictivo, permitiendo a los usuarios interactuar de forma intuitiva con las predicciones de demanda y facilitando la automatización del proceso de pedidos en tiempo real.

Entregable: Plataforma web con los resultados de los pronósticos obtenidos.

3.4. Metodología para la medición de resultados de la implementación

3.4.1. Raíz del error cuadrático medio (RMSE)

El término utilizado para denotar el error que surge de la diferencia entre los valores predichos y los valores observados por un modelo o estimador es conocido como error cuadrático medio (RMSE). Esta medida se obtiene al calcular la raíz cuadrada de la media de los errores cuadráticos, lo cual refleja la disparidad entre los valores reales y los valores pronosticados. Es importante destacar que el RMSE, al ser siempre positivo, donde valores menores indican un ajuste más acertado de los datos al modelo. La formulación de este concepto se detalla en la siguiente sección.

$$\hat{y}_i = \sqrt{\frac{\sum_{i=1}^n (y_i - \hat{y}_i)^2}{n}} \quad (\text{Ecuación 3.10})$$

3.4.2. Error cuadrático medio (MSE)

El término utilizado para medir la discrepancia entre los valores observados y los valores predichos por un modelo o estimador es conocido como el *Error Cuadrático Medio* (*Mean Squared Error*, MSE). Esta métrica se calcula como el promedio de los cuadrados de las diferencias entre los valores reales y los valores estimados. El MSE proporciona una medida global

del error del modelo, donde valores más bajos indican un mejor ajuste de los datos al modelo. Es importante destacar que el MSE siempre es no negativo, ya que los errores al cuadrado eliminan cualquier signo.

La formulación matemática del MSE se presenta a continuación:

$$\text{MSE} = \frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2 \quad (\text{Ecuación 3.11})$$

3.4.3. Error Porcentual Absoluto Medio (MAPE)

El *Error Porcentual Absoluto Medio* (*Mean Absolute Percentage Error*, MAPE) es una métrica utilizada para medir la precisión de un modelo de predicción. Representa el promedio de los errores absolutos expresados en porcentaje, lo que permite interpretar el error en términos relativos respecto a los valores observados. Es una medida ampliamente utilizada debido a su simplicidad y capacidad para comparar errores en diferentes escalas.

El MAPE se calcula mediante la siguiente fórmula:

$$\text{MAPE} = \frac{1}{n} \sum_{i=1}^n \left| \frac{y_i - \hat{y}_i}{y_i} \right| \cdot 100 \quad (\text{Ecuación 3.12})$$

3.4.4. Coeficiente de determinación

El valor del coeficiente de determinación (R^2) oscila entre 0 y 1, reflejando la fracción de puntos en un conjunto de datos que se ajustan a la línea de regresión. Este coeficiente es una medida de la cantidad de variabilidad de la variable dependiente que puede ser explicada por el modelo de regresión. En el contexto de modelos estadísticos, R^2 se emplea para predecir resultados futuros o validar hipótesis, siendo una herramienta crucial para evaluar la calidad del modelo y la proporción de variación en los resultados que este puede explicar. La formulación de R^2 se presenta en la siguiente línea. (Bruce, P. et al. 2020)

$$\hat{R}^2 = 1 - \frac{\sum_{i=1}^n (y_i - \hat{y}_i)^2}{\sum_{i=1}^n (y_i - \bar{y})^2} \quad (\text{Ecuación 3.13})$$

3.5. Cronograma de actividades y presupuesto

ACTIVIDADES O TAREAS	PERÍODO DE EJECUCIÓN / SEMANAS									
	1	2	3	4	5	6	7	8	9	10
Planteamiento del problema y objetivos	■	■								
Revisión bibliográfica			■							
Recopilación y preparación de datos				■						
Limpieza y transformación de datos				■						
Análisis exploratorio de datos					■	■				
Identificación de patrones y características de datos						■	■			
Selección de modelos							■			
Desarrollo e implementación del modelo seleccionado								■	■	
Estimación de parámetros del modelo									■	
Validación del modelo y comparación con datos reales									■	
Interpretación de resultados y análisis									■	
Redacción del informe final										■

Figura 3.10: Cronograma de actividades

Fuente: Elaboración propia

Tabla 3.7: Presupuesto

Recurso	Categoría	Descripción	Costo (Soles)
Laptop	Equipo	Equipo de procesamiento del modelo de ML	3000
Internet	Servicio	Servicio básico para el uso del estudio	100
Electricidad	Servicio	Servicio básico para el uso del estudio	200
Python	Software	Lenguaje de programación de alto nivel	-

Fuente: Elaboración propia

Capítulo 4

ENTORNO EMPRESARIAL

4.1. Descripción de la empresa

4.1.1. Reseña histórica y actividad económica

Donna S.A.C, una exitosa empresa dedicada a los minimercados, se ha establecido como un destino de compras esencial para la comunidad. Con cuatro ubicaciones estratégicas, esta cadena se ha convertido en un punto de referencia para aquellos que buscan productos de calidad y atención personalizada. Su lema, "Donna S.A.C, donde cada compra es una experiencia", refleja su compromiso con la creación de un ambiente cálido y acogedor para sus clientes. Desde la entrada, los clientes son recibidos con un diseño moderno y limpio, facilitando una experiencia de compra placentera. La atención al cliente es primordial, con empleados capacitados siempre dispuestos a brindar ayuda, garantizando que cada visita sea positiva.

Las cuatro tiendas de Donna S.A.C están estratégicamente ubicadas para ofrecer fácil acceso a una amplia gama de productos, desde alimentos frescos hasta artículos para el hogar, satisfaciendo las cambiantes necesidades de sus clientes. Con un equipo de veinte empleados comprometidos, Donna S.A.C ha cultivado un ambiente laboral colaborativo y motivador mediante una capacitación continua que asegura un servicio informado y útil para los clientes. Esta dedicación al desarrollo del equipo no solo beneficia a los empleados, sino que también contribuye al ambiente positivo que caracteriza a cada tienda.

4.1.2. Descripción de la organización

Descripción de Donna S.A.C: Más Allá de un Minimarket, una Experiencia de Compra Inigualable.

Donna S.A.C, una cadena de minimarkets que va más allá de las expectativas convencionales, ha dejado una marca distintiva en el mundo de las compras minoristas. Con cuatro ubicaciones estratégicas, esta empresa se ha convertido en un pilar esencial para aquellos que buscan no solo productos de elevada calidad, así mismo una experiencia de compra inigualable.

Cada tienda Donna S.A.C ha sido diseñada con esmero para crear un ambiente acogedor y moderno. Desde la entrada, los clientes son recibidos con un diseño limpio y una disposición intuitiva de productos. La tienda no es solo un espacio de transacciones; es un destino donde la atención al cliente es una prioridad. Nuestro equipo de veinte empleados capacitados está siempre disponible para ayudar, proporcionando un servicio personalizado que transforma cada visita en una experiencia positiva. La diversidad de productos en Donna Sac es impresionante, desde alimentos frescos y productos del hogar hasta opciones de conveniencia para satisfacer las necesidades diarias. La cadena se enorgullece de mantener sus estantes abastecidos con productos de alta calidad, ofreciendo a los clientes la confianza de que encontrarán lo que necesitan, cuando lo necesiten.

Detrás de la exitosa operación de Donna Sac se encuentra un equipo de veinte trabajadores dedicados que personifican los valores de la empresa. La capacitación frecuente y el desarrollo profesional son fundamentales para nuestro enfoque en el servicio al cliente, asegurando que cada miembro del equipo esté bien informado y preparado para brindar asesoramiento útil.

4.1.2.1. Organigrama

Este organigrama es una representación simplificada de la estructura jerárquica de Donna Sac. Cada posición puede tener roles específicos y responsabilidades detalladas, y la organización está diseñada para fomentar la eficiencia operativa, la atención al cliente excepcional y la participación comunitaria.



Figura 4.1: Organigrama Donna SAC

4.1.3. Datos generales estratégicos de la empresa

Información Básica:

- Nombre completo de la empresa: Donna Sac.
- Fecha de fundación: 2005.
- Fundadores o actuales propietarios: Donaciano Paucar.
- Tiendas: 4 tiendas.
- Ubicación de cada tienda: Lince, San Miguel, Miraflores, San Juan de Miraflores.
- Tamaño promedio de las tiendas en pies cuadrados: 120 ft²
- Número total de empleados: 40.
- Productos y Servicios: Consumo masivo.
- Segmentos de mercado objetivo: Personas proximas a las tiendas de Donna SAC.

4.1.3.1. Visión, misión y valores o principios

Visión: “Ser reconocidos como el referente líder en la experiencia de compra minorista, destacando por nuestra dedicación excepcional al cliente, la innovación en productos y servi-

cios, y nuestro impacto positivo en las comunidades que servimos.”

Misión: “En Donna Sac, nos comprometemos a ofrecer a nuestros clientes una experiencia de compra única y satisfactoria, brindando productos de alta calidad, un servicio personalizado y contribuyendo activamente al bienestar de las comunidades locales. Nos esforzamos por ser un destino esencial para aquellos que buscan más que una simple transacción, buscando una conexión significativa con sus necesidades diarias y valores compartidos.”

4.1.3.2. Objetivos estratégicos

Excelencia en la Experiencia del Cliente:

- Mejorar continuamente la atención al cliente para garantizar una experiencia de compra excepcional.
- Implementar programas de capacitación para el equipo humano que refuercen la significación del servicio al cliente.

Diversificación y Ampliación de Productos:

- Investigar y agregar nuevos productos que satisfagan las tendencias del mercado y las necesidades cambiantes de los clientes.
- Expandir las líneas de productos propios para aumentar la diferenciación en el mercado.

Innovación en Tecnología y Operaciones:

- Implementar tecnologías avanzadas para mejorar la eficiencia operativa, desde sistemas de gestión de inventario hasta soluciones de punto de venta.
- Explorar oportunidades para la implementación de plataformas digitales que mejoren la experiencia del cliente y faciliten la expansión en línea.

Desarrollo de la Cadena de Suministro Sostenible:

- Contribuir con proveedores implicados con prácticas sostenibles y éticas.
- Reducir la huella ambiental mediante prácticas de gestión de residuos y opciones de embalaje sostenibles.

Expansión Geográfica y Nuevas Tiendas:

- Identificar y evaluar nuevas ubicaciones estratégicas para la apertura de tiendas.
- Establecer alianzas con desarrolladores inmobiliarios para facilitar la expansión.
- Iniciativas de Responsabilidad Social Corporativa.
- Introducir iniciativas de responsabilidad social corporativa
- Establecer asociaciones con organizaciones benéficas y participar activamente en eventos comunitarios.

Optimización Financiera:

- Mejorar la eficiencia financiera mediante la implementación de herramientas de análisis y seguimiento.
- Buscar oportunidades para mejorar los márgenes de beneficio sin afectar la calidad de los recursos y servicios.

4.1.3.3. Evaluación interna y externa. FODA

Oportunidades	Ponderación	Clasificación	Puntuación
El crecimiento de la clase media peruana está generando una mayor demanda de productos y servicios de calidad. La tendencia de los peruanos se está centrando en la obtención de productos de manera más rápida y en menores tiempos de espera.	0.3	3	0.90

Oportunidades	Ponderación	Clasificación	Puntuación
El cambio en los hábitos de consumo, los nuevos consumidores buscan cuidar su salud por lo que buscan frutas al momento de entrar a una tienda minorista.	0.05	3	0.15
Cada vez salen nuevas marcas de productos de consumo masivo al mercado. Las alianzas estratégicas con otras empresas podrían ayudar a Donna a ampliar su oferta de productos.	0.1	2	0.20
La innovación tecnológica podría ayudar a Donna a mejorar la eficiencia y la experiencia de compra de los clientes. Implementación de IA en la capacitación o cajeros automáticos.	0.05	2	0.10
Las inversiones en marketing podrían ayudar a Donna el aumentar su reconocimiento de marca y atraer a nuevos clientes. Expansión de sus redes sociales y crear campañas que se alineen con las nuevas tendencias en su público objetivo.	0.15	1	0.15
	0.65		1.50

Tabla 4.1: Oportunidades de Donna Sac

Amenazas	Ponderación	Clasificación	Puntuación
El crecimiento del sector de las tiendas minoristas está generando una mayor competencia.	0.15	2	0.30
Los cambios en la inestabilidad económica y cambios de gobierno reducen el tiempo de compra de productos. Muchos consumidores obtan por las tiendas mayoristas en este tipo de situaciones.	0.05	2	0.10
Tambo posee una participación del 30 % en la categoria de tiendas minoristas.	0.05	2	0.10
Los cambios en los hábitos de consumo, hacia una mayor orientación hacia los productos orgánicos o saludables, podrían afectar la demanda de los productos de Donna y replantear un nuevo stock de productos.	0.05	3	0.15
Problemas de politica exterior de Perú con países a los que compramos productos internacionales podrian afectar el precio compra al que llegan a nuestro país.	0.05	2	0.10
	0.35		0.75

Tabla 4.2: Amenazas de Donna Sac

La empresa Donna se encuentra por debajo del promedio en cuestión de respuesta a los

factores exteriores. Se recomienda darle más importancia a lo que esta pasando en su entorno macro para poder aprovechar las oportunidades del mercado.

Fortalezas	Ponderación	Clasificación	Puntuación
Experiencia de 20 años en el mercado minorista, conocimientos del entorno y adaptación a los diversos escenarios del proceso de compra del consumidor.	0.20	4	0.80
Ofrece productos mucho más variados que otras tiendas minoristas que estan top en la categoría, Donna ofrece productos que abarcan hasta frutas y verduras que son del día.	0.10	4	0.40
Donna se ubica en zonas de alto tráfico peatonal, lo que facilita el acceso a nuevos clientes	0.05	3	0.15
Se ofrece una pequeña capacitación de unos 3 días al personal para que se enfoque en crear relación con el cliente y que no solo se convierta en una transacción de bienes. Se le proporciona videos y un taller que se enfoca en ser empatico con el cliente al preguntar cosas de su vida diaria.	0.15	4	0.60
Empleados jóvenes, más ágiles y que recomiendan productos a los clientes con mayor rapidez de acuerdo a las tendencias del mercado.	0.10	3	0.30

Fortalezas	Ponderación	Clasificación	Puntuación
	0.60		2.25

Tabla 4.3: Fortalezas de Donna Sac

Debilidades	Ponderación	Clasificación	Puntuación
La mayoría de las tiendas de Donna se encuentran en zonas urbanas, lo que limita su alcance al mercado rural.	0.15	1	0.15
Donna tiene una marca poco diferenciada, lo que puede dificultar su posicionamiento frente a la competencia que son en su mayoría tiendas de esquina o los mismos mercados.	0.05	1	0.05
Donna se concentra en la venta de productos básicos, lo que limita su oferta de productos a un público más especializado.	0.05	2	0.10
Donna no posee un horario de atención de 24 horas.	0.10	1	0.10
Alta rotación de personal, no se crea identidad de marca con el personal interno.	0.05	2	0.10
	0.40		0.50

Tabla 4.4: Debilidades de Donna Sac




Figura 4.2: Matriz interna y externa

Donna se encuentra en la Celda V, por lo tanto le conviene la estrategia de mantener y conservar. Lo que se plantea que haga Donna al no ser una opción la penetración de mercado por razones económicas es optar por la estrategia de desarrollo de producto. Lo que se plantea es introducir nuevos productos orgánicos y saludables, debido a la demanda de salud que está en crecimiento. Además, mejorar la calidad de productos y priorizar el bienestar del consumidor, darle un extra a cada compra para que pueda recordar nuestra marca.

Capítulo 5

DESARROLLO DEL EXPERIMENTO

5.1. Determinación y evaluación de alternativas de solución

En primer lugar, se observó que la empresa cuenta con un amplio portafolio de productos, con más de 20 familias diferentes. Sin embargo, no todas estas familias tienen la misma relevancia en términos de ventas. Para abordar el desafío de predecir las ventas en este diverso conjunto de familias de productos, se llevó a cabo un proceso de selección cuidadoso. Se identificaron y seleccionaron las familias con mayor relevancia en las ventas, basándose en datos históricos y análisis de rendimiento comercial.




Figura 5.1: Familia de productos

Fuente: Elaboración propia

Las familias de productos seleccionadas para el análisis representan una parte significativa de las operaciones comerciales de la empresa. Se priorizaron según su contribución a los ingresos totales y su impacto en la rentabilidad general. Esta selección se basó en datos concretos, incluidos registros de ventas, análisis de tendencias del mercado y consultas con los departamentos de ventas y marketing. Con las familias de productos relevantes identificadas, se procedió a explorar diferentes enfoques para predecir las ventas futuras. Se reconocieron dos alternativas principales, diseñadas para maximizar la utilidad de los datos disponibles y adaptarse a las necesidades específicas de cada familia de productos:

1. Utilizar un Único Modelo de Predicción para las Familias Relevantes: En esta alternativa, se propone emplear un único modelo de predicción que abarque todas las familias de productos consideradas relevantes para las ventas. Este modelo se entrenaría utilizando datos históricos recopilados de estas familias y se utilizaría para realizar predicciones en tiempo real. Se considera que esta opción puede simplificar el proceso de predicción y ser más eficiente en términos de recursos y tiempo de implementación. No obstante, existe la preocupación de que este enfoque pueda subutilizar la información específica de cada familia, lo que podría resultar en predicciones menos precisas y adaptadas a las particularidades de cada una.
2. Probar múltiples modelos para cada familia relevante: Esta alternativa implica la eva-

luación de varios modelos de predicción para cada familia de productos relevante en las ventas. Dado que la empresa cuenta con un amplio conjunto de familias de productos, se seleccionaron las seis más relevantes en términos de ventas. Se considera probar modelos como regresión logística, LSTM y XGBoost, entre otros, para determinar cuál proporciona las mejores métricas de rendimiento para cada familia. Aunque esta opción puede ser más compleja y requerir más recursos computacionales y tiempo de implementación, ofrece la ventaja de una mayor personalización y optimización para cada familia, lo que podría resultar en predicciones más precisas y adaptadas a sus características específicas.

5.2. Propuesta solución

Esta propuesta, como se explicó anteriormente, implica un enfoque más granular y específico para cada familia de productos seleccionada. En lugar de aplicar un único modelo de predicción a todas las familias, se explorará la idoneidad de múltiples modelos para cada una, teniendo en cuenta sus características individuales y su historial de ventas. Entre estos modelos se encuentran los siguientes:

- **Linear Regression:** Un modelo de regresión lineal que busca la mejor relación lineal entre las variables independientes y la variable dependiente.
- **Decision Tree:** Un modelo basado en árboles de decisión que segmenta los datos en subconjuntos homogéneos.
- **Random Forest:** Un modelo de conjunto que utiliza múltiples árboles de decisión para mejorar la precisión de las predicciones.
- **Support Vector Regression (SVR):** Un modelo de regresión que utiliza máquinas de soporte vectorial para encontrar la mejor línea de ajuste en un espacio de características de alta dimensión.
- **XGBoost:** Un modelo de boosting de gradiente extremo que optimiza iterativamente los errores de predicción anteriores.
- **ARIMA:** Un modelo de series temporales que captura las dependencias auto-regresivas y de medias móviles.
- **LSTM:** Un tipo de red neuronal recurrente diseñada para manejar dependencias de largo plazo en series temporales.

- **Prophet:** Un modelo desarrollado por Facebook que se especializa en la predicción de series temporales con componentes estacionales y días festivos.

Todos estos modelos se entrenarán con la misma finalidad: determinar cuál es el más óptimo para realizar las predicciones de las ventas semanales de la familia de productos de verduras. Esta evaluación se llevará a cabo utilizando métricas de rendimiento como el Error Cuadrático Medio (MSE), la Raíz del Error Cuadrático Medio (RMSE), R2 Y (error porcentual absoluto medio) MAPE. Además, se considerará la capacidad de cada modelo para capturar patrones estacionales y tendencias a largo plazo presentes en los datos de ventas.




Figura 5.2: Predicción Vs. valores actuales

Fuente: Elaboración propia

5.3. Planeamiento y descripción de actividades

5.3.1. Adquirir Base de Datos

Este paso involucra obtener acceso a la base de datos de la empresa que contiene los registros históricos de ventas de las diferentes familias de productos. Se establecerá comunicación con los departamentos pertinentes para obtener los datos necesarios de manera segura y

ética. En la Figura observamos que se adquieren las ventas desde el año 2023 al 2024, sumando más de 620 mil registros de ventas en este periodo.

```
df = pd.read_csv("data_with_added_columns.csv")
df
```

	SERIE	NUMERO	FECHA	TOTAL	producto	descripcio	unidad	igv	cantidad	precio	impuesto	subtotal	total	FAMILIA	dia_semana	dias_Feriado	gasto_a_proveedores	numero_Transacciones
0	1	1082	2023-02-15	247,25	5601.0	NARANJA JUGO X KG	KG	0.0	107,5	2,3	0	247,25	247,25	FRUTA	2	0	1092	1084
1	1	1198	2024-08-04	184	5601.0	NARANJA JUGO X KG	KG	0.0	80	2,3	0	184	184	FRUTA	6	0	1118	1323
2	1	79238	2023-10-20	108	4843.0	BOLSAS T-SHIRT ASA PB 16X19	UND	18.0	10	4,3	6,559	36,441	43	DESCAR	4	0	902	960
3	1	79238	2023-10-20	108	4845.0	BOLSAS T-SHIRT ASA PB 21X24	PQT	18.0	5	10	7,627	42,373	50	DESCAR	4	0	1511	900
4	1	79238	2023-10-20	108	4849.0	BOLSAS WARA 10X15	UND	18.0	10	1,5	2,288	12,712	15	DESCAR	4	0	1011	877
...	...	...	...	...	...	...	...	...	...	...	...	...	...	...	...	...	...	...
620790	S001	59	2023-03-15	35,14	5763.0	PIMIENTO ROJO X KG	kg	18.0	0,73	6	0,66813	3,71186	4,38	VERDUR	2	0	927	1167
620791	S001	59	2023-03-15	35,14	5773.0	ROCOTO ENTERO X KG	KG	0.0	0,91	5	0	4,55	4,55	VERDUR	2	0	1131	1022
620792	S001	59	2023-03-15	35,14	5775.0	TOMATE ITALIANO X KG	KG	0.0	0,23	3	0	0,69	0,69	VERDUR	2	0	1536	1046
620793	S001	59	2023-03-15	35,14	5781.0	ZANAHORIA X KG	KG	0.0	0,52	2,2	0	1,144	1,144	VERDUR	2	0	1208	976
620794	S001	59	2023-03-15	35,14	5787.0	AJI VERDE X KG	KG	0.0	0,26	2,9	0	0,754	0,754	VERDUR	2	0	780	936

620795 rows x 18 columns

Figura 5.3: Datos históricos de ventas

Fuente: Elaboración propia

Posteriormente se decide agregar 3 nuevas columnas que serán relevantes para el pronostico de ventas. Siendo las columnas agregadas dias_Feriado, gasto_a_proveedores y numero_Transacciones

```
df = df[['FECHA', 'FAMILIA', 'cantidad', 'precio', 'dias_Feriado', 'gasto_a_proveedores', 'numero_Transacciones']].copy()
df
```

	FECHA	FAMILIA	cantidad	precio	dias_Feriado	gasto_a_proveedores	numero_Transacciones
0	2023-02-15	FRUTA	107,5	2,3	0	1092	1084
1	2024-08-04	FRUTA	80	2,3	0	1118	1323
2	2023-10-20	DESCAR	10	4,3	0	902	960
3	2023-10-20	DESCAR	5	10	0	1511	900
4	2023-10-20	DESCAR	10	1,5	0	1011	877
...	...	...	...	...	...	...	...
620790	2023-03-15	VERDUR	0,73	6	0	927	1167
620791	2023-03-15	VERDUR	0,91	5	0	1131	1022
620792	2023-03-15	VERDUR	0,23	3	0	1536	1046
620793	2023-03-15	VERDUR	0,52	2,2	0	1208	976
620794	2023-03-15	VERDUR	0,26	2,9	0	780	936

620795 rows x 7 columns

Figura 5.4: Datos históricos de ventas con 3 columnas agregadas

Fuente: Elaboración propia

5.3.2. Preprocesamiento de datos

Antes de utilizar los datos para el análisis y modelado, es fundamental realizar un preprocesamiento adecuado. Esto incluye la limpieza de datos para eliminar valores faltantes o erróneos, la normalización para asegurar que todas las variables estén en la misma escala y la

codificación de variables categóricas si es necesario. Adicional a estos pasos para asegurar la calidad, se decidió trabajar con la familia de Verduras para este análisis de Forecasting




Figura 5.5: Ventas de la familia verduras

Fuente: Elaboración propia

5.3.3. Selección de algoritmos a utilizar

En este escenario, se han seleccionado los siguientes modelos para la predicción de ventas semanales de la familia de productos de verduras: Árbol de Decisión, Bosque Aleatorio, SVR, XGBoost, Regresión Lineal, ARIMA, LSTM y Prophet. Antes de proceder con el entrenamiento de estos modelos, se dividirán los datos en conjuntos de entrenamiento y prueba, asignando el 80 % de los datos para entrenamiento y el 20 % restante para pruebas.

5.3.3.1. Proceso de Entrenamiento y Evaluación de Modelos

1. **División de Datos:** Los datos se dividirán en dos conjuntos:

- **Entrenamiento (80 %):** Utilizado para entrenar los modelos.
- **Prueba (20 %):** Utilizado para evaluar el rendimiento de los modelos.

2. **Entrenamiento de Modelos:** Cada uno de los modelos seleccionados se entrenará utilizando el conjunto de datos de entrenamiento. Este proceso implicará ajustar los parámetros de los modelos.

tros de cada modelo para optimizar su rendimiento.

5.3.4. Definir parámetros

Una vez seleccionados los modelos, se procederá a definir los parámetros iniciales de cada modelo y a realizar la optimización de hiperparámetros para mejorar su rendimiento predictivo. Esto se realizará utilizando técnicas como la búsqueda en cuadrícula o la optimización bayesiana. Una vez obteniendo estos parámetros se verá cual modelo es mejor para cada familia y se tomará la decisión de cual modelo trabajar con cada familia.

```
# Initialize models
models = {
    "Linear Regression": LinearRegression(),
    "Decision Tree": DecisionTreeRegressor(),
    "Random Forest": RandomForestRegressor(n_estimators=100),
    "SVR": SVR(),
    "XGBoost": XGBRegressor(),
    "ARIMA": None, # Placeholder for ARIMA model
    "LSTM": None, # Placeholder for LSTM model
    "Prophet": None # Placeholder for Prophet model
}

# Train and predict with each model
predictions = {}
for name, model in models.items():
    if name == "ARIMA":
        # Fit the ARIMA model on the training data (y_train)
        arima_model = auto_arima(y_train, seasonal=False, trace=True)
        arima_model.fit(y_train)
        # Make predictions for the test data (y_test)
        arima_forecast = arima_model.predict(n_periods=len(y_test))
        predictions[name] = arima_forecast.values
    elif name == "LSTM":
        # [samples, timestep, features] -> 1 for predicting using the previous timestep
        X_train_lstm = X_train.values.reshape((X_train.shape[0], 1, X_train.shape[1]))
        X_test_lstm = X_test.values.reshape((X_test.shape[0], 1, X_test.shape[1]))

        # Define LSTM model
        lstm_model = Sequential()
        lstm_model.add(LSTM(50, activation='relu', input_shape=(X_train_lstm.shape[1], X_train_lstm.shape[2])))
        lstm_model.add(Dense(1))
        lstm_model.compile(optimizer='adam', loss='mse')

        # Fit the LSTM model
        lstm_model.fit(X_train_lstm, y_train, epochs=200, batch_size=32, verbose=0)

        # Make predictions
        lstm_predictions = lstm_model.predict(X_test_lstm)
        predictions[name] = lstm_predictions.flatten()
    elif name == "Prophet":
        # Define and fit the Prophet model
        prophet_model = Prophet()
        prophet_model.fit(train_df)

        # Make predictions
        prophet_forecast = prophet_model.predict(test_df[['ds']])
        predictions[name] = prophet_forecast['yhat'].values
    else:
        model.fit(X_train, y_train)
        predictions[name] = model.predict(X_test)
```

Figura 5.6: Parametros de los modelos elegidos

Fuente: Elaboración propia

5.4. Desarrollo de actividades. Aplicación de herramientas de solución

5.4.1. Preprocesamiento de datos

Se realizará un análisis exhaustivo para identificar y cuantificar los datos faltantes en el conjunto de datos históricos. Este análisis se llevará a cabo por columnas para determinar qué variables tienen valores ausentes y en qué medida.



Figura 5.7: Identificando las columnas con datos faltantes

Fuente: Elaboración propia

5.4.2. Selección de Columnas relevantes

Una vez completada la imputación de datos, se procederá a la selección de las columnas más relevantes para el análisis de predicción de ventas. En este caso, se considerarán las siguientes columnas como las más pertinentes:

- Date: Fecha de transacción de venta.
- Family_id: Identificador unico del tipo de producto perecible

- Total: Medida principal de las ventas totales.
- Leisure_days: Día feriado por festividad gubernamental.
- Supplier_cost: Número de pagos que se hicieron a proveedores en el día.
- Num_transaction: Número de ventas en el día.

```
df_vendura = df_vendura[['FECHA', 'id', 'FAMILIA', 'total_sales', 'dias_Feriado', 'gasto_a_proveedores', 'numero_Transacciones']].copy()
df_vendura = df_vendura.rename(columns={
    'FECHA': 'date',
    'id': 'family_id',
    'FAMILIA': 'family_name',
    'total_sales': 'total_sales',
    'dias_Feriado': 'leisure_days',
    'gasto_a_proveedores': 'supplier_cost',
    'numero_Transacciones': 'num_transaction'
})
df_vendura.reset_index(drop=True, inplace=True)
```

	date	family_id	family_name	total_sales	leisure_days	supplier_cost	num_transaction
0	2023-04-30	32	VERDUR	3.000	0	943	1261
1	2023-04-30	32	VERDUR	2.700	0	1082	1450
2	2023-04-30	32	VERDUR	24.000	0	647	1108
3	2023-04-30	32	VERDUR	9.800	0	503	1364
4	2023-01-05	32	VERDUR	6.000	0	1215	1113
...	...	...	...	...	...	...	...
174757	2023-03-15	32	VERDUR	4.380	0	927	1167
174758	2023-03-15	32	VERDUR	4.550	0	1131	1022
174759	2023-03-15	32	VERDUR	0.690	0	1536	1046
174760	2023-03-15	32	VERDUR	1.144	0	1208	976
174761	2023-03-15	32	VERDUR	0.754	0	780	936

174762 rows x 7 columns

Figura 5.8: Columnas de datos

Fuente: Elaboración propia

	date	family_id	total	leisure_days	supplier_cost	num_transaction
0	2008-04-30	32	387.24600	0	1085	1236
1	2023-01-03	32	1619.51505	0	1031	917
2	2023-01-04	32	1413.67632	0	986	896
3	2023-01-05	32	1339.90988	0	1215	1113
4	2023-01-06	32	1761.43734	0	1444	1224
...	...	...	...	...	...	...
436	2024-11-04	32	1297.79216	0	1498	1005
437	2024-12-01	32	1284.77588	0	581	951
438	2024-12-02	32	626.67150	0	774	1044
439	2024-12-03	32	1576.66163	0	1516	1205
440	2024-12-04	32	1375.76215	0	1242	1202

Figura 5.9: Datos históricos de ventas

Fuente: Elaboración propia

5.4.3. Seleccionamos los modelos a utilizar

En este escenario, se han seleccionado los siguientes modelos: Árbol de Decisión, Random Forest, SVR, XGBoost y Regresión Lineal. Antes de proceder con el entrenamiento de estos modelos, se dividirá los datos en conjuntos de entrenamiento y prueba, asignando el 80 % de los datos para entrenamiento y el 20 % restante para pruebas.

```
[ ] # Split the data into training and test sets (80% train, 20% test)
train_size = int(len(df_aggregated) * 0.8)
X_train, X_test = X[:train_size], X[train_size:]
y_train, y_test = y[:train_size], y[train_size:]

# Split the data into training and test sets (80% train, 20% test) (For Prophet)
train_size = int(len(df_prophet) * 0.8)
train_df = df_prophet[:train_size]
test_df = df_prophet[train_size:]
```

Figura 5.10: División de prueba y entrenamiento

Fuente: Elaboración propia

```
# Initialize models
models = {
    "Linear Regression": LinearRegression(),
    "Decision Tree": DecisionTreeRegressor(),
    "Random Forest": RandomForestRegressor(n_estimators=100),
    "SVR": SVR(),
    "XGBoost": XGBRegressor(),
    "ARIMA": None, # Placeholder for ARIMA model
    "LSTM": None, # Placeholder for LSTM model
    "Prophet": None # Placeholder for Prophet model
}
```

Figura 5.11: Modelos elegidos

Fuente: Elaboración propia

A continuación se vera como se entrenan los modelos y las métricas que se eligieron que vendrían a ser RMSE, MSE, R2 y MAPE

```

# Calculate evaluation metrics
metrics = {}
for name in models.keys():
    mse = mean_squared_error(y_test, predictions[name])
    rmse = np.sqrt(mse)
    r2 = r2_score(y_test, predictions[name])
    mape = mean_absolute_percentage_error(y_test, predictions[name])
    metrics[name] = {'MSE': mse, 'RMSE': rmse, 'R2': r2, 'MAPE': mape}

metrics_df = pd.DataFrame(metrics).T

# Sort the metrics by RMSE
metrics_df = metrics_df.sort_values(by='RMSE')

```

Figura 5.12: Definición de modelos y métricas*Fuente: Elaboración propia*

A continuación se vera la comparación de todos los modelos y apartir de eso se eligira el mejor modelo para trabajar con una familia.

```

Comparison of Predictions:
Linear Regression Decision Tree Random Forest SVR XGBoost \
0 0.069538 -0.218179 -0.085736 -0.016636 0.008099
1 0.343931 0.949108 0.956031 0.815770 0.842380
2 -0.131470 0.121896 0.049919 -0.142297 0.085248
3 0.075698 0.272734 0.041180 -0.011560 -0.090930
4 0.041402 0.181531 0.166403 -0.038608 0.055559
.. ...
83 -0.428999 -0.193489 -0.135985 -0.056831 -0.155912
84 0.049011 0.137241 -0.017479 -0.032696 0.017488
85 0.003657 -0.469812 -0.222035 -0.070401 -0.271452
86 0.321266 0.361548 0.480062 0.741376 0.858926
87 -0.414903 -0.077075 -0.095099 -0.021421 -0.087687

ARIMA LSTM Prophet Actual
0 -0.067563 -0.080846 -0.432196 -0.767554
1 0.000000 0.581751 0.347125 0.290735
2 0.000000 -0.171467 0.118667 -0.170443
3 0.000000 -0.072596 0.000367 -0.094097
4 0.000000 -0.118003 -0.042818 0.865615
.. ...
83 0.000000 -0.126154 0.356935 -0.111035
84 0.000000 -0.108039 -0.421405 -0.010072
85 0.000000 -0.166493 0.357916 -0.717101
86 0.000000 0.515314 0.129458 0.921682
87 0.000000 -0.128086 0.011158 -0.136209

[88 rows x 9 columns]

```

Figura 5.13: Comparación de resultados




Figura 5.14: Resultados de modelos

5.5. Medición de la solución

Los parámetros que se utilizaron para poder elegir el mejor modelo son los siguientes:

Raíz del error cuadrático medio (RMSE): El término utilizado para denotar el error que surge de la diferencia entre los valores predichos y los valores observados por un modelo o estimador es conocido como error cuadrático medio (RMSE). Esta medida se obtiene al calcular la raíz cuadrada de la media de los errores cuadráticos, lo cual refleja la disparidad entre los valores reales y los valores pronosticados. Es importante destacar que el RMSE, al ser siempre positivo, donde valores menores indican un ajuste más acertado de los datos al modelo. La formulación de este concepto se detalla en la siguiente sección.

$$\hat{y}_i = \sqrt{\frac{\sum_{i=1}^n (y_i - \hat{y}_i)^2}{n}} \quad (\text{Ecuación 5.1})$$

Error Cuadrático Medio (MSE - Mean Squared Error): El MSE mide el promedio de los cuadrados de los errores entre las ventas reales y las ventas predichas por el modelo de regresión lineal. En otras palabras, indica cuán cerca están las ventas predichas de las ventas reales en términos de la diferencia cuadrada entre ellos.

$$MSE = \frac{1}{n} \sum_{i=1}^{\hat{n}} (y_i - \hat{y}_i)^2 \quad (\text{Ecuación 5.2})$$

Error Porcentual Absoluto Medio (MAPE - Mean Absolute Percentage Error): El MAPE proporciona una medida de la precisión relativa del modelo de regresión lineal en términos porcentuales. Mide el promedio de los errores porcentuales absolutos entre las ventas reales y las ventas predichas. Esto te permite comprender cuánto se desvían, en promedio, las ventas predichas de las ventas reales en términos de porcentaje.

$$MAPE = \frac{1}{n} \sum_{i=1}^n \left| \frac{y_i - \hat{y}_i}{y_i} \right| \times 100 \% \quad (\text{Ecuación 5.3})$$

Coefficiente de determinación: El valor del coeficiente de determinación (R²) oscila entre 0 y 1, reflejando la fracción de puntos en un conjunto de datos que se ajustan a la línea de regresión. Este coeficiente es una medida de la cantidad de variabilidad de la variable dependiente que puede ser explicada por el modelo de regresión. En el contexto de modelos estadísticos, R² se emplea para predecir resultados futuros o validar hipótesis, siendo una herramienta crucial para evaluar la calidad del modelo y la proporción de variación en los resultados que este puede explicar. La formulación de R² se presenta en la siguiente línea. (Bruce, P. et al. 2020)

$$\hat{R}^2 = 1 - \frac{\sum_{i=1}^n (y_i - \hat{y}_i)^2}{\sum_{i=1}^n (y_i - \bar{y})^2} \quad (\text{Ecuación 5.4})$$

5.5.1. Simulación de la predicción

Se realizó la simulación a la familia que tiene más relevancia ósea “VERDURAS” como se mencionó en el anterior punto se utilizó el modelo de regresión lineal ya que mostró mejores resultados en los parámetros RMSE, MSE, R² y MAPE. A continuación muestro el código con el que se trabajó para realizar la simulación de la predicción

	Fecha	Predicción de Ventas
0	2024-12-05	1210.093236
1	2024-12-06	896.476252
2	2024-12-07	1349.228761
3	2024-12-08	1484.135639
4	2024-12-09	530.030177
5	2024-12-10	624.548013
6	2024-12-11	1371.403709
7	2024-12-12	601.895914
8	2024-12-13	1372.283743
9	2024-12-14	696.605018
10	2024-12-15	1364.993437
11	2024-12-16	1426.659136
12	2024-12-17	1413.277662
13	2024-12-18	610.083298
14	2024-12-19	1440.662065
15	2024-12-20	1481.117804
16	2024-12-21	1238.078806
17	2024-12-22	436.560815
18	2024-12-23	723.127282
19	2024-12-24	1667.618054
20	2024-12-25	1400.416338
21	2024-12-26	584.913984
22	2024-12-27	1428.422168
23	2024-12-28	1380.877022
24	2024-12-29	1325.741232
25	2024-12-30	693.436408
26	2024-12-31	1537.753603
27	2025-01-01	1407.199608

Figura 5.15: Predicción numerica del mejor modelo

Fuente: Elaboración propia




Figura 5.16: Predicción con el mejor modelo

Fuente: Elaboración propia

Capítulo 6

ANÁLISIS DE RESULTADOS

6.1. Resultados

A continuación se muestran los resultados obtenidos a partir de la metodología seguida. Estos resultados abarcan diferentes modelos de predicción como LSTM, Prophet, SVR, ARIMA, Linear Regression, Random Forest, Decision Tree, XGBoost.

1. LSTM (Long Short-Term Memory)

- **Uso:** Redes neuronales recurrentes diseñadas para analizar datos secuenciales, como series temporales.
- **Escenarios:** Aplicaciones incluyen pronósticos de series temporales, procesamiento de lenguaje natural (NLP), y reconocimiento de voz.
- **Predictor:** Destacado por su capacidad para modelar patrones complejos y dependencias a largo plazo en datos de ventas.

2. Prophet

- **Uso:** Modelo de series temporales desarrollado por Facebook para prever datos con estacionalidad y tendencias cambiantes.
- **Escenarios:** Utilizado en pronósticos de ventas, gestión de inventarios y planificación de recursos.
- **Predictor:** Eficiente para capturar variaciones estacionales y cambios de tendencia en datos de ventas.

3. SVR (Support Vector Regression)

- **Uso:** Algoritmo de aprendizaje supervisado que encuentra un hiperplano óptimo en un espacio dimensional alto para la regresión.
- **Escenarios:** Aplicado en predicción de series temporales, análisis financiero y clasificación.
- **Predictor:** Efectivo cuando hay una separación clara entre los datos de ventas y se necesita evitar el sobreajuste.

4. ARIMA (AutoRegressive Integrated Moving Average)

- **Uso:** Modelo estadístico para analizar y pronosticar series temporales.
- **Escenarios:** Usado en pronóstico de demanda, análisis económico y finanzas.
- **Predictor:** Adecuado para datos de ventas con patrones estacionarios lineales o estacionales.

5. Linear Regression

- **Uso:** Modelo básico de regresión que asume una relación lineal entre variables.
- **Escenarios:** Aplicado en predicción de precios, análisis de mercado y evaluación de impacto.
- **Predictor:** Simple y rápido, útil cuando se requiere una interpretación clara de las relaciones entre variables.

6. Random Forest

- **Uso:** Método de aprendizaje en conjunto que combina múltiples árboles de decisión para mejorar la precisión.
- **Escenarios:** Utilizado en clasificación y regresión, detección de anomalías y análisis predictivo de marketing.
- **Predictor:** Eficiente para grandes conjuntos de datos con muchas variables, capturando relaciones no lineales.

7. Decision Tree

- **Uso:** Modelo que divide el conjunto de datos en subconjuntos más pequeños según características específicas.
- **Escenarios:** Aplicaciones en análisis de riesgos, diagnósticos médicos y segmentación de mercado.
- **Predictor:** Fácil de interpretar y visualizar, adecuado para datos estructurados y no estructurados.

8. XGBoost (Extreme Gradient Boosting)

- **Uso:** Algoritmo de aprendizaje en conjunto que utiliza árboles de decisión potenciados con gradientes.
- **Escenarios:** Utilizado en competencias de Kaggle, pronóstico de series temporales, clasificación y regresión.
- **Predictor:** Potente para mejorar la precisión en grandes conjuntos de datos, especialmente en problemas complejos de predicción de ventas.

En la investigación sobre la predicción de ventas en Market Donna, se evaluó varios modelos para determinar su eficacia. Tras analizar métricas como MSE, RMSE, R^2 y MAPE, se encontró que el modelo de Regresión Lineal destacó como el mejor predictor entre los comparados. Con un MSE de 0.282840 y un RMSE de 0.531821, Regresión Lineal demostró una precisión superior en las predicciones en comparación con modelos como Prophet, SVR, ARIMA, LSTM, Random Forest, Decision Tree y XGBoost, los cuales mostraron métricas menos favorables. Este resultado destacó la capacidad de la regresión lineal para capturar patrones complejos en las series temporales de ventas de Market Donna, resaltando su relevancia en aplicaciones donde la exactitud en la predicción era crucial para la toma de decisiones estratégicas y operativas.

Tabla 6.1: Comparación de métricas

	MSE	RMSE	R^2	MAPE
LSTM	0.253145	0.503135	0.311354	1.901903
Prophet	0.347766	0.589717	0.053949	1.680879
SVR	0.261895	0.511757	0.287550	1.435059
ARIMA	0.366476	0.605372	0.003053	0.999000
Linear Regression	0.282840	0.531827	0.230572	1.940515
Random Forest	0.312075	0.558636	0.151043	3.434788
Decision Tree	0.350198	0.591775	0.047334	4.422758
XGBoost	0.360486	0.600405	0.019348	2.744646

Fuente: Elaboración propia

Capítulo 7

CONCLUSIONES

Se puede concluir que el desarrollo de modelos predictivos de demanda, utilizando técnicas avanzadas como Regresión Lineal Múltiple, es esencial para mejorar la rentabilidad en la venta de productos perecibles. Integrar datos históricos de ventas con variables clave como feriados, pago proveedores y precios no solo facilita una gestión de inventario más precisa, sino que también optimiza las estrategias de precios y promociones, lo que resulta en una planificación más efectiva y en un aumento de la rentabilidad.

La investigación enfocada en modelos de Forecasting para maximizar la planificación de recursos en Donna S.A.C. destaca la importancia de recopilar datos detallados sobre el desempeño de ventas en diversas áreas y períodos. Estos datos son cruciales para identificar patrones de comportamiento de los clientes, evaluar el impacto de estrategias comerciales variadas y anticipar cambios en la demanda. La implementación adecuada de modelos de Forecasting no solo facilita la predicción precisa de ventas futuras, sino que también proporciona valiosos insights para la toma de decisiones estratégicas que impulsan el crecimiento sostenido de la empresa.

El análisis de modelos de Forecasting, al considerar la estructura temporal de los datos y factores como tendencias, estacionalidad y variación aleatoria, permite la aplicación de modelos estadísticos avanzados para pronosticar con precisión el comportamiento futuro de las ventas. Este enfoque es fundamental para empresas como Donna S.A.C., donde la capacidad de prever la demanda de manera confiable puede marcar la diferencia en la planificación operativa y estratégica. Así, el uso efectivo de modelos de Forecasting no solo mejora la eficiencia en la gestión de recursos, sino que también fortalece la capacidad de la empresa para adaptarse ágilmente a cambios en el mercado y maximizar su rentabilidad.

Anexos

Anexos A

Anexo I: Matriz de Consistencia

PROBLEMAS	OBJETIVOS	HIPÓTESIS
Problema General	Objetivo General	Hipótesis General
¿Como la implementación de un modelo predictivo de la demanda de productos perecibles beneficiará la toma de decisiones en el proceso del pedido a los proveedores en la empresa Donna SAC?	Implementar un modelo predictivo de la demanda de productos perecibles que beneficie la toma de decisiones en el proceso del pedido a los proveedores en la empresa Donna SAC.	La implementación de un modelo predictivo de la demanda de productos perecibles beneficiará en la toma de decisiones en el proceso de pedido a los proveedores en la empresa Donna SAC.
Problemas Específicos	Objetivos Específicos	Hipótesis Específicas
¿Cómo pueden los modelos de predicción de demanda contribuir a una planificación de existencias de productos?	Determinar cómo los modelos de predicción de demanda pueden contribuir a optimizar la planificación de existencias de productos.	El uso de modelos de predicción de demanda mejora la planificación de existencias de productos asegurando la disponibilidad adecuada.
¿Qué técnicas de preprocesamiento de datos son más efectivas para mejorar la precisión de los modelos de predicción de demanda en productos perecibles?	Determinar las técnicas de preprocesamiento de datos más efectivas para mejorar la precisión de los modelos de predicción de demanda en productos perecibles.	Las técnicas de procesamiento de datos como la normalización de datos, el tratamiento de valores atípicos y la selección de características relevantes, serán más efectivas para mejorar la precisión de los modelos de predicción de demanda en productos perecibles
¿Cuál es la influencia de las variables de la demanda para predecir productos perecibles y como pueden ajustarse en función al modelo?	Determinar que variables de la demanda influyen en predecir productos perecibles.	Las variables escogidas de la demanda tienen influencia significativa en el modelo.
¿Cuál es la función de los modelos avanzados de Forecasting de la demanda y cómo se comparan con otros métodos de aprendizaje automático en cuanto a precisión y aplicabilidad?	Evaluar la eficacia de los modelos avanzados de Forecasting en la predicción de la demanda en una tienda, comparándolos con otros métodos de aprendizaje automático en términos de precisión y aplicabilidad	Los modelos avanzados de Forecasting proporcionan una mayor precisión y aplicabilidad en la predicción de la demanda en un entorno de tienda, en comparación con otros métodos de aprendizaje automático

Tabla A.1: Matriz de consistencia

BIBLIOGRAFÍA

- Benites Sernaqué, J. M. (2021). *Implementación de un sistema de pronóstico de ventas utilizando redes neuronales artificiales para la empresa Cerámicos Lambayeque SAC* [Tesis de grado]. Universidad Señor de Sipán.
- Brockwell, P. J., & Davis, R. A. (2002). *Introduction to time series and forecasting*. Springer.
- Brownlee, J. (2017). *Long Short-Term Memory Networks With Python: Develop Sequence Prediction Models with Deep Learning*. Machine Learning Mastery. <https://books.google.com.pe/books?id=m7SoDwAAQBAJ>
- Fayyad, U., Piatetsky-Shapiro, G., & Smyth, P. (1996). The KDD process for extracting useful knowledge from volumes of data. *Communications of the ACM*, 39(11), 27-34.
- Feng, M., Zheng, J., Ren, J., Hussain, A., Li, X., Xi, Y., & Liu, Q. (2019). Big data analytics and mining for effective visualization and trends forecasting of crime data. *IEEE Access*, 7, 106111-106123.
- Fierro Torres, C. Á., Castillo Pérez, V. H., & Torres Saucedo, C. I. (2022). Análisis comparativo de modelos tradicionales y modernos para pronóstico de la demanda: enfoques y características. *Revista Iberoamericana para la Investigación y el Desarrollo Educativo*, 24. <https://doi.org/https://doi.org/10.23913/ride.v12i24.1203>
- Gupta, D., Sambyo, K., Prasad, M., & Agarwal, S. (2022). *Advanced Machine Intelligence and Signal Processing*. Springer Nature Singapore. <https://books.google.com.pe/books?id=SU3EAAAQBAJ>
- Heredia, A. (2020). *Políticas de fomento para la incorporación de las tecnologías digitales en las micro, pequeñas y medianas empresas de América Latina: revisión de experiencias y oportunidades* [Accessed: 2024-10-24].
- Higa Shimabukuro, H. (2021). Análisis de pronóstico de demanda para poder gestionar el inventario aplicado al sector salud.
- Hoarau, M. (2022). *Time Series Analysis on AWS: Learn how to build forecasting models and detect anomalies in your time series data*. Packt Publishing. <https://books.google.com.pe/books?id=4ohbEAAAQBAJ>

- Jamali, S., & Rangwala, H. (2009). Digging Digg: Comment Mining, Popularity Prediction, and Social Network Analysis. *2009 International Conference on Web Information Systems and Mining*. <https://doi.org/10.1109/WISM.2009.15>
- Laura Huaita, R. M. (2020). *Modelo predictivo de demanda basado en redes neuronales para aprovisionamiento en empresas textiles* [Tesis doctoral]. Universidad Mayor de San Andres.
- Mintarya, L. N., Halim, J. N., Angie, C., Achmad, S., & Kurniawan, A. (2023). Machine learning approaches in stock market prediction: A systematic literature review [7th International Conference on Computer Science and Computational Intelligence 2022]. *Procedia Computer Science*, 216, 96-102. <https://doi.org/https://doi.org/10.1016/j.procs.2022.12.115>
- Mitchell, T. (1997). *Machine Learning*. McGraw-Hill. <https://books.google.com.pe/books?id=EoYBngEACAAJ>
- Molina, J. P. (2017). Modelación econométrica de la demanda de semilla de chile dulce Lamuyo y Blocky en Costa Rica mediante series de tiempo univariadas. *e-Agronegocios*, 3(2).
- Montgomery, D., Peck, E., & Vining, G. (2013). *Introduction to Linear Regression Analysis*. Wiley. <https://books.google.com.pe/books?id=lSyiRZh09oEC>
- Neba Cyril, C., Shu Fuhnwi, G., Nsuh, G., Agbara, P., Neba, A., Webnda, F., & Ikpe, V. (2024). Advancing Retail Predictions: Integrating Diverse Machine Learning Models for Accurate Walmart Sales Forecasting. *Asian Journal of Probability and Statistics*, 26, 1-23. <https://doi.org/10.9734/ajpas/2024/v26i7626>
- New Research Presents Policy Opportunities for China to Reduce Food Loss and Waste — The Global FoodBanking Network* [Accessed: 2024-11-04]. (2023). <https://www.foodbanking.org/es/news/new-research-presents-policy-opportunities-for-china-to-reduce-food-loss-and-waste/>
- Ocampo, E. M. T., GIRALDO, D. A. M., & Isaza, H. S. (2004). Pronóstico de ventas usando redes neuronales. *Scientia et technica*, 10(26), 25-30.
- Panda, S. K., & Mohanty, S. N. (2023). Time Series Forecasting and Modeling of Food Demand Supply Chain Based on Regressors Analysis. *IEEE Access*, 11, 42679-42700. <https://doi.org/10.1109/ACCESS.2023.3266275>
- Parra Ortega, M. W., et al. (2017). Gestión de la cadena de suministro Supply Chain Management y logística en Colombia.
- Paul, L. C., Suman, A. A., & Sultan, N. (2013). Methodological analysis of principal component analysis (PCA) method. *International Journal of Computational Engineering & Management*, 16(2), 32-38.
- Perú Panorama general* [Accessed: 2023-01-15]. (2024). <https://www.bancomundial.org/es/country/peru/overview>

- Robles Rakov, M. A., & Valverde Campos, M. Y. (2021). *Sistema de predicción para incrementar las ventas de accesorios y repuestos automotrices en la empresa GGP Automotriz* [Tesis de grado]. Universidad San Martín de Porres.
- Rodríguez-León, J., & Pachón-Rincón, M. (2021). Estudio de pronóstico para la planeación, caso de estudio empresa distribuidora del sector farmacéutico. *Revista UIS ingenierías*, 20(4), 59-78.
- Villarreal, F. (2016). Introducción a los Modelos de Pronósticos. *Univ. Nac. del Sur*, 1-121.
- Villarreal Buenaventura, D. E., & Prada Gómez, Y. (2016). Una versión homotópica del teorema de Cauchy y su aplicación a los gráficos alfa.
- Wang, L. (2005). *Support Vector Machines: Theory and Applications*. Springer Berlin Heidelberg. <https://books.google.com.pe/books?id=uTzMPJjVjsMC>
- Zhou, Z.-H. (2021). *Machine Learning*. Springer Singapore. <https://doi.org/https://doi.org/10.1007/978-981-15-1967-3>